

Algebra Linear Algoritmica

Operações Elementares

1. $L_i \rightarrow k \cdot L_i$ (Multiplicar uma linha por um escalar K , ex: 2, $\frac{1}{2}$)
2. $L_i \leftrightarrow L_j$ (Inverter linhas)
3. $L_i \rightarrow L_i + k \cdot L_j$ (Somar duas linhas)

Semântica \rightarrow Sintática

$$\text{Usuário} \begin{cases} 3x_1 + 2x_2 + 5x_3 = y_1 \\ 4x_1 + 5x_2 + 10x_3 = y_2 \\ 4x_1 + 10x_2 + 10x_3 = y_3 \end{cases} \rightarrow \text{Programador} \begin{bmatrix} & X_1 & X_2 & X_3 & y_1 & y_2 & y_3 \\ \text{(Eq. 1)} & 3 & 2 & 5 & 1 & 0 & 0 \\ \text{(Eq. 2)} & 4 & 5 & 10 & 0 & 1 & 0 \\ \text{(Eq. 3)} & 4 & 10 & 10 & 0 & 0 & 1 \end{bmatrix}$$

Resolvemos na **sintaxe** e verificamos no modo **semântico**

Matriz:

\Downarrow

$$\begin{aligned} A_{(1,1)}x_1 + A_{(1,2)}x_2 + A_{(1,3)}x_3 &= y_1 \\ A_{(2,1)}x_1 + A_{(2,2)}x_2 + A_{(2,3)}x_3 &= y_2 \\ A_{(3,1)}x_1 + A_{(3,2)}x_2 + A_{(3,3)}x_3 &= y_3 \end{aligned} \rightarrow \begin{bmatrix} a_{(1,1)} & a_{(1,2)} & a_{(1,3)} \\ a_{(2,1)} & a_{(2,2)} & a_{(2,3)} \\ a_{(3,1)} & a_{(3,2)} & a_{(3,3)} \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

Composição de Função

$$f: R^2 \rightarrow R^2 \quad g: R^2 \rightarrow R^2$$
$$f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} 3x_1 + 2x_2 \\ 5x_1 + 4x_2 \end{bmatrix} \quad g\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} 10x_1 + 11x_2 \\ 14x_1 + 5x_2 \end{bmatrix}$$

Exemplo: $g(f(x))$

$$\begin{aligned} f\left(\begin{bmatrix} 3x_1 + 2x_2 \\ 5x_1 + 4x_2 \end{bmatrix}\right) &= \begin{bmatrix} 10(3x_1 + 2x_2) + 11(5x_1 + 4x_2) \\ 14(3x_1 + 2x_2) + 5(5x_1 + 4x_2) \end{bmatrix} = \begin{bmatrix} 85x_1 + 62x_2 \\ 67x_1 + 48x_2 \end{bmatrix} \\ f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) &= \begin{bmatrix} 3 & 2 \\ 5 & 4 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad g\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} 10 & 11 \\ 14 & 5 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ g \circ f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) &= \begin{bmatrix} 10 & 11 \\ 14 & 5 \end{bmatrix}^A \cdot \begin{bmatrix} 3 & 2 \\ 5 & 4 \end{bmatrix}^B \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 85 & 62 \\ 67 & 48 \end{bmatrix}^C \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \end{aligned}$$

Onde $A \cdot B = C$, é o mesmo que $A(\text{Linha } i) \cdot B(\text{Coluna } j) = C_{(i,j)}$

Exemplo:

$$\begin{bmatrix} 10 & 11 \\ 14 & 5 \end{bmatrix}^A \cdot \begin{bmatrix} 3 & 2 \\ 5 & 4 \end{bmatrix}^B = \begin{bmatrix} ((A_{(1,1)} \cdot B_{(1,1)}) + (A_{(1,2)} \cdot B_{(2,1)})) & ((A_{(1,1)} \cdot B_{(1,2)}) + (A_{(1,2)} \cdot B_{(2,2)})) \\ ((A_{(2,1)} \cdot B_{(1,1)}) + (A_{(2,2)} \cdot B_{(2,1)})) & ((A_{(2,1)} \cdot B_{(1,2)}) + (A_{(2,2)} \cdot B_{(2,2)})) \end{bmatrix}$$

Função Inversa

$$f(x) = y \leftrightarrow x = g(y)$$

$$\begin{cases} x_1 + 3x_2 = y_1 \\ x_1 + 4x_2 = y_2 \end{cases} \xrightarrow{\text{Gauss-Jordan}} \begin{cases} x_1 = y_1 - 3(y_2 - y_1) \\ x_2 = y_2 - y_1 \end{cases} \rightarrow \begin{cases} x_1 = 4y_2 - 3y_1 \\ x_2 = y_2 - y_1 \end{cases} \rightarrow x = g(y)$$

$$g\left(\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right) = \begin{bmatrix} 4y_2 - 3y_1 \\ y_2 - y_1 \end{bmatrix}$$

$$\text{Teorema: } f(g(y)) = y \leftrightarrow g(f(x)) = x$$

Vetores Linearmente Independentes

$$\begin{bmatrix} & x_1 & x_2 & x_3 & x_4 & x_5 \\ \text{(Eq 1)} & 1 & 0 & 0 & 0 & 0 \\ \text{(Eq 2)} & 0 & 0 & 1 & 0 & 0 \\ \text{(Eq 3)} & 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

Onde, x_2 , x_5 são **variáveis dependentes** e x_1 , x_3 , x_4 são **variáveis independentes**, ou seja, x_2 e x_5 podem ser escritos como combinação linear de x_1 , x_3 , x_4 .

Matriz Inversa

Se $b = Ax$ então $A^{-1}b = x$, ou seja

$$A \cdot A^{-1} = A^{-1} \cdot A = 1$$

Obs: A inversa existe se, e somente se, a eliminação produzir n pivôs

Se $\text{Det}(A) = 0$, então não tem inversa

Matriz quadrada 2×2

$$A^{-1} \leftrightarrow \begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{\text{Det}(A)} \begin{bmatrix} a & -b \\ -c & d \end{bmatrix}$$

Determinante

$$\text{Det}\left(\begin{bmatrix} a & b \\ c & d \end{bmatrix}\right) = ad - bc$$

Propriedades

- $\text{Det}(I) = 1$
- $\text{Det}(A^{-1}) = \frac{1}{\text{Det}(A)}$
- $\text{Det}(AB) = \text{Det}(A) \cdot \text{Det}(B)$
- $\text{Det}(A^T) = \text{Det}(A)$

Transformações Lineares

Toda matriz simétrica A pode ser descrita como:

$$A\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = R_{\theta}(T(R_{\theta}^{-1}))$$

Ou seja, $R_{\theta} \begin{bmatrix} a & b \\ c & d \end{bmatrix} R_{\theta}^{-1} = A$

Identidade

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \end{bmatrix} = \begin{bmatrix} x_2 \\ y_2 \end{bmatrix}$$

Cisalhamento

$$A = \begin{bmatrix} 1 & a \\ b & 1 \end{bmatrix}$$

Rotação

$$R_{\theta} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

Reflexão

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

Projeção (no eixo x)

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

Regra de Linearidade

Para c e d escalares e A , V e W vetores:

$$A(cV + dW) = c(AV) + d(AW)$$

Autovalores e Autovetores

$$Av = \lambda v$$

Manipulando a equação acima:

$$\begin{aligned} Av &= \lambda v \\ Av - \lambda v &= \bar{0} \\ Av - \lambda I v &= \bar{0} \\ (A - \lambda I)v &= \bar{0} \end{aligned}$$

Como consequência, sabemos que: $\det(A - \lambda I) = \bar{0}$

Espaços Vetoriais

Um espaço vetorial é um conjunto V , não vazio, munido de duas operações:

- Soma ($V \times V \rightarrow V$)
- Produto ($\mathbb{R} \times V \rightarrow V$)

Temos que,

1. $(\vec{u} + \vec{v}) + \vec{w} = \vec{u} + (\vec{v} + \vec{w})$ - Comutatividade
2. $\vec{u} + \vec{v} = \vec{v} + \vec{u}$
3. $\exists \vec{0} \in V \mid \vec{u} + \vec{0} = u$
4. $\exists -\vec{u} \in V \mid \vec{u} + (-\vec{u}) = \vec{0}$
5. $a(\vec{u} + \vec{v}) = a\vec{u} + a\vec{v}$
6. $(a + b)\vec{v} = a\vec{v} + b\vec{v}$
7. $(ab)\vec{v} = a(b\vec{v})$
8. $1 \times \vec{u} = \vec{u}$

Subespaço vetorial

Seja V um espaço vetorial. $W \subset V$ é um subespaço vetorial se $\vec{0} \in W$ e:

- $\vec{u} + \vec{v} \in W$
- $a\vec{u} \in W, \forall a \in \mathbb{R}$

Espaço Coluna ($c(A)$)

Dado o SL $A_{m \times n} x_n = b_m$

Se A é inversível, a solução do SL é única

Se A não tem inversa, há infinitas soluções ou nenhuma

De um modo gera

$$Ax + b = A_1x_1 + A_2x_2 + \dots + x_nA_n = b$$

onde A_n é a n -ésima vetor coluna de A .

Para que o SL tenha solução, é preciso que b possa ser descrito como uma combinação linear de A .

$Ax = b$ tem solução $\leftrightarrow b$ está no espaço coluna de A

Espaço Nulo ou Núcleo ($n(A)$)

O espaço nulo, ou núcleo, do SL homogêneo, é o conjunto de vetores que satisfazem $A_{m \times n} x_n = \vec{0}$.

OBS: A quantidade de variáveis livres (variáveis que são combinações lineares) nos diz a dimensão do vetor

Espaço Linha e Posto de A ($c(A^T)/r(A)$)

O posto de uma matriz $A_{m \times n}$ é o número de pivôs, ou seja, o número de linhas não nulas da matriz escalonada.

Os vetor colunas que não tem pivôs são combinações lineares as colunas com pivôs.

1. $r(A) = m = n$

- Matriz quadrada invertível
- $Ax = b$ tem solução única
- Posto linha completo, posto coluna completo

2. $r(A) = m < n$

- $Ax = b$ tem infinitas sol.
- Posto linha completo

3. $r(A) = n < m$

- $Ax = b$ tem 1 ou 0 sol.
- Posto coluna completo

4. $r(A) < n, r(A) < m$

- $Ax = b$ tem 0 ou infinitas sol.

As colunas de A são linearmente independentes (LI) quando $r(A) = n$, ou seja, há n pivôs e nenhum variável livre. $\rightarrow N(A) = \{0\}$

Um conjunto de vetores é uma base de um espaço vetorial se:

Não são nulos

São LI

Eles geram o espaço

A Dimensão de um espaço vetorial é a quantidade de vetores na base, ou seja, é a quantidade mínima necessária para representarmos um vetor qualquer do espaço como combinação linear dos vetores.

Teorema Fundamental da Algebra Linear

$c(A)$ tem dimensão $r(A)$ e $N(A^T)$ tem dimensão $m - r(A)$, ambos são subespaço R^m

$c(A^T)$ tem dimensão $r(A)$ e $N(A)$ tem dimensão $n - r(A)$, ambos são subespaços de R^n

$N(A)$ é o complemento ortogonal de $c(A^T)$

$N(A^T)$ é o complemento ortogonal de $c(A)$

Complemento ortogonal (V^\perp) é o conjunto de vetores que é ortogonal a um subespaço

Produto Interno

$$\langle w, v \rangle = w^T v = [w_1 \ w_2] \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = w_1 v_1 + w_2 v_2$$

Propriedades

- $w^T v = v^T w$
- $\|v\|^2 = v^T v = v_1^2 + v_2^2$
-

Ortogonalidade


Dois vetores são ortogonais se $p^T v = \bar{0} = \langle p, v \rangle$.

Se p e v são ortogonais então:

$$||p + v||^2 = ||p||^2 + ||v||^2$$

Dois espaços vetoriais V e W são ortogonais se todos os vetores de V são ortogonais a todos vetores de W .

Projeção



Seja $e = v - p$, temos que $P = \alpha \vec{u}$

$$\alpha = \frac{u^T v}{u^T u}$$

Seja P um operador que leva qualquer vetor \vec{v} ao vetor P , então

$$Pv = p$$

$$p = \alpha u = u \frac{u^T v}{u^T u} = \frac{u u^T}{u^T u} v$$

obs: $v^T u = u^T v$

Logo,

$$P = \frac{uu^T}{u^T u}$$

Tamanho: $\|v\|$

obs: $\|v\|^2 = v^T v$

Distância: $d(v, w) = \|v - w\|$

Ângulo: $\cos(\theta) = \frac{P_v w}{w}$

Projeção ortogonal de W em V: $P_v(w) = \left(\frac{w^T v}{\|v\|^2}\right) \cdot v$

Tamanho da projeção: $w^T \cdot \tilde{v}$

Normalização: $\tilde{v} = \frac{v}{\|v\|}$

Projeção sobre um subespaço

$$A^T A = A^T v \rightarrow \bar{x} = (A^T A)^{-1} A^T v$$

$$p = A(A^T A)^{-1} A^T v \rightarrow \text{Projeção de v sobre o espaço}$$

$$P = A(A^T A)^{-1} A^T \rightarrow \text{Matriz de Projeção}$$

Bases Ortogonais e Gram-Schmitt

Os vetores são ortonormais se:

$$\langle z_i, z_j \rangle = z_i \cdot z_j = z_i^T \cdot z_j = \begin{cases} 0 & \text{se } i \neq j \\ 1 & \text{se } i = j \end{cases}$$

Seja A uma matriz cujas as colunas são LI

Queremos transformar essas colunas em vetores ortonormais, ou seja, transformar A em Q.

$$\text{tomar } e_1 = q_1 = \frac{u_1}{\|u_1\|} = \frac{v_1}{\|v_1\|}$$

Para

$$\text{proj}_u(v) = \frac{\langle v, u \rangle}{\langle u, u \rangle} u = \frac{v^T u}{u^T u} u$$

Então,

$$\begin{array}{ll} u_1 = v_1, & q_1 = \frac{u_1}{\|u_1\|} \\ u_2 = v_2 - \text{proj}_{u_1}(v_2) & q_2 = \frac{u_2}{\|u_2\|} \\ u_3 = v_3 - \text{proj}_{u_1}(v_3) - \text{proj}_{u_2}(v_3) & q_3 = \frac{u_3}{\|u_3\|} \\ u_4 = v_4 - \text{proj}_{u_1}(v_4) - \text{proj}_{u_2}(v_4) - \text{proj}_{u_3}(v_4) & q_4 = \frac{u_4}{\|u_4\|} \\ \vdots & \vdots \\ u_k = v_k - \sum \text{proj}_{q_j}(v_k) & q_k = \frac{u_k}{\|u_k\|} \end{array}$$

$$\begin{aligned}
\mathbf{u}_1 &= \mathbf{v}_1, & \mathbf{e}_1 &= \frac{\mathbf{u}_1}{\|\mathbf{u}_1\|} \\
\mathbf{u}_2 &= \mathbf{v}_2 - \text{proj}_{\mathbf{u}_1}(\mathbf{v}_2), & \mathbf{e}_2 &= \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|} \\
\mathbf{u}_3 &= \mathbf{v}_3 - \text{proj}_{\mathbf{u}_1}(\mathbf{v}_3) - \text{proj}_{\mathbf{u}_2}(\mathbf{v}_3), & \mathbf{e}_3 &= \frac{\mathbf{u}_3}{\|\mathbf{u}_3\|} \\
\mathbf{u}_4 &= \mathbf{v}_4 - \text{proj}_{\mathbf{u}_1}(\mathbf{v}_4) - \text{proj}_{\mathbf{u}_2}(\mathbf{v}_4) - \text{proj}_{\mathbf{u}_3}(\mathbf{v}_4), & \mathbf{e}_4 &= \frac{\mathbf{u}_4}{\|\mathbf{u}_4\|} \\
&\vdots & & \vdots \\
\mathbf{u}_k &= \mathbf{v}_k - \sum_{j=1}^{k-1} \text{proj}_{\mathbf{u}_j}(\mathbf{v}_k), & \mathbf{e}_k &= \frac{\mathbf{u}_k}{\|\mathbf{u}_k\|}.
\end{aligned}$$

OBS:

$$A = Q \cdot R \rightarrow R = Q^T A$$

Fatoração QR

- $A = QR$, multiplique ambos os lados por Q^T :
- $Q^T A = Q^T QR$
- Dado $Q^T Q = I$, teremos $R = Q^T A$
- Dados $A = \begin{bmatrix} | & | & \cdots & | \\ \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_n \\ | & | & \cdots & | \end{bmatrix}$ e $Q = \begin{bmatrix} | & | & \cdots & | \\ \mathbf{q}_1 & \mathbf{q}_2 & \cdots & \mathbf{q}_n \\ | & | & \cdots & | \end{bmatrix}$
- Então: $\langle q, a \rangle = q^T a = q_1 a_1 + q_2 a_2 + \dots$

$$R = Q^T A = \begin{bmatrix} \mathbf{q}_1^T \mathbf{a}_1 & \mathbf{q}_1^T \mathbf{a}_2 & \cdots & \mathbf{q}_1^T \mathbf{a}_n \\ \mathbf{q}_2^T \mathbf{a}_1 & \mathbf{q}_2^T \mathbf{a}_2 & \cdots & \mathbf{q}_2^T \mathbf{a}_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{q}_n^T \mathbf{a}_1 & \mathbf{q}_n^T \mathbf{a}_2 & \cdots & \mathbf{q}_n^T \mathbf{a}_n \end{bmatrix} = \begin{bmatrix} \mathbf{q}_1^T \mathbf{a}_1 & \mathbf{q}_1^T \mathbf{a}_2 & \cdots & \mathbf{q}_1^T \mathbf{a}_n \\ 0 & \mathbf{q}_2^T \mathbf{a}_2 & \cdots & \mathbf{q}_2^T \mathbf{a}_n \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \mathbf{q}_n^T \mathbf{a}_n \end{bmatrix}$$

Determinante

Dada uma matriz $A_{m \times n}$, $A = [A_{ij}]$, então

$$\det(A) = |A| = \det[A_{ij}] = \sum (-1)^j a_{1f1} \cdot a_{1f2} \times \cdots \times a_{nf n}$$

Onde $j = (j_1, j_2, \dots, j_n)$ é o número de inversões para cada permutação de $\{1, 2, \dots, n\} = (f_1, f_2, f_3, \dots)$

Exemplo: $j = (0, 1) \rightarrow f = \{(1, 2), (2, 1)\}$ e $A = A_{2 \times 2}$

$$\det(A) = (-1)^0 a_{11} \cdot a_{22} + (-1)^1 a_{12} \cdot a_{21} = a_{11} \cdot a_{22} - a_{12} \cdot a_{21}$$

Generalizando:

$$\det(A) = \sum (-1)^{i+j} a_{ij} |A_{ij}|$$

onde $|A_{ij}|$ é uma matriz formada após se retirar de A a linha i e coluna j.

Matriz Adjunta

Definimos o cofator Δ_{ij} do elemento a_{ij} de uma matriz $A_{m \times n}$, por

$$\Delta_{ij} = (-1)^{i+j} \det(A_{ij})$$

onde A_{ij} é a submatriz de A obtida após retirar a linha i e a coluna j.

A matriz \overline{A} de cofatores de A é definida por $A = [\Delta_{ij}]$ e a matriz adjunta é definida por $\text{adj}(A) = \overline{A}$.

Teorema: $A \cdot A^{-1} = A \cdot \text{adj}(A) = \det(A)I$.

Autovalores e Autovetores

$$A = XDX^{-1}$$

onde D é uma matriz diagonalizável, X é a matriz de autovetores invertível.

$$Av = \lambda v$$

Manipulando a equação acima:

$$Av = \lambda v$$

$$Av - \lambda v = \overline{0}$$

$$Av - \lambda I v = \overline{0}$$

$$(A - \lambda I)v = \overline{0}$$

Como consequência, sabemos que: $\det(A - \lambda I) = \overline{0}$