

Análise de Risco

Sessão 6

Modelagem da correlação

Prof. E.A. Schmitz

BCMT/DCC/UFRJ

October 10, 2019

Revisão - 5 teoremas importantes

Sejam X, Y variáveis aleatórias quaisquer:

- ▶ T1 - $E(a+bX) = a + bE(X)$.
- ▶ T2 - $E(X + Y) = E(X) + E(Y)$.
- ▶ T3 - $E(XY) = E(X) \cdot E(Y)$ se X indep Y .
- ▶ T4 - $V(X+Y) = V(X) + V(Y) + 2 \cdot \text{Cov}(X, Y)$
 - ▶ Onde $\text{Cov}(X, Y) = E[(X - \mu_x)(Y - \mu_y)]$
- ▶ T5 - $V(X + Y) = V(X) + V(Y)$ se X indep Y .

A omissão da inclusão da correlação pode afetar a análise do risco de um projeto? Por quê?

Definições

1-Função de probabilidade conjunta

$$f_{xy}(x, y) = Prob(X = x \text{ e } Y = y)$$

2-Função de probabilidade marginal

$$f_x(x, y) = \sum_y f_{xy}(x, y)$$

$$f_y(x, y) = \sum_x f_{xy}(x, y)$$

3-Sejam duas VAs X, Y , com função de probabilidade conjunta f_{xy} e marginais f_x e f_y e respectivamente. Dizemos que X e Y são independentes sse:

$$f_{xy}(x, y) = f_x(x) * f_y(y)$$

Exemplo

A tabela abaixo mostra distribuição conjunta de probabilidade dos pontos obtidos ao jogar dois dados de 4 faces.

1. calcule as duas funções de probabilidades marginais
2. avalie se as variáveis são independentes

4	0	$1/20$	$1/20$	$1/20$
3	$1/20$	$2/20$	$3/20$	$1/20$
2	$1/20$	$2/20$	$3/20$	$1/20$
1	$1/20$	$1/20$	$1/20$	0
	1	2	3	4

Dependência e risco 1

Variáveis do modelo podem apresentar alguma forma de dependência entre si.

1-Observe este fragmento de modelo em R

- ▶ `c1 < -rtriangle(1000, 10, 30, 20)`
- ▶ `c2 < -rtriangle(1000, 20, 60, 40)`
- ▶ `plot(c1, c2)`

2-repita com:

- ▶ `e1 < -rnorm(1000, 0, 5)`
- ▶ `c3 < -2 * c1 + 10 + e1`
- ▶ `plot(c1, c3)`

3-repita com:

- ▶ `c4 < -80 - 2 * c1 + e1`
- ▶ `plot(c1, c4)`

Dependência e risco 2

4-Observe este fragmento de modelo em R

- ▶ `cov(c1, c2)`
- ▶ `m1 < -mean(c1)`
- ▶ `m2 < -mean(c2)`
- ▶ `sp < -(c1 - m1) * (c2 - m2)`
- ▶ `head(sp)`

5-repita com:

- ▶ `library(MASS)`
- ▶ `cormat < -matrix(c(1, 1, 1, 1), ncol = 2)`
- ▶ `cc < -mvrnorm(500, mu = c(0, 0), Sigma = cormat)`
- ▶ `plot(cc[, 1], cc[, 2])`

Coeficientes de correlação de Pearson

Coeficiente de correlação (Pearson):

$$\text{Cor}(X, Y) = \text{Cov}(X, Y) / (\delta_x * \delta_y)$$

O coeficiente de correlação é a covariância normalizada.

O valor de $\text{Cor}(.,.)$ varia entre $(-1..0..1)$.

Se $\text{Cor}(X,Y)=$

- ▶ 0: não há correlação (covariância é 0).
- ▶ +1: forte correlação positiva.
- ▶ -1: forte correlação negativa.

Não-correlação versus Independência

Sejam duas VAs X, Y , com função de probabilidade conjunta f_{xy} e marginais f_x e f_y e

1. $Cor(X, Y) = Cov(X, Y) / (\delta_x * \delta_y)$ se $Cor(X, Y) = 0$ então X e Y são não correlacionadas.
2. Se $f_{xy}(x, y) = f_x(x) * f_y(y)$ então X e Y são independentes senão são ditas dependentes. Em particular, se Y for uma função de X então serão ambas dependentes.
3. Se X, Y forem independentes também serão não-correlacionadas.
4. Se a correlação for igual a zero não garante a independência. Exemplo: $X = \text{Unif}(-1, 1)$ e $Y = \text{abs}(X)$ são dependentes mas apresentam correlação igual a zero.
5. O único caso geral onde correlação igual a zero implica independência é quando f_{xy} é normal.

Coeficientes de correlação de Spearman

Coeficiente de correlação de Spearman ρ

Estatística *não-paramétrica* para medir a relação entre 2 VAs

Algoritmo:


1. encontre a *ordem* das observações de X e Y (u_i, v_i), onde $i=1$ corresponde ao maior valor.
2. calcule

$$\rho = 1 - 6 * \sum \frac{(u_i - v_i)^2}{(n(n^2 - 1))}$$

ρ é o coeficiente de correlação de Spearman

Exemplos de correlação

Diversos tipos de correlação entre variáveis aleatórias



Funções para correlação e covariância em R

```
cov(x, y = NULL, use = "everything", method = c("pearson",  
"kendall", "spearman"))
```

```
cor(x, y = NULL, use = "everything", method = c("pearson",  
"kendall", "spearman"))
```

Como gerar amostras correlacionadas

Técnicas mais utilizadas

- ▶ 1-usando uma matriz de correlação
- ▶ 2-técnica de look-up
- ▶ 3-técnica da envoltória (envelope method)

Geração de amostras normais correlacionadas em R

Método

1. instalar o pacote MASS
2. usar a função `mvrnorm(m,mu,Sigma)`: retorna uma lista de m amostras de (n) variáveis aleatórias normalmente distribuídas.
 - ▶ m: número de amostras
 - ▶ mu: vetor das médias das n variáveis
 - ▶ Sigma: matriz da covariância entre as n variáveis:
 - ▶ $\text{Sigma}[i,j] = \text{cov}(i,j)$
 - ▶ Sigma: simétrica e positiva-definida (consistente).

Exemplo:

```
x ← mvrnorm(500,mu=c(0,0),Sigma=matrix(c(1,1,1,1),ncol=2))
```

Gerando a matriz de covariância a partir do coeficiente de correlação

1. `mu <- rep(1.0,10)` mean vector
2. `sd <- 0.9`
3. `R <- matrix(rep(0.9,100),nrow=10,ncol=10)`
4. `diag(R) <- 1`
5. `c <- rep(1.3,10)`
6. `D <- diag(c)`
7. `cvm <- D %*% R %*% D`
8. `z <- mvrnorm(1000,mu,Sigma=cvm)`

Geração de amostras triangulares correlacionadas em R

Algoritmo para gerar n VAs distintas ($V_1, V_2, \dots, V_n$), interligadas por uma matriz de correlação A $[n, n]$

1. gerar $Z[m, n]$: m n -plas amostras normais reduzidas correlacionadas por A

$$Z \leftarrow \text{mvrnorm}(m, \mu = \text{rep}(0, \text{times} = n), \text{Sigma} = A)$$

2. gerar U com m n -plas uniformes

$$U \leftarrow \text{pnorm}(Z)$$

3. gerar matriz de triangulares correlacionadas

$$T[, 1] \leftarrow \text{qtriangle}(U[, 1], \text{min}_1, \text{max}_1, \text{mp}_1)$$

Geração de amostras correlacionadas (não-paramétrica)

Algoritmo não-paramétrico de Iman&Conover

Entradas:

$X[N, k]$: matriz de amostras não correlacionadas

C : matriz de correlação de Spearman entre as k variáveis

Saida:

$Y[N, k]$: matriz de amostras correlacionas por C

Passos

1. ache $P.P^T = C$
2. $R \leftarrow \text{matrix}[N, k]$
3. $S \leftarrow \phi^{-1}(i/N + 1) \forall i \in \{1..N\}$
4. $R[:, j] \leftarrow \text{perm}(S) \forall j \in \{1..k\}$
5. $R^* \leftarrow R.P^T$
6. $Y[:, j] \leftarrow X^*[:, j]$ que tem a mesma ordem que $R^*[:, j]$