

Análise de Risco

Sessão 7

Convergência e Bootstrap

Prof. E.A. Schmitz

BCMT/DCC/UFRJ

October 14, 2019

Convergência MC

Quantas amostras são necessárias para termos um resultado confiável na nossa simulação MC?

Exercício 1 – Gere amostras de tamanho N de uma normal $(0,1)$. Construa um gráfico mostrando a evolução da média e da variância da amostra para N variando de 100, 200 $\dots$ 900, 1000.

Função empírica de probabilidade cumulativa - $ecdf(x)$

Como gerar a $ecdf(x)$ de uma amostra de uma VA:

1. gere $x[1:N]$ amostras de uma VA
2. ordene os valores de x (crescente)
3. construa um vetor $y|y[i] = i/N \ i \in 1..N$
4. $y[i] = ecdf(x[i])$

Teorema importante - KS 1/6

Devido a dois matemáticos russos – Kolmogorov e Smirnov (KS)

Queremos saber quanto uma função de probabilidade cumulativa $F_n^*(x)$ obtida por MC usando n amostras é próxima da verdadeira (mas desconhecida) $F(x)$.

Em outras palavras qual o valor máximo do módulo da diferença entre as duas? Formalmente:

$$\sup |F_n^*(x) - F(x)|$$

Teorema importante - KS 2/6

Exercício 2: Usando os dados do exercício 1, calcule o valor de $\sup|F_n^*(x) - F(x)|$ para cada um dos tamanho de amostra.

Exercício 3: Mostre a convergência de $\delta_n = \sup|F_{n+1}^*(x) - F(x)| - \sup|F_n^*(x) - F(x)|$ para o caso do projeto de construção, para valores do tamanho da amostra no seguinte conjunto: $\{500, 1000, 1500, 2000\}$. Mostre também a convergência da média e da variância do custo total para os casos acima.

Teorema importante - KS 3/6

Dois fatos importantes:

1. $\sup |F_n^*(x) - F(x)|$ não depende de $F(x)$
2. $\text{prob}(\sqrt{n} * |F_n^*(x) - F(x)| \leq t) \rightarrow H(t)$

Considere a seguinte estatística:

$$D_n = \sqrt{n} * |F_n^*(x) - F(x)|$$

Pode ser mostrado que D_n só depende de n e tende a uma função $H(t)$ que **só depende de t**

$$\lim_{n \rightarrow \infty} \text{Prob}(D_n^* \leq t) = H(t) = 1 - 2 \sum_{i=1}^{\infty} (-1)^{i-1} e^{-2i^2 t^2}$$

Teorema importante - KS 4/6




Figure 13.2: Kolmogorov-Smirnov test statistic.

Teorema importante - KS 5/6

Como calcular o número de amostras?

1. defina o nível de confiança $= 1 - \alpha$
2. ache $t = H^{-1}(1 - \alpha)$ (próximo slide)
3. defina o erro máximo aceitável $\delta = |F_n^*(x) - F(x)|$
4. encontre $n = (\frac{t}{\delta})^2$

Exemplo:

1. nível de confiança $= 1 - \alpha = 0.95$
2. ache $t = H^{-1}(1 - \alpha) = 1.40$
3. erro máximo $\delta = 2.5\%$
4. calcule $n = (1.40/0.025)^2 = 3.136$

$H(t)$ - KS 6/6

t	H(t)
0.3	0
0.35	0.0003
0.4	0.0028
0.45	0.0126
0.5	0.0361
0.55	0.0772
0.6	0.1357
0.65	0.208
0.7	0.2888
0.75	0.3728
0.8	0.4559
0.85	0.5347
0.9	0.6073
0.95	0.6725
1	0.73
1.05	0.7798
1.1	0.8223
1.15	0.858
1.2	0.8878
1.25	0.9121
1.3	0.9319
1.35	0.9478
1.4	0.9603
1.45	0.9702
1.5	0.9778
1.6	0.988
1.7	0.9938
1.8	0.9969
1.9	0.9985
2	0.9993
2.1	0.9997
2.2	0.9999
2.4	1

Testes de aderência

Problema: seja $f^*(x)$ uma aproximação empírica de uma VA. Queremos testar a hipótese: $f^*(x)$ é uma boa aproximação para a distribuição teórica verdadeira $f(x)$. Dentre os inúmeros métodos podemos apresentar dois:

- ▶ usar a estatística KS
- ▶ usar a estatística do χ^2

Teste de aderência: chi-quadrado

Teorema: Sejam $n_1, n_2, \dots, n_k; e_1, e_2, \dots, e_k$ os valores das frequências relativas medidos e esperados de um experimento repetido k vezes ($k \rightarrow \infty$). Então a distribuição da quantidade:

$$\sum_1^k \frac{(n_i - e_i)^2}{n - 1}$$

vai tender a uma distribuição χ^2 com $k - 1$ graus de liberdade.

Usado para saber qual a aderência da pdf obtida pelo modelo com aquela obtida experimentalmente.

Estimadores e erros

Def 1: Um estimador é um algoritmo para calcular a estimativa *ex ante* de um parâmetro baseado numa amostra aleatória.

Def 2: A estimativa de um parâmetro é o valor *ex post* obtido por um estimador baseado em dados observados

Sejam θ, θ_e os valores reais e estimados de um parâmetro.
 θ_e é uma VA que depende da tanto da amostra como da função de probabilidade das VAs da amostra.

Pode ser determinado analiticamente ou pela técnica do *bootstrap*

Estimadores e erros

Def 3: $Erro(\theta, \theta_e) = \theta - \theta_e$

Def 4: $Bias = E[Erro(\theta, \theta_e)] = E[\theta_e] - \theta$

Def 5: θ_e é dito *unbiased* $\iff E[(\theta - \theta_e)] = 0$

Estimador *unbiased* é correto na média.

Def. 6: *Precision* ou *mean square error* (*mse*):

$$mse(\theta, \theta_e) = E[Erro(\theta, \theta_e)^2] = E[(\theta - \theta_e)^2]$$

$$mse(\theta, \theta_e) = bias(\theta, \theta_e)^2 + var(\theta_e)$$

Se $bias(\theta, \theta_e) = 0$ então a *precision* é medida pelo erro padrão de $\theta_e = SE(\theta_e)$.

$$SE(\theta_e) = var(\theta_e)^{0.5}$$

Bootstrap

- ▶ Antes dos computadores, análise estatística envolvia o uso de matemática e teoria da probabilidade para derivar fórmulas estatísticas para erros e intervalos de confiança.
- ▶ Geralmente estas formulas são aproximações que só valem para amostras muito grandes.
- ▶ Computação permite o uso de metodos de reamostragem como o bootstrap para produzir estimativas de erros e intervalos de confiança sem o uso de fórmulas
- ▶ Geralmente mais confiáveis que a fórmulas estatísticas

Bootstrap - vantagens

- ▶ menos restritivo não requer normalidade dos dados
- ▶ maior precisão não depende de amostras grandes em contraste com o TLC
- ▶ generalidade aplicável a uma variedade de estatísticas (média, variância, correlação, etc)

Bootstrap - passos

1. Reamostrar - criar B amostras bootstrap amostradas com reposição dos dados originais. Cada amostra tem T observações (igual a amostra original)
 - ▶ $\{r_{11}, r_{12}, \dots, r_{1T}\} = 1^a$ amostra bootstrap
 - ▶ ...
 - ▶ $\{r_{B1}, r_{B2}, \dots, r_{BT}\} = B^a$ amostra bootstrap
2. Calcule a distribuição bootstrap para a estatística de interesse θ_e . Para cada amostra bootstrap calcule θ_i . Teremos B valores de $\theta_i = \{\theta_1, \theta_2, \dots, \theta_B\}$
3. Use a distribuição bootstrap para obter informação sobre o formato, centro e espalhamento da pdf de θ_e .

Bootstrap - estimadores

- ▶ seja: $\theta_* = \text{mean}(\{\theta_1, \theta_2, \dots, \theta_B\})$
- ▶ $\text{bias} = \theta_* - \theta_e$
- ▶ erro padrão = $\text{sd}(\{\theta_1, \theta_2, \dots, \theta_B\})$
- ▶ se simétrica: intervalo de confiança(IC) (95%) =
 $\text{IC} = \text{boot}(\text{mean}) \pm 2 * \text{boot}(\text{SE})$
- ▶ se não simétrica: intervalo de confiança (IC) (95%) =
 $\text{IC} = [q * 0.025, q * 0.975]$ onde:
 - ▶ $q * 0.025 = 2.5\%$ quantil da distribuição bootstrap
 - ▶ $q * 0.975 = 97.5\%$ da distribuição bootstrap