

# Análise de Risco

## Sessão 5

### Teoremas fundamentais e correlação

Prof. E.A. Schmitz

IC/BCMT/UFRJ

May 27, 2026

# Variáveis aleatórias

Variável Aleatória(VA): é uma variável numérica definida no espaço amostral

$$VA : EA \rightarrow \mathbb{R}$$

Função de probabilidade (discreta) : retorna a probabilidade que  $X$  assumo o valor  $x$ , denotado por  $f(x)$

$$f : \mathbb{R} \rightarrow 0..1$$

$$f(x) = Prob(X = x)$$

Função de probabilidade cumulativa: retorna a probabilidade que  $X$  assumo o valor  $\leq x$ , denotado por  $F(x)$

$$F : \mathbb{R} \rightarrow 0..1$$

$$F(x) = Prob(X \leq x)$$

# Exemplo 1- Número obtido ao lançar um dado




Figure: Função de probabilidade para lançamento de um dado

## Exemplo 1- Número obtido ao lançar um dado




Figure: Função cumulativa para lançamento de dado

## Exemplo 2- Número de lançamentos até obter Cara




Figure: Função de probabilidade para número de lançamentos

## Exemplo 2- Número de lançamentos até obter Cara




Figure: Função de probabilidade cumulativa para número de lançamentos

# Média

Seja  $X$  uma VA com função de probabilidade  $f(x)$ : a média de  $X$  é definida como:

- ▶  $X$  é discreta:  $\mu = \sum_{i=1}^n x_i * f(x_i)$
- ▶  $X$  é contínua:  $\mu = \int_{-\infty}^{\infty} x * f(x) dx$
- ▶ Média é análoga a posição do centro de massa do gráfico da função

# Variância

Variância de uma VA com  $f_p=f(x)$ :

- ▶ X é discreta:  $\sigma^2 = \sum_{i=1}^n (x_i - \mu)^2 * f(x_i)$
- ▶ X é contínua:  $\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 * f(x) dx$
- ▶ Variância representa o espalhamento ao redor do centro de massa do gráfico da função

Média do quadrado de X:

$$\mu_{x^2} = \sigma_x^2 + \mu_x^2$$



# Exemplo moeda

Seja  $X$ ="valor obtido ao jogar uma moeda"

- ▶  $\{H, T\} \rightarrow \{0, 1\}$
- ▶  $f(x) = \{(0, 1/2), (1, 1/2)\}$
- ▶  $\mu = 0 * f(0) + 1 + 1 * f(1) = 1/2$
- ▶  $\sigma^2 = (0 - 1/2)^2 * f(0) + (1 - 1/2)^2 * f(1) = 1/4$

# Algumas fps usadas em AR

- ▶ Uniforme: valores contínuos dentro de um intervalo
- ▶ Discreta: conjunto de valores discretos
- ▶ Triangular: continua (mínimo, mais provável e máximo)
- ▶ Normal: curva do sino (média, desvio padrão)
- ▶ Binomial: sorteio de eventos com probabilidade  $p$

# Uniforme

## Uniforme Continua

- ▶ VA assume valores numa faixa continua todos igualmente prováveis
- ▶ R: `runif(n, min = 0, max = 1)`
- ▶ `Uniforme(0,1)`: base da geração das outras distribuições
  - ▶  $\mu = \int_0^1 x * 1 dx = 1/2$
  - ▶  $\sigma^2 = \int_0^1 (x - 1/2)^2 * 1 dx = 1/12$

## Uniforme discreta

- ▶ VA assume valores num conjunto todos igualmente prováveis
- ▶ R: `sample(set,size=1,replace=TRUE)`

# Triangular

- ▶ VA segue uma estimativa de 3 pontos: mínimo (a) , mais provável (m) e máximo (b)
- ▶ R: `rtriangle(min,max, mprov)` Package:triangle
- ▶  $\mu = (a + b + m)/3$
- ▶  $\sigma^2 = (a^2 + b^2 + m^2 - a * b - a * m - b * m)/18$

# Normal

- ▶ VA expressa variabilidade de muitos fenomenos naturais
- ▶ R: `rnorm(mu,sd)`
- ▶  $f(x) = \frac{1}{\sqrt{2*\pi}*sigma} * e^{-\frac{(x-\mu)^2}{\sigma^2}}$
- ▶ média= $\mu$
- ▶ variancia=  $\sigma^2$

Normal reduzida:  $\mu = 0, \sigma^2 = 1$

Alguns números importantes:

- ▶  $Prob(-1 \leq X \leq 1) = 0.68$
- ▶  $Prob(-2 \leq X \leq 2) = 0.95$
- ▶  $Prob(-2.3 \leq X \leq 2.3) = 0.98$
- ▶  $Prob(-3 \leq X \leq 3) = 0.995$

# Binomial

VA Bernoulli: VA com dominio  $\{0,1\}$  e função de probabilidade  $f(x) = \{(0, 1 - p), (1, p)\}$

Experimento binomial: número de vezes em que  $X=1$  numa sequencia de  $n$  experimentos Bernoulli.

- ▶  $f(n, x) = \binom{n}{x} * p^x * (1 - p)^{n-x}$

- ▶  $\mu = n * p$

- ▶  $\sigma^2 = n * p * q$

- ▶  $R : \text{rbinom}(1, n, p)$

# Teoremas (1)

## Teorema 1: Transformação linear de VAs

Sejam  $\mu, \sigma^2$  os parâmetros de  $X$ :

Se  $X_1 = a * X + b$  então seus parâmetros são:

$$\mu_1 = a * \mu + b$$

$$\sigma_1^2 = a^2 * \sigma$$

## Teoremas (2)

### Teorema 2: Soma de n VAs

Seja

$$Z = \sum_{i=1}^n X_i$$

Se os parâmetros de  $X_i = (\mu_i, \sigma_i^2)$  então os parâmetros de  $Z$  são:

$$\mu_z = \sum_{i=1}^n \mu_i$$

A média da soma de n VAs é igual à soma das médias

$$\sigma_z^2 = \sum_{i=1}^n \sigma_i^2$$

A variância da soma de n VAs *independentes* é igual a soma das variâncias.



# Teoremas(3)

Teorema 3: Produto de 2 VAs

$$Z = X * Y$$

$X$  tem parâmetros  $(\mu_x, \sigma_x^2)$

$Y$  tem parâmetros  $(\mu_y, \sigma_y^2)$

Então:  $Z$  terá como parâmetros:

$$\mu_z = \mu_x * \mu_y + \sigma_{xy}^2$$

$$\sigma_z^2 = \mu_y^2 * \sigma_x^2 + \mu_x^2 * \sigma_y^2 + \sigma_x^2 \sigma_y^2$$

Fórmula prática simplificada:

$$\mu_z \approx \mu_x * \mu_y$$

$$\sigma_z^2 \approx \mu_y^2 * \sigma_x^2 + \mu_x^2 * \sigma_y^2$$

# Teoremas (4)

## Teorema 4: Uso da normal reduzida

Notação:  $X \sim f(x)$  significa que  $f(x)$  é a função de probabilidade de  $X$

Sejam  $X \sim Normal(\mu, \sigma^2)$  e:

$$\Phi(x) = \int_{-\infty}^x f(u) du$$

onde  $f(u)$  é a função de probabilidade da normal reduzida.

Então:

$$P(a < X \leq b) = F(b) - F(a) = \Phi((b - \mu)/\sigma) - \Phi((a - \mu)/\sigma)$$

# Teoremas (5)

Teorema 5: Soma de  $n$  VAs normais independentemente distribuídas

Sejam  $X_i \sim \text{Normal}(\mu_i, \sigma_i^2), i \in 1..n$

$$Z = \sum_1^n X_i$$

então:

- ▶  $Z \sim \text{Normal}(\mu_z, \sigma_z^2)$
- ▶  $\mu_z = \sum_1^n \mu_i$
- ▶  $\sigma_z = \sum_1^n \sigma_i^2$

# Teoremas (6)

Teorema 6: Teorema central do limite (TCL)

Sejam  $X_i, i \in 1..n$ , independentemente distribuidas com  $(\mu_i, \sigma_i^2)$

$$Z = \sum_1^n X_i$$

então se  $n \rightarrow \infty$

- ▶  $Z \rightarrow Normal(\mu_z, \sigma_z^2)$
- ▶  $\mu_z = \sum_1^n \mu_i$
- ▶  $\sigma_z = \sum_1^n \sigma_i^2$

# Teoremas (7)

## Teorema 7: Teorema de Glivenko-Cantelli

A função de probabilidade cumulativa  $F_n^*(x)$  obtida usando  $n$  amostras de  $F(x)$  (desconhecida) tende à verdadeira  $F(x)$ .

Seja:  $D_n = \sup |F_n^*(x) - F(x)|$

Então:

$$\lim_{n \rightarrow \infty} D_n = 0$$

a.k.a. **Teorema Fundamental da Estatística.**

# Independência

- ▶ até este ponto na disciplina assumimos que as VAs envolvidas no modelo são independentes (definição a seguir).
- ▶ exemplo: modelamos o custo do cimento e da areia fazendo amostras independentes (um sorteio não tem nada a ver com outro)
- ▶ essa simplificação é realista?
- ▶ a variância da soma de duas VAs é dada por
$$Z = X + Y, V[Z] = V[X] + V[Y] + 2.cov(X, Y)$$
- ▶ nossos modelos ignoram o termo da covariância
- ▶ qual o efeito no resultado?
- ▶ covariância é um fator importante nos modelos de risco financeiro

# Definições importantes

Sejam  $X, Y$  variáveis aleatórias quaisquer:

- ▶  $E[X] = \int x \cdot f(x) \cdot dx$
- ▶  $V[X] = E[(X - \mu_x)^2]$
- ▶  $Cov(X, Y) = E[(X - \mu_x)(Y - \mu_y)] = E[X \cdot Y] - E[X] \cdot E[Y]$
- ▶ Função de probabilidade conjunta (variáveis discretas)  
 $f_{XY}(x, y) = Prob(X = x \text{ e } Y = y)$
- ▶ Função de probabilidade marginal (variáveis discretas)

$$f_X(x, y) = \sum_y f_{XY}(x, y)$$

,

$$f_Y(x, y) = \sum_x f_{XY}(x, y)$$

# Independencia

- Dadas duas VAs  $X, Y$ , com função de probabilidade conjunta  $f_{xy}$  e marginais  $f_x$  e  $f_y$ .  $X$  e  $Y$  são independentes sse:

$$f_{xy}(x, y) = f_x(x) * f_y(y)$$

$$E[X, Y] = E[X].E[Y]$$

Exemplo: a tabela abaixo mostra distribuição conjunta de probabilidade dos pontos obtidos ao jogar dois dados de 4 faces.

1. calcule as duas funções de probabilidades marginais
2. avalie se as variáveis são independentes

|   |      |      |      |      |
|---|------|------|------|------|
| 4 | 0    | 1/20 | 1/20 | 1/20 |
| 3 | 1/20 | 2/20 | 3/20 | 1/20 |
| 2 | 1/20 | 2/20 | 3/20 | 1/20 |
| 1 | 1/20 | 1/20 | 1/20 | 0    |
|   | 1    | 2    | 3    | 4    |



# Coeficiente de correlação 1/2

Sejam duas VAs  $X, Y$ , com função de probabilidade conjunta  $f_{xy}$  e marginais  $f_x, f_y$  então o coeficiente de correlação entre  $X, Y$ , é denotado por  $\text{Cor}(X, Y)$  :

- ▶ Coeficiente de correlação:

$$\text{Cor}(X, Y) = \rho_{x,y} = \text{Cov}(X, Y) / (\sigma_x * \sigma_y)$$

- ▶  $\rho$  é o xímbolo usado para o coeficiente de correlação
- ▶  $\text{Cor}(X, Y)$  é a covariância normalizada e seu valor varia entre  $(-1..0..1)$ .

# Coeficiente de correlação 2/2

Se  $\text{Cor}(X,Y) = 0$

- ▶ 0: não há correlação (covariância é 0).
- ▶ +1: forte correlação positiva.
- ▶ -1: forte correlação negativa.

Além disso:

- ▶ Se  $f_{xy}(x,y) = f_x(x) * f_y(y)$  então  $\text{Cor}(X,Y) = 0$ .
- ▶ Mas,  $\text{Cor}(X,Y)=0$  não implica independência. Exemplo:  $X=\text{Unif}(-1,1)$  e  $Y=\text{abs}(X)$ .
- ▶ O único caso geral onde correlação igual a zero implica independência é quando  $f_{xy}$  é normal.

# Dependência e risco 1/2

Variáveis do modelo podem apresentar alguma forma de dependência entre si.

1-Observe este fragmento de modelo em R

- ▶ `c1 <- rtriangle(1000, 10, 30, 20)`
- ▶ `c2 <- rtriangle(1000, 20, 60, 40)`
- ▶ `plot(c1, c2)`

2-repita com:

- ▶ `e1 <- rnorm(1000, 0, 5)`
- ▶ `c3 <- -2 * c1 + 10 + e1`
- ▶ `plot(c1, c3)`

3-repita com:

- ▶ `c4 <- -80 - 2 * c1 + e1`
- ▶ `plot(c1, c4)`

## Dependência e risco 2/2

4-Observe este fragmento de modelo em R


- ▶ `cov(c1, c2)`
- ▶ `m1 < -mean(c1)`
- ▶ `m2 < -mean(c2)`
- ▶ `sp < -(c1 - m1) * (c2 - m2)`
- ▶ `head(sp)`

5-repita com:

- ▶ `library(MASS)`
- ▶ `cormat < -matrix(c(1, 1, 1, 1), ncol = 2)`
- ▶ `cc < -mvrnorm(500, mu = c(0, 0), Sigma = cormat)`
- ▶ `plot(cc[, 1], cc[, 2])`


# Exemplos de correlação 1/2

Exemplos de diagramas de dispersão com vários graus de coeficientes de correlação entre duas VAs normais reduzidas.



# Exemplos de correlação 2/2

Observe alguns tipos de correlação entre variáveis aleatórias como mostrado na figura abaixo. Em alguns casos o coeficiente de correlação é igual a zero. Faz sentido?



# Coeficientes de correlação de Spearman

Coeficiente de correlação de Spearman  $\rho$

Estatística *não-paramétrica* para medir a relação entre 2 VAs

Algoritmo:

1. encontre a *ordem* das observações de X e Y ( $u_i, v_i$ ), onde  $i=1$  corresponde ao maior valor.
2. calcule

$$\rho = 1 - 6 * \sum \frac{(u_i - v_i)^2}{(n(n^2 - 1))}$$

Consulte o auxílio às funções do R: `cov(.)` que calcula a covariância e `cor(.)` calcula a correlação

# Correlação entre muitas variáveis

- ▶ Muitas situações no mundo real apresentam uma correlação entre um conjunto de variáveis (múltipla)
- ▶ Sejam  $N$  variáveis aleatórias  $X_1, X_2, \dots, X_N$ 
  1. A correlação entre estas VAs é definida por  $M$ , chamada de matriz de correlação
  2.  $M$  deve ser triangular, simétrica e positiva definida.
  3. Um elemento da matriz  $M[i,j]$  representa o coeficiente de correlação entre  $X_i$  e  $X_j$
  4.  $M$  pode representar também a covariância entre  $X_i$  e  $X_j$
  5.  $Cor(X, Y) = Cov(X, Y) / (\sigma_x * \sigma_y) = Cov(X, Y)$  se  $\sigma_x = \sigma_y$



# Geração de amostras normais correlacionadas em R

## Método

1. instalar o pacote MASS
2. usar a função `mvrnorm(m,mu,Sigma)`: retorna uma lista de  $m$  amostras de  $(n)$  variáveis aleatórias normalmente distribuídas.
  - ▶  $m$ : número de amostras
  - ▶  $\mu$ : vetor das médias das  $n$  variáveis
  - ▶  $\Sigma$ : matriz da covariância entre as  $n$  variáveis:
  - ▶  $\Sigma[i,j]=\text{cov}(i,j)$
  - ▶  $\Sigma$ : simétrica e positiva-definida (consistente).

## Exemplo:

```
x←mvrnorm(500,mu=c(0,0),Sigma=matrix(c(1,1,1,1),ncol=2))
```

*Nota: a matriz de covariância de normais reduzidas é igual a matriz de correlação!*

# Geração de amostras triangulares correlacionadas em R

Algoritmo para gerar  $n$  VAs distintas ( $V_1, V_2, \dots, V_n$ ), interligadas por uma matriz de correlação  $A$   $[n, n]$

1. gerar  $Z[m, n]$ :  $m$   $n$ -plas amostras normais reduzidas correlacionadas por  $A$

$$Z \leftarrow \text{mvrnorm}(m, \mu = \text{rep}(0, \text{times} = n), \text{Sigma} = A)$$

2. gerar  $U$  com  $m$   $n$ -plas uniformes

$$U \leftarrow \text{pnorm}(Z)$$

3. gerar matriz de triangulares correlacionadas

$$T[, 1] \leftarrow \text{qtriangle}(U[, 1], \text{min}_1, \text{max}_1, \text{mp}_1)$$