Trabalho_Final

July 7, 2025

1 Trabalho Final de Computação Científica e Análise de Dados

Nome: Davi dos Santos Mattos
DRE: 119133049

1.1 Tema: Agrumapento e Recomendação de música por similaridade

O objetivo do trabalho é, através de um dataset contendo informações de músicas, onde cada linha representa uma música, e cada colunas representa características da música (ex: Nome, Intérprete, popularidae, duração, etc.), tentar agrupar as músicas com base em suas similaridades e fazer uma recomendação com base em uma música escolhida

Para isso utilizaremos o seguinte dataset Spotify Tracks Dataset, que contém informações de 114 mil músicas.

Vamos começar carregando dataset e dando uma breve olhada nele...

[67]:
```
import pandas as pd

file_path = r'D:\REPOSITÓRIOS\obsidian_notebook\Computação Científica e Análise␣
 ↪de Dados\Trabalho Final\dataset.csv'
df_musicas = pd.read_csv(file_path, index_col=0, sep=',')
df_musicas.head()
```

[67]:
```
                 track_id                 artists  \
0  5SuOikwiRyPMVoIQDJUgSV             Gen Hoshino
1  4qPNDBW1i3p13qLCt0Ki3A            Ben Woodward
2  1iJBSr7s7jYXzM8EGcbK5b  Ingrid Michaelson;ZAYN
3  6lfxq3CG4xtTiEg7opyCyx             Kina Grannis
4  5vjLSffimiIP26QG5WcN2K        Chord Overstreet

                                           album_name  \
0                                              Comedy
1                                  Ghost (Acoustic)
2                                    To Begin Again
3  Crazy Rich Asians (Original Motion Picture Sou…
4                                             Hold On

                  track_name  popularity  duration_ms  explicit  \
```

```
0                     Comedy          73       230666     False
1           Ghost - Acoustic          55       149610     False
2             To Begin Again          57       210826     False
3  Can't Help Falling In Love          71       201933     False
4                    Hold On          82       198853     False

   danceability  energy  key  loudness  mode  speechiness  acousticness  \
0         0.676  0.4610    1    -6.746     0       0.1430        0.0322
1         0.420  0.1660    1   -17.235     1       0.0763        0.9240
2         0.438  0.3590    0    -9.734     1       0.0557        0.2100
3         0.266  0.0596    0   -18.515     1       0.0363        0.9050
4         0.618  0.4430    2    -9.681     1       0.0526        0.4690

   instrumentalness  liveness  valence    tempo  time_signature track_genre
0          0.000001    0.3580    0.715   87.917               4    acoustic
1          0.000006    0.1010    0.267   77.489               4    acoustic
2          0.000000    0.1170    0.120   76.332               4    acoustic
3          0.000071    0.1320    0.143  181.740               3    acoustic
4          0.000000    0.0829    0.167  119.949               4    acoustic
```

Verificando o tamanho do dataset

[68]:
```
df_musicas.shape
```

[68]:
```
(114000, 20)
```

Vamos analisar o que compõem cada coluna e de que tipo são

[69]:
```
df_musicas.dtypes.to_frame('types')
```

[69]:
```
                   types
track_id          object
artists           object
album_name        object
track_name        object
popularity         int64
duration_ms        int64
explicit            bool
danceability     float64
energy           float64
key                int64
loudness         float64
mode               int64
speechiness      float64
acousticness     float64
instrumentalness float64
liveness         float64
valence          float64
```

```
tempo             float64
time_signature      int64
track_genre        object
```

1.2 Colunas

Coluna	Descrição
`track_id`	ID do Spotify para a faixa.
`artists`	Nome(s) dos artistas que performaram a faixa. Se houver mais de um, são separados por ponto e vírgula (`;`).
`album_name`	Nome do álbum/playlist onde a faixa aparece.
`track_name`	Nome da faixa.
`popularity`	Popularidade da faixa (0 a 100). Calculada por algoritmo com base no número total de execuções e quão recentes essas execuções são. Faixas duplicadas são avaliadas separadamente.
`duration_ms`	Duração da faixa em milissegundos.
`explicit`	Indica se a faixa possui conteúdo explícito (`True`) ou não/desconhecido (`False`).
`danceability`	Indica quão dançante é a faixa (`0.0` a `1.0`). Leva em conta tempo, estabilidade do ritmo, força da batida, entre outros.
`energy`	Mede a intensidade e atividade da faixa (`0.0` a `1.0`). Faixas rápidas, altas e barulhentas têm maior energia. (Ex: Heavy Metal possue alta energia enquanto Musica Clássica possui meno energia)
`key`	Tom da faixa em notação Pitch Class (ex: 0 = C, 1 = C /D , 2 = D, ...), se o tom não for detectado seu valor é -1.
`loudness`	Volume geral da faixa em decibéis (dB).
`mode`	Modalidade da faixa: `1` para maior (major), `0` para menor (minor).
`speechiness`	Mede a presença de fala na faixa (`0.0` a `1.0`). Valores [`> 0.66`] = fala pura; [`0.33~0.66`] = fala + música (ex: rap) e [`< 0.33`] = predominantemente música.
`acousticness`	Confiança de que a faixa é acústica (`0.0` a `1.0`). Quanto mais próximo de 1.0, maior a probabilidade de ser acústica.
`instrumentalness`	Prediz se a faixa é instrumental (sem vocais). Quanto mais próximo de 1.0, maior a chance de não conter voz.
`liveness`	Detecta a presença de audiência (música ao vivo). Valores `> 0.8` indicam forte chance de gravação ao vivo.
`valence`	Medida de positividade emocional da música (0.0 = negativa, 1.0 = positiva).
`tempo`	Tempo estimado da faixa em batidas por minuto (BPM).
`time_signature`	Compasso estimado da música (valores entre 3 e 7 indicando 3/4 até 7/4).
`track_genre`	Gênero musical ao qual a faixa pertence.

Antes de seguir com o processo de clusterização, precisamos nos certificar de que o dataset está o mais limpo possível

[70]:
```
df_musicas[df_musicas.duplicated()]
```

[70]:
```
                     track_id                  artists  \
1925    0CDucx9lKxuCZplLXUz0iX   Buena Onda Reggae Club
```

```
2155    2aibwv5hGXSgw7Yru8IYTO    Red Hot Chili Peppers
3738    7mULVp0DJrI2Nd6GesLvxn              Joy Division
4648    6d3RIvHfVkoOtW1WHXmbX3          Little Symphony
5769    481beimUiUnMUzSbOAFcUT             SUPER BEAVER
…                        …                        …
111246  0sSjIvTvd6fUSZZ5rnTPDW  Everything But The Girl
111362  2zg3iJW4fK7KZgHOvJU67z                Faithless
111980  46FPub2Fewe7XrgM0smTYI                Morcheeba
112968  6qVA1MqDrDKfk9144bhoKp              Acil Servis
113345  5WaioelSGekDk3UNQy8zaw              Matt Redman

                                            album_name  \
1925                                           Disco 2
2155                                  Stadium Arcadium
3738                               Timeless Rock Hits
4648                                         Serenity
5769                                            /
…                                                  …
111246                            Eden (Deluxe Edition)
111362                                   Faithless 2.0
111980                             Parts of the Process
112968                                       Küçük Adam
113345  Sing Like Never Before: The Essential Collection

                          track_name  popularity  duration_ms  explicit  \
1925                 Song for Rollins          16       219346     False
2155                    Snow (Hey Oh)          80       334666     False
3738          Love Will Tear Us Apart           0       204621     False
4648                           Margot          27        45714     False
5769                                          54       255080     False
…                                  …         …          …       …
111246  Another Bridge - 2012 Remaster          26       132826     False
111362                      Tarantula          21       398152     False
111980                Undress Me Now           17       203773     False
112968                         Bebek           38       319933     False
113345        Our God - New Recording          34       265373     False

        danceability  energy  key  loudness  mode  speechiness  acousticness  \
1925           0.841   0.577    0    -7.544     1       0.0438      0.238000
2155           0.427   0.900   11    -3.674     1       0.0499      0.116000
3738           0.524   0.902    2    -8.662     1       0.0368      0.000989
4648           0.269   0.142    0   -23.695     1       0.0509      0.866000
5769           0.472   0.994    8    -1.786     1       0.1140      0.025900
…                  …     …  …       …   …          …           …
111246         0.480   0.853    0    -6.276     1       0.0734      0.030600
111362         0.622   0.816    6   -11.095     0       0.0483      0.009590
111980         0.576   0.352    7   -10.773     0       0.0268      0.700000
```

```
112968         0.486   0.485    5   -12.391     0       0.0331       0.004460
113345         0.487   0.895   11    -5.061     1       0.0413       0.000183

        instrumentalness  liveness  valence    tempo  time_signature  \
1925            0.860000    0.0571    0.843   90.522               4
2155            0.000017    0.1190    0.599  104.655               4
3738            0.695000    0.1370    0.907  146.833               4
4648            0.904000    0.1140    0.321   67.872               3
5769            0.000000    0.0535    0.262  103.512               4
…                    …         …        …        …               …
111246          0.000001    0.3200    0.775   85.181               4
111362          0.578000    0.0991    0.427  136.007               4
111980          0.270000    0.1600    0.360   95.484               4
112968          0.000017    0.3690    0.353  120.095               4
113345          0.000000    0.3590    0.384  105.021               4

        track_genre
1925       afrobeat
2155       alt-rock
3738    alternative
4648        ambient
5769          anime
…               …
111246     trip-hop
111362     trip-hop
111980     trip-hop
112968      turkish
113345  world-music

[450 rows x 20 columns]
```

[71]:
```
print(df_musicas.duplicated().sum())
```

```
450
```

Existem 450 faixas que possuem cópias idênticas dentro do dataset, vamos investigar essas duplicatas

[72]:
```
df_musicas[df_musicas['track_id']=='2aibwv5hGXSgw7Yru8IYTO']
```

[72]:
```
                    track_id                artists        album_name  \
2109   2aibwv5hGXSgw7Yru8IYTO  Red Hot Chili Peppers  Stadium Arcadium
2155   2aibwv5hGXSgw7Yru8IYTO  Red Hot Chili Peppers  Stadium Arcadium
3259   2aibwv5hGXSgw7Yru8IYTO  Red Hot Chili Peppers  Stadium Arcadium
37216  2aibwv5hGXSgw7Yru8IYTO  Red Hot Chili Peppers  Stadium Arcadium
71158  2aibwv5hGXSgw7Yru8IYTO  Red Hot Chili Peppers  Stadium Arcadium
91854  2aibwv5hGXSgw7Yru8IYTO  Red Hot Chili Peppers  Stadium Arcadium
```

	track_name	popularity	duration_ms	explicit	danceability	energy	\
2109	Snow (Hey Oh)	80	334666	False	0.427	0.9	
2155	Snow (Hey Oh)	80	334666	False	0.427	0.9	
3259	Snow (Hey Oh)	80	334666	False	0.427	0.9	
37216	Snow (Hey Oh)	80	334666	False	0.427	0.9	
71158	Snow (Hey Oh)	80	334666	False	0.427	0.9	
91854	Snow (Hey Oh)	80	334666	False	0.427	0.9	

	key	loudness	mode	speechiness	acousticness	instrumentalness	\
2109	11	-3.674	1	0.0499	0.116	0.000017	
2155	11	-3.674	1	0.0499	0.116	0.000017	
3259	11	-3.674	1	0.0499	0.116	0.000017	
37216	11	-3.674	1	0.0499	0.116	0.000017	
71158	11	-3.674	1	0.0499	0.116	0.000017	
91854	11	-3.674	1	0.0499	0.116	0.000017	

	liveness	valence	tempo	time_signature	track_genre
2109	0.119	0.599	104.655	4	alt-rock
2155	0.119	0.599	104.655	4	alt-rock
3259	0.119	0.599	104.655	4	alternative
37216	0.119	0.599	104.655	4	funk
71158	0.119	0.599	104.655	4	metal
91854	0.119	0.599	104.655	4	rock

Vamos remover esssas duplicatas idênticas

[73]:
```
df_musicas = df_musicas.drop_duplicates()
df_musicas.shape
```

[73]: (113550, 20)

Passamos a ter 113550 músicas no dataset, vamos verificar se ainda há duplicatas

[74]:
```
df_musicas[df_musicas['track_name'] == "Snow (Hey Oh)"]
```

[74]:

	track_id	artists	album_name	\
2109	2aibwv5hGXSgw7Yru8IYTO	Red Hot Chili Peppers	Stadium Arcadium	
3259	2aibwv5hGXSgw7Yru8IYTO	Red Hot Chili Peppers	Stadium Arcadium	
23630	4dIZsI7RjIHeNgBJInhpli	Goldbird;Offmind	Snow (Hey Oh)	
37216	2aibwv5hGXSgw7Yru8IYTO	Red Hot Chili Peppers	Stadium Arcadium	
71158	2aibwv5hGXSgw7Yru8IYTO	Red Hot Chili Peppers	Stadium Arcadium	
91854	2aibwv5hGXSgw7Yru8IYTO	Red Hot Chili Peppers	Stadium Arcadium	

	track_name	popularity	duration_ms	explicit	danceability	energy	\
2109	Snow (Hey Oh)	80	334666	False	0.427	0.900	
3259	Snow (Hey Oh)	80	334666	False	0.427	0.900	
23630	Snow (Hey Oh)	59	164221	False	0.603	0.714	
37216	Snow (Hey Oh)	80	334666	False	0.427	0.900	

```
71158  Snow (Hey Oh)          80       334666     False         0.427   0.900
91854  Snow (Hey Oh)          80       334666     False         0.427   0.900

       key  loudness  mode  speechiness  acousticness  instrumentalness  \
2109    11    -3.674     1       0.0499         0.116          0.000017
3259    11    -3.674     1       0.0499         0.116          0.000017
23630    8    -9.071     0       0.1080         0.419          0.002050
37216   11    -3.674     1       0.0499         0.116          0.000017
71158   11    -3.674     1       0.0499         0.116          0.000017
91854   11    -3.674     1       0.0499         0.116          0.000017

       liveness  valence    tempo  time_signature  track_genre
2109      0.119    0.599  104.655               4     alt-rock
3259      0.119    0.599  104.655               4  alternative
23630     0.713    0.736  113.917               4   deep-house
37216     0.119    0.599  104.655               4         funk
71158     0.119    0.599  104.655               4        metal
91854     0.119    0.599  104.655               4         rock
```

Ao investigar uma musica que tenha uma duplicata, podemos perceber que provavelmente é por causa de que uma música pode pertencer a dois "albuns" (Album ou EP) ou então a mais de um gênero

Vamos começar retirando as músicas com o mesmo `track_id` e ver se todas as duplicatas foram retiradas

[75]:
```
df_musicas = df_musicas.drop_duplicates(subset=['track_id'], keep='first')
df_musicas[df_musicas['track_name'] == "Snow (Hey Oh)"]
```

[75]:
```
                    track_id                artists        album_name  \
2109   2aibwv5hGXSgw7Yru8IYTO  Red Hot Chili Peppers  Stadium Arcadium
23630  4dIZsI7RjIHeNgBJInhpli       Goldbird;Offmind     Snow (Hey Oh)

          track_name  popularity  duration_ms  explicit  danceability  energy  \
2109   Snow (Hey Oh)          80       334666     False         0.427   0.900
23630  Snow (Hey Oh)          59       164221     False         0.603   0.714

       key  loudness  mode  speechiness  acousticness  instrumentalness  \
2109    11    -3.674     1       0.0499         0.116          0.000017
23630    8    -9.071     0       0.1080         0.419          0.002050

       liveness  valence    tempo  time_signature track_genre
2109      0.119    0.599  104.655               4    alt-rock
23630     0.713    0.736  113.917               4  deep-house
```

Aparentemente remover duplicatas de `track_id`, foi o sufieciente para tratar das duplicatas

[76]:
```
print(df_musicas.shape)
```

```
(89741, 20)
```

Vamos verificar se há também valores nulos

[77]:
```
df_musicas[df_musicas.isnull().any(axis=1)]
```

[77]:
```
                     track_id artists album_name track_name  popularity  \
65900  1kR4gIb7nGxHPI3D2ifs59     NaN        NaN        NaN           0

       duration_ms  explicit  danceability  energy  key  loudness  mode  \
65900            0     False         0.501   0.583    7     -9.46     0

       speechiness  acousticness  instrumentalness  liveness  valence  \
65900       0.0605          0.69           0.00396    0.0747    0.734

         tempo  time_signature track_genre
65900  138.391               4       k-pop
```

[78]:
```
df_musicas = df_musicas.dropna(axis=0)
```

Após remover todas as duplicatas e valores nulos do dataset, vamos conferir quantos dados sobraram.

[79]:
```
df_musicas.shape
```

[79]:
```
(89740, 20)
```

Com isso nosso dataset que havia 114 mil músicas, na verdade tem 89740 músicas.

Com isso vamos pegar apenas as colunas que possuem valores numéricos

[80]:
```
df_dados = df_musicas.select_dtypes(include='number')
df_dados
```

[80]:
```
        popularity  duration_ms  danceability  energy  key  loudness  mode  \
0               73       230666         0.676  0.4610    1    -6.746     0
1               55       149610         0.420  0.1660    1   -17.235     1
2               57       210826         0.438  0.3590    0    -9.734     1
3               71       201933         0.266  0.0596    0   -18.515     1
4               82       198853         0.618  0.4430    2    -9.681     1
…              …          …             …      …   …        …   …
113995          21       384999         0.172  0.2350    5   -16.393     1
113996          22       385000         0.174  0.1170    0   -18.318     0
113997          22       271466         0.629  0.3290    0   -10.895     0
113998          41       283893         0.587  0.5060    7   -10.889     1
113999          22       241826         0.526  0.4870    1   -10.204     0

        speechiness  acousticness  instrumentalness  liveness  valence  \
0            0.1430        0.0322          0.000001    0.3580   0.7150
1            0.0763        0.9240          0.000006    0.1010   0.2670
```

```
2            0.0557        0.2100          0.000000    0.1170   0.1200
3            0.0363        0.9050          0.000071    0.1320   0.1430
4            0.0526        0.4690          0.000000    0.0829   0.1670
…               …             …                …          …        …
113995       0.0422        0.6400          0.928000    0.0863   0.0339
113996       0.0401        0.9940          0.976000    0.1050   0.0350
113997       0.0420        0.8670          0.000000    0.0839   0.7430
113998       0.0297        0.3810          0.000000    0.2700   0.4130
113999       0.0725        0.6810          0.000000    0.0893   0.7080

           tempo  time_signature
0         87.917               4
1         77.489               4
2         76.332               4
3        181.740               3
4        119.949               4
…            …               …
113995   125.995               5
113996    85.239               4
113997   132.378               4
113998   135.960               4
113999    79.198               4

[89740 rows x 14 columns]
```

Que pertencem as seguintes colunas

[81]:
```
df_dados.columns
```

[81]:
```
Index(['popularity', 'duration_ms', 'danceability', 'energy', 'key',
       'loudness', 'mode', 'speechiness', 'acousticness', 'instrumentalness',
       'liveness', 'valence', 'tempo', 'time_signature'],
      dtype='object')
```

Agora sim, podemos seguir para o processo de Clusterização

1.3 Funções Necessárias

Porém antes vamos definir algumas funções que vão nos ajudar posteriormente

`calcular_soma_erros()` - soma dos quadrados intra-clusters

`optimal_number_of_clusters()` - a quantidade ótima de clusters baseado na distância entre um ponto e uma reta

Referência: Como definir o número de clusters para o seu KMeans

`tamanho_amostra()` - Faz o calculo do tamanho da amostra necessária com grau de confiança de 95% e margem de erro de 5% (Para que seja computacionalmente viável)

`recomendar_musicas()` - Recomenda 10 músicas com base na faixa escolhida levando em conta o cluster em que ela se encontra e a distância da mesma para as demais faixas.

[82]:
```
from math import sqrt
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

def calcular_soma_erros(matrix):

    soma_erros = []
    for k in range(1, 20):
        kmeans = KMeans(n_clusters=k, random_state=14)
        kmeans.fit(matrix)
        soma_erros.append(kmeans.inertia_)
    return soma_erros

def optimal_number_of_clusters(wcss):
    x1, y1 = 1, wcss[0]
    x2, y2 = 20, wcss[len(wcss)-1]

    distances = []
    for i in range(len(wcss)):
        x0 = i+2
        y0 = wcss[i]
        numerator = abs((y2-y1)*x0 - (x2-x1)*y0 + x2*y1 - y2*x1)
        denominator = sqrt((y2 - y1)**2 + (x2 - x1)**2)
        distances.append(numerator/denominator)

    return distances.index(max(distances)) + 2
```

[83]:
```
def tamanho_amostra(populacao):
    import math
    z = 1.96  # para 95% de confiança
    e = 0.05  # margem de erro
    p = 0.5   # proporção mais conservadora

    n0 = (z**2 * p * (1 - p)) / (e**2)
    n = (populacao * n0) / (populacao + n0 - 1)
    return math.ceil(n)
```

[84]:
```
from scipy.spatial.distance import euclidean, cosine

def recomendar_musicas(track_id, df_dados_normalizados, df_musicas):
    idx = df_musicas.index[df_musicas['track_id'] == track_id][0]
    cluster_id = df_musicas.loc[idx, 'cluster']
    print(f"Cluster: {cluster_id}")
    musica_base = df_dados_normalizados.drop(columns='cluster').iloc[idx].values
```

```
    subset = df_dados_normalizados[df_dados_normalizados['cluster'] ==␣
↪cluster_id].copy()
    subset['distancia'] = subset.drop(columns='cluster').apply(lambda row:␣
↪cosine(row.values, musica_base), axis=1)

    resultado_idx = subset.sort_values('distancia').index
    recomendacoes = df_musicas.iloc[resultado_idx][['track_name',␣
↪'artists','track_genre']]
    recomendacoes = recomendacoes[recomendacoes.index != idx]

    return recomendacoes.head(10)
```

Além de fazer o agrupamento por similaridade e a recomendação de músicas parecidas, vamos também analisar o impacto no agrupamento e consequêntemente na recomendação de acordo com o modelo de normalização que utilizarmos.

Para exemplificar, vamos usar 4 tipos de normalização de dados - Robust Scale

Usa mediana e intervalo interquartil (IQR) para escalonar, ignorando outliers. Reduzindo o impacto de valores extremos sem removê-los. *Recomendado quando: Há outliers que distorcem a média ou o desvio padrão.*

- Min Max Scale

Reescala os dados para um intervalo específico (padrão: 0 a 1). Útil quando é importante preservar proporções relativas dos dados. *Recomendado quando: Os dados estão em escalas distintas e não há outliers relevantes.*

- Standart Scale

Transforma os dados para terem média 0 e desvio padrão 1. Ideal para algoritmos que assumem distribuição normal (ex: PCA, SVM, regressão logística). *Recomendado quando: Há presença de variáveis gaussianas ou com variâncias diferentes.*

- Max Abs Scale

Escala os dados pela magnitude máxima absoluta de cada atributo. Mantém sinais (positivo/negativo) e é útil em dados esparsos. *Recomendado quando: Você usa dados com muitos zeros (sparse) e não quer centrar em zero.*

De acordo com as recomendações as melhores normalizações são as *Robust Scale* e *Standart Scale*

2 Robust Scale

Primeiro normalizaremos os dados com Robust Scale

[85]:
```
from sklearn.preprocessing import robust_scale
escala1 = robust_scale(df_dados)
df_dados_normalizados1 =  pd.DataFrame(escala1, columns=df_dados.columns[:])
df_dados_normalizados1
```

[85]:

	popularity	duration_ms	danceability	energy	key	loudness	\
0	1.333333	0.190355	0.413223	-0.542929	-0.666667	0.084192	
1	0.733333	-0.697900	-0.644628	-1.287879	-0.666667	-1.927410	
2	0.800000	-0.027062	-0.570248	-0.800505	-0.833333	-0.488853	
3	1.266667	-0.124516	-1.280992	-1.556566	-0.833333	-2.172892	
4	1.633333	-0.158269	0.173554	-0.588384	-0.500000	-0.478688	
…	…	…	…	…	…	…	
89735	-0.400000	1.881620	-1.669421	-1.113636	0.000000	-1.765930	
89736	-0.366667	1.881631	-1.661157	-1.411616	-0.833333	-2.135111	
89737	-0.366667	0.637464	0.219008	-0.876263	-0.833333	-0.711512	
89738	0.266667	0.773646	0.045455	-0.429293	0.333333	-0.710361	
89739	-0.366667	0.312653	-0.206612	-0.477273	-0.666667	-0.578990	

	mode	speechiness	acousticness	instrumentalness	liveness	valence	\
0	-1.0	1.885772	-0.256292	-0.000584	1.250000	0.595843	
1	0.0	0.549098	1.210725	-0.000537	-0.171460	-0.438799	
2	0.0	0.136273	0.036190	-0.000594	-0.082965	-0.778291	
3	0.0	-0.252505	1.179470	0.000130	0.000000	-0.725173	
4	0.0	0.074148	0.462247	-0.000594	-0.271571	-0.669746	
…	…	…	…	…	…	…	
89735	0.0	-0.134269	0.743543	9.505168	-0.252765	-0.977136	
89736	-1.0	-0.176353	1.325876	9.996845	-0.149336	-0.974596	
89737	-1.0	-0.138277	1.116960	-0.000594	-0.266040	0.660508	
89738	0.0	-0.384770	0.317486	-0.000594	0.763274	-0.101617	
89739	-1.0	0.472946	0.810989	-0.000594	-0.236173	0.579677	

	tempo	time_signature
0	-0.835395	0.0
1	-1.090893	0.0
2	-1.119241	0.0
3	1.463386	-1.0
4	-0.050571	0.0
…	…	…
89735	0.097564	1.0
89736	-0.901009	0.0
89737	0.253955	0.0
89738	0.341719	0.0
89739	-1.049021	0.0

[89740 rows x 14 columns]

Agora precisamos descobrir qual é a melhor quantidade de clusters para agrupar os dados, e para isso vamos utilizar o método do cotovelo e usando as funções `calcular_soma_erros` e `optimal_number_of_clusters`

[86]:
```
soma_e1 = calcular_soma_erros(escala1)

plt.plot(range(1, 20), soma_e1, marker='o')
```

```
plt.xlabel('Número de Clusters (k)')
plt.ylabel('Soma dos Erros Quadrados (SEQ)')
plt.title('Método do Cotovelo')
plt.show()
```

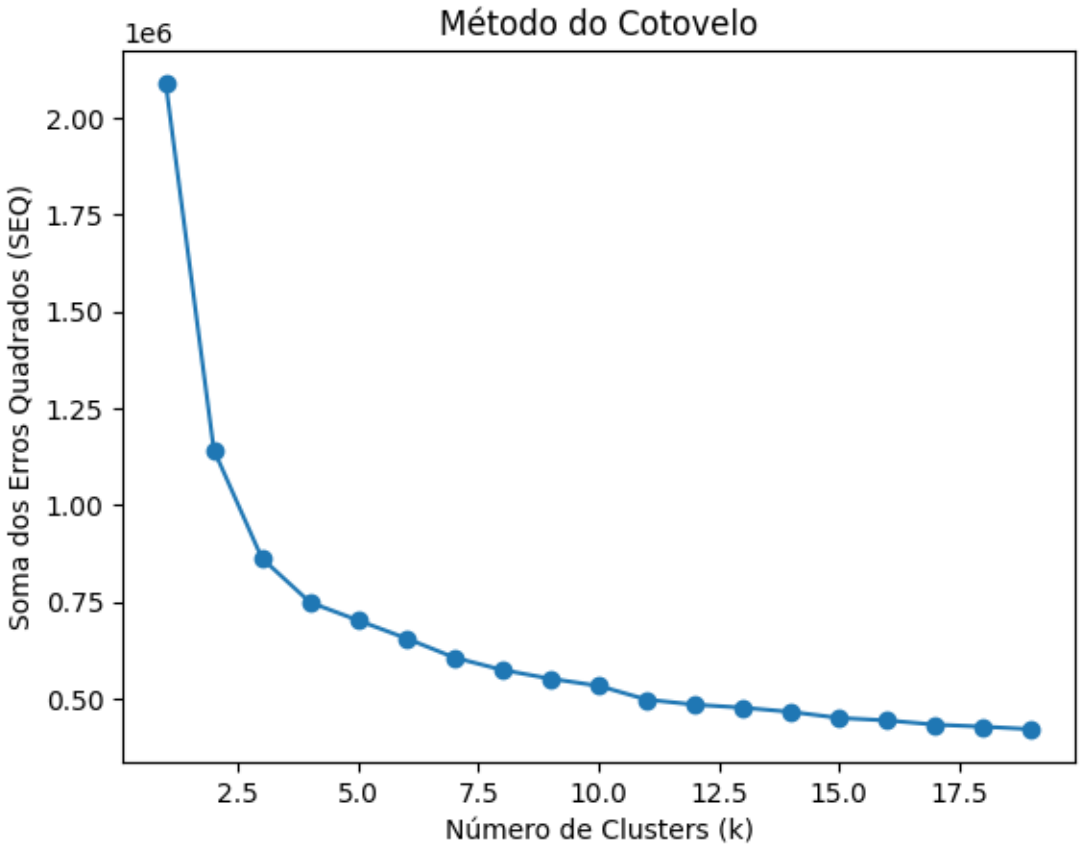

Se tentarmos escolher o número de cluster a olho nu pelo gráfico, aparentemente um número bons de clusters seria $k = 9$, porém temos uma função que descobre o k ideal para nós

[87]:
```
ncluster1 = optimal_number_of_clusters(soma_e1)
ncluster1
```

[87]: 5

Rodando a função, vemos que o k ideal é $k = 5$

Portanto agora vamos agrupar a faixas, `df_musicas_rs` para agrupar o dataset original, `df_dados` para agrupar o dados sem serem normalizados, e `df_dados_normalizados1` para agrupar os dados normalizados

[88]:
```
kmeans = KMeans(n_clusters=ncluster1, random_state=14)
clusters = kmeans.fit_predict(escala1)
```

```
df_musicas_rs = df_musicas.copy()
df_musicas_rs['cluster'] = clusters
df_dados['cluster'] = clusters
df_dados_normalizados1['cluster'] = clusters
```

Criei 3 variáveis pelos seguintes motivos, fazer a plotagem de gráficos e rodar a função `recomendar_musicas()`

2.1 Plotagem 2D e 3D dos clusters

Vamos utiliza o PCA para ter vizualização dos cluster em 2D e 3D

[89]:
```
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches

pca = PCA(n_components=2)
X_pca = pca.fit_transform(escala1)

# Plot
scatter = plt.scatter(X_pca[:, 0], X_pca[:, 1],␣
 ↪c=df_dados_normalizados1['cluster'], cmap='viridis')

# Legenda manual
clusters = df_dados_normalizados1['cluster'].unique()
colors = scatter.cmap(scatter.norm(clusters))

handles = [mpatches.Patch(color=colors[i], label=f'Cluster {clusters[i]}') for␣
 ↪i in range(len(clusters))]

plt.legend(handles=handles, title='Clusters', bbox_to_anchor=(1.05, 1),␣
 ↪loc='upper left')
plt.xlabel('PCA 1')
plt.ylabel('PCA 2')
plt.title('Clusters de músicas')

plt.tight_layout()
plt.show()
```

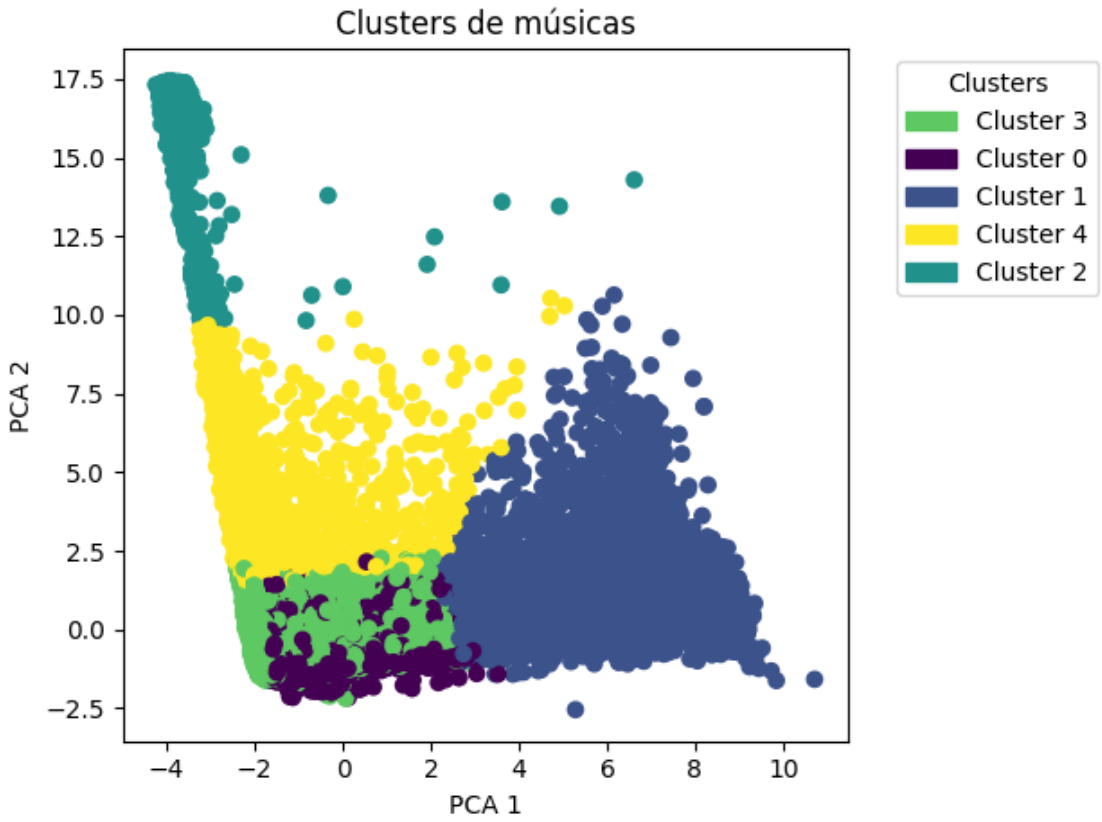

[90]:
```
from mpl_toolkits.mplot3d import Axes3D

pca = PCA(n_components=3)
X_pca_3d = pca.fit_transform(escala1)

fig = plt.figure(figsize=(10,8))
ax = fig.add_subplot(111, projection='3d')
scatter = ax.scatter(X_pca_3d[:, 0], X_pca_3d[:, 1], X_pca_3d[:, 2],
                     c=df_dados_normalizados1['cluster'], cmap='viridis')
ax.set_xlabel('PCA 1')
ax.set_ylabel('PCA 2')
ax.set_zlabel('PCA 3')
plt.title('Clusters em 3D com PCA')
plt.show()
```

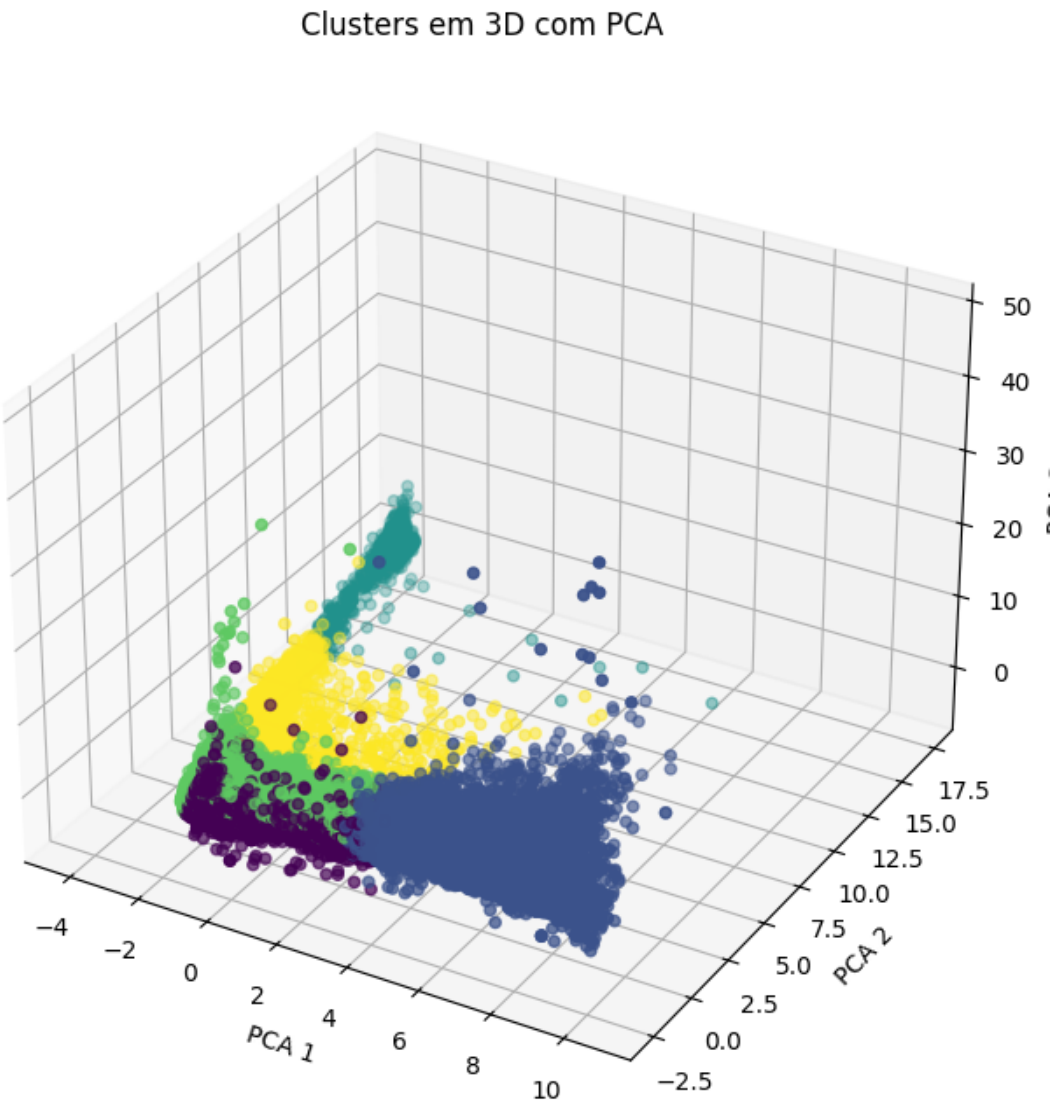

2.2 Analise de agrupamento

Vamos ver quantas músicas foram agrupadas em cada cluster, e verificar se todas as variáveis possuem a mesma quantidade por cluster

[91]:
```
df_musicas_rs['cluster'].value_counts()
```

[91]:
```
cluster
3    41235
0    22472
1    17371
4     7733
```

```
2      929
Name: count, dtype: int64
```

Vamos tentar fazer uma análise bruta, calculando a média das características para cada cluster e comparar com as médias agrupadas por gênero da música do dataset original

2.2.1 Dados Originais

[92]:
```
df_dados_media = df_dados.groupby('cluster').mean(numeric_only=True)
df_dados_media
```

[92]:

cluster	popularity	duration_ms	danceability	energy	key	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	32.960306	219468.585662	0.534000	0.398945	5.051175	-10.854193	0.730109	0.043434	0.598251	0.021228	0.157000	0.418517	113.080880	3.815148
1	28.088020	256630.304531	0.497905	0.547896	5.252605	-12.773717	0.589200	0.064965	0.386202	0.810877	0.184031	0.303307	118.951770	3.830868
2	23.758881	222023.057051	0.567002	0.694920	5.067815	-11.209023	0.696448	0.884701	0.762481	0.005928	0.696433	0.429245	100.385352	3.578041
3	35.539299	228428.393961	0.587537	0.784274	5.382733	-5.673428	0.620783	0.065279	0.161312	0.020798	0.250684	0.555456	128.028073	3.963793
4	34.026251	200192.427906	0.652508	0.707178	5.525152	-6.793617	0.552826	0.288229	0.251861	0.017640	0.227870	0.537177	125.893784	3.970516

Para os dados originais sem estarem normalizados, vemos o seguinte: - **Cluster 0**:

```
Músicas populares,
Menos intensas,
Menos barulhentas,
Com pouca ou nenhuma fala ,
Mais acústicas, Gravadas em estúdio,
```

- **Cluster 1**:

  Baixa popularidade, Mais longas, Não muito dançante, Não tão barulhentas, Mais calmas, com pouca ou nenhuma voz, Faixas instrumentais,

- **Cluster 2**:

  Mais popular, alta energia, som alto, dançante e de humor positivo.

- **Cluster 3**:

  Extremamente “falado”, alta “liveness” (ao vivo), muito acústico, baixíssima popularidade.

- **Cluster 4**:

  Muito dançante, alta energia, nível de “fala” típico de rap.

2.2.2 Dados Normalizados

[93]:
```
df_dados_normalizados1_media = df_dados_normalizados1.groupby('cluster').mean()␣
↪# Para gráfico de médias
df_dados_normalizados1_media
```

[93]:

cluster	popularity	duration_ms	danceability	energy	key	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	-0.001323	0.067648	-0.173553	-0.699635	0.008529	-0.703686	-0.269891	-0.109545	0.674866	0.216852	0.138276	-0.088875	-0.218848	-0.184852
1	-0.163733	0.474886	-0.322708	-0.323496	0.042101	-1.071816	-0.410800	0.321935	0.326044	8.305441	0.287780	-0.354950	-0.075004	-0.169132
2	-0.308037	0.095641	-0.037181	0.047778	0.011302	-0.771736	-0.303552	16.749514	0.945025	0.060125	3.121861	-0.064100	-0.529904	-0.421959
3	0.084643	0.165834	0.047672	0.273419	0.063789	0.289892	-0.379217	0.328231	-0.043903	0.212444	0.656441	0.227381	0.147377	-0.036207
4	0.034208	-0.143591	0.316147	0.078732	0.087525	0.075060	-0.447174	4.796180	0.105052	0.180096	0.530256	0.185167	0.095084	-0.029484

Analisando os dados normalizadados podemos ver que ele, esta casando com os dados originais, porém ficando mais claro distinguir cada grupo

Cluster 0: Mais calmas, menos fala, gravadas em estúdio

Cluster 1: Maior duração, mais dançantes, menos barulhentas, mais faixas instrumentais e atmosféricas

Cluster 2: Maior popularidade, Mais barulhentas, mais animadas, com maior bpm e predominantemente músicas acústicas

Cluster 3: Menos populares, mais enérgicas, mais faladas, acústicas, ao vivo, menor bpm

Cluster 4: Sem faixa instrumental, menos dançantes, menor duração

[94]:
```
df_musicas_rs[df_musicas_rs['cluster']==2][['artists','track_name','track_genre']].head(10)
```

[94]:

	artists	track_name	track_genre
1321	Afrocidade	Vivão (vinheta)	afrobeat
1492	Jorge Drexler	Fractura de escafoides tarsiano derecho - Cara B	afrobeat
1574	Afrocidade;Nildes Bomfim	Canoeiro (vinheta)	afrobeat
4073	Mohan;Murali;Chandiran	Varraaru Vaarraaru Yaaru Varraaru	ambient
9152	Sant;Stau	O Que Separa os Homens dos Meninos	brazil
9769	Racionais MC's	De Volta À Cena	brazil
10886	Noisia;Trolley Snatcha;Foreign Beggars	Contact - Trolley Snatcha Remix	breakbeat
14146	The Laurie Berkner Band	Down Down Baby	children
14427	WowKidz	Aao Bhai Aao Kyon Bhai Kyon	children
14587	Caillou	Cours, papa!	children

[95]:
```
df_musicas_rs[df_musicas_rs['cluster']==3][['artists','track_name','track_genre']].head(10)
```

[95]:

	artists	track_name	track_genre
0	Gen Hoshino	Comedy	acoustic
5	Tyrone Wells	Days I Will Remember	acoustic
14	Chord Overstreet;Deepend	Hold On - Remix	acoustic
24	Jason Mraz	Unlonely	acoustic
27	Jason Mraz		
40	Eddie Vedder		
42	Brandi Carlile;Lucius		
43	Brandi Carlile;Lucius		
44	Brandi Carlile		
45	Brandi Carlile;Lucius		

```
27                                    If It Kills Me    acoustic
40                                         The Haves    acoustic
42                              You and Me on the Rock    acoustic
43                              You and Me on the Rock    acoustic
44  Speak Your Mind (From the Netflix Series "We T…    acoustic
45                              You and Me on the Rock    acoustic
```

Aparentemente está batendo o que observamos

2.2.3 Gênero de músicas por cluster

Vamos tentar validar o que vimos acima com os gêneros mais presentes em cada cluster

[96]:
```
genero_por_cluster = df_musicas_rs.groupby('cluster').apply(
    lambda x: x['track_genre'].value_counts().head(10),
    include_groups=False
)
genero_por_cluster
```

[96]:
```
cluster  track_genre
0        honky-tonk        834
         cantopop          784
         romance           767
         acoustic          684
         opera             663
         tango             659
         mandopop          580
         show-tunes        555
         rock-n-roll       532
         bluegrass         518
1        study             905
         sleep             803
         new-age           785
         minimal-techno    783
         idm               772
         ambient           763
         detroit-techno    762
         iranian           676
         grindcore         609
         classical         576
2        comedy            786
         kids               17
         show-tunes         14
         children           12
         funk                9
         jazz                7
         iranian             7
         chill               5
```

```
          german              4
          garage              4
3         forro             931
          j-idol            868
          heavy-metal       816
          alt-rock          781
          dance             750
          party             731
          salsa             725
          pagode            723
          grunge            710
          power-pop         681
4         dancehall         441
          j-dance           426
          kids              299
          hardcore          280
          funk              262
          french            233
          hip-hop           219
          turkish           197
          emo               188
          hardstyle         181
Name: count, dtype: int64
```

2.3 Gráficos

Vamos plotar os gráficos e ver se está condizente com a classificaçao feita anteriormente

2.3.1 Características X Cluster

Utilizando as médias das caracteristicas dos dados normalizados

[97]:
```
df_dados_normalizados1_media.plot(kind='bar')
plt.title('Caracteristicas por cluster')
plt.legend(bbox_to_anchor=(1.0, 1.0))
plt.show()
```

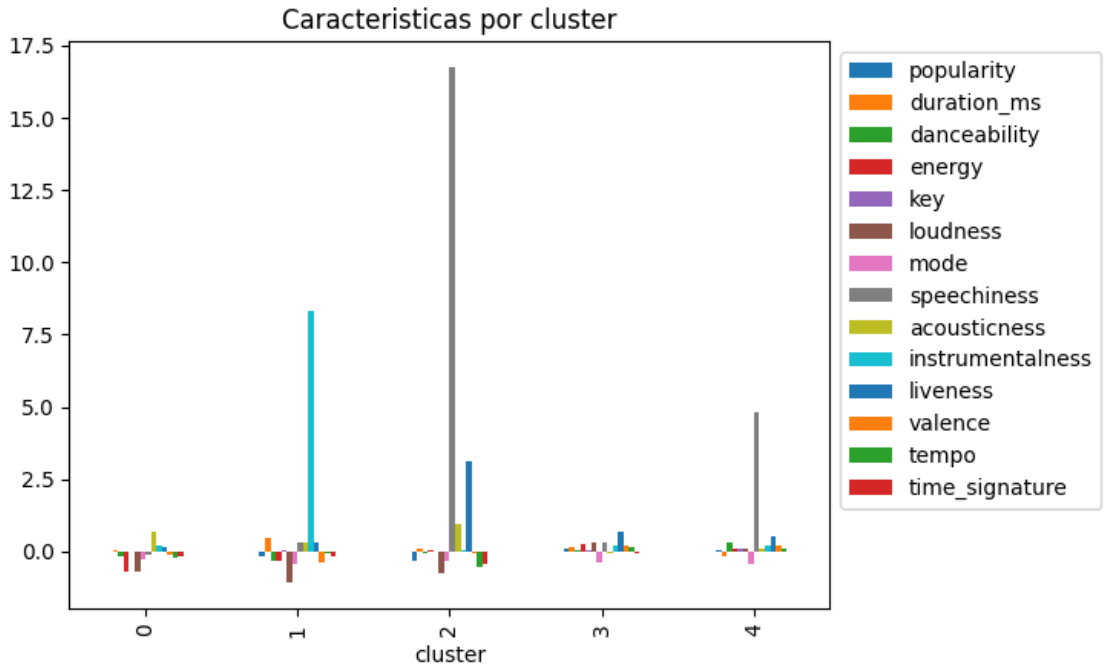

Olhando o gráfico acima vamos tentar classificar cada cluster

- Cluster 0: Menos 'energy' e 'loudness', e mais 'acousticness'
- Cluster 1: Maior 'instrumentalness' e 'valence' e menor 'loudness'
- Cluster 2: Alto 'liveness', 'speechiness', 'loudness' e 'energy'
- Cluster 3: Maior 'instrumentalness', 'liveness' e 'acousticness'
- Cluster 4: 'Speechiness', 'danceability' e 'liveness' altos, menor duração

2.3.2 Cluster X Características

[98]:
```
df_dados_normalizados1_media.T.plot(kind='bar')
plt.title('Clusters por característica')
plt.legend(title='Cluster', bbox_to_anchor=(1.0, 1.0))
plt.tight_layout()
plt.show()
```

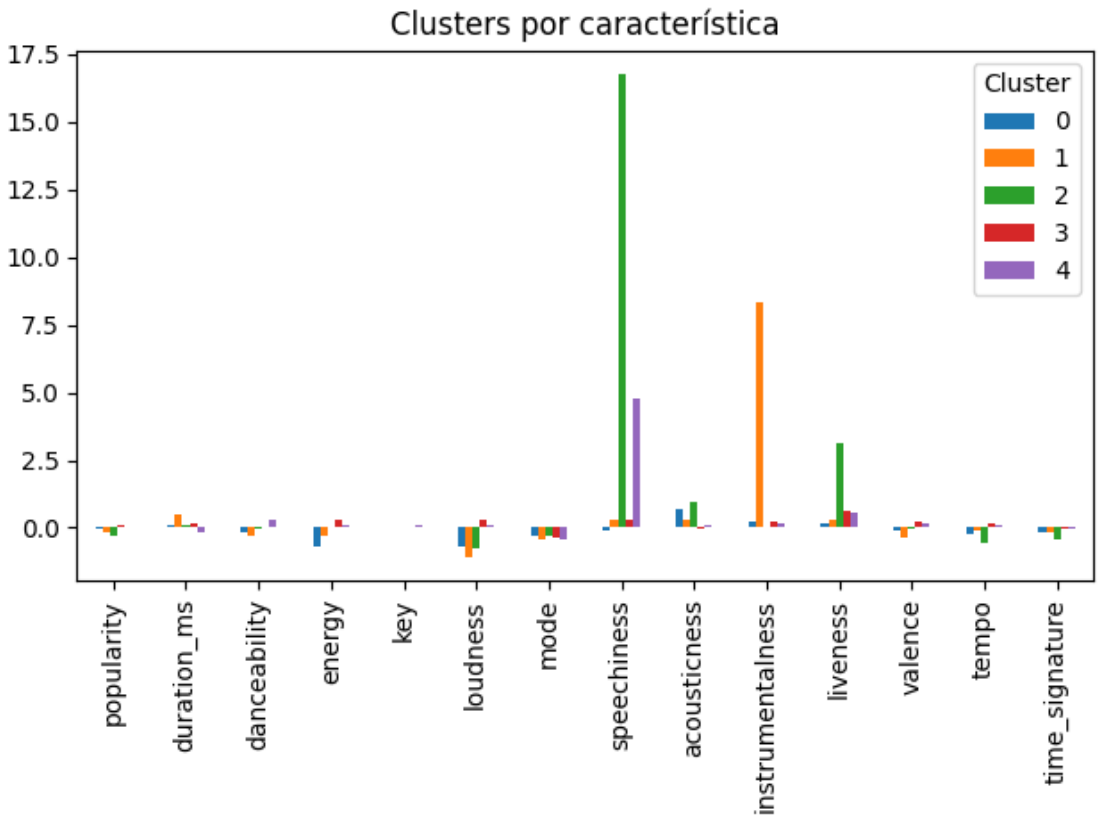

2.3.3 Histogramas

Utilizando os dados reais agrupados vamo analisar a frequência por característica, mas para ser computacionalemente viável, vamos pegar uma amostra usando a função `tamanho_amostra`, para um intevalo com 95% de confiança e 5% de margem de erro.

[99]:
```
import matplotlib.pyplot as plt

for feature in df_dados.columns.drop('cluster'):
    plt.figure(figsize=(8, 5))

    for cluster_id in sorted(df_dados['cluster'].unique()):
        subset = df_dados[df_dados['cluster'] == cluster_id]
        tamanho = tamanho_amostra(len(subset))
        amostra = subset.sample(n=min(tamanho, len(subset)), random_state=42) ␣
 ↪# Garante que não passa o tamanho real
        plt.hist(amostra[feature], bins=30, alpha=0.5, label=f'Cluster␣
 ↪{cluster_id} (n={len(amostra)})')

    plt.title(f'Distribuição de {feature} por Cluster (com amostragem)')
    plt.xlabel(feature)
```

```
    plt.ylabel('Frequência')
    plt.legend()
    plt.tight_layout()
    plt.show()
```

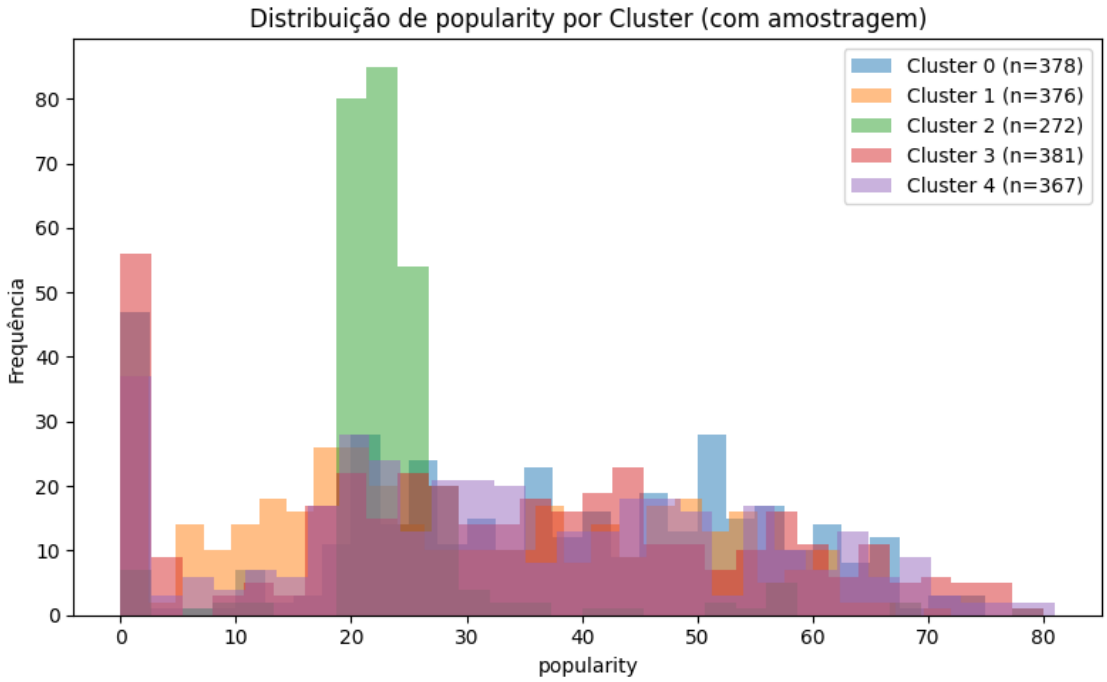

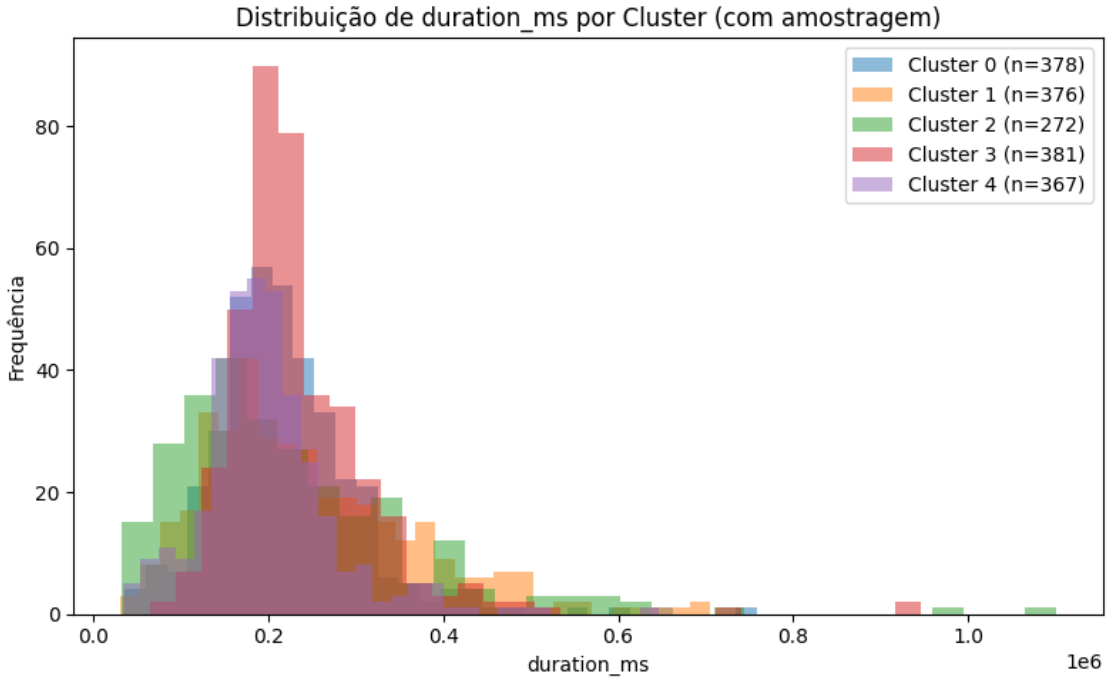

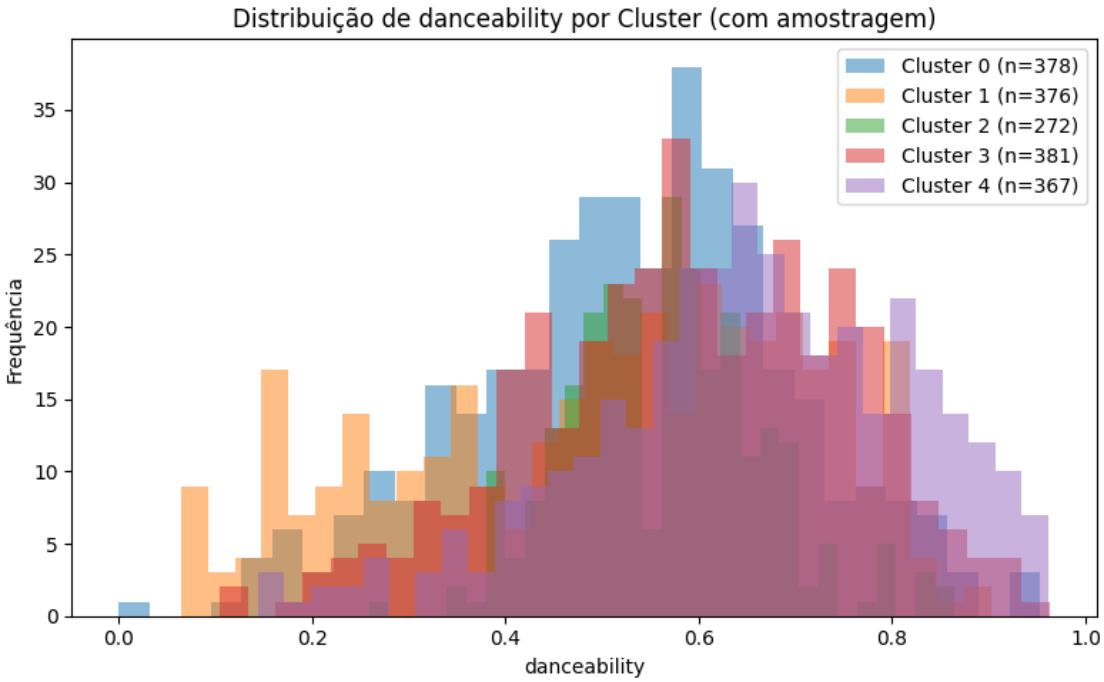
Distribuição de danceability por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
danceability
0
5
10
15
20
25
30
35
0.0
0.2
0.4
0.6
0.8
1.0

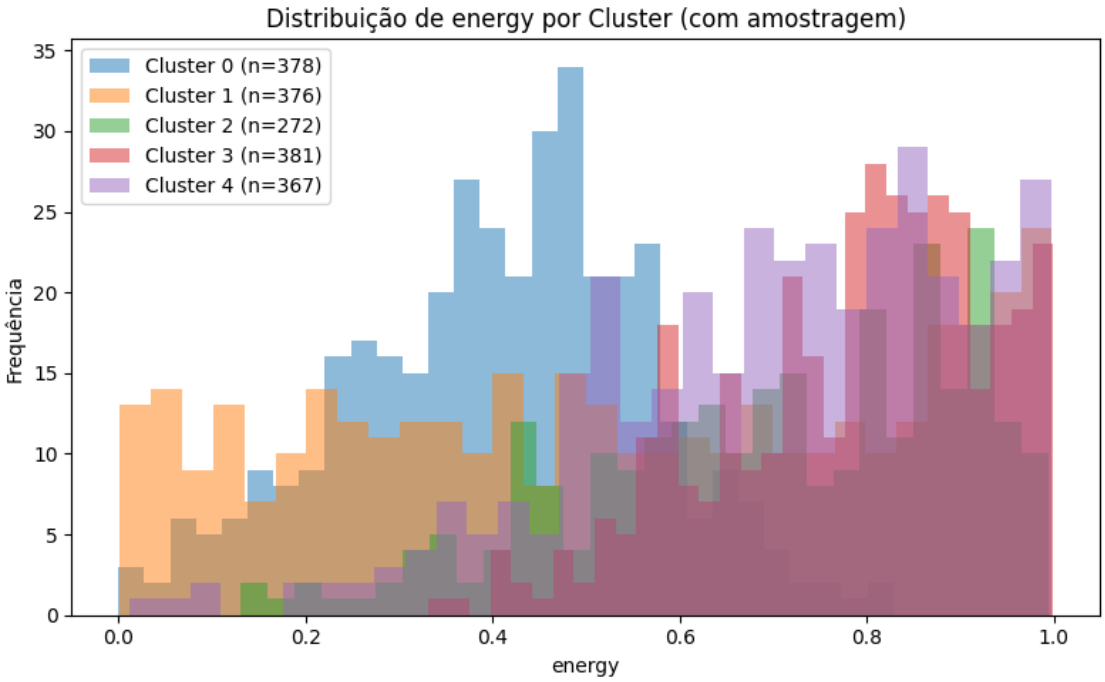
Distribuição de energy por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
energy
0
5
10
15
20
25
30
35
0.0
0.2
0.4
0.6
0.8
1.0

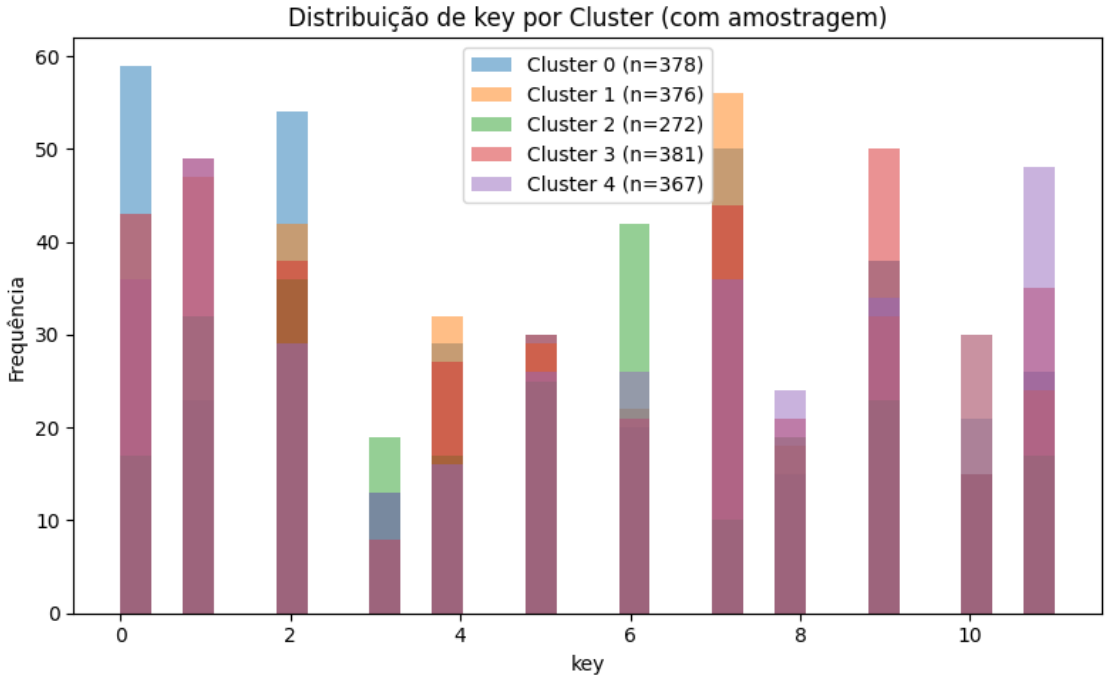
Distribuição de key por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
key
0
10
20
30
40
50
60
0
2
4
6
8
10

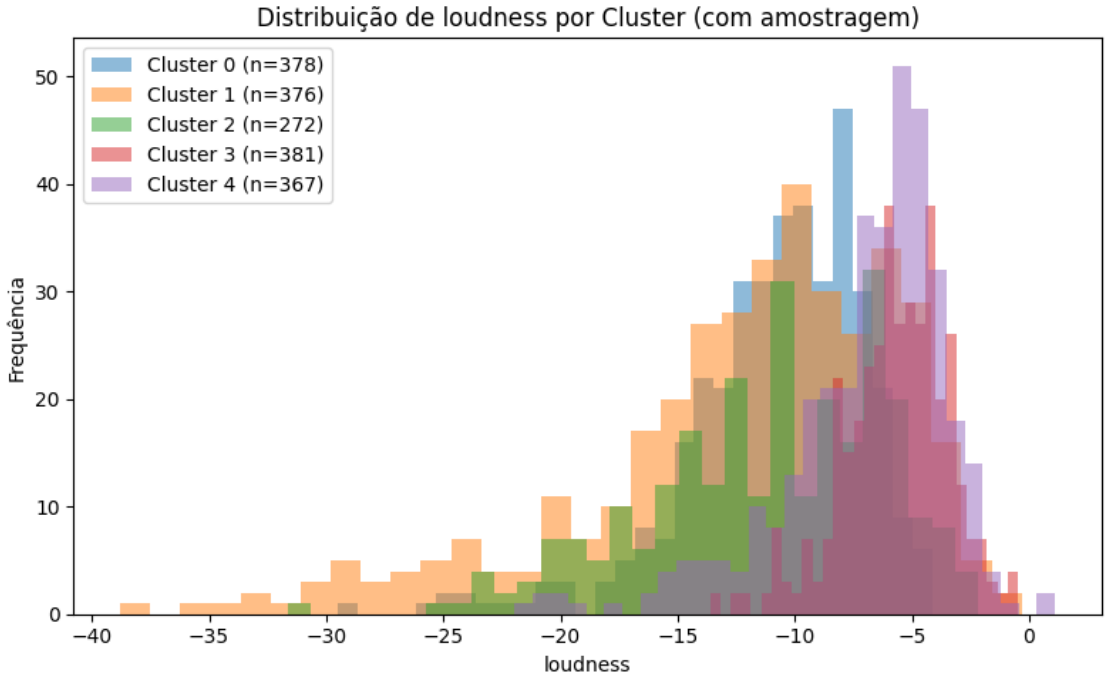
Distribuição de loudness por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
loudness
0
10
20
30
40
50
−40
−35
−30
−25
−20
−15
−10
−5
0

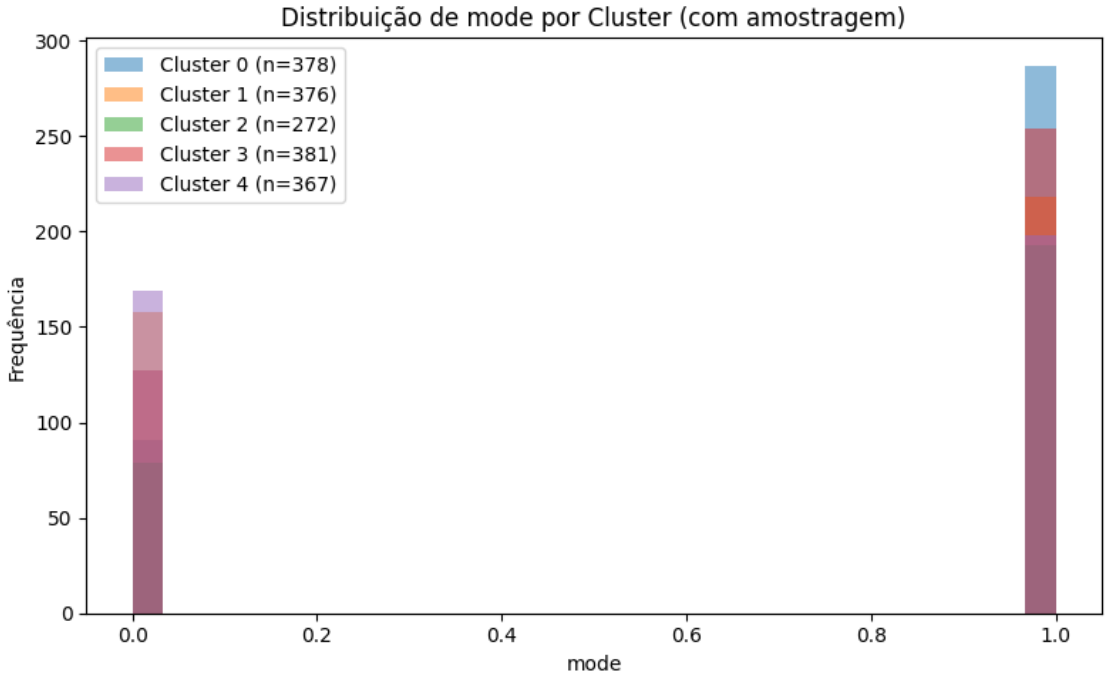
Distribuição de mode por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
mode
0
50
100
150
200
250
300
0.0
0.2
0.4
0.6
0.8
1.0

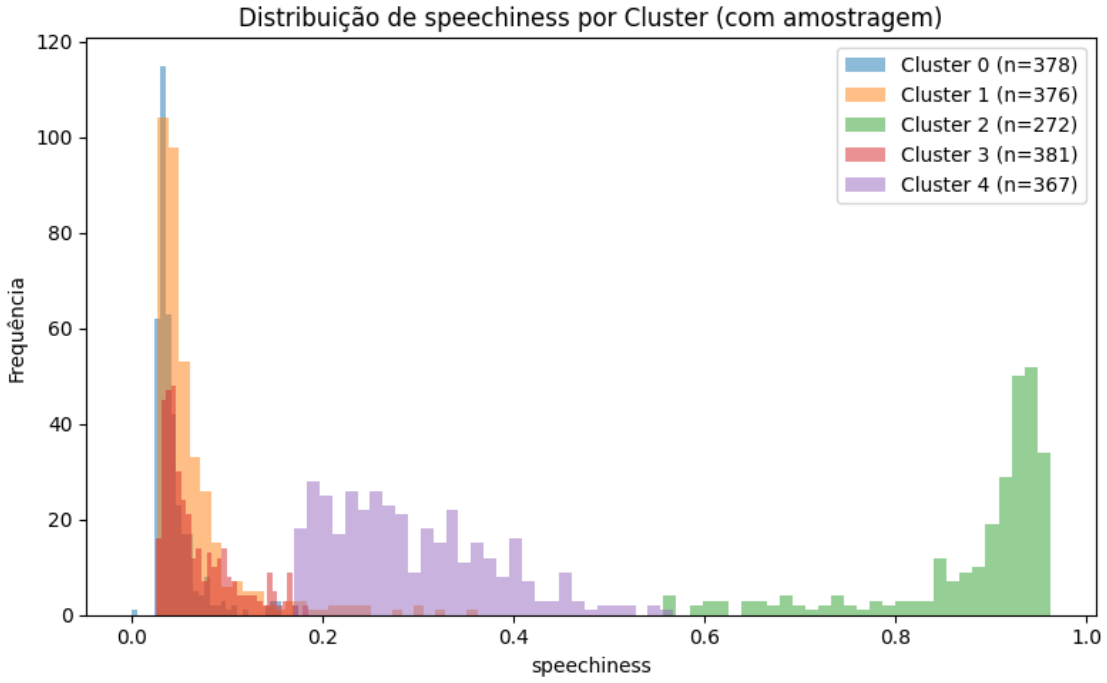
Distribuição de speechiness por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
speechiness
0
20
40
60
80
100
120
0.0
0.2
0.4
0.6
0.8
1.0

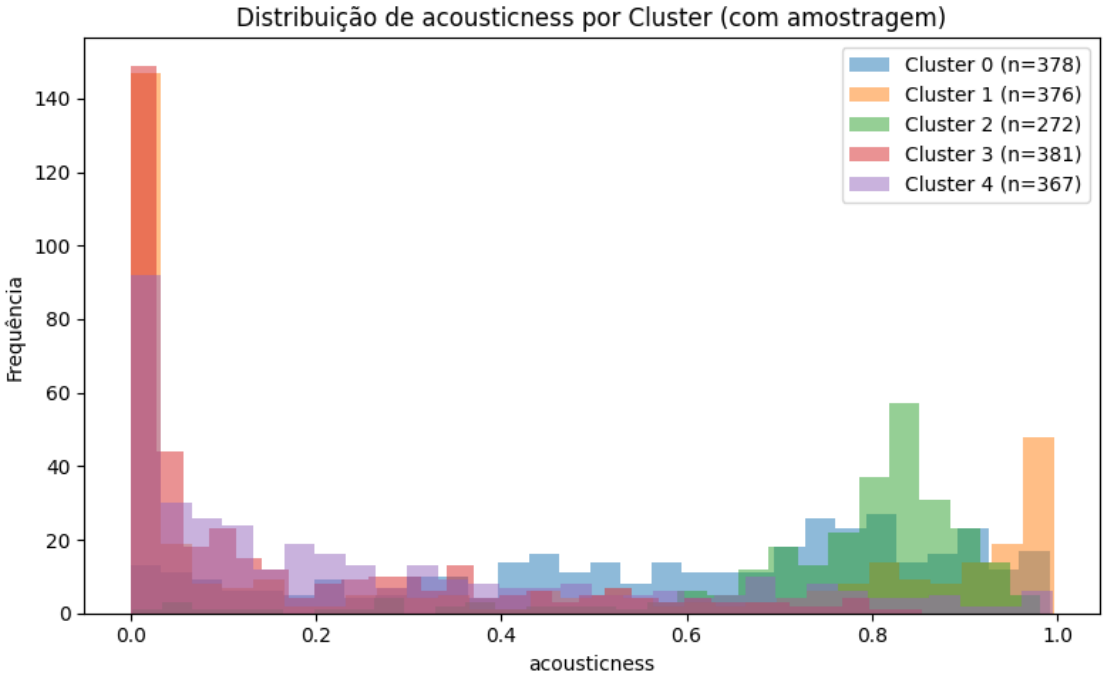
Distribuição de acousticness por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
acousticness
0
20
40
60
80
100
120
140
0.0
0.2
0.4
0.6
0.8
1.0

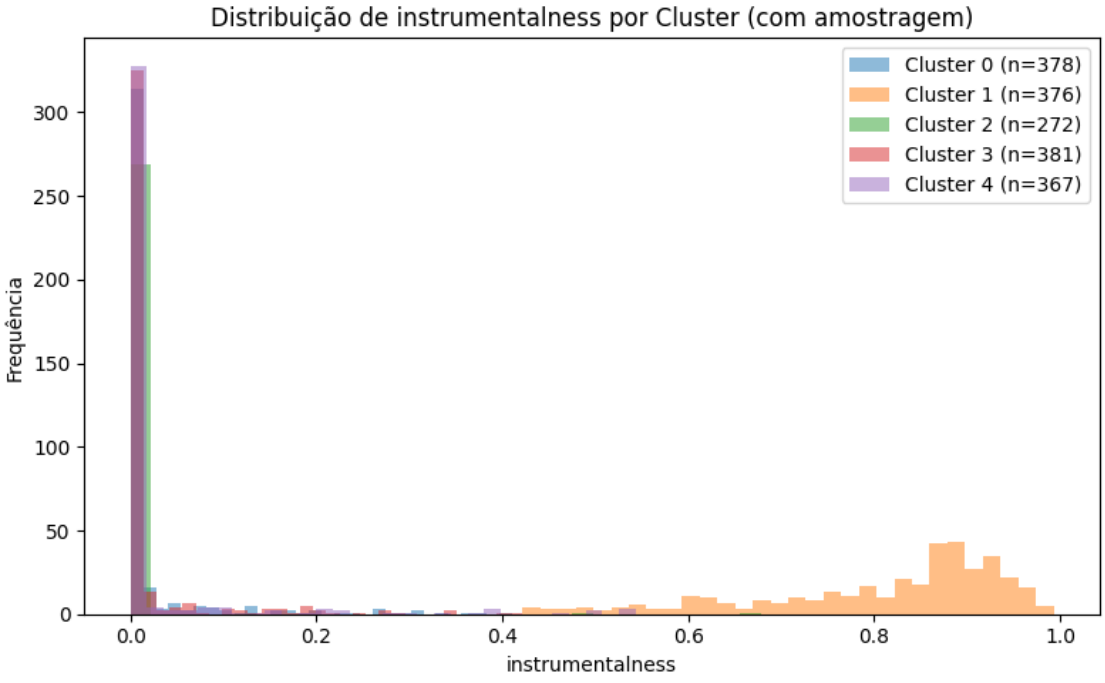
Distribuição de instrumentalness por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
instrumentalness
0
50
100
150
200
250
300
0.0
0.2
0.4
0.6
0.8
1.0

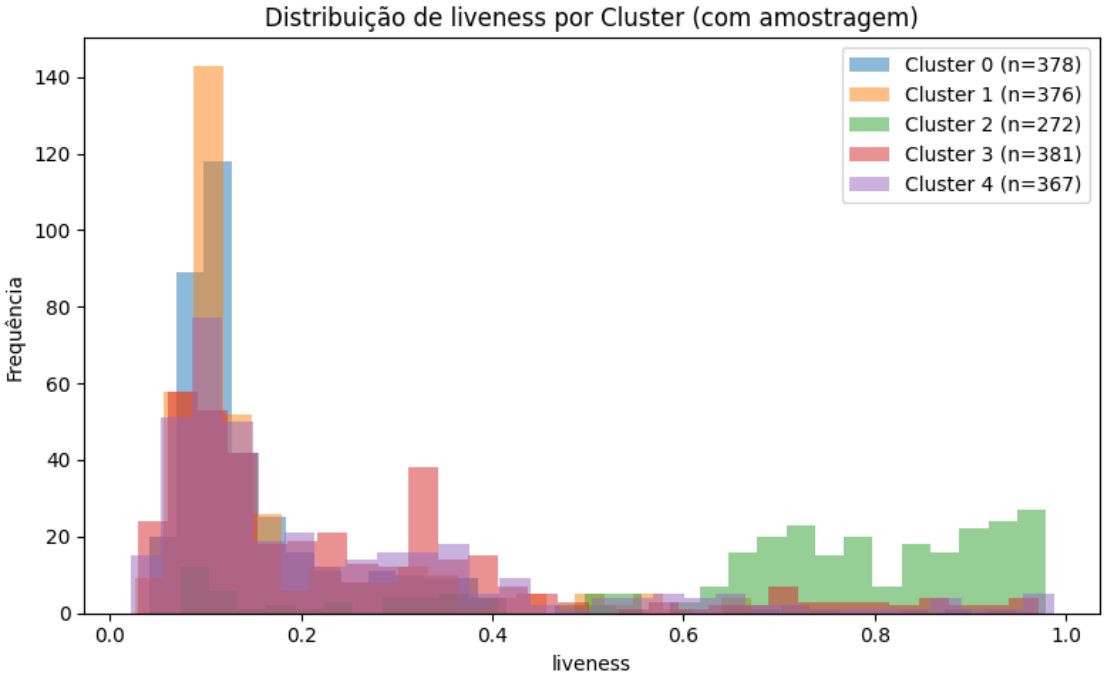
Distribuição de liveness por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
liveness
0
20
40
60
80
100
120
140
0.0
0.2
0.4
0.6
0.8
1.0

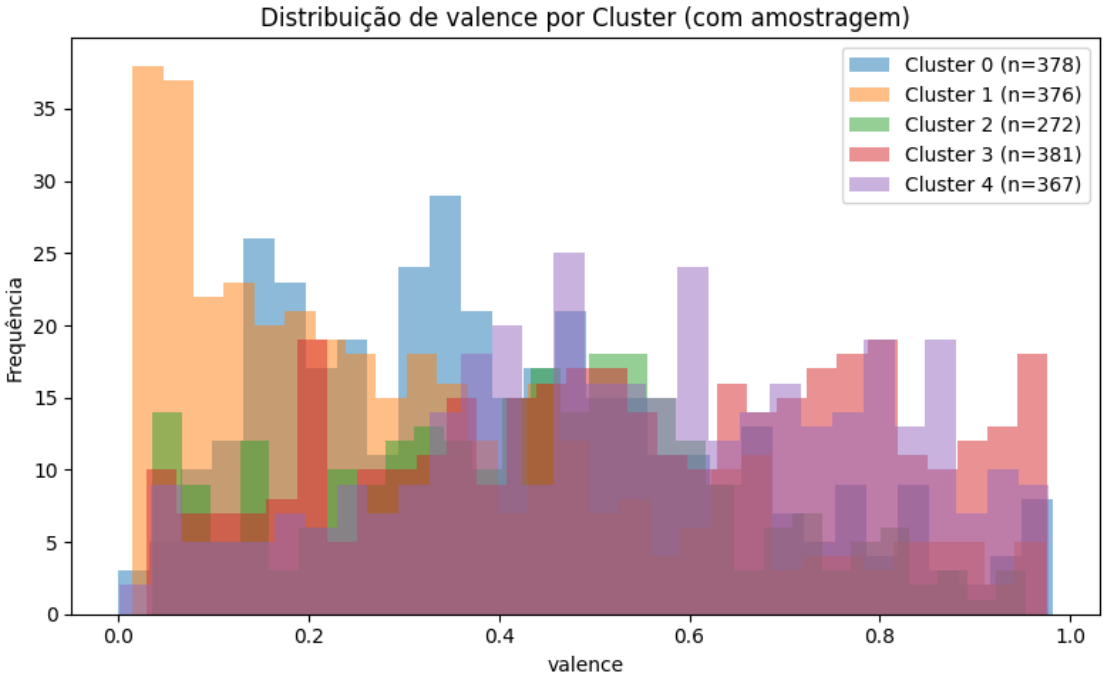
Distribuição de valence por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
valence
0
5
10
15
20
25
30
35
0.0
0.2
0.4
0.6
0.8
1.0

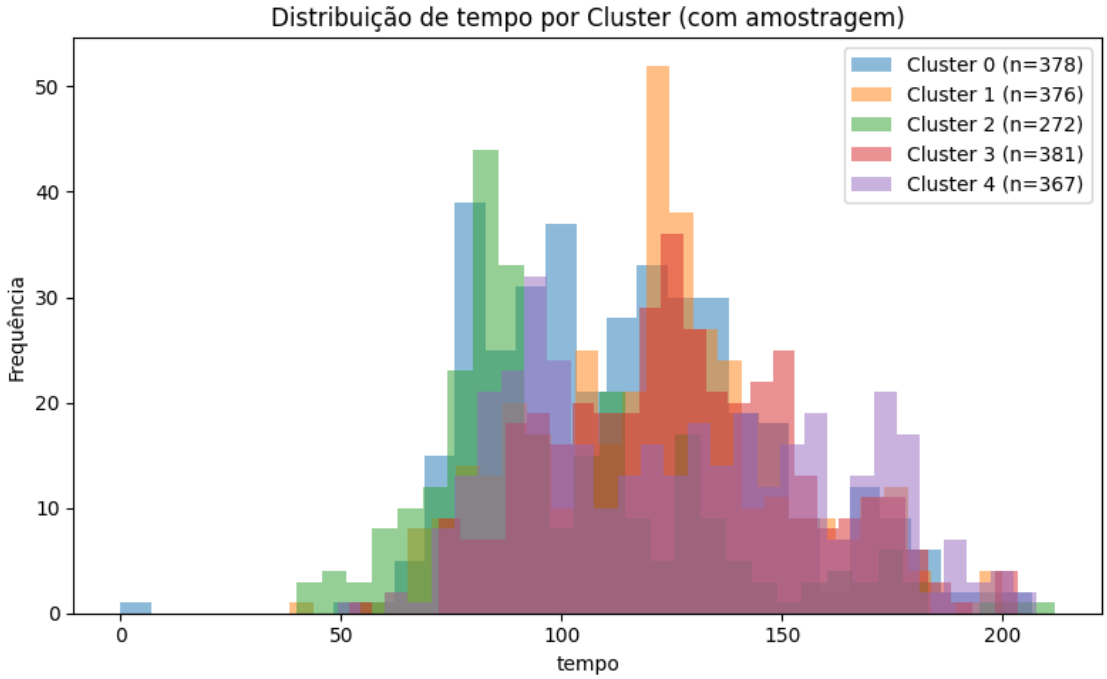
Distribuição de tempo por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
tempo
0
10
20
30
40
50
0
50
100
150
200

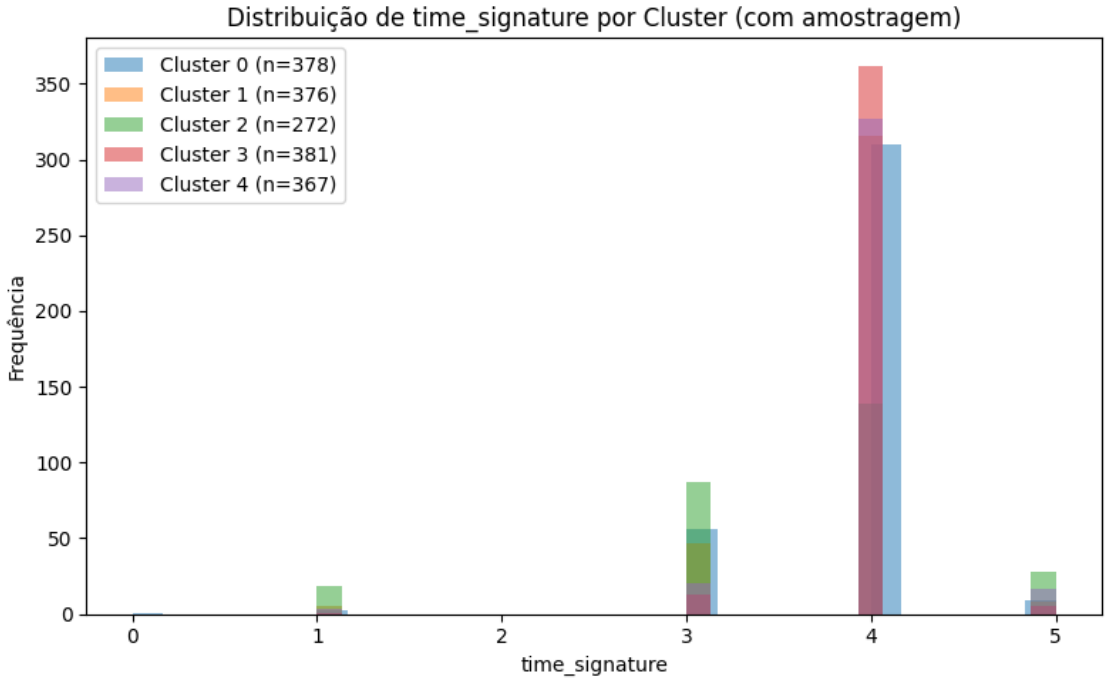
Distribuição de time_signature por Cluster (com amostragem)
Cluster 0 (n=378)
Cluster 1 (n=376)
Cluster 2 (n=272)
Cluster 3 (n=381)
Cluster 4 (n=367)
Frequência
time_signature
0
50
100
150
200
250
300
350
0
1
2
3
4
5

2.4 Musica

Agora que temos as musicas agrupadas por similaridade podemos recomendar 10 músicas mais parecidas dentro do grupo com base na distância

Vamos usar como exemplo a seguinte musica:

[100]:
```
df_musicas_rs[df_musicas['track_id'] ==␣
↪'2aibwv5hGXSgw7Yru8IYTO'][['artists','track_name','track_genre','cluster']]
```

[100]:

	artists	track_name	track_genre	cluster
2109	Red Hot Chili Peppers	Snow (Hey Oh)	alt-rock	3

[101]:
```
recomendar_musicas('2aibwv5hGXSgw7Yru8IYTO', df_dados_normalizados1,␣
↪df_musicas_rs)
```

```
Cluster: 3
```

[101]:

	track_name	artists	track_genre
2110	Monster	Skillet	alt-rock
44195	Fake It	Seether	grunge
11266	cotton candy	YUNGBLUD	british
83624	Runaway - Radio Edit	Pierce Fulton	progressive-house
53762	Under Control (feat. Hurts)	Calvin Harris;Alesso;Hurts	house
80561	Ek Toh Kum Zindagani (From "Marjaavaan")	Neha Kakkar;Yash Narvekar;Tanishk Bagchi	pop-film
8256	Ex's & Oh's	Elle King	blues
30764	What Would You Do?	Joel Corry;David Guetta;Bryson Tiller	edm
30562	Head & Heart (feat. MNEK)	Joel Corry;MNEK	edm
56383	SUPERMODEL	Måneskin	indie-pop

E agora vamos repetir o mesmo processo para os outros modelos de normalização, e continuaremos utilizando a música *Red Hot Chili Peppers - Snow (Hey Oh)* como exemplo

3 Min Max Scale

[102]:
```
from sklearn.preprocessing import minmax_scale
escala2 = minmax_scale(df_dados)
df_dados_normalizados2 =  pd.DataFrame(escala2, columns=df_dados.columns[:])
df_dados_normalizados2
```

[102]:

	popularity	duration_ms	danceability	energy	key	loudness	\
0	0.73	0.042473	0.686294	0.4610	0.090909	0.791392	
1	0.55	0.026971	0.426396	0.1660	0.090909	0.597377	
2	0.57	0.038679	0.444670	0.3590	0.000000	0.736123	
3	0.71	0.036978	0.270051	0.0596	0.000000	0.573701	
4	0.82	0.036389	0.627411	0.4430	0.181818	0.737103	
…	…	…	…	…	…	…	
89735	0.21	0.071990	0.174619	0.2350	0.454545	0.612952	
89736	0.22	0.071990	0.176650	0.1170	0.000000	0.577345	
89737	0.22	0.050276	0.638579	0.3290	0.000000	0.714648	
89738	0.41	0.052653	0.595939	0.5060	0.636364	0.714759	
89739	0.22	0.044608	0.534010	0.4870	0.090909	0.727429	

	mode	speechiness	acousticness	instrumentalness	liveness	valence	\
0	0.0	0.148187	0.032329	0.000001	0.3580	0.718593	
1	1.0	0.079067	0.927711	0.000006	0.1010	0.268342	
2	1.0	0.057720	0.210843	0.000000	0.1170	0.120603	
3	1.0	0.037617	0.908635	0.000071	0.1320	0.143719	
4	1.0	0.054508	0.470884	0.000000	0.0829	0.167839	
…	…	…	…	…	…	…	
89735	1.0	0.043731	0.642570	0.928000	0.0863	0.034070	
89736	0.0	0.041554	0.997992	0.976000	0.1050	0.035176	
89737	0.0	0.043523	0.870482	0.000000	0.0839	0.746734	
89738	1.0	0.030777	0.382530	0.000000	0.2700	0.415075	
89739	0.0	0.075130	0.683735	0.000000	0.0893	0.711558	

	tempo	time_signature	cluster
0	0.361245	0.8	0.75
1	0.318397	0.8	0.00
2	0.313643	0.8	0.00
3	0.746758	0.6	0.00
4	0.492863	0.8	0.00
…	…	…	…
89735	0.517705	1.0	0.25
89736	0.350242	0.8	0.25
89737	0.543933	0.8	0.00
89738	0.558651	0.8	0.00
89739	0.325420	0.8	0.00

[89740 rows x 15 columns]

Aplicando o método do cotevelo

[103]:
```
soma_e2 = calcular_soma_erros(escala2)
```

[104]:
```
plt.plot(range(1, 20), soma_e2, marker='o')
plt.xlabel('Número de Clusters (k)')
plt.ylabel('Soma dos Erros Quadrados (SEQ)')
plt.title('Método do Cotovelo')
plt.show()
```

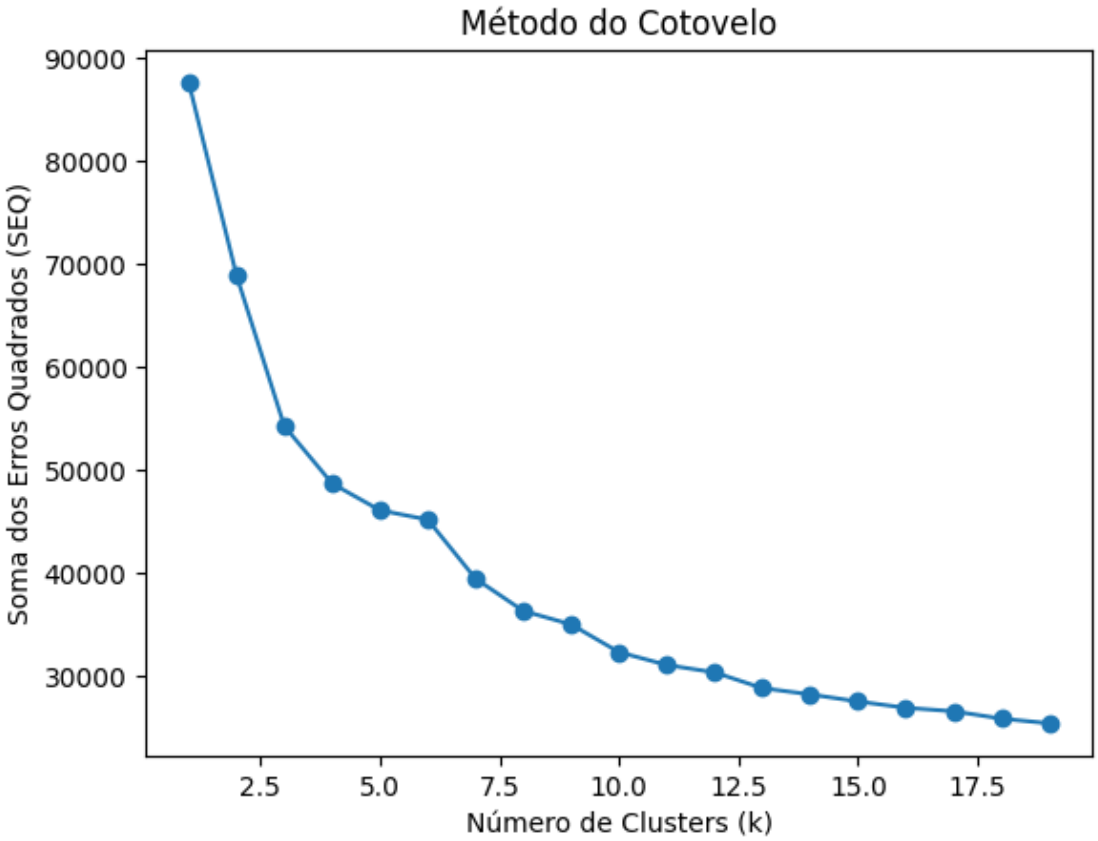

Melhor número de clusters

[105]:
```
nc2 = optimal_number_of_clusters(soma_e2)
nc2
```

[105]: 5

[106]:
```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=nc2, random_state=14)
clusters = kmeans.fit_predict(escala2)
```

```
df_musicas_minmax = df_musicas.copy()
df_musicas_minmax['cluster'] = clusters
df_dados['cluster'] = clusters
df_dados_normalizados2['cluster'] = clusters
```

3.1 Plotagem 2D e 3D dos clusters

[107]:
```
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches

pca = PCA(n_components=2)
X_pca = pca.fit_transform(escala2)

# Plot
scatter = plt.scatter(X_pca[:, 0], X_pca[:, 1],␣
 ↪c=df_dados_normalizados2['cluster'], cmap='viridis')

# Legenda manual
clusters = df_dados_normalizados2['cluster'].unique()
colors = scatter.cmap(scatter.norm(clusters))

handles = [mpatches.Patch(color=colors[i], label=f'Cluster {clusters[i]}') for␣
 ↪i in range(len(clusters))]

plt.legend(handles=handles, title='Clusters', bbox_to_anchor=(1.05, 1),␣
 ↪loc='upper left')
plt.xlabel('PCA 1')
plt.ylabel('PCA 2')
plt.title('Clusters de músicas')

plt.tight_layout()
plt.show()
```

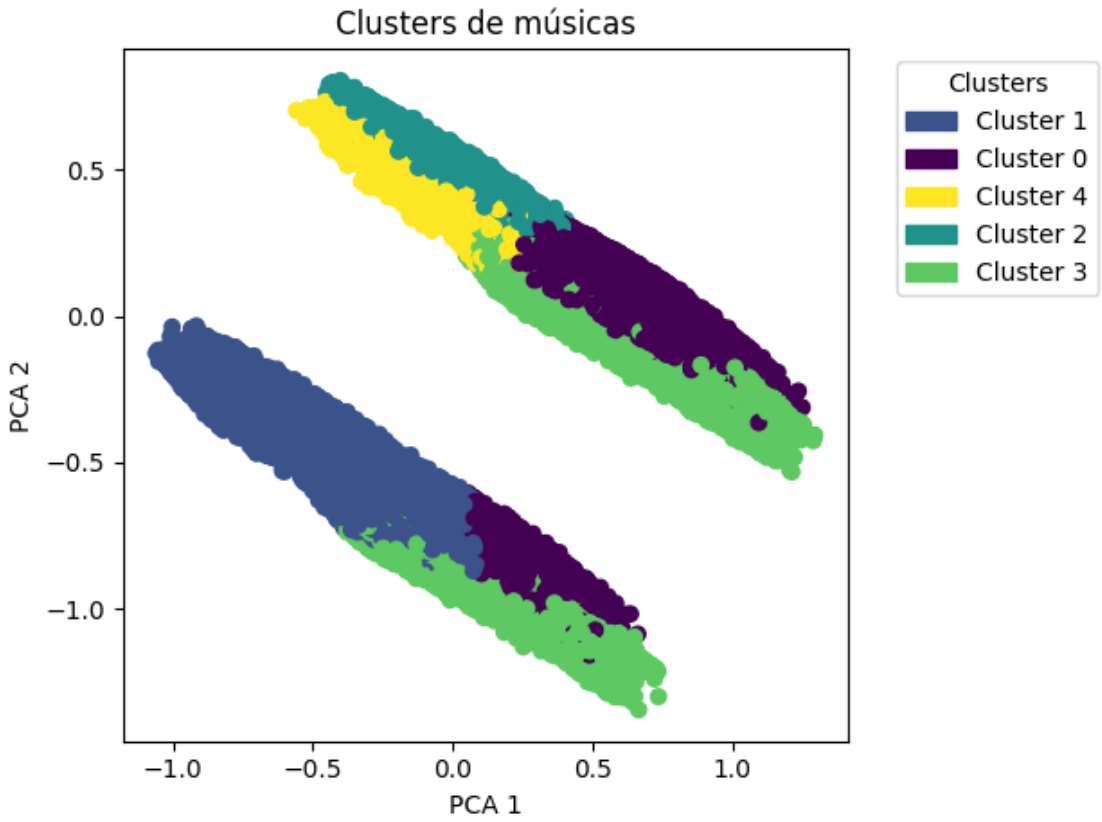

[108]:
```
from mpl_toolkits.mplot3d import Axes3D

pca = PCA(n_components=3)
X_pca_3d = pca.fit_transform(escala2)

fig = plt.figure(figsize=(10,8))
ax = fig.add_subplot(111, projection='3d')
scatter = ax.scatter(X_pca_3d[:, 0], X_pca_3d[:, 1], X_pca_3d[:, 2],
                     c=df_dados_normalizados2['cluster'], cmap='viridis')
ax.set_xlabel('PCA 1')
ax.set_ylabel('PCA 2')
ax.set_zlabel('PCA 3')
plt.title('Clusters em 3D com PCA')
plt.show()
```

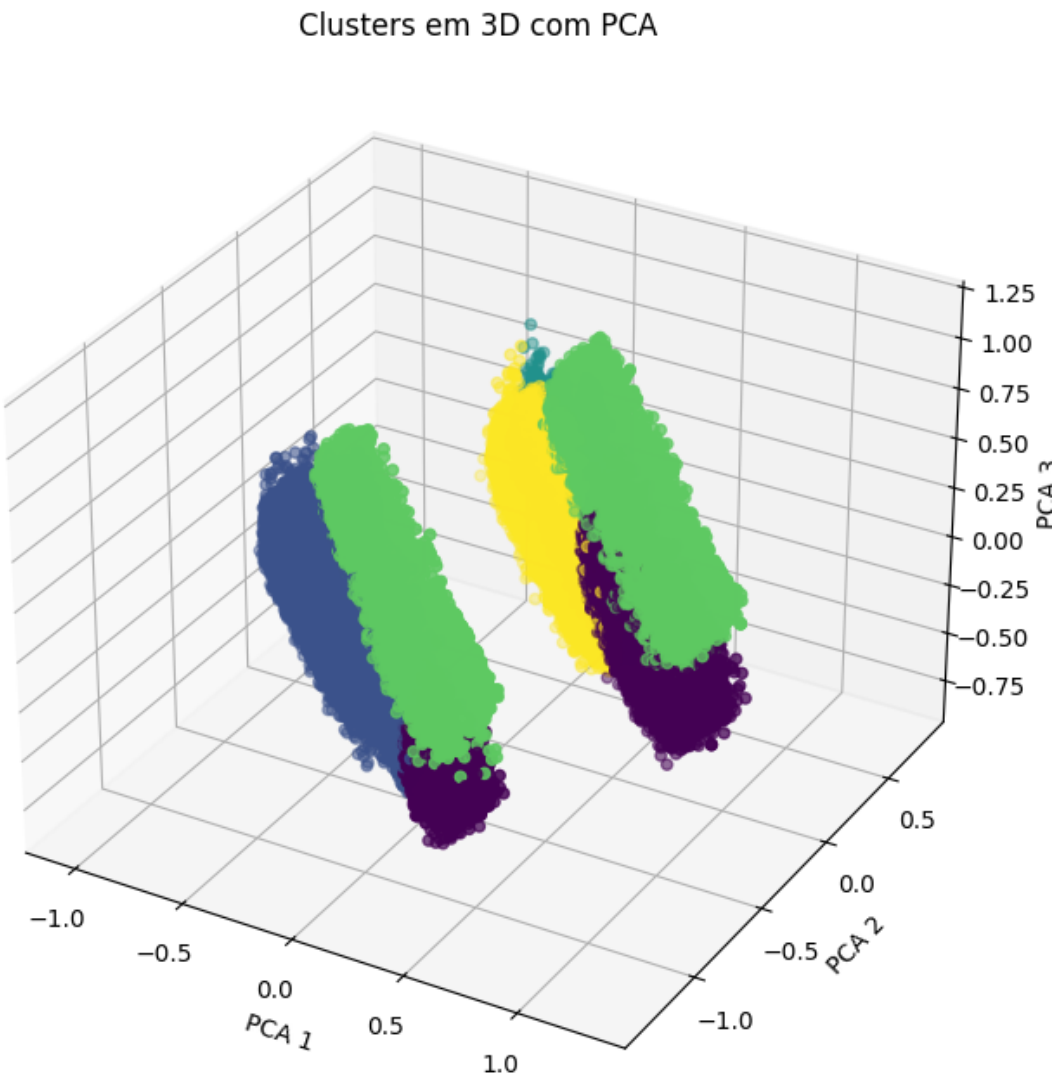

3.2 Analisando o agrupamento

Quantas músicas tem em cada cluster

[109]:
```
df_dados_normalizados2['cluster'].value_counts()
```

[109]:
```
cluster
1    24439
0    19594
4    17207
3    14531
2    13969
Name: count, dtype: int64
```

3.2.1 Dados Originais

[110]:
```
df_dados_media = df_dados.groupby('cluster').mean(numeric_only=True) #Para␣
↪histogramas
df_dados_media
```

[110]:

cluster	popularity	duration_ms	danceability	energy	key
0	32.383893	217019.983617	0.525607	0.380379	4.886904
1	35.350996	232453.544376	0.608186	0.741494	6.141331
2	34.556303	224643.552724	0.587936	0.774527	1.430310
3	28.161448	252224.914321	0.477336	0.498026	5.004886
4	34.221945	222413.414250	0.589153	0.773267	7.880281

cluster	loudness	mode	speechiness	acousticness	instrumentalness
0	-11.055943	0.845106	0.048566	0.646504	0.022783
1	-6.552397	0.000000	0.105628	0.184148	0.080628
2	-5.977167	1.000000	0.110073	0.182374	0.032919
3	-13.827622	0.648751	0.064213	0.444474	0.841625
4	-5.899418	1.000000	0.107127	0.190973	0.026497

cluster	liveness	valence	tempo	time_signature
0	0.162928	0.412569	113.253678	3.801572
1	0.225470	0.520812	124.491413	3.955031
2	0.266191	0.554182	127.931355	3.954972
3	0.179173	0.263937	116.950708	3.806896
4	0.258402	0.566165	128.173123	3.954495

3.2.2 Dados Normalizados

[111]:
```
df_dados_normalizados2_media = df_dados_normalizados2.groupby('cluster').mean()␣
↪# Para gráfico de médias
df_dados_normalizados2_media
```

[111]:

cluster	popularity	duration_ms	danceability	energy	key	loudness
0	0.323839	0.039863	0.533612	0.380379	0.444264	0.711671
1	0.353510	0.042815	0.617447	0.741494	0.558303	0.794973
2	0.345563	0.041321	0.596890	0.774527	0.130028	0.805613
3	0.281614	0.046596	0.484605	0.498026	0.454990	0.660403
4	0.342219	0.040895	0.598125	0.773267	0.716389	0.807051

cluster	mode	speechiness	acousticness	instrumentalness	liveness
0	0.845106	0.050328	0.649100	0.022783	0.162928
1	0.000000	0.109459	0.184887	0.080628	0.225470

```
2        1.000000     0.114065      0.183106          0.032919  0.266191
3        0.648751     0.066542      0.446259          0.841625  0.179173
4        1.000000     0.111013      0.191740          0.026497  0.258402

          valence     tempo  time_signature
cluster
0        0.414642  0.465352        0.760314
1        0.523430  0.511527        0.791006
2        0.556967  0.525662        0.790994
3        0.265263  0.480543        0.761379
4        0.569010  0.526655        0.790899
```

3.2.3 Gênero de músicas por cluster

[112]:
```
genero_por_cluster = df_musicas_minmax.groupby('cluster').apply(
    lambda x: x['track_genre'].value_counts().head(6),
    include_groups=False
)
genero_por_cluster
```

[112]:
```
cluster  track_genre
0        honky-tonk        836
         romance           737
         cantopop          707
         acoustic          658
         tango             647
         opera             647
1        turkish           494
         dancehall         471
         hardstyle         467
         deep-house        445
         dance             440
         afrobeat          423
2        j-idol            285
         power-pop         279
         comedy            275
         kids              272
         forro             261
         sertanejo         249
3        study             867
         sleep             801
         new-age           776
         ambient           749
         idm               695
         minimal-techno    662
4        j-idol            382
         party             363
```

```
forro              362
sertanejo          326
country            304
alt-rock           303
Name: count, dtype: int64
```

3.3 Gráficos

3.3.1 Características x Cluster

[113]:
```
df_dados_normalizados2_media.plot(kind='bar')
plt.title('Caracteristicas por cluster')
plt.legend(bbox_to_anchor=(1.0, 1.0))
plt.show()
```

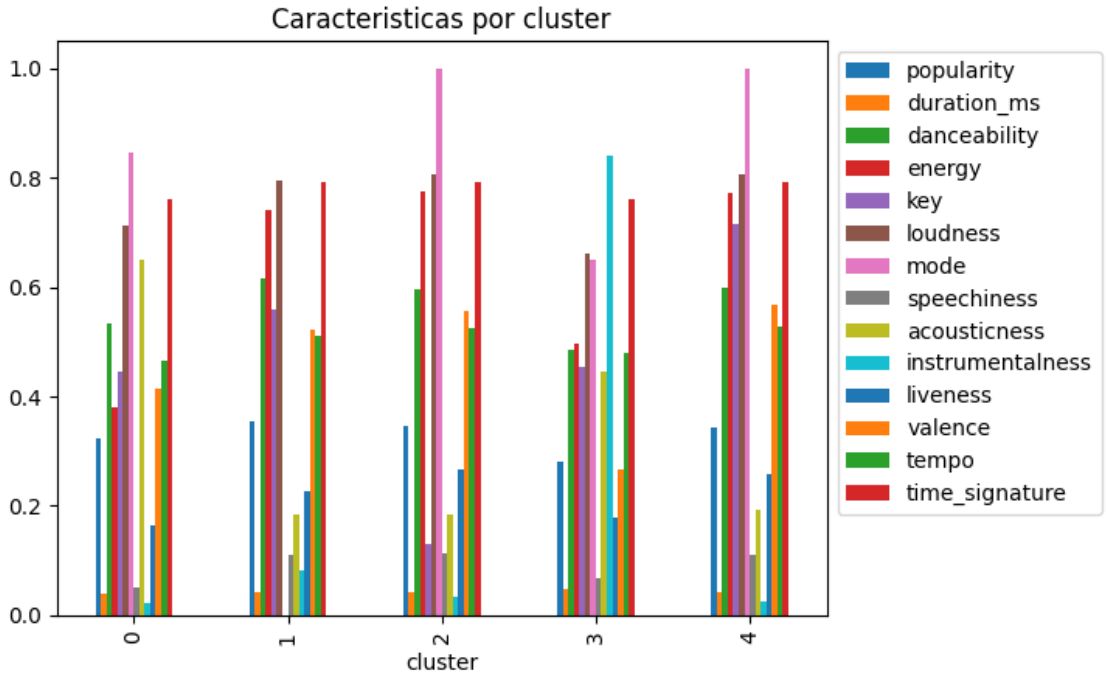

Olhando os gráficos acima, podemos perceber que os cluster 0,1,3,4 possuem 'mode' = 1, e os clusters 2,5,6 tendo mode = 0.

Os clusters 2 e 4 possuem 'instrumentalness' alto, indicando serem músicas clássica, ambiente, etc

Os clusters 0 e 5 possuem 'acoustiness' alto e 'energy' baixo, indicando ter faixas predominantemente acusticas.

Os cluster 1, 3, 6 possuem 'valence' alto, indicando músicas animadas e de sentimento positivo

3.3.2 Cluster x Características

[114]:
```
df_dados_normalizados2_media.T.plot(kind='bar')
plt.title('Clusters por característica')
plt.legend(title='Cluster', bbox_to_anchor=(1.0, 1.0))
plt.tight_layout()
plt.show()
```

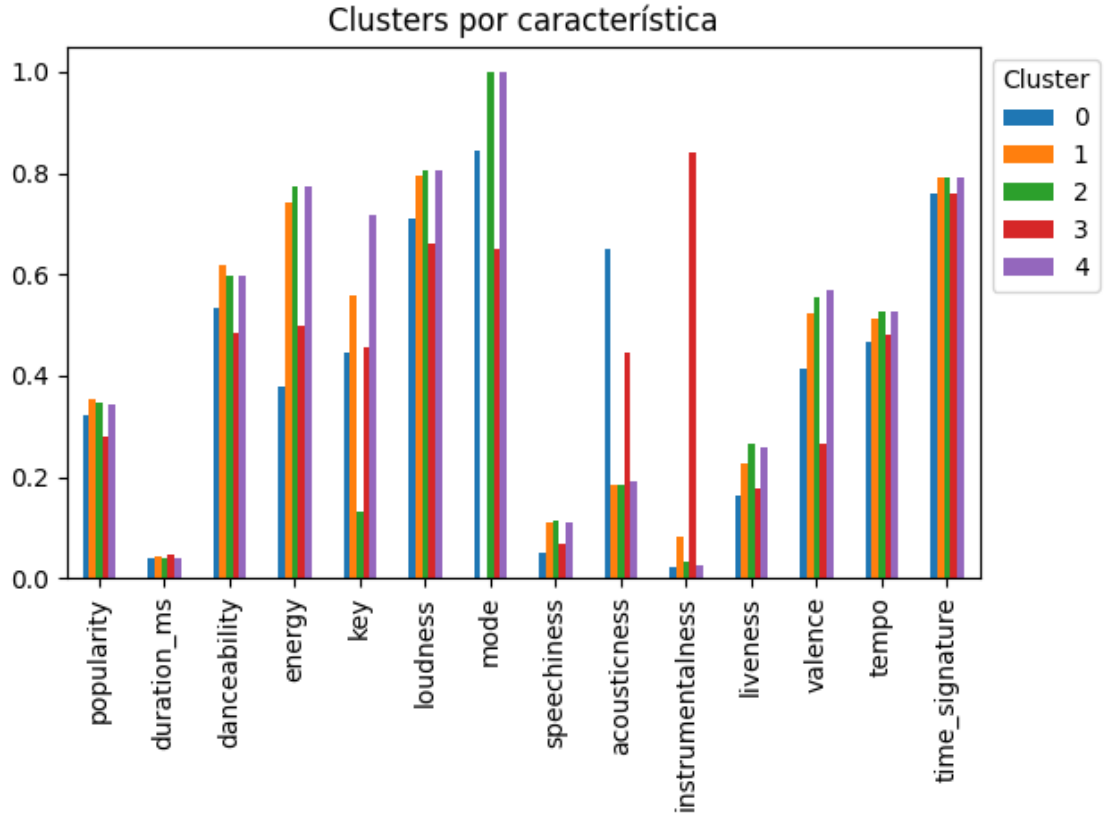

Analisando o gráfico acima

Os clusters 2,4 possuem menos populares e com maior duração

Os clusters 0,5 possuem músicas menos dançantes

Os clusters 0,5 possuem musicas mais calmas, menos barulhentas, mais músicas acústicas, e com menor bpm

Os clusters 1,3,6 possuem músicas que tem mais fala

Os cluster 2,4 possuem mais músicas intrumentais e ambiente

Os clusters 1,3,6 e possuem mais músicas ao vivo e mais felizes

3.3.3 Histogramas

[115]:
```
import matplotlib.pyplot as plt

for feature in df_dados.columns.drop('cluster'):
    plt.figure(figsize=(8, 5))

    for cluster_id in sorted(df_dados['cluster'].unique()):
        subset = df_dados[df_dados['cluster'] == cluster_id]
        tamanho = tamanho_amostra(len(subset))
        amostra = subset.sample(n=min(tamanho, len(subset)), random_state=42)
 ↪# Garante que não passa o tamanho real
        plt.hist(amostra[feature], bins=30, alpha=0.5, label=f'Cluster
 ↪{cluster_id} (n={len(amostra)})')

    plt.title(f'Distribuição de {feature} por Cluster (com amostragem)')
    plt.xlabel(feature)
    plt.ylabel('Frequência')
    plt.legend()
    plt.tight_layout()
    plt.show()
```

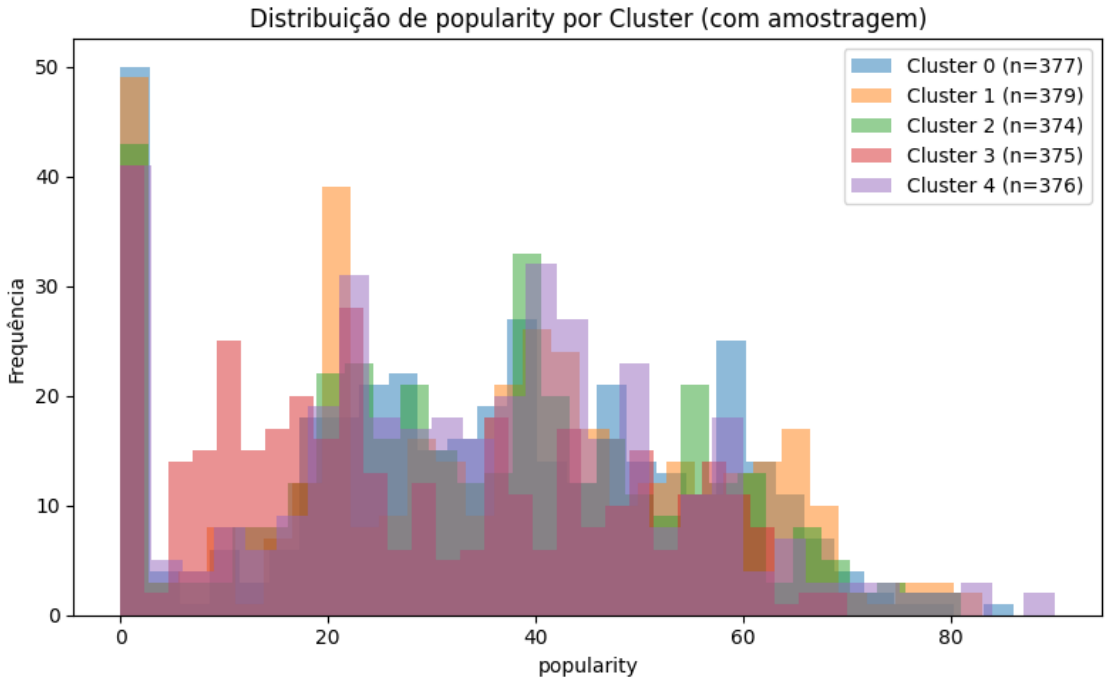

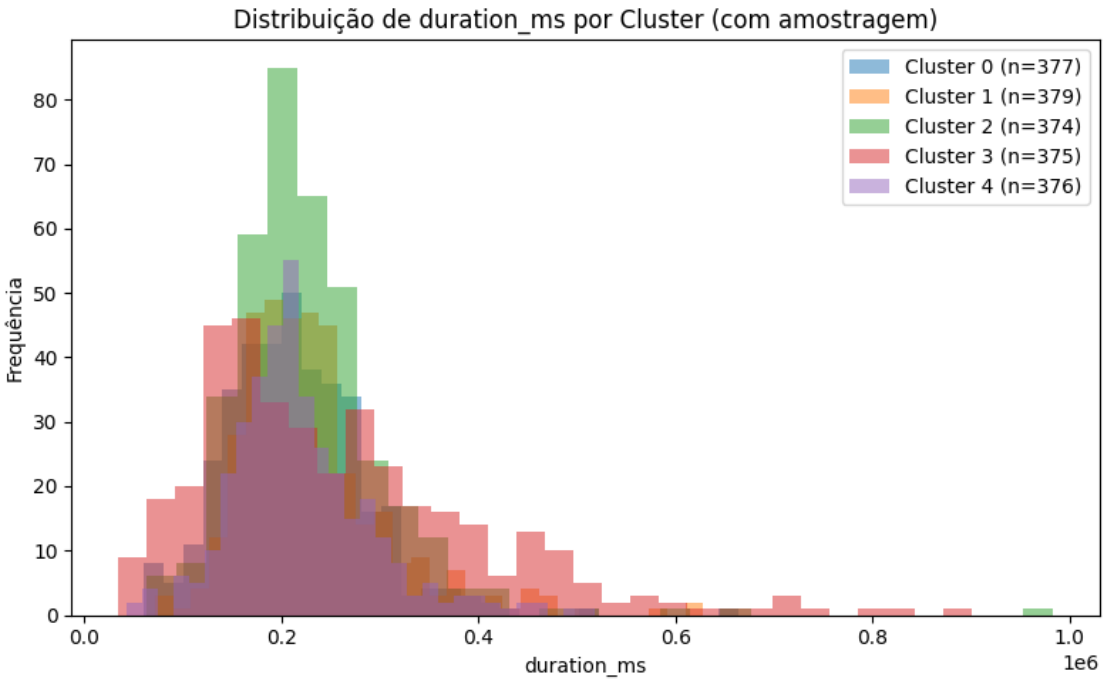
Distribuição de duration_ms por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
duration_ms
1e6

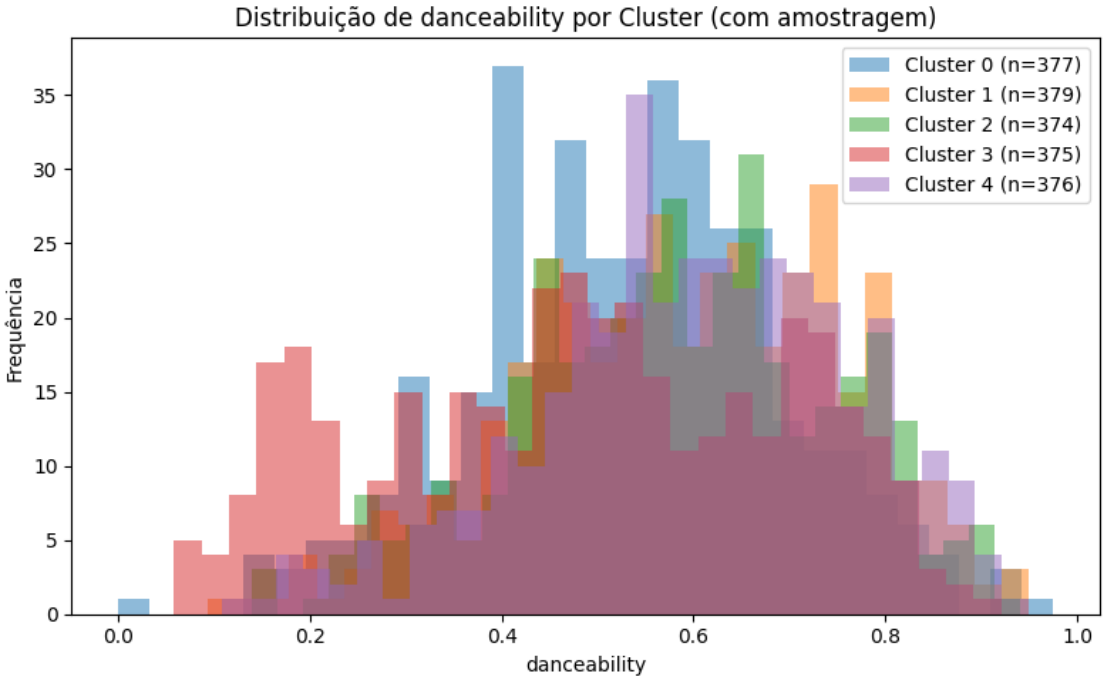
Distribuição de danceability por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
danceability

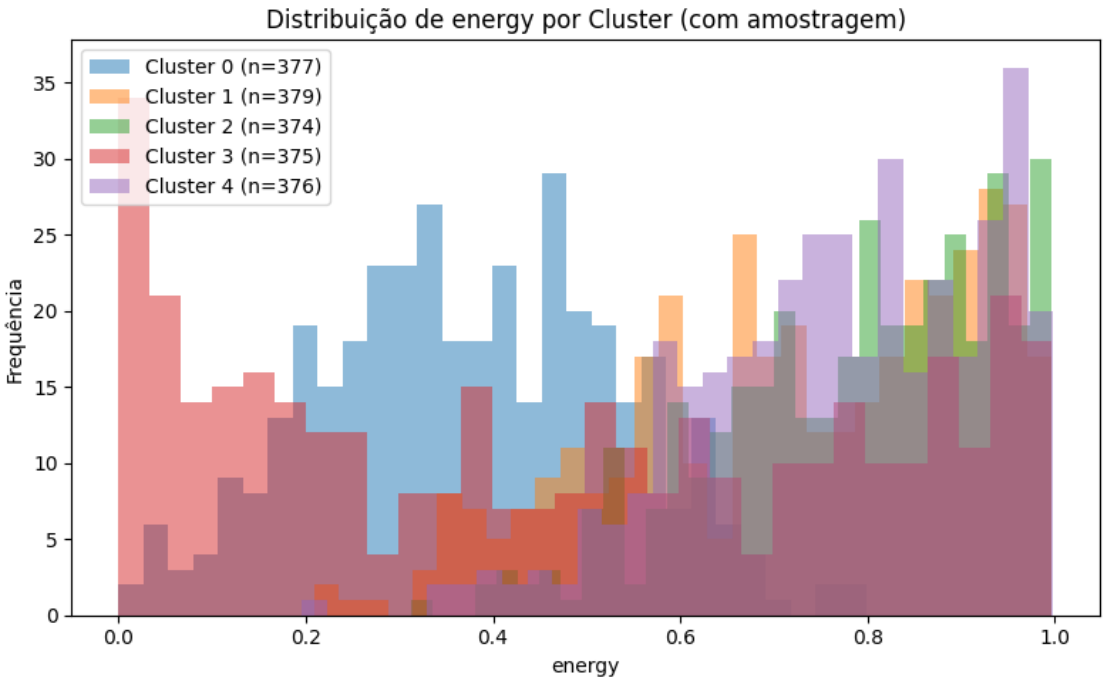
Distribuição de energy por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
energy
0
5
10
15
20
25
30
35
0.0
0.2
0.4
0.6
0.8
1.0

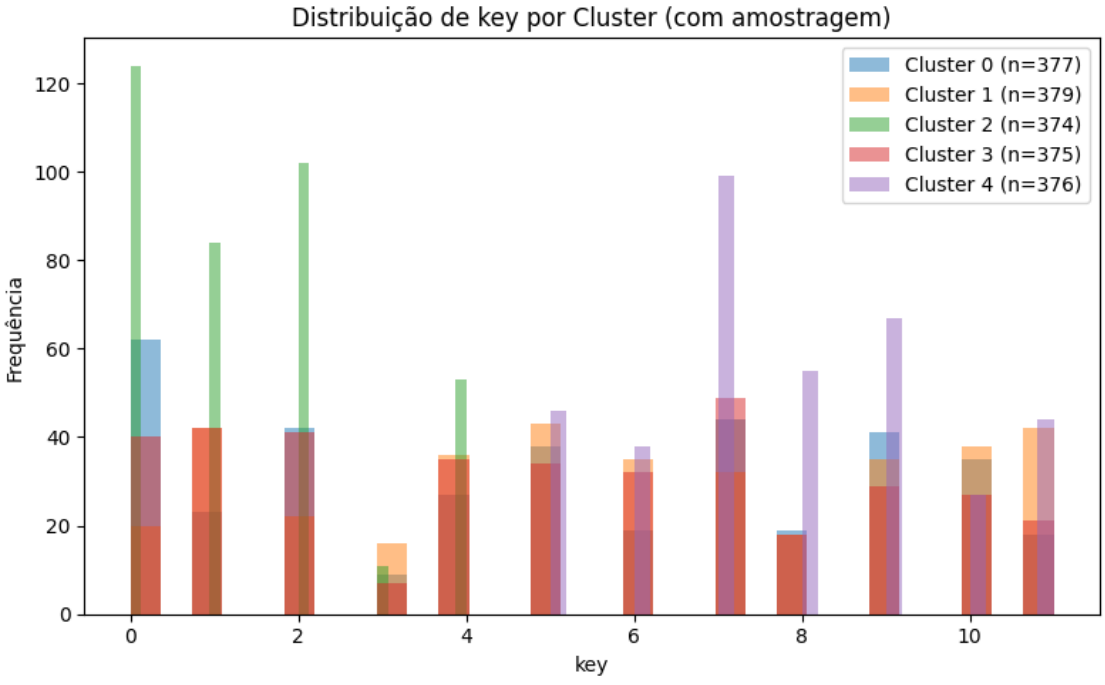
Distribuição de key por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
key
0
20
40
60
80
100
120
0
2
4
6
8
10

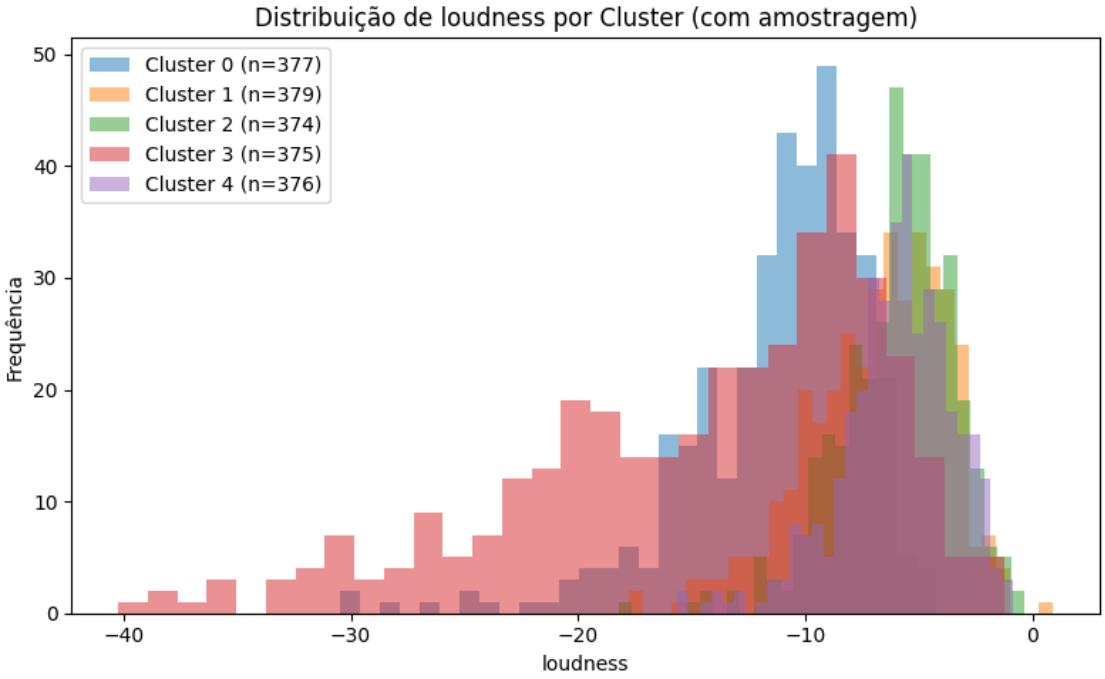
Distribuição de loudness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
loudness
50
40
30
20
10
0
−40
−30
−20
−10
0

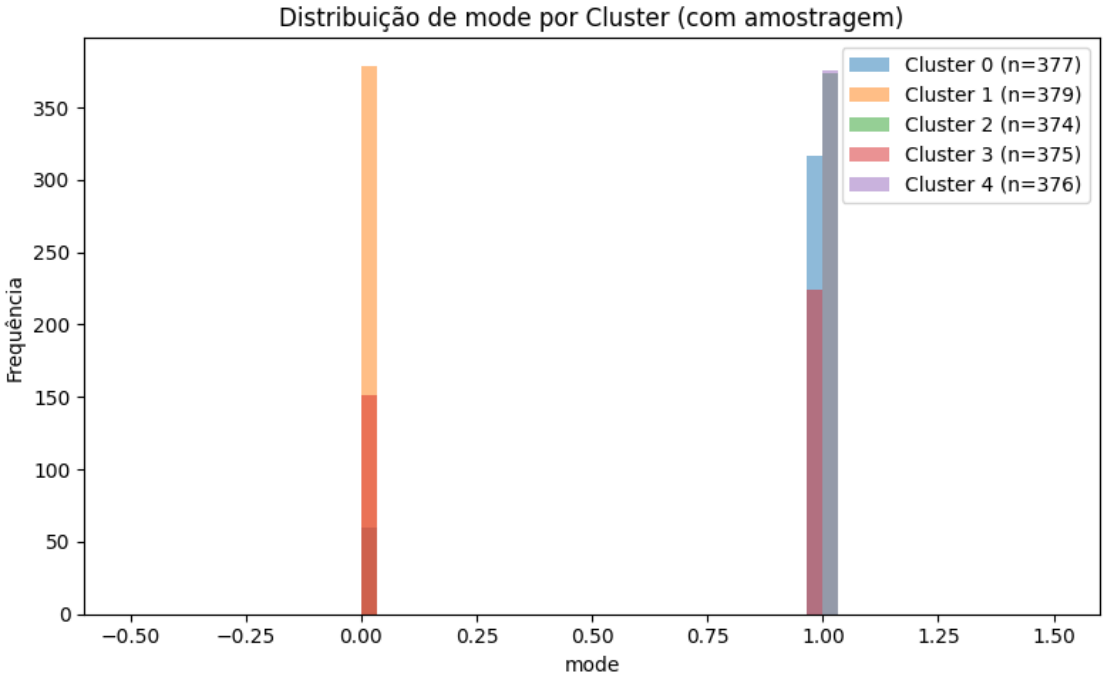
Distribuição de mode por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
mode
350
300
250
200
150
100
50
0
−0.50
−0.25
0.00
0.25
0.50
0.75
1.00
1.25
1.50

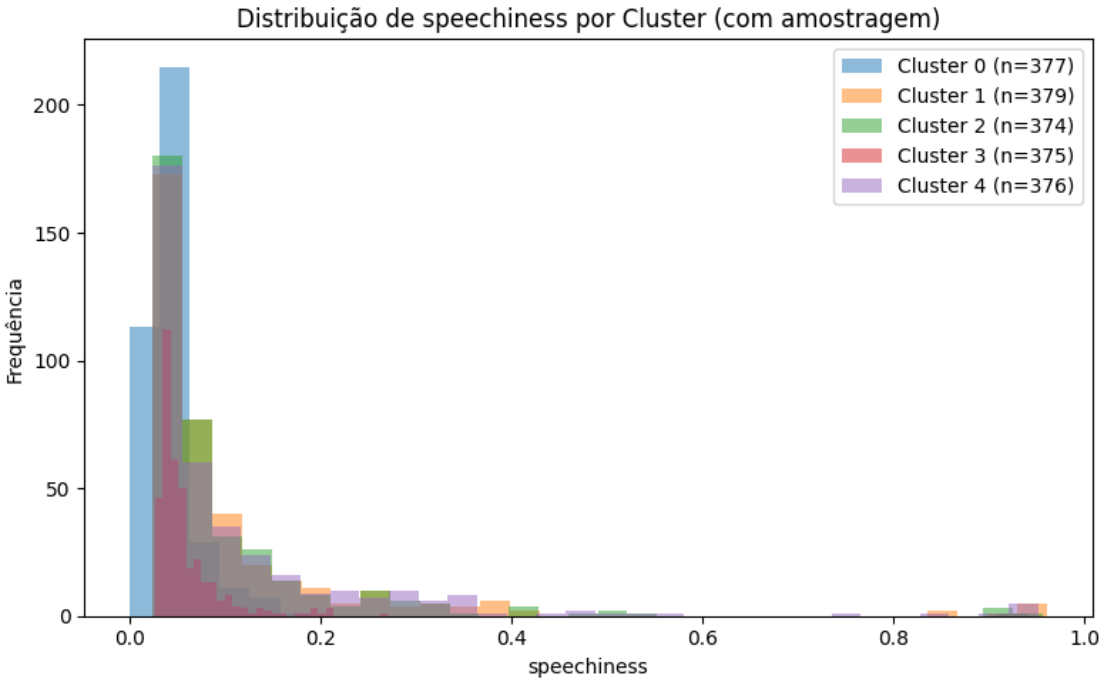
Distribuição de speechiness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
speechiness
0
50
100
150
200
0.0
0.2
0.4
0.6
0.8
1.0

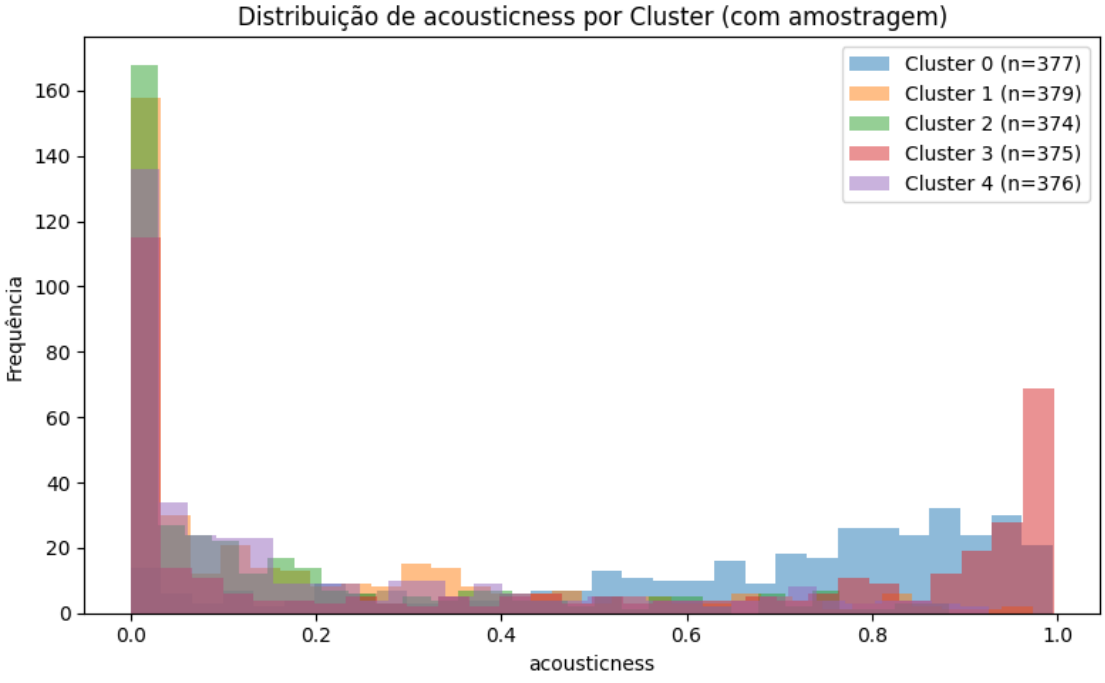
Distribuição de acousticness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
acousticness
0
20
40
60
80
100
120
140
160
0.0
0.2
0.4
0.6
0.8
1.0

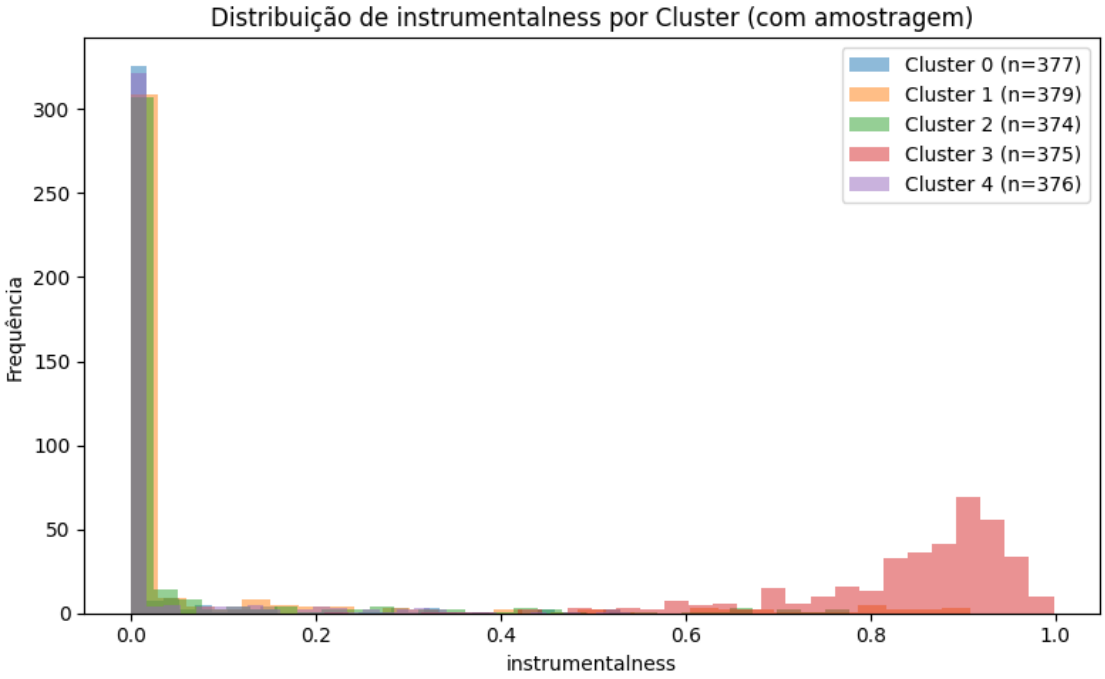
Distribuição de instrumentalness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
instrumentalness
0
50
100
150
200
250
300
0.0
0.2
0.4
0.6
0.8
1.0

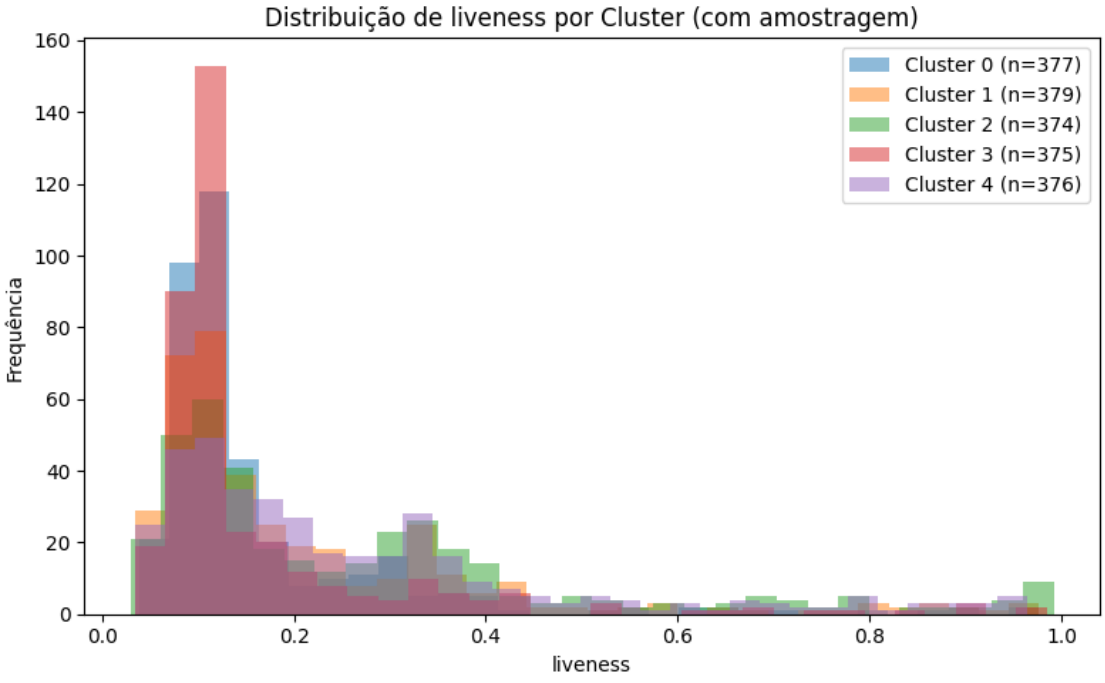
Distribuição de liveness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
liveness
0
20
40
60
80
100
120
140
160
0.0
0.2
0.4
0.6
0.8
1.0

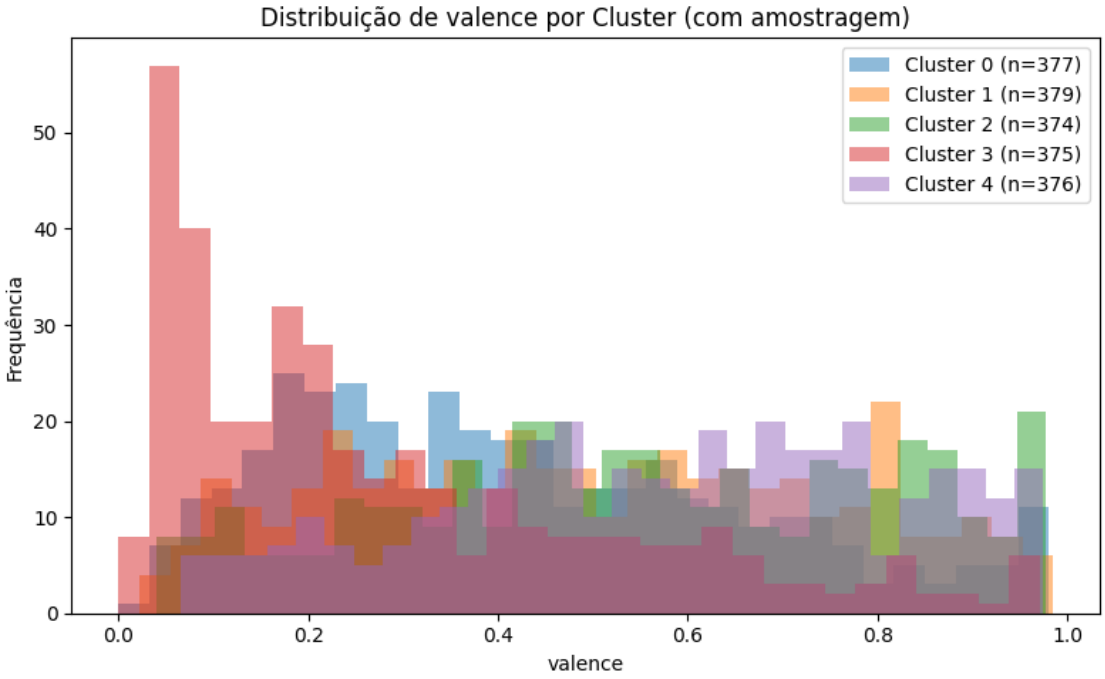
Distribuição de valence por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
valence
0
10
20
30
40
50
0.0
0.2
0.4
0.6
0.8
1.0

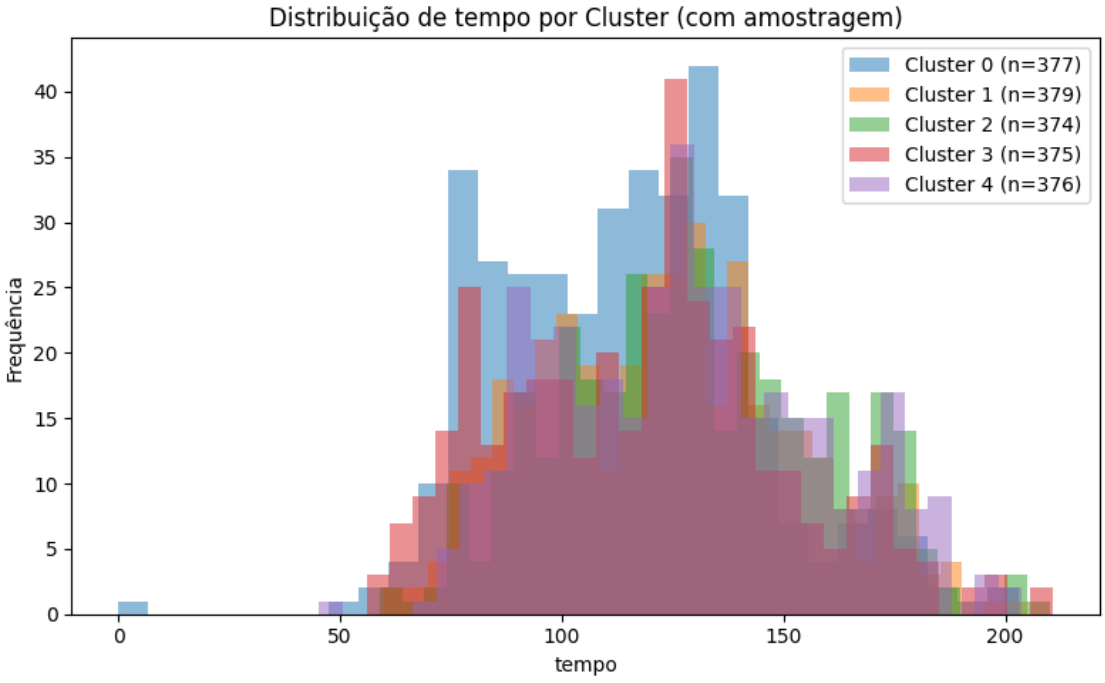
Distribuição de tempo por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=379)
Cluster 2 (n=374)
Cluster 3 (n=375)
Cluster 4 (n=376)
Frequência
tempo
0
5
10
15
20
25
30
35
40
0
50
100
150
200

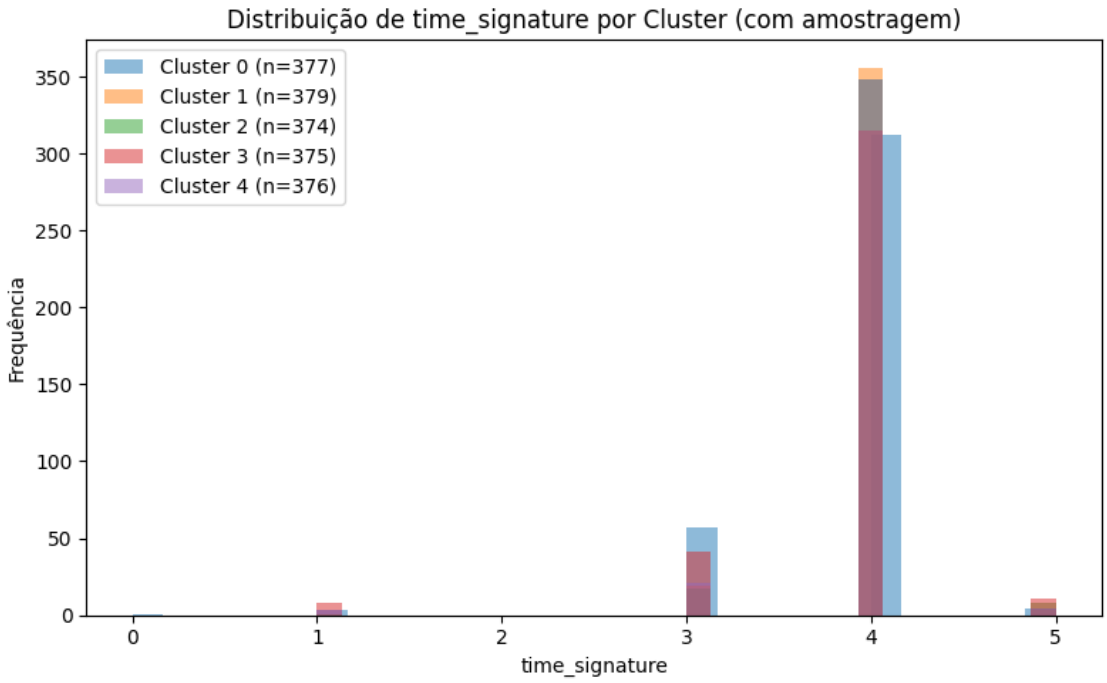

3.4 Musica

[116]:
```
recomendar_musicas('2aibwv5hGXSgw7Yru8IYTO', df_dados_normalizados2,␣
↪df_musicas_minmax)
```

```
Cluster: 4
```

[116]:

	track_name	artists	track_genre
2110	Monster	Skillet	alt-rock
44195	Fake It	Seether	grunge
56827	I'm Born To Run	American Authors	indie-pop
82063	Buddy Holly	Weezer	power-pop
2357	HandClap	Fitz and The Tantrums	alt-rock
65364	Love Maze	BTS	k-pop
65464	Alcohol-Free	TWICE	k-pop
30764	What Would You Do?	Joel Corry;David Guetta;Bryson Tiller	edm
44284	Semi-Charmed Life	Third Eye Blind	grunge
38090	Teddy Picker	Arctic Monkeys	garage

4 Standart Scale

[117]:
```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
escala3 = scaler.fit_transform(df_dados)
```

```
df_dados_normalizados3 =  pd.DataFrame(escala3, columns=df_dados.columns[:])
df_dados_normalizados3
```

[117]:

```
       popularity  duration_ms  danceability    energy       key  loudness  \
0        1.933925     0.013472      0.644253 -0.675975 -1.203275  0.335727
1        1.059312    -0.704186     -0.804604 -1.825602 -1.203275 -1.673087
2        1.156491    -0.162188     -0.702731 -1.073473 -1.484183 -0.236524
3        1.836746    -0.240925     -1.676182 -2.240247 -1.484183 -1.918228
4        2.371232    -0.268195      0.315996 -0.746122 -0.922368 -0.226373
…             …           …             …       …       …       …
89735   -0.592735     1.379914     -2.208184 -1.556706 -0.079646 -1.511831
89736   -0.544146     1.379923     -2.196865 -2.016557 -1.484183 -1.880499
89737   -0.544146     0.374710      0.378251 -1.190384 -1.484183 -0.458874
89738    0.379057     0.484736      0.140548 -0.500608  0.482169 -0.457725
89739   -0.544146     0.112281     -0.204687 -0.574652 -1.203275 -0.326536

           mode  speechiness  acousticness  instrumentalness  liveness  \
0     -1.324621     0.490458     -0.875166         -0.535482  0.723656
1      0.754933    -0.098364      1.760810         -0.535468 -0.595078
2      0.754933    -0.280219     -0.349626         -0.535485 -0.512978
3      0.754933    -0.451480      1.704650         -0.535266 -0.436009
4      0.754933    -0.307585      0.415925         -0.535485 -0.687954
…           …           …             …                 …       …
89735  0.754933    -0.399395      0.921365          2.330062 -0.670508
89736 -1.324621    -0.417934      1.967716          2.478280 -0.574553
89737 -1.324621    -0.401161      1.592330         -0.535485 -0.682823
89738  0.754933    -0.509744      0.155815         -0.535485  0.272105
89739 -1.324621    -0.131910      1.042553         -0.535485 -0.655114

        valence     tempo  time_signature   cluster
0      0.934047 -1.133599        0.226216 -0.584473
1     -0.770269 -1.479843        0.226216 -1.283274
2     -1.329497 -1.518259        0.226216 -1.283274
3     -1.241999  1.981635       -1.979174 -1.283274
4     -1.150696 -0.070030        0.226216 -1.283274
…           …         …              …       …
89735 -1.657046  0.130717        2.431606  0.813129
89736 -1.652861 -1.222517        0.226216  0.813129
89737  1.040567  0.342654        0.226216 -1.283274
89738 -0.214844  0.461588        0.226216 -1.283274
89739  0.907417 -1.423098        0.226216 -1.283274

[89740 rows x 15 columns]
```

Aplicando o método do cotovelo

[118]:

```
soma_e3 = calcular_soma_erros(escala3)
```

[119]:
```
plt.plot(range(1, 20), soma_e3, marker='o')
plt.xlabel('Número de Clusters (k)')
plt.ylabel('Soma dos Erros Quadrados (SEQ)')
plt.title('Método do Cotovelo')
plt.show()
```

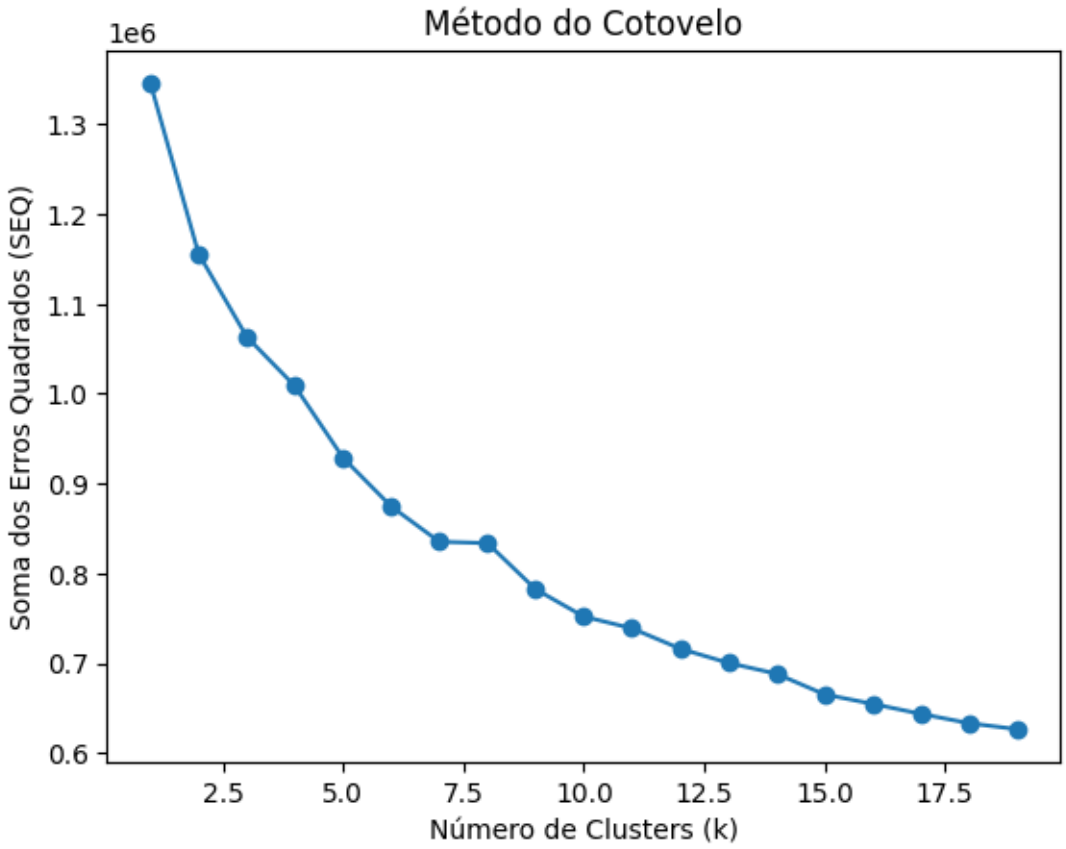

Diferentemente do método anterior, neste caso conseguimos ver claramente o 'cotovelo', por isso definimos o **número de clusters = 7**

[120]:
```
nc3=7
```

[121]:
```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=nc3, random_state=14)
clusters = kmeans.fit_predict(escala3)

df_musicas_stand = df_musicas.copy()
df_musicas_stand['cluster'] = clusters
df_dados['cluster'] = clusters
df_dados_normalizados3['cluster'] = clusters
```

4.1 Plotagem 2D e 3D dos clusters

[122]:
```
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches

pca = PCA(n_components=2)
X_pca = pca.fit_transform(escala3)

# Plot
scatter = plt.scatter(X_pca[:, 0], X_pca[:, 1],␣
 ↪c=df_dados_normalizados3['cluster'], cmap='viridis')

# Legenda manual
clusters = df_dados_normalizados3['cluster'].unique()
colors = scatter.cmap(scatter.norm(clusters))

handles = [mpatches.Patch(color=colors[i], label=f'Cluster {clusters[i]}') for␣
 ↪i in range(len(clusters))]

plt.legend(handles=handles, title='Clusters', bbox_to_anchor=(1.05, 1),␣
 ↪loc='upper left')
plt.xlabel('PCA 1')
plt.ylabel('PCA 2')
plt.title('Clusters de músicas')

plt.tight_layout()
plt.show()
```

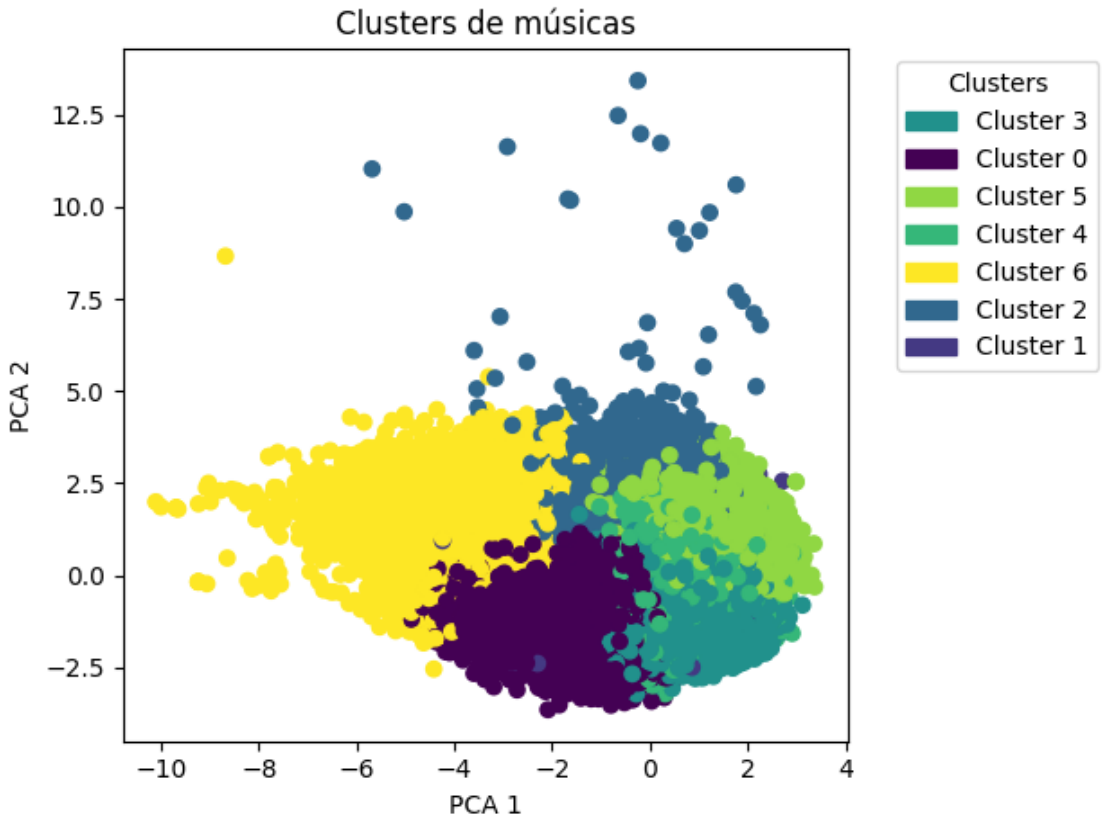

[123]:
```
from mpl_toolkits.mplot3d import Axes3D

pca = PCA(n_components=3)
X_pca_3d = pca.fit_transform(escala3)

fig = plt.figure(figsize=(10,8))
ax = fig.add_subplot(111, projection='3d')
scatter = ax.scatter(X_pca_3d[:, 0], X_pca_3d[:, 1], X_pca_3d[:, 2],
                     c=df_dados_normalizados3['cluster'], cmap='viridis')
ax.set_xlabel('PCA 1')
ax.set_ylabel('PCA 2')
ax.set_zlabel('PCA 3')
plt.title('Clusters em 3D com PCA')
plt.show()
```

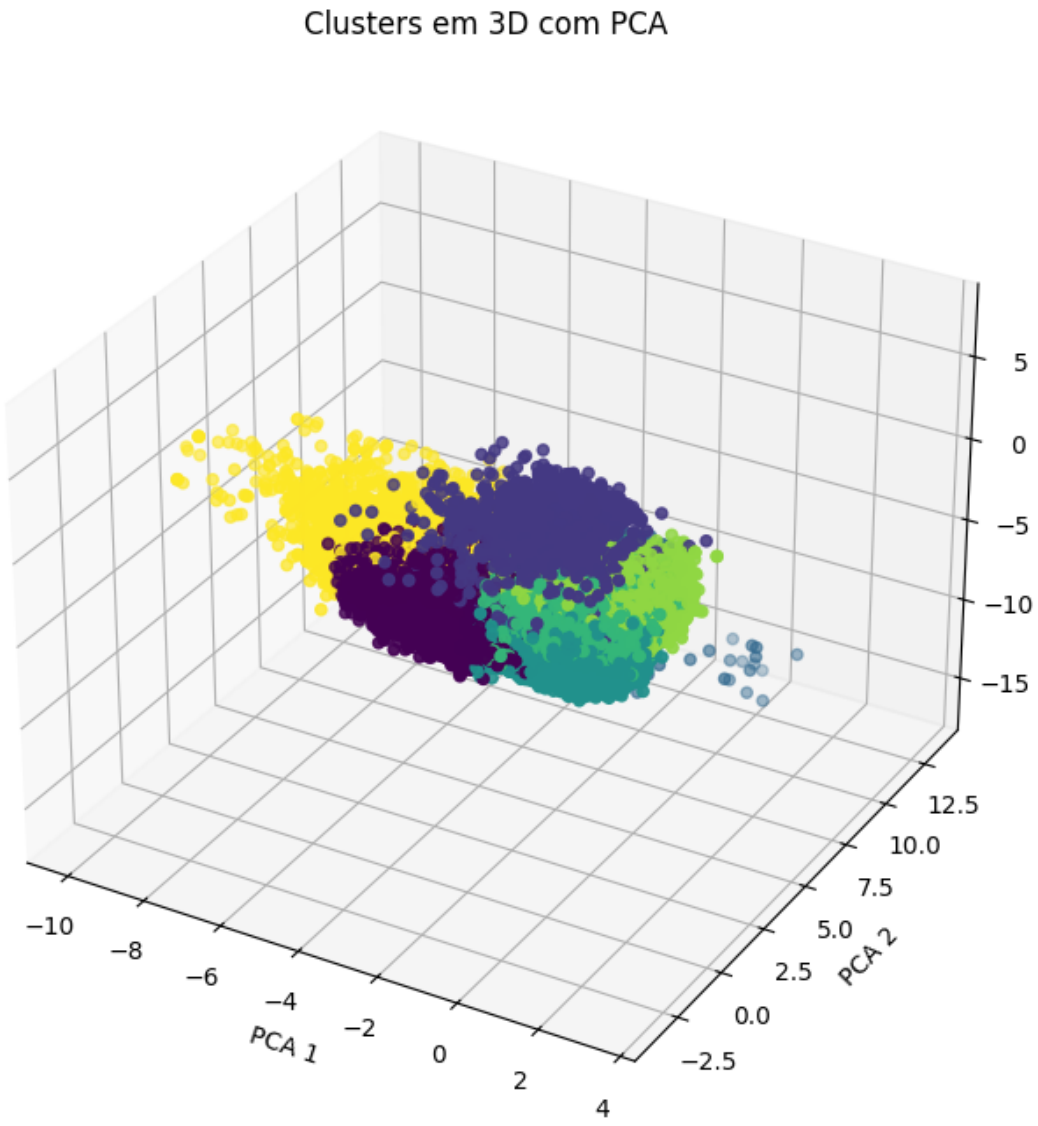

4.2 Analisando os dados

[124]:
```
df_dados_normalizados3['cluster'].value_counts()
```

[124]:
```
cluster
3    22104
0    18773
5    16778
4    14447
2    10029
6     6544
1     1065
```

```
Name: count, dtype: int64
```

4.2.1 Dados Originais

[125]:
```
df_dados_media = df_dados.groupby('cluster').mean(numeric_only=True) #Para␣
↪histogramas
df_dados_media
```

[125]:

cluster	popularity	duration_ms	danceability	energy	key	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	32.504927	215846.004688	0.526570	0.374973	5.092260	-10.868613	0.817024	0.046370	0.662169	0.020890	0.164118	0.410774	113.427991	3.806105
1	24.567136	218449.107981	0.570402	0.675837	5.081690	-11.196860	0.693897	0.836988	0.740297	0.006451	0.673429	0.444778	100.919011	3.583099
2	25.833782	301005.254163	0.565043	0.739642	5.467345	-8.582128	0.558879	0.073359	0.123740	0.797845	0.188640	0.327106	127.400637	3.936484
3	36.422774	226008.865590	0.612985	0.745666	6.071571	-6.278753	0.000181	0.097442	0.178467	0.040702	0.220076	0.531866	124.859598	3.972901
4	35.043608	220436.050253	0.591548	0.765430	1.403682	-6.050017	0.999931	0.089257	0.168797	0.032542	0.246794	0.560779	127.820266	3.966221
5	34.544761	219725.037490	0.590372	0.774489	7.881392	-5.792718	1.000000	0.093049	0.181285	0.026267	0.251183	0.570707	128.765935	3.963643
6	29.468062	212870.119957	0.349699	0.187127	4.826406	-20.979222	0.649756	0.052707	0.851916	0.817720	0.173681	0.188213	102.686851	3.574114

4.2.2 Dados Normalizados

[126]:
```
df_dados_normalizados3_media = df_dados_normalizados3.groupby('cluster').mean()␣
↪# Para gráfico de médias
df_dados_normalizados3_media
```

[126]:

cluster	popularity	duration_ms	danceability	energy	key	loudness	...
0	-0.033715	-0.117742	-0.201459	-1.011227	-0.053729	-0.453821	...

```
1         -0.419410    -0.094694      0.046610  0.161255 -0.056698 -0.516685
2         -0.357864     0.636246      0.016281  0.409905  0.051635 -0.015922
3          0.156651    -0.027761      0.287614  0.433381  0.221366  0.425212
4          0.089638    -0.077102      0.166287  0.510402 -1.089878  0.469019
5          0.065399    -0.083397      0.159632  0.545703  0.729759  0.518296
6         -0.181276    -0.144090     -1.202478 -1.743270 -0.128410 -2.390167

              mode  speechiness  acousticness  instrumentalness  liveness  \
cluster
0         0.374426    -0.362579      0.986892         -0.470978 -0.271203
1         0.118375     6.616923      1.217822         -0.515566  2.342207
2        -0.162401    -0.124328     -0.604592          1.928159 -0.145373
3        -1.324244     0.088274     -0.442832         -0.409803  0.015934
4         0.754789     0.016024     -0.471413         -0.434999  0.153032
5         0.754933     0.049499     -0.434500         -0.454376  0.175548
6         0.026581    -0.306639      1.547745          1.989530 -0.222131

           valence     tempo  time_signature
cluster
0        -0.223312 -0.286549       -0.201399
1        -0.093950 -0.701889       -0.693214
2        -0.541607  0.177389        0.086139
3         0.237356  0.093018        0.166452
4         0.347346  0.191322        0.151721
5         0.385116  0.222721        0.146034
6        -1.069995 -0.643191       -0.713029
```

4.2.3 Gênero de músicas por cluster

[127]:
```
genero_por_cluster = df_musicas_stand.groupby('cluster').apply(
    lambda x: x['track_genre'].value_counts().head(6),
    include_groups=False
)
genero_por_cluster
```

[127]:
```
cluster  track_genre
0        honky-tonk      833
         romance         747
         tango           719
         cantopop        694
         acoustic        650
         opera           571
1        comedy          806
         show-tunes       32
         kids             22
         children         19
         french           15
```

```
          funk                14
2         minimal-techno     747
          detroit-techno     742
          grindcore          582
          study              573
          chicago-house      502
          black-metal        497
3         turkish            479
          dancehall          467
          dance              439
          hardstyle          436
          hip-hop            419
          k-pop              407
4         power-pop          303
          j-idol             286
          kids               279
          forro              266
          sertanejo          253
          heavy-metal        252
5         j-idol             381
          party              363
          forro              362
          sertanejo          325
          country            304
          alt-rock           304
6         sleep              814
          new-age            751
          ambient            660
          classical          608
          piano              418
          disney             415
Name: count, dtype: int64
```

4.3 Gráficos

4.3.1 Características x Cluster

[128]:
```
df_dados_normalizados3_media.plot(kind='bar')
plt.title('Caracteristicas por cluster')
plt.legend(bbox_to_anchor=(1.0, 1.0))
plt.show()
```

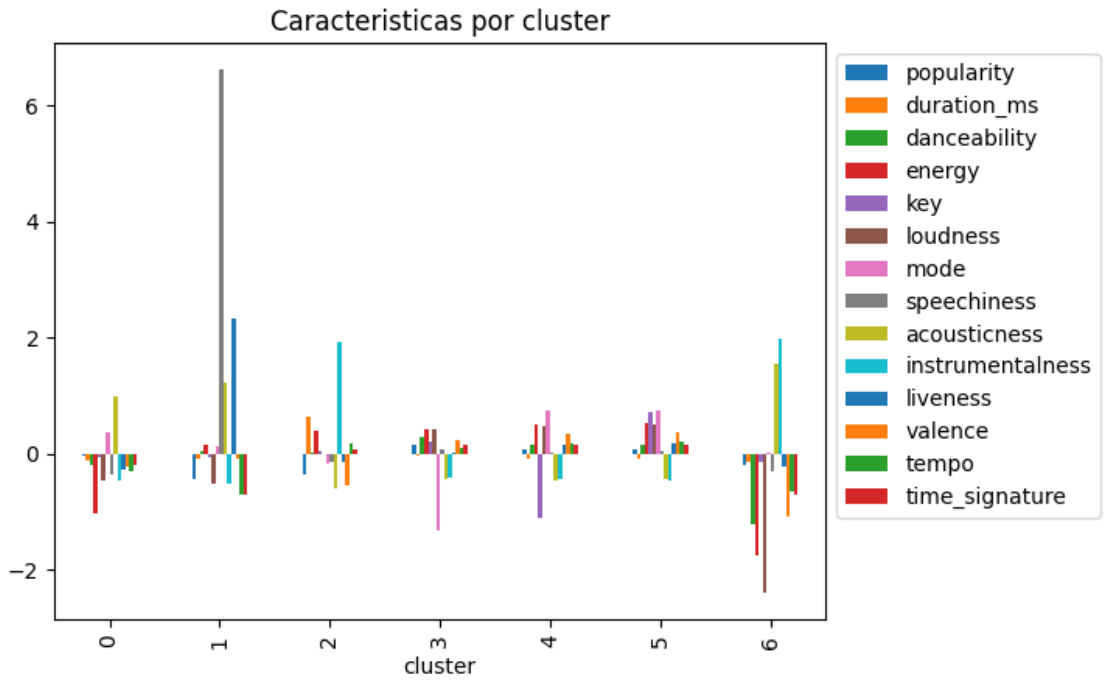

4.3.2 Cluster x Características

[129]:
```
df_dados_normalizados3_media.T.plot(kind='bar')
plt.title('Clusters por característica')
plt.legend(title='Cluster', bbox_to_anchor=(1.0, 1.0))
plt.tight_layout()
plt.show()
```

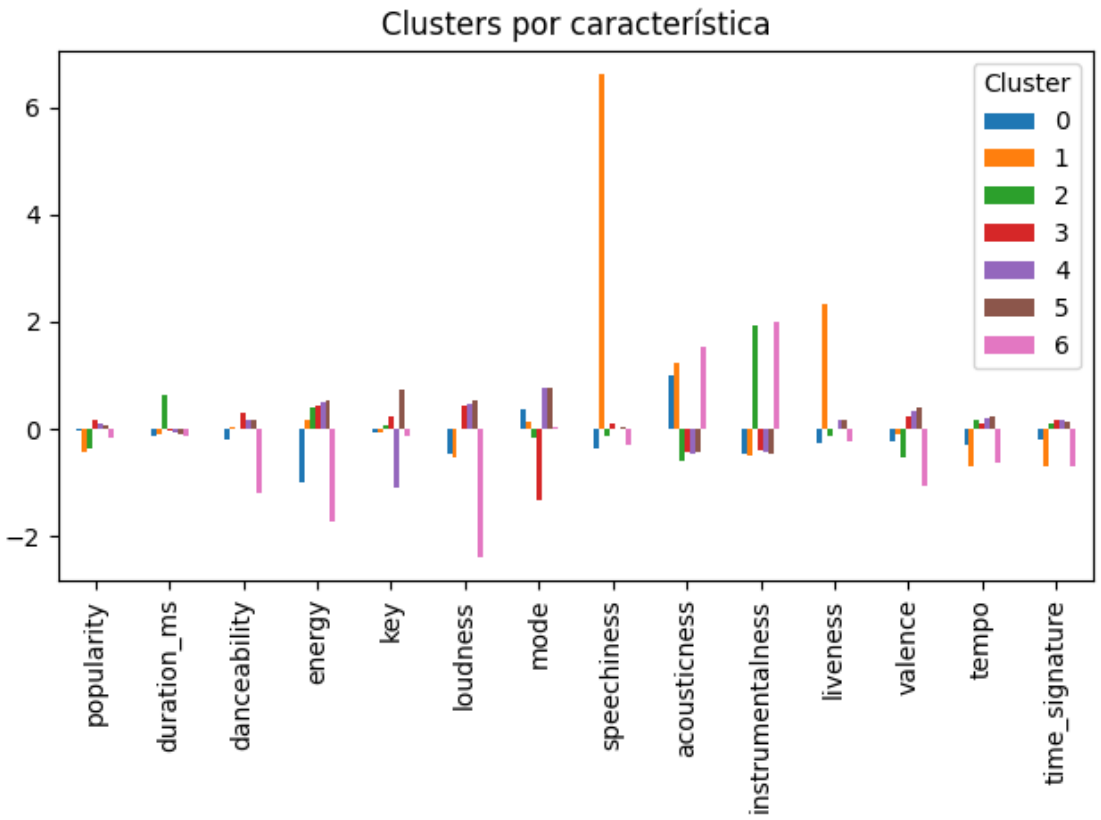

4.3.3 Histogramas

[130]:
```
import matplotlib.pyplot as plt

for feature in df_dados.columns.drop('cluster'):
    plt.figure(figsize=(8, 5))

    for cluster_id in sorted(df_dados['cluster'].unique()):
        subset = df_dados[df_dados['cluster'] == cluster_id]
        tamanho = tamanho_amostra(len(subset))
        amostra = subset.sample(n=min(tamanho, len(subset)), random_state=42) ␣
 ↪# Garante que não passa o tamanho real
        plt.hist(amostra[feature], bins=30, alpha=0.5, label=f'Cluster␣
 ↪{cluster_id} (n={len(amostra)})')

    plt.title(f'Distribuição de {feature} por Cluster (com amostragem)')
    plt.xlabel(feature)
    plt.ylabel('Frequência')
    plt.legend()
    plt.tight_layout()
```

```
    plt.show()
```

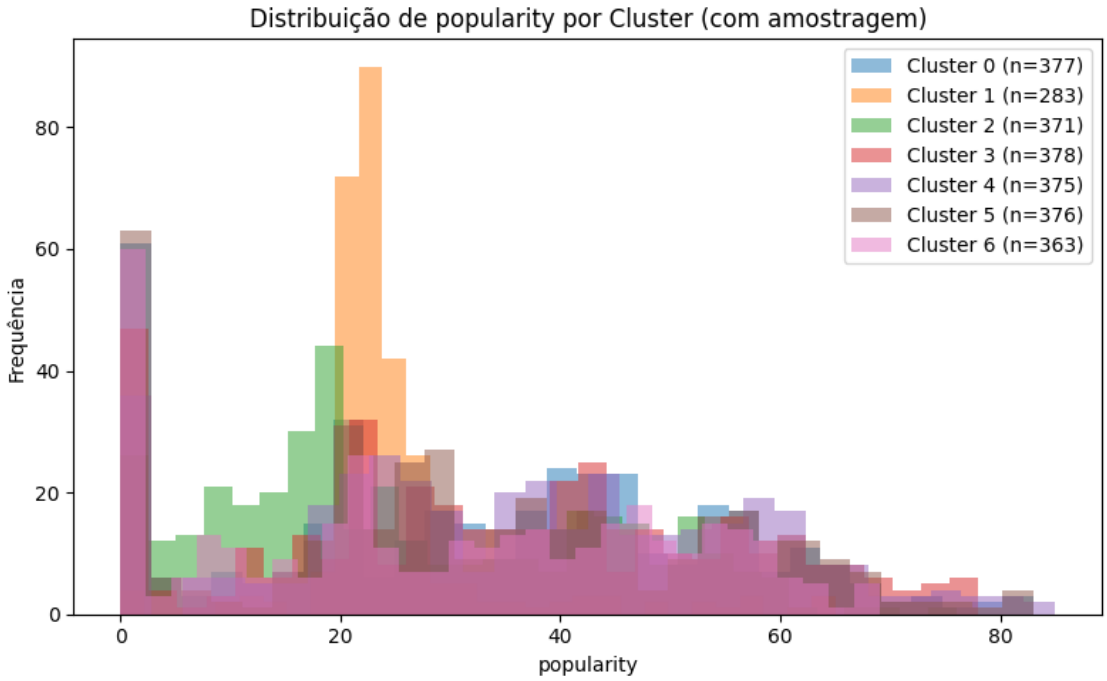
Distribuição de popularity por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
popularity
0
20
40
60
80

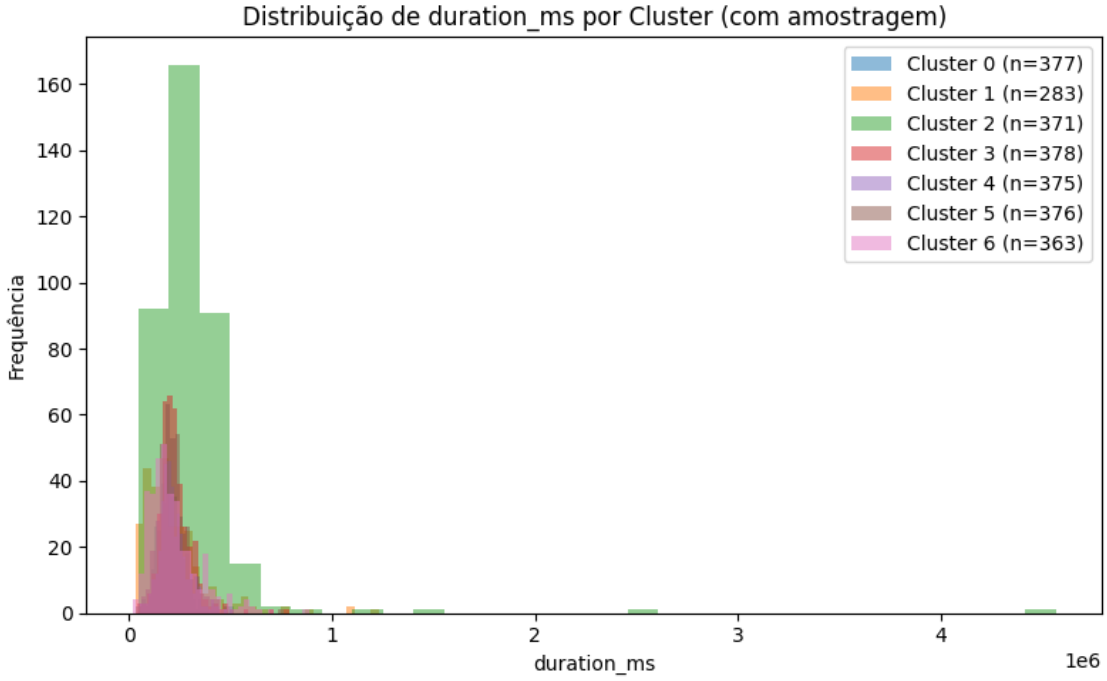
Distribuição de duration_ms por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
duration_ms
1e6
0
1
2
3
4

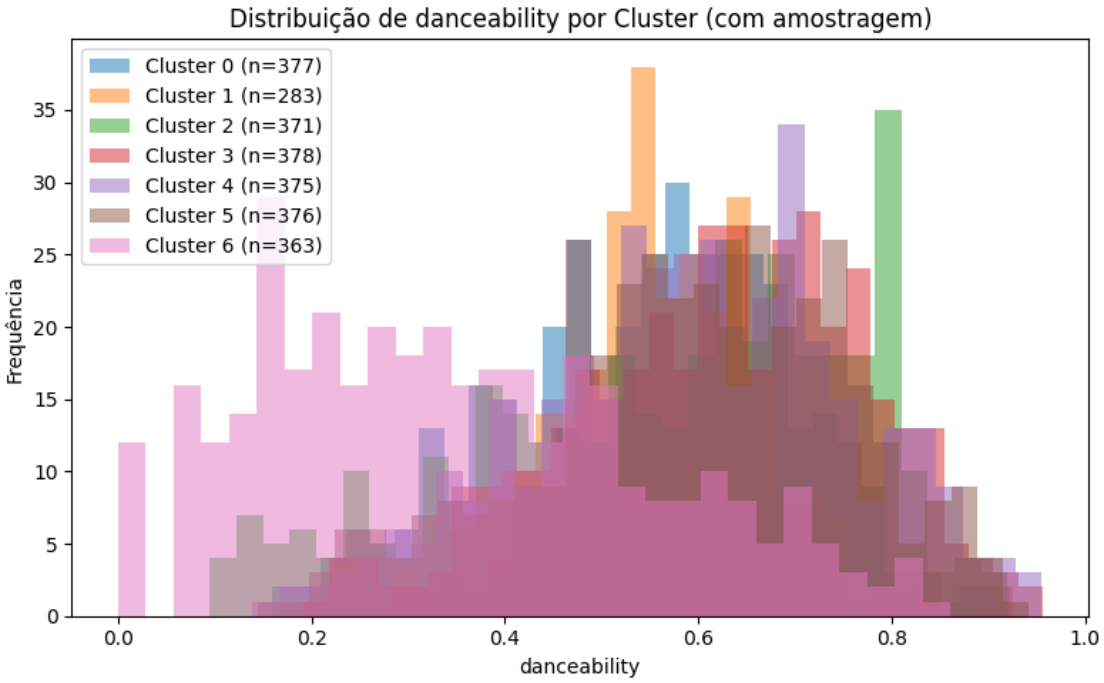
Distribuição de danceability por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
danceability
0
5
10
15
20
25
30
35
0.0
0.2
0.4
0.6
0.8
1.0

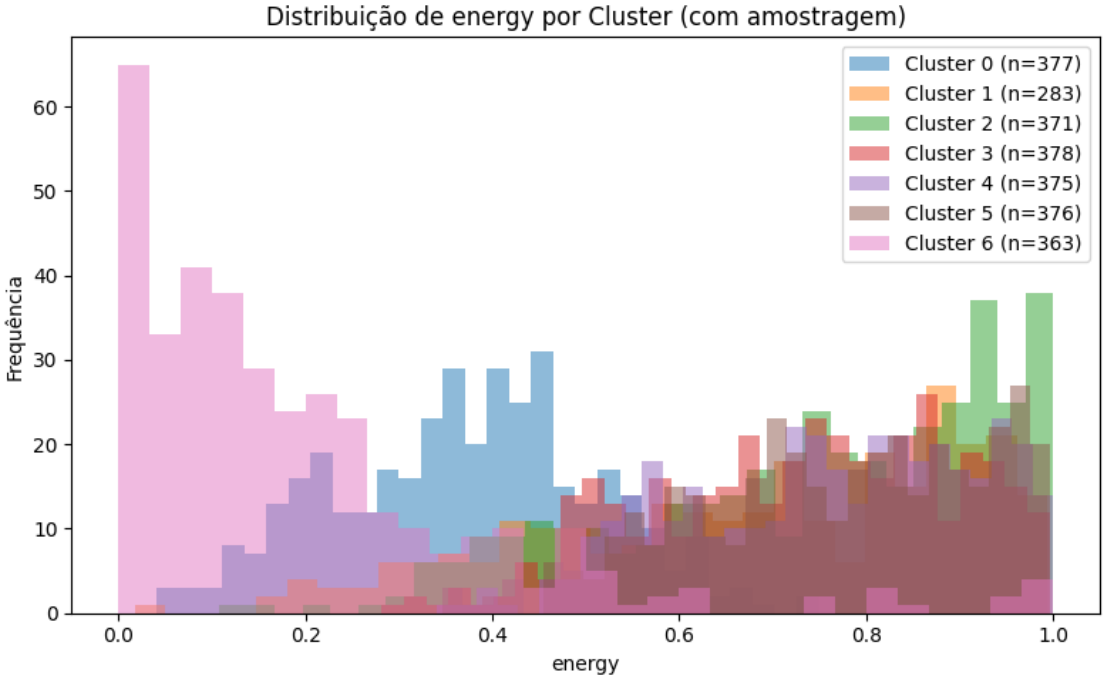
Distribuição de energy por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
energy
0
10
20
30
40
50
60
0.0
0.2
0.4
0.6
0.8
1.0

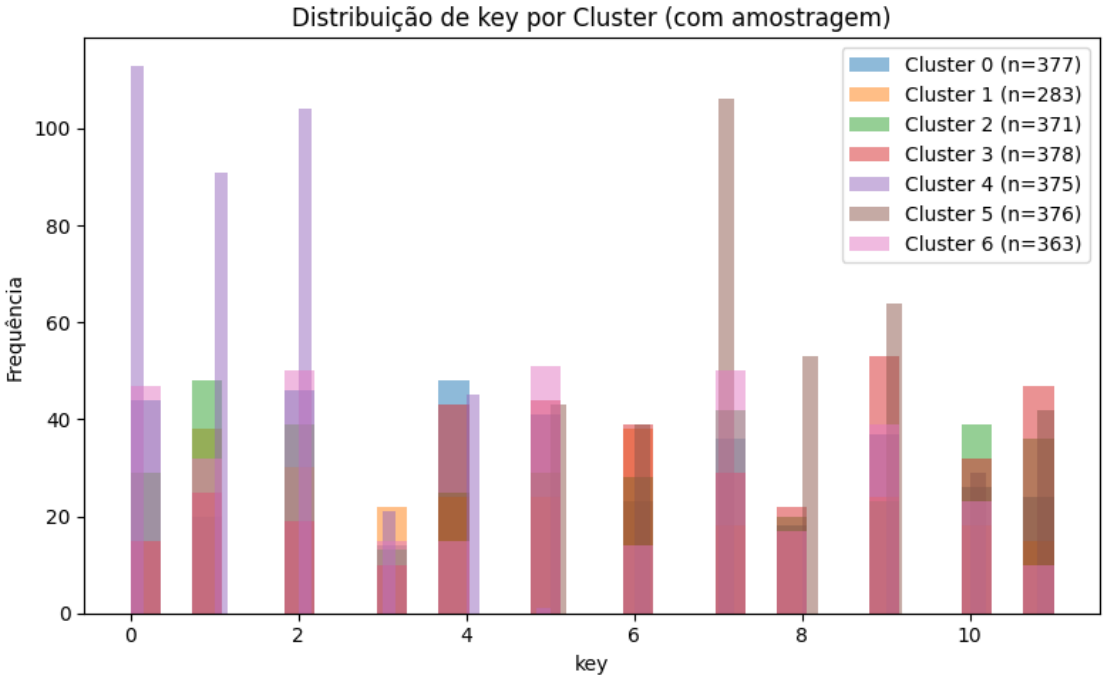
Distribuição de key por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
key
0
20
40
60
80
100
0
2
4
6
8
10

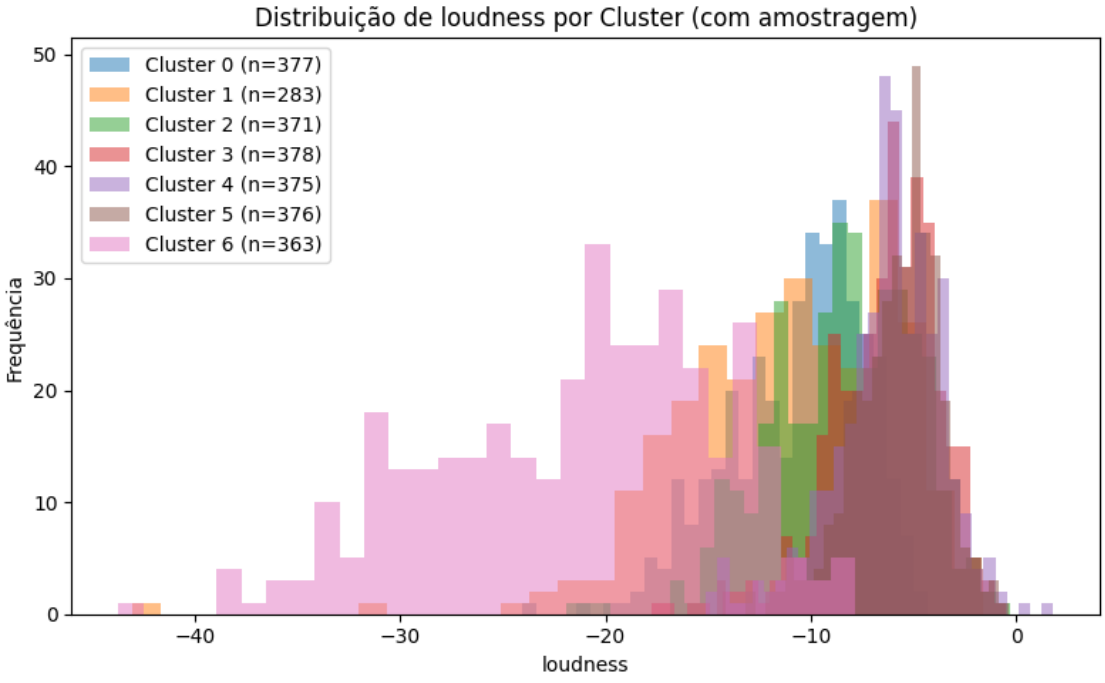
Distribuição de loudness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
loudness
0
10
20
30
40
50
−40
−30
−20
−10
0

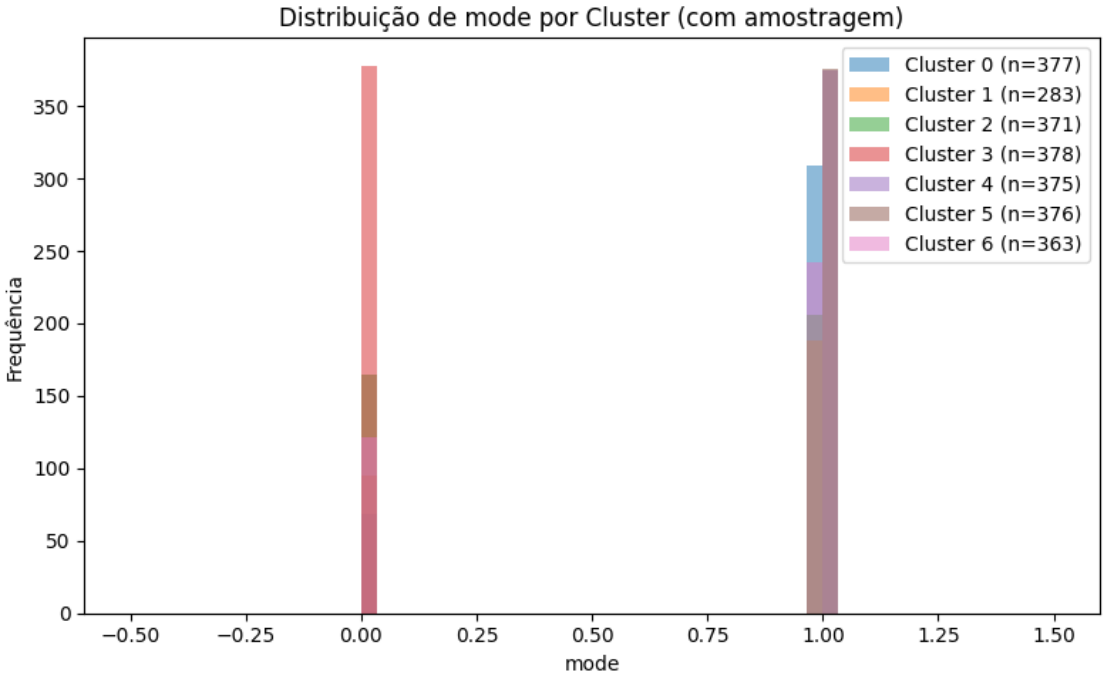
Distribuição de mode por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
mode

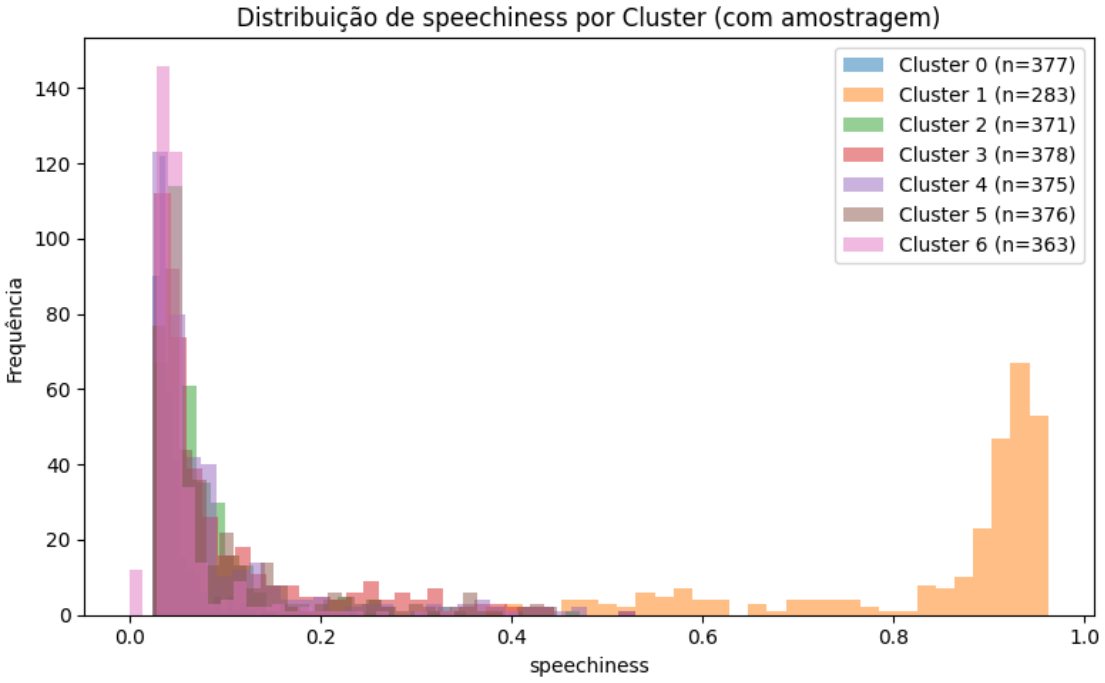
Distribuição de speechiness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
speechiness

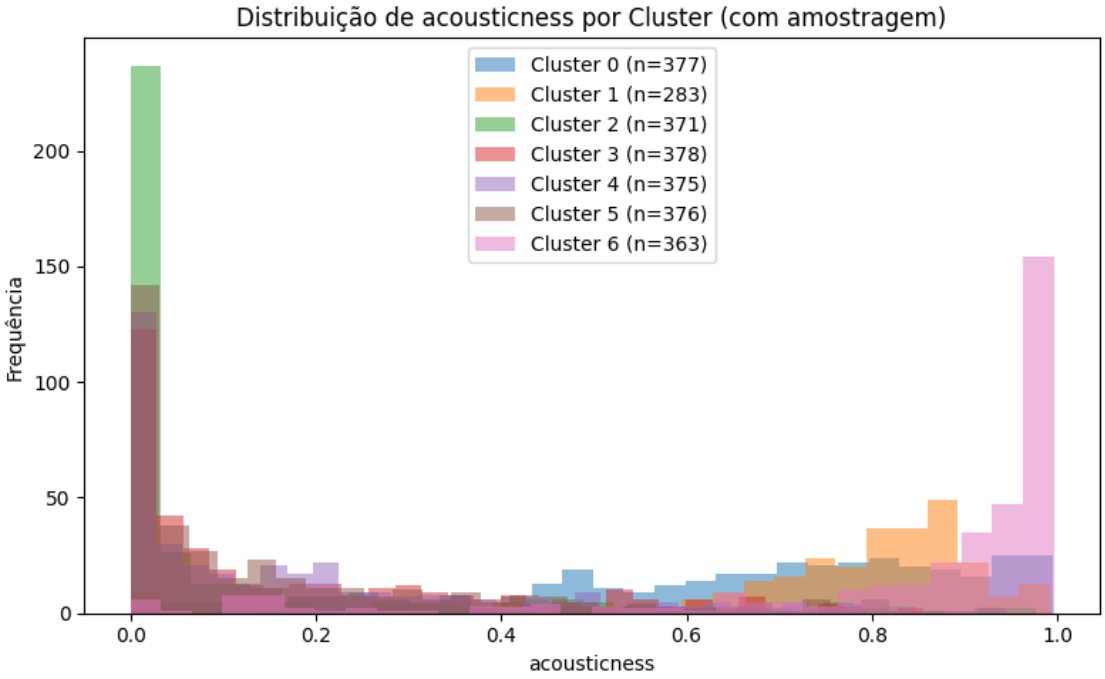
Distribuição de acousticness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
acousticness
0
50
100
150
200
0.0
0.2
0.4
0.6
0.8
1.0

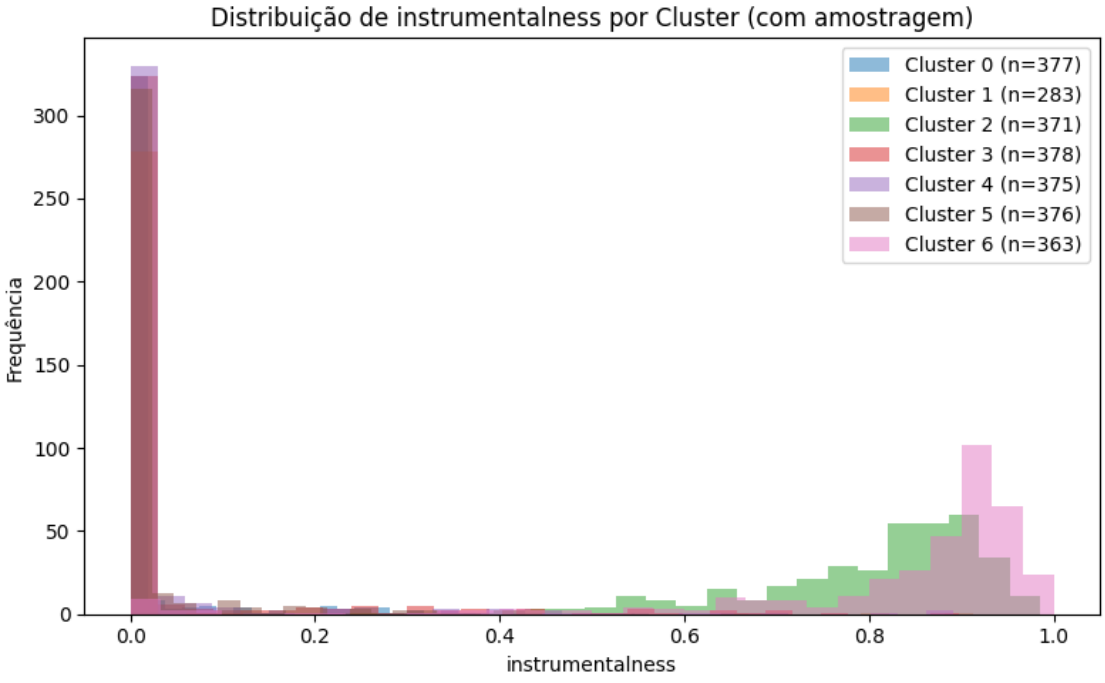
Distribuição de instrumentalness por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
instrumentalness
0
50
100
150
200
250
300
0.0
0.2
0.4
0.6
0.8
1.0

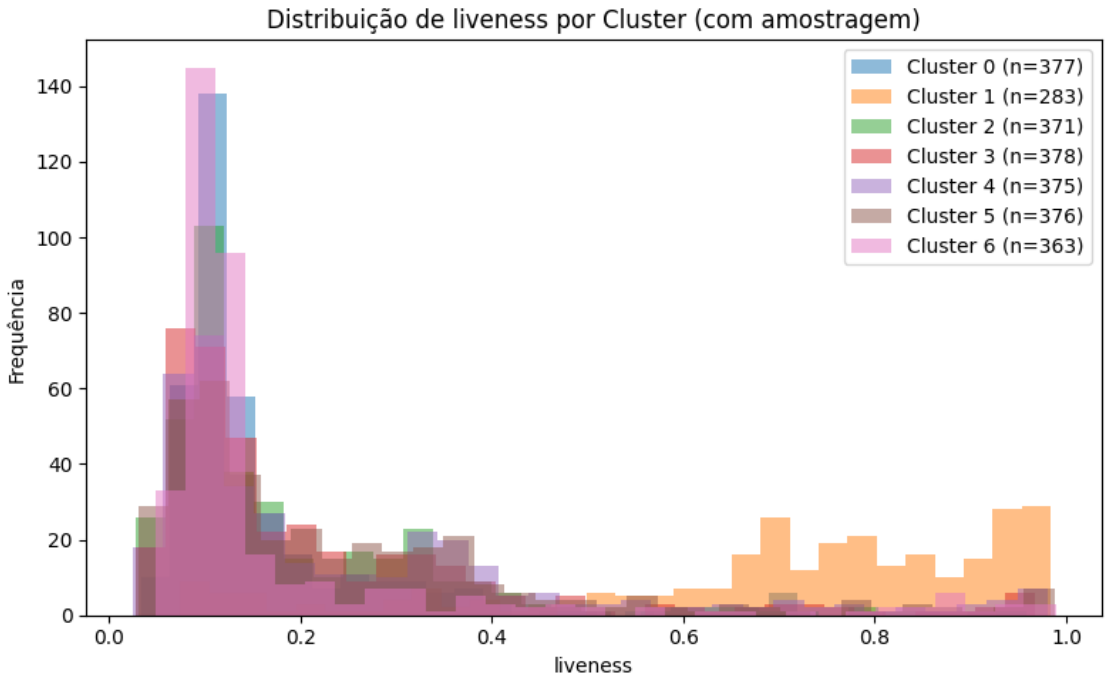


```
C:\Users\conta\AppData\Roaming\Python\Python313\site-
packages\IPython\core\pylabtools.py:170: UserWarning: Creating legend with
loc="best" can be slow with large amounts of data.
  fig.canvas.print_figure(bytes_io, **kw)
```

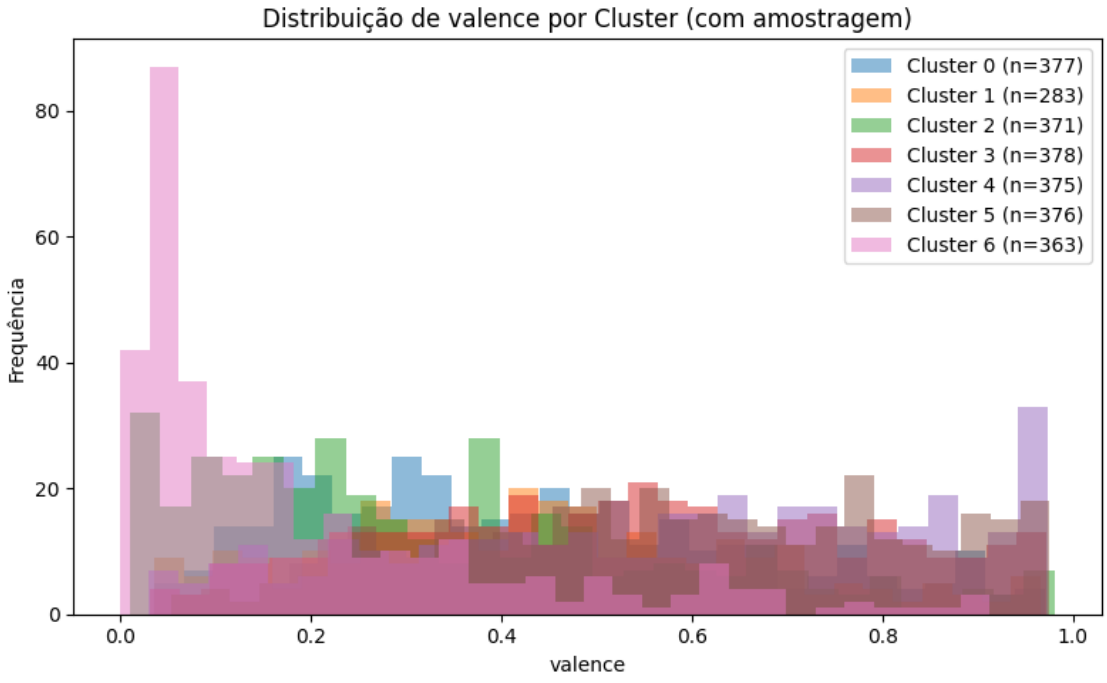

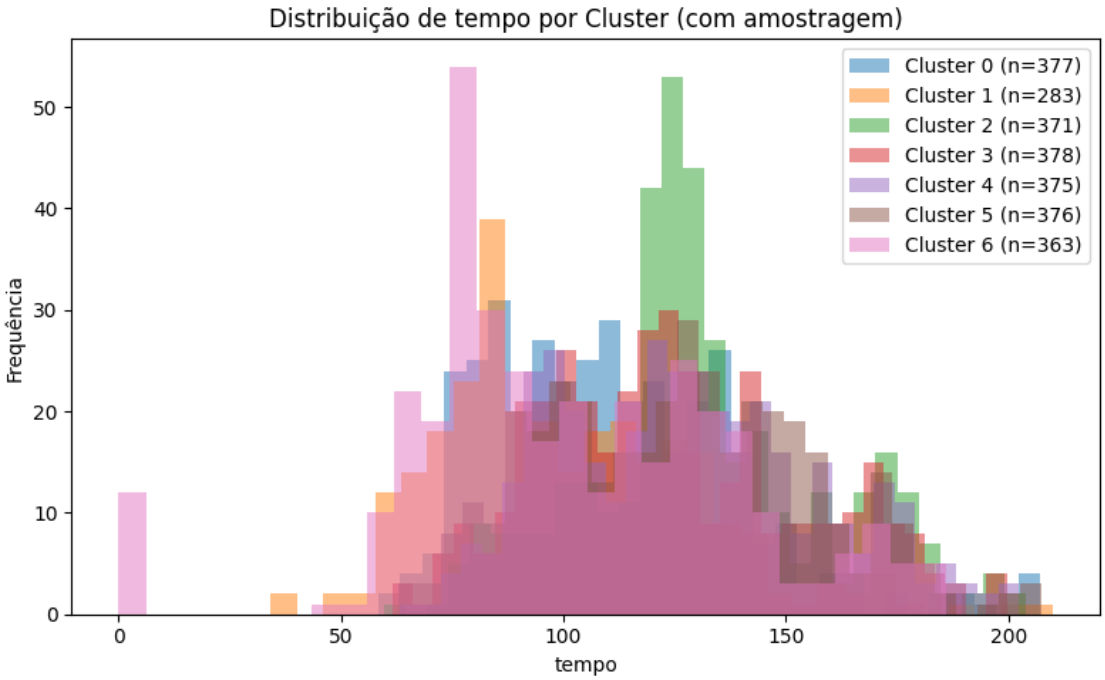
Distribuição de tempo por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
tempo
0
10
20
30
40
50
0
50
100
150
200

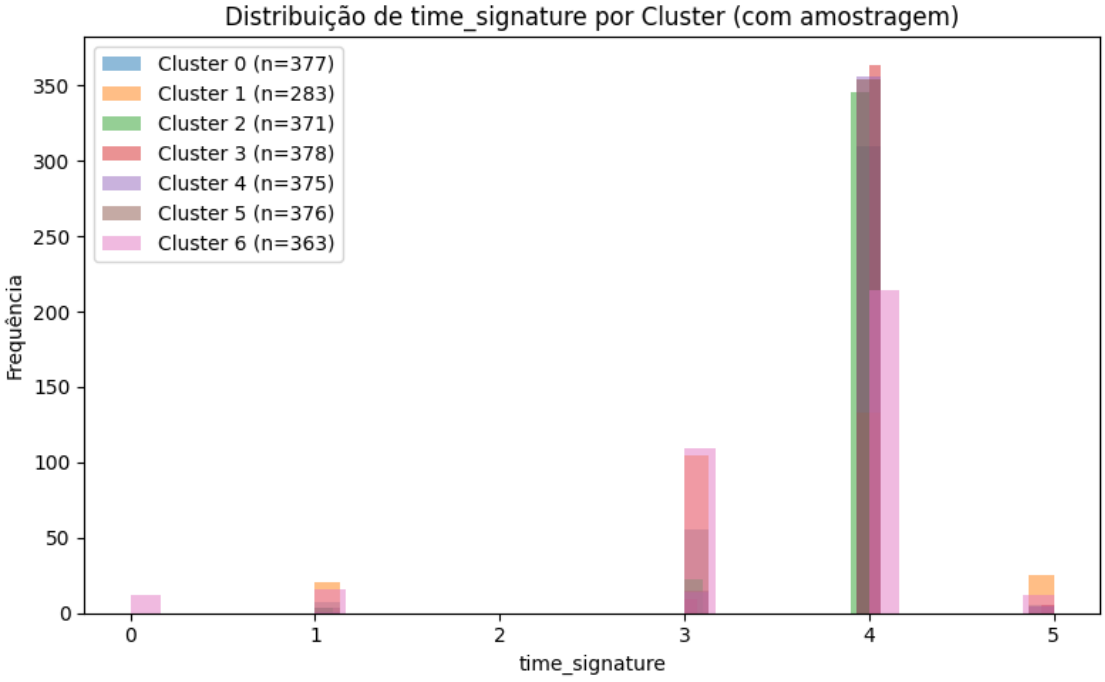
Distribuição de time_signature por Cluster (com amostragem)
Cluster 0 (n=377)
Cluster 1 (n=283)
Cluster 2 (n=371)
Cluster 3 (n=378)
Cluster 4 (n=375)
Cluster 5 (n=376)
Cluster 6 (n=363)
Frequência
time_signature
0
50
100
150
200
250
300
350
0
1
2
3
4
5

4.4 Musica

[131]:
```
recomendar_musicas('2aibwv5hGXSgw7Yru8IYTO', df_dados_normalizados3,␣
↪df_musicas_stand)
```

```
Cluster: 5
```

[131]:

	track_name	artists	track_genre
2110	Monster	Skillet	alt-rock
44195	Fake It	Seether	grunge
30764	What Would You Do?	Joel Corry;David Guetta;Bryson Tiller	edm
2357	HandClap	Fitz and The Tantrums	alt-rock
56827	I'm Born To Run	American Authors	indie-pop
11266	cotton candy	YUNGBLUD	british
56383	SUPERMODEL	Måneskin	indie-pop
80561	Ek Toh Kum Zindagani (From "Marjaavaan")	Neha Kakkar;Yash Narvekar;Tanishk Bagchi	pop-film
38090	Teddy Picker	Arctic Monkeys	garage
53762	Under Control (feat. Hurts)	Calvin Harris;Alesso;Hurts	house

5 Max Abs Scale

[132]:
```
from sklearn.preprocessing import MaxAbsScaler
scaler = MaxAbsScaler()
escala4 = scaler.fit_transform(df_dados)
df_dados_normalizados4 =  pd.DataFrame(escala4, columns=df_dados.columns[:])
df_dados_normalizados4
```

[132]:

	popularity	duration_ms	danceability	energy	key	loudness
0	0.73	0.044043	0.686294	0.4610	0.090909	-0.136198
1	0.55	0.028566	0.426396	0.1660	0.090909	-0.347964
2	0.57	0.040255	0.444670	0.3590	0.000000	-0.196523
3	0.71	0.038557	0.270051	0.0596	0.000000	-0.373806
4	0.82	0.037969	0.627411	0.4430	0.181818	-0.195453
…	…	…	…	…	…	…
89735	0.21	0.073511	0.174619	0.2350	0.454545	-0.330964
89736	0.22	0.073511	0.176650	0.1170	0.000000	-0.369829

```
89737        0.22     0.051833      0.638579  0.3290  0.000000 -0.219963
89738        0.41     0.054206      0.595939  0.5060  0.636364 -0.219842
89739        0.22     0.046174      0.534010  0.4870  0.090909 -0.206012

       mode  speechiness  acousticness  instrumentalness  liveness   valence  \
0       0.0     0.148187      0.032329          0.000001    0.3580  0.718593
1       1.0     0.079067      0.927711          0.000006    0.1010  0.268342
2       1.0     0.057720      0.210843          0.000000    0.1170  0.120603
3       1.0     0.037617      0.908635          0.000071    0.1320  0.143719
4       1.0     0.054508      0.470884          0.000000    0.0829  0.167839
…     …           …             …                 …         …       …
89735   1.0     0.043731      0.642570          0.928000    0.0863  0.034070
89736   0.0     0.041554      0.997992          0.976000    0.1050  0.035176
89737   0.0     0.043523      0.870482          0.000000    0.0839  0.746734
89738   1.0     0.030777      0.382530          0.000000    0.2700  0.415075
89739   0.0     0.075130      0.683735          0.000000    0.0893  0.711558

          tempo  time_signature  cluster
0      0.361245             0.8      0.5
1      0.318397             0.8      0.0
2      0.313643             0.8      0.0
3      0.746758             0.6      0.0
4      0.492863             0.8      0.0
…         …               …       …
89735  0.517705             1.0      1.0
89736  0.350242             0.8      1.0
89737  0.543933             0.8      0.0
89738  0.558651             0.8      0.0
89739  0.325420             0.8      0.0

[89740 rows x 15 columns]
```

[133]:
```
soma_e4 = calcular_soma_erros(escala4)
```

[134]:
```
plt.plot(range(1, 20), soma_e4, marker='o')
plt.xlabel('Número de Clusters (k)')
plt.ylabel('Soma dos Erros Quadrados (SEQ)')
plt.title('Método do Cotovelo')
plt.show()
```

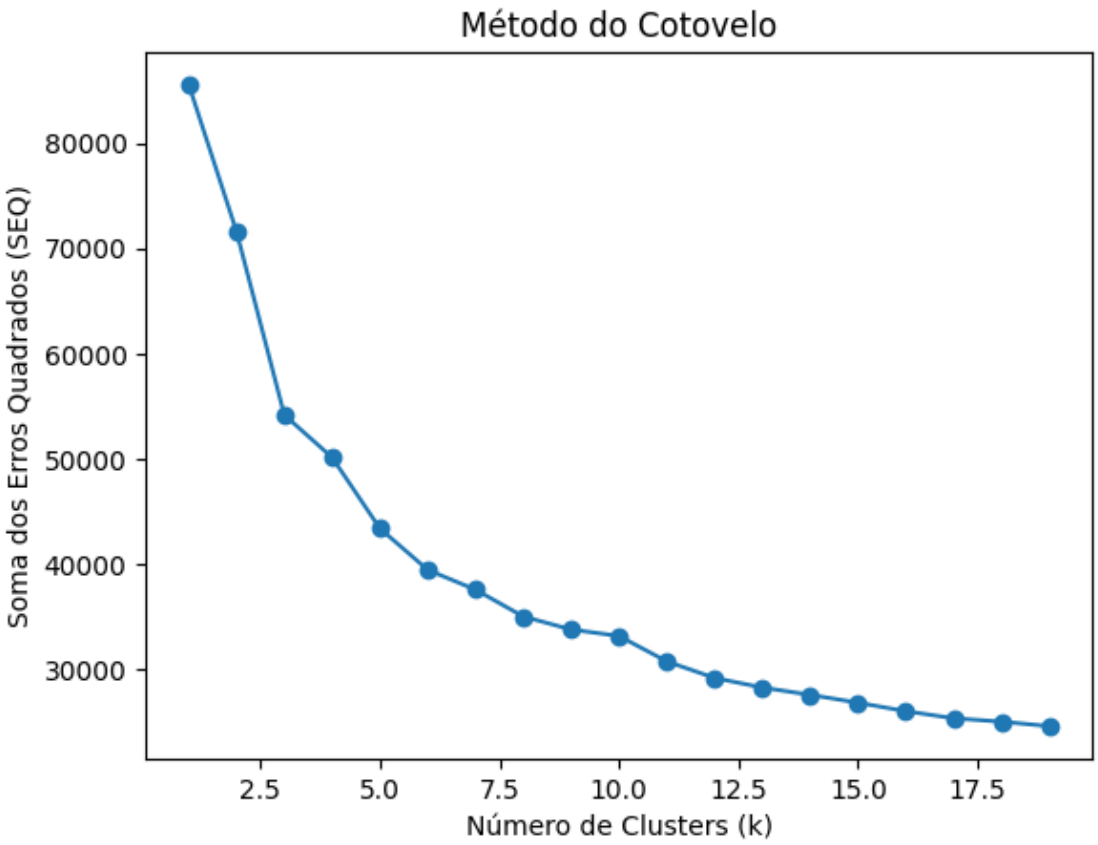

Número de Clusters

[135]:
```
nc4 = optimal_number_of_clusters(soma_e4)
nc4
```

[135]: 7

[136]:
```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=nc4, random_state=14)
clusters = kmeans.fit_predict(escala4)

df_musicas_maxabs = df_musicas.copy()
df_musicas_maxabs['cluster'] = clusters

df_dados['cluster'] = clusters

df_dados_normalizados4['cluster'] = clusters
```

5.1 Plotagem 2D e 3D dos clusters

[137]:
```
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt

pca = PCA(n_components=2)
X_pca = pca.fit_transform(escala4)

plt.scatter(X_pca[:, 0], X_pca[:, 1], c=df_dados_normalizados4['cluster'],␣
 ↪cmap='viridis')
plt.xlabel('PCA 1')
plt.ylabel('PCA 2')
plt.title('Clusters de músicas')
plt.show()
```

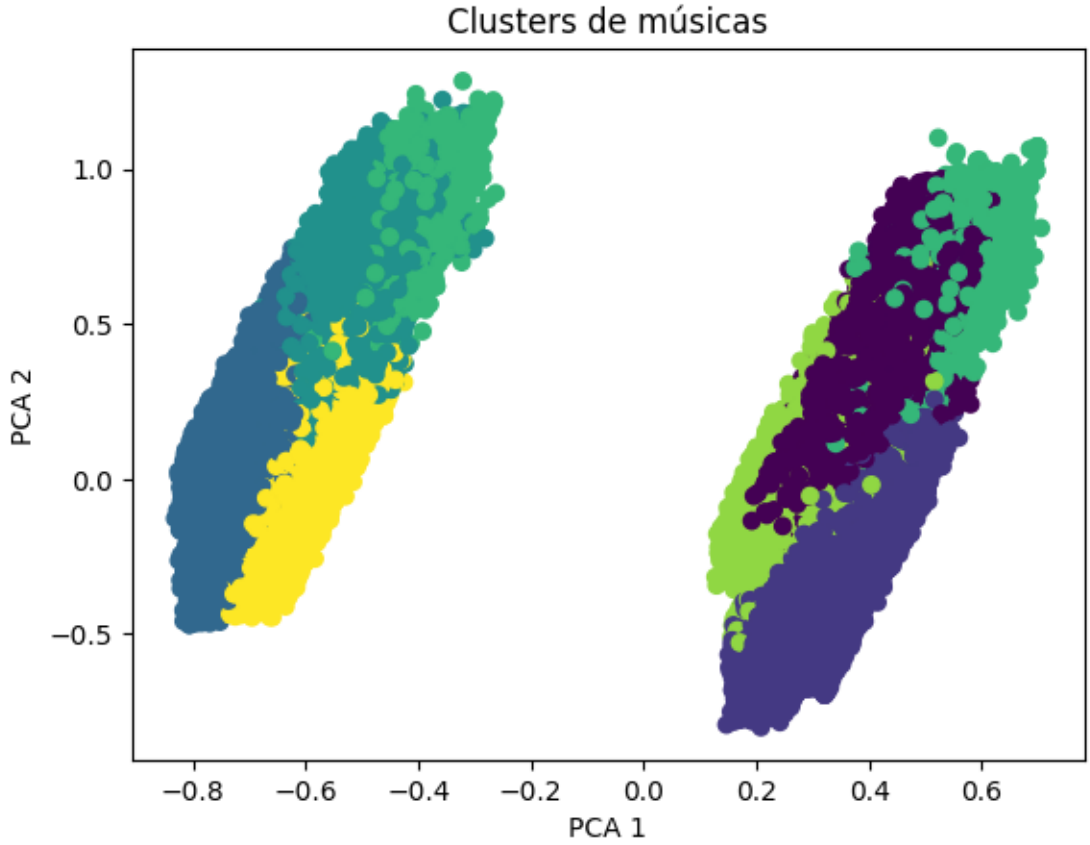

[138]:
```
from mpl_toolkits.mplot3d import Axes3D

pca = PCA(n_components=3)
X_pca_3d = pca.fit_transform(escala4)
```

```
fig = plt.figure(figsize=(10,8))
ax = fig.add_subplot(111, projection='3d')
scatter = ax.scatter(X_pca_3d[:, 0], X_pca_3d[:, 1], X_pca_3d[:, 2],
                     c=df_dados_normalizados4['cluster'], cmap='viridis')
ax.set_xlabel('PCA 1')
ax.set_ylabel('PCA 2')
ax.set_zlabel('PCA 3')
plt.title('Clusters em 3D com PCA')
fig.colorbar(scatter, ax=ax, label='Cluster')
plt.show()
```

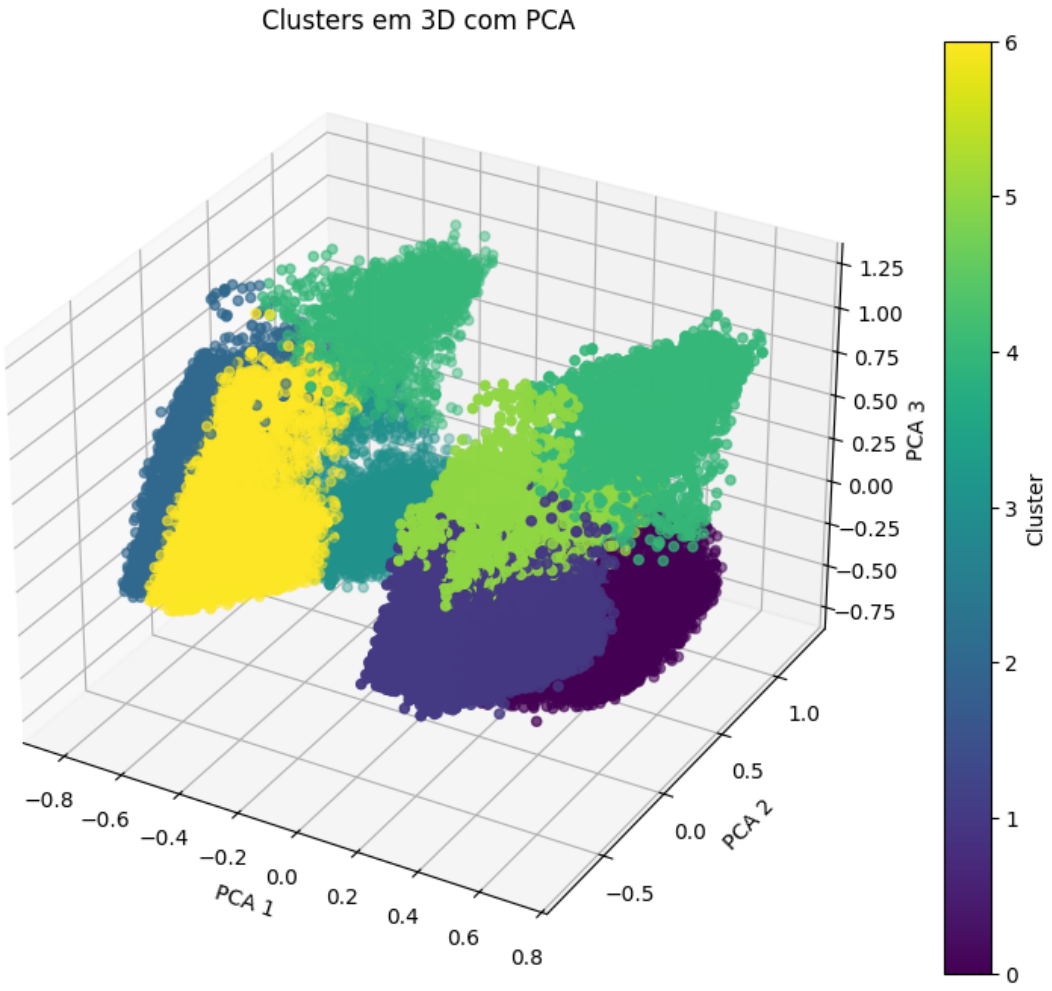

5.2 Analisando os Dados

[139]:
```
df_dados_normalizados4['cluster'].value_counts()
```

[139]:
```
cluster
1    30831
0    16102
6    12653
2    12354
4     6349
5     6044
3     5407
Name: count, dtype: int64
```

5.2.1 Dados Originais

[140]:
```
df_dados_media = df_dados.groupby('cluster').mean(numeric_only=True) #Para␣
↪histogramas
df_dados_media
```

[140]:

cluster	popularity	duration_ms	danceability	energy	key	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	32.795864	218357.337846	0.534535	0.397805	5.056018	-10.693765	1.000000	0.080258	0.645617	0.020292	0.184727	0.421555	113.042340	3.808782
1	34.794914	221842.710486	0.590766	0.769514	4.910869	-5.917412	1.000000	0.091659	0.175628	0.021109	0.249172	0.566335	128.199835	3.963673
2	33.316254	246772.990853	0.607742	0.755957	9.165129	-6.848869	0.000000	0.094254	0.129465	0.225609	0.212826	0.487327	125.634418	3.956694
3	30.463658	217480.252820	0.537491	0.407466	5.525985	-10.909479	0.000000	0.112988	0.749975	0.078030	0.222964	0.422468	113.871474	3.803773
4	29.563396	215031.307135	0.355796	0.178936	4.813829	-20.899163	0.659159	0.052027	0.871596	0.829377	0.163899	0.194033	103.489860	3.601827
5	26.485771	275757.100099	0.555490	0.760994	4.643779	-8.450949	1.000000	0.076642	0.101583	0.782472	0.200676	0.335155	127.462723	3.923891
6	35.907374	233251.716431	0.600431	0.753038	3.128902	-6.378263	0.000000	0.091674	0.146014	0.109119	0.215442	0.499468	125.308435	3.966648

5.2.2 Dados Normalizados

[141]:
```
df_dados_normalizados4_media = df_dados_normalizados4.groupby('cluster').mean()␣
 ↪# Para gráfico de médias
df_dados_normalizados4_media
```

[141]:

cluster	popularity	duration_ms	danceability	energy	key	loudness
0	0.327959	0.041693	0.542675	0.397805	0.459638	-0.215900
1	0.347949	0.042358	0.599762	0.769514	0.446443	-0.119469
2	0.333163	0.047118	0.616997	0.755957	0.833194	-0.138274
3	0.304637	0.041525	0.545676	0.407466	0.502362	-0.220256
4	0.295634	0.041058	0.361214	0.178936	0.437621	-0.421941
5	0.264858	0.052653	0.563950	0.760994	0.422162	-0.170619
6	0.359074	0.044537	0.609575	0.753038	0.284446	-0.128773

cluster	mode	speechiness	acousticness	instrumentalness	liveness
0	1.000000	0.083168	0.648210	0.020292	0.184727
1	1.000000	0.094983	0.176334	0.021109	0.249172
2	0.000000	0.097672	0.129985	0.225609	0.212826
3	0.000000	0.117086	0.752987	0.078030	0.222964
4	0.659159	0.053914	0.875096	0.829377	0.163899
5	1.000000	0.079422	0.101991	0.782472	0.200676
6	0.000000	0.094999	0.146601	0.109119	0.215442

cluster	valence	tempo	time_signature
0	0.423673	0.464484	0.761756
1	0.569181	0.526765	0.792735
2	0.489776	0.516224	0.791339
3	0.424591	0.467891	0.760755
4	0.195008	0.425233	0.720365
5	0.336840	0.523736	0.784778
6	0.501978	0.514884	0.793330

5.2.3 Gênero de músicas por cluster

[142]:
```
genero_por_cluster = df_musicas_maxabs.groupby('cluster').apply(
    lambda x: x['track_genre'].value_counts().head(7),
    include_groups=False
)
genero_por_cluster
```

[142]:

cluster	track_genre	
0	honky-tonk	819
	comedy	604
	cantopop	588

```
          acoustic          556
          show-tunes        481
          opera             466
          mandopop          445
1         j-idol            661
          forro             628
          party             600
          sertanejo         577
          power-pop         571
          kids              551
          pagode            523
2         chicago-house     327
          detroit-techno    322
          drum-and-bass     301
          breakbeat         271
          minimal-techno    263
          hardstyle         258
          deep-house        247
3         romance           503
          tango             447
          comedy            250
          chill             150
          study             144
          malay             137
          opera             132
4         new-age           741
          sleep             693
          ambient           657
          classical         604
          piano             418
          disney            415
          iranian           400
5         minimal-techno    419
          detroit-techno    388
          grindcore         383
          black-metal       311
          study             281
          breakbeat         273
          chicago-house     269
6         dancehall         265
          deep-house        263
          dance             244
          metalcore         239
          turkish           236
          k-pop             231
          hardstyle         229
Name: count, dtype: int64
```

5.3 Gráficos

5.3.1 Características x Cluster

[143]:
```
df_dados_normalizados4_media.plot(kind='bar')
plt.title('Caracteristicas por cluster')
plt.legend(bbox_to_anchor=(1.0, 1.0))
plt.show()
```

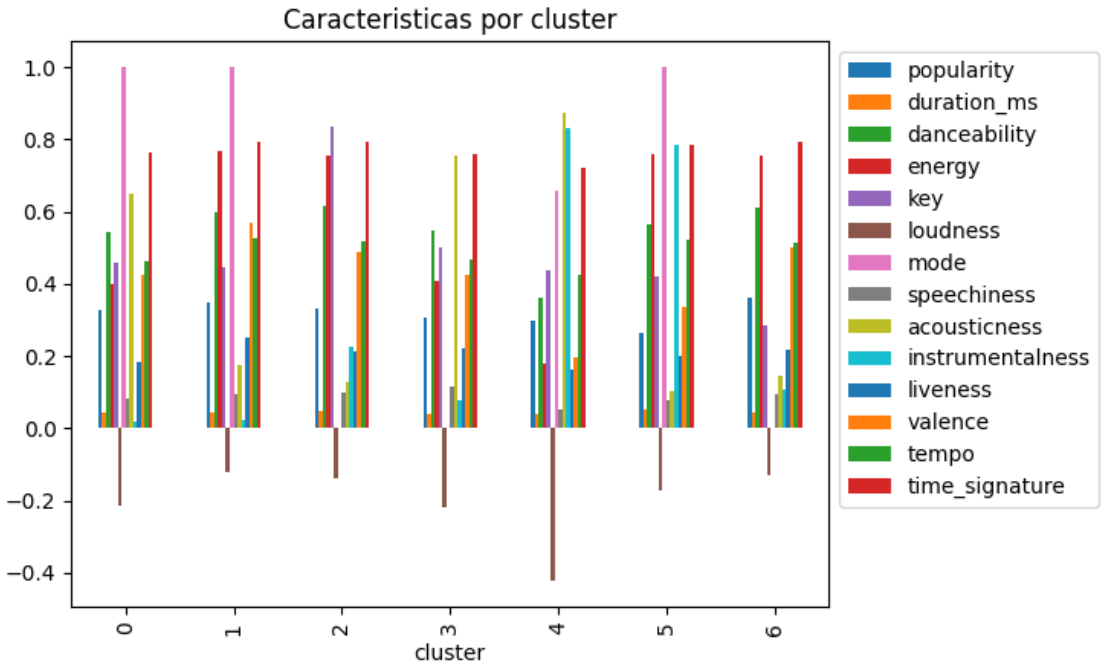

5.3.2 Cluster x Características

[144]:
```
df_dados_normalizados4_media.T.plot(kind='bar')
plt.title('Clusters por característica')
plt.legend(title='Cluster', bbox_to_anchor=(1.0, 1.0))
plt.tight_layout()
plt.show()
```

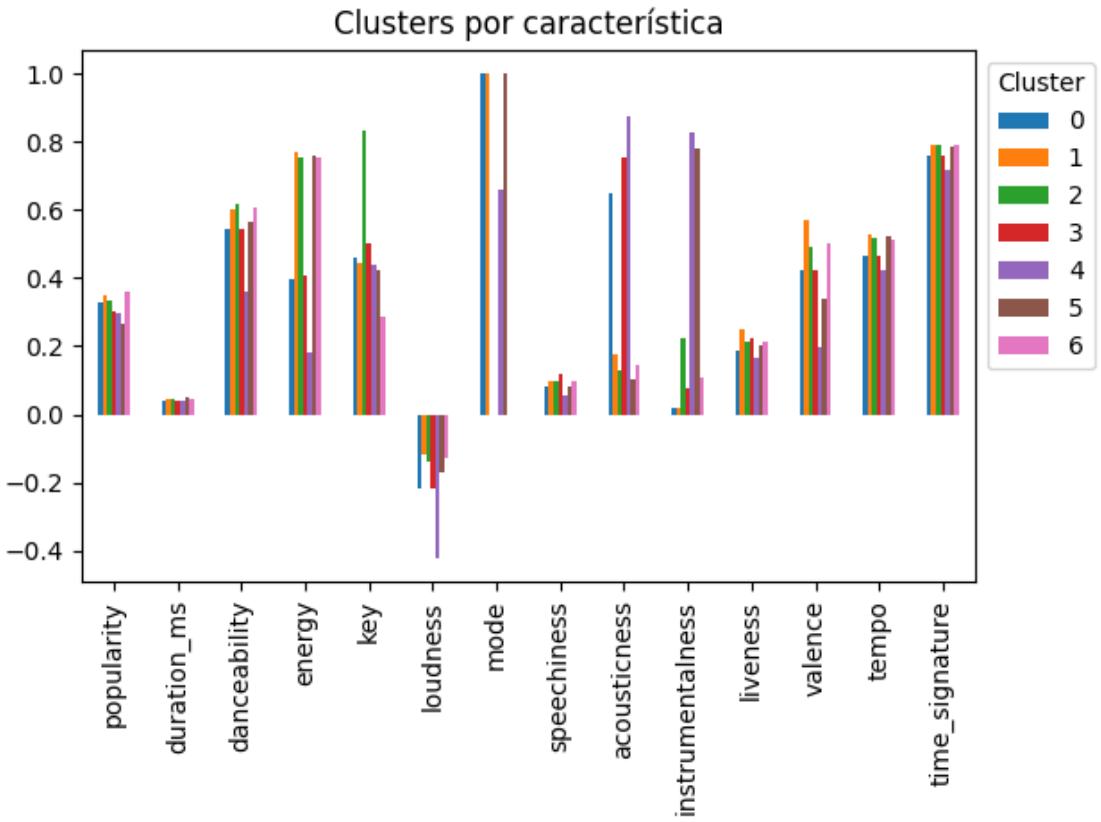

5.3.3 Histogramas

[145]:
```
import matplotlib.pyplot as plt

for feature in df_dados.columns.drop('cluster'):
    plt.figure(figsize=(8, 5))

    for cluster_id in sorted(df_dados['cluster'].unique()):
        subset = df_dados[df_dados['cluster'] == cluster_id]
        tamanho = tamanho_amostra(len(subset))
        amostra = subset.sample(n=min(tamanho, len(subset)), random_state=42)
 ↪# Garante que não passa o tamanho real
        plt.hist(amostra[feature], bins=30, alpha=0.5, label=f'Cluster
 ↪{cluster_id} (n={len(amostra)})')

    plt.title(f'Distribuição de {feature} por Cluster (com amostragem)')
    plt.xlabel(feature)
    plt.ylabel('Frequência')
    plt.legend()
    plt.tight_layout()
```

```
plt.show()
```

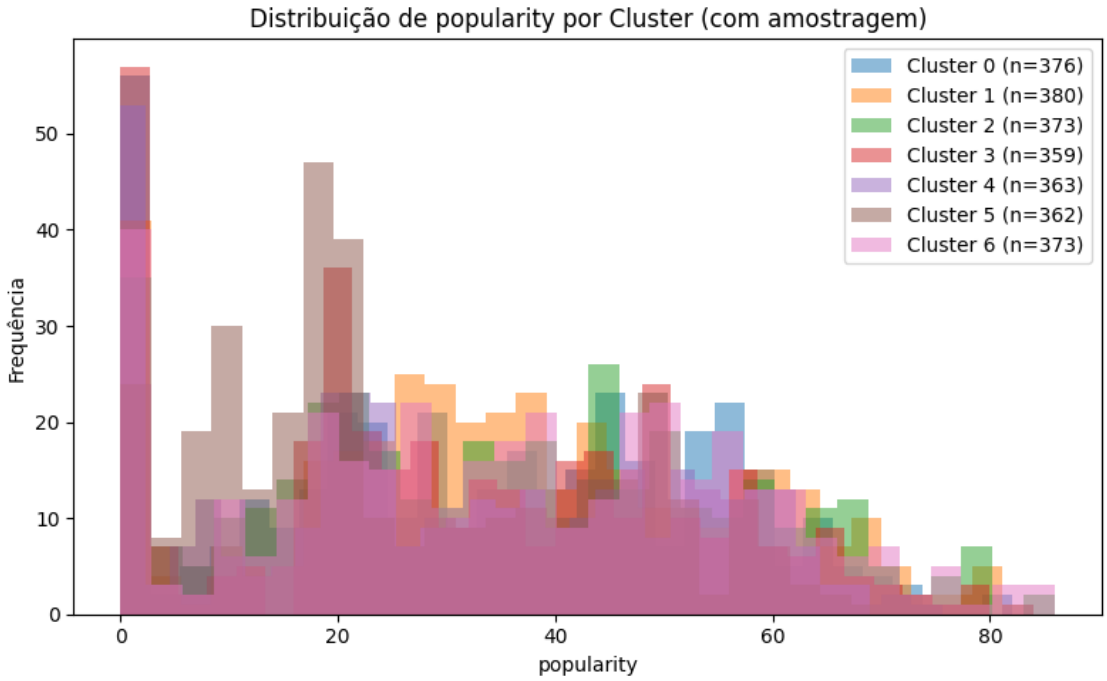
Distribuição de popularity por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
popularity
0
10
20
30
40
50
0
20
40
60
80

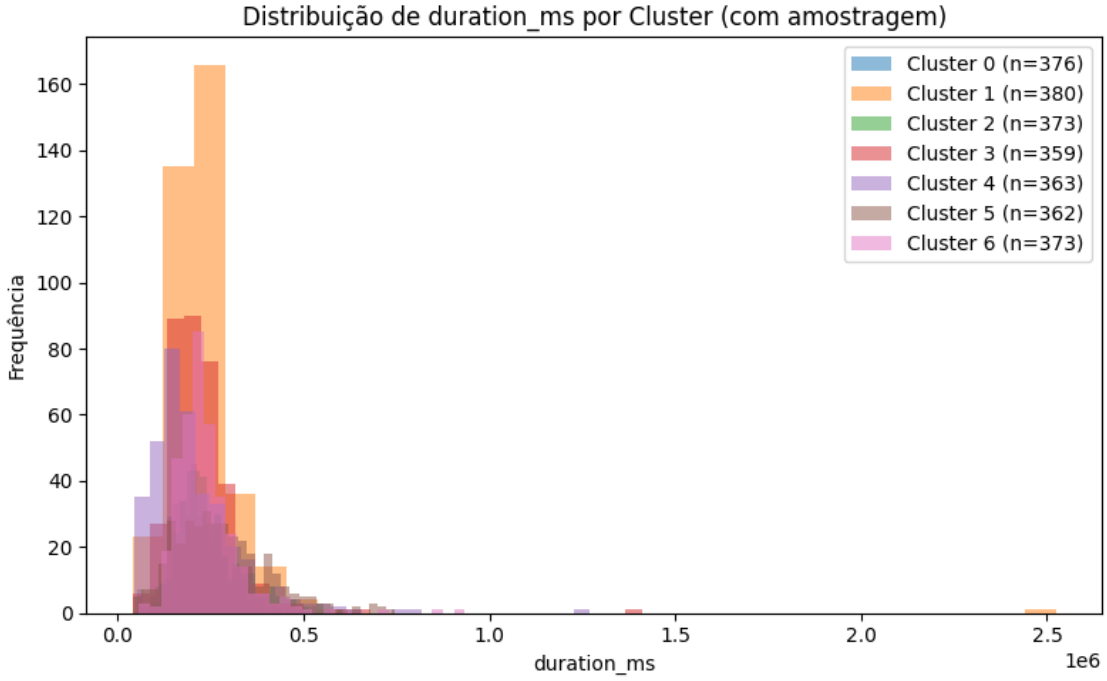
Distribuição de duration_ms por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
duration_ms
1e6
0
20
40
60
80
100
120
140
160
0.0
0.5
1.0
1.5
2.0
2.5

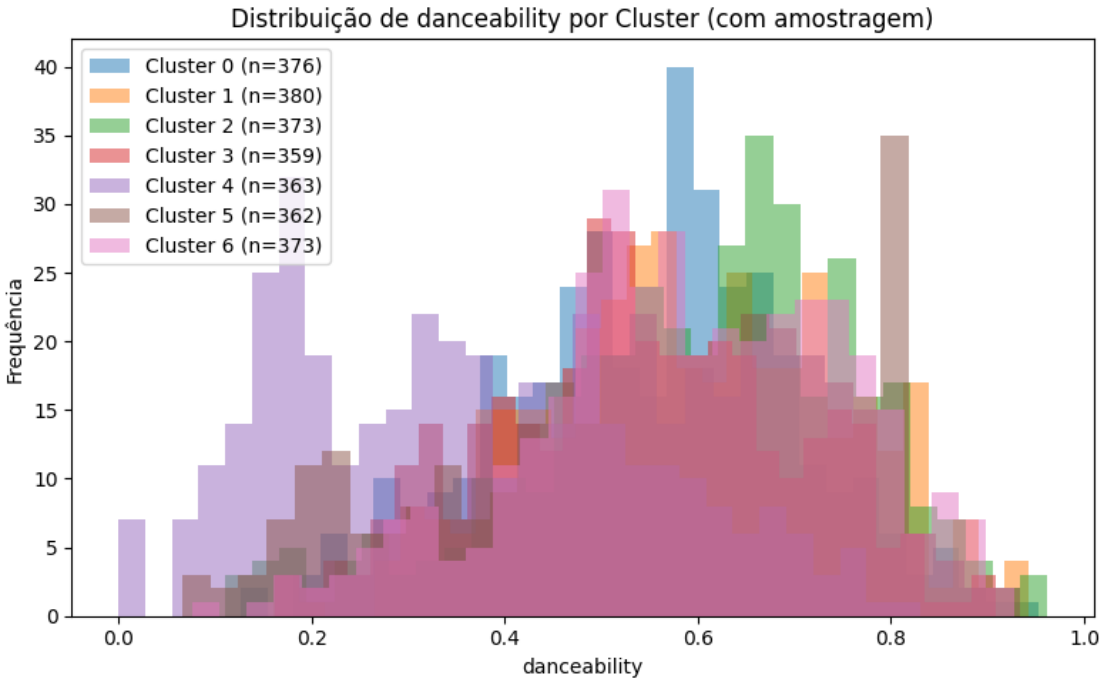
Distribuição de danceability por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
danceability
0
5
10
15
20
25
30
35
40
0.0
0.2
0.4
0.6
0.8
1.0

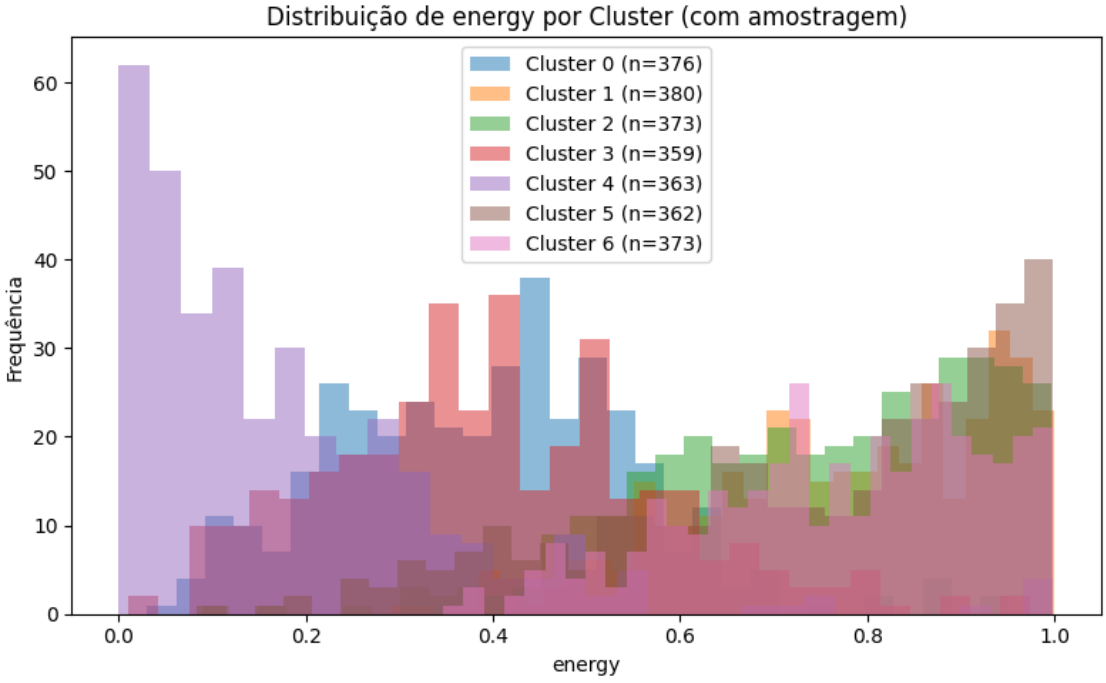
Distribuição de energy por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
energy
0
10
20
30
40
50
60
0.0
0.2
0.4
0.6
0.8
1.0

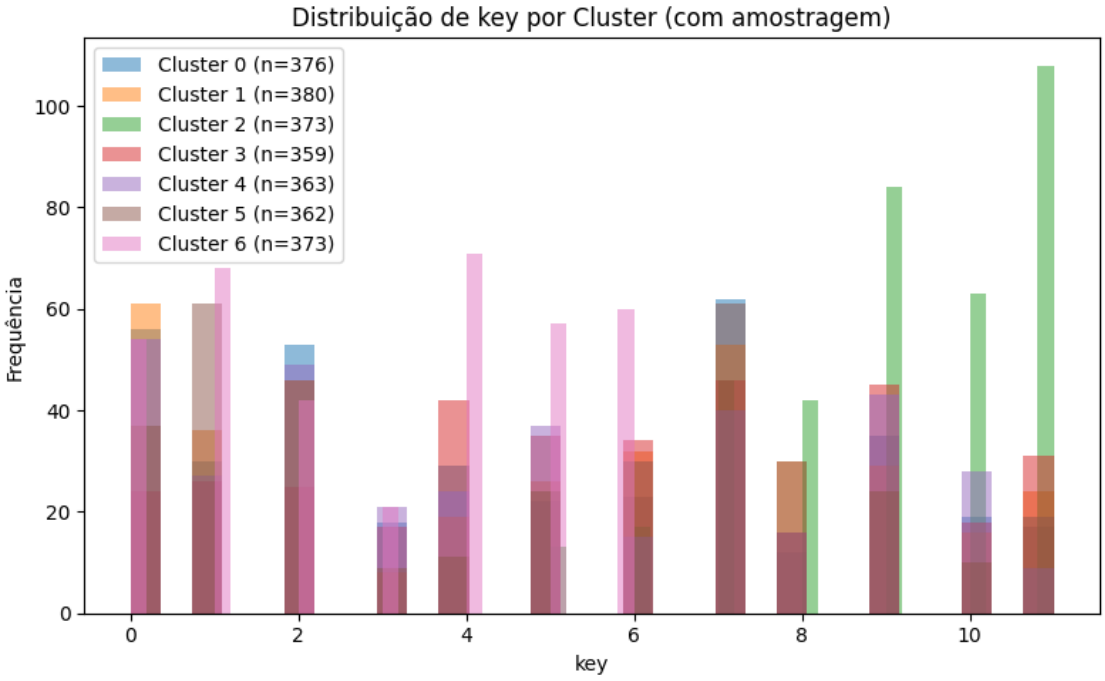
Distribuição de key por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
key

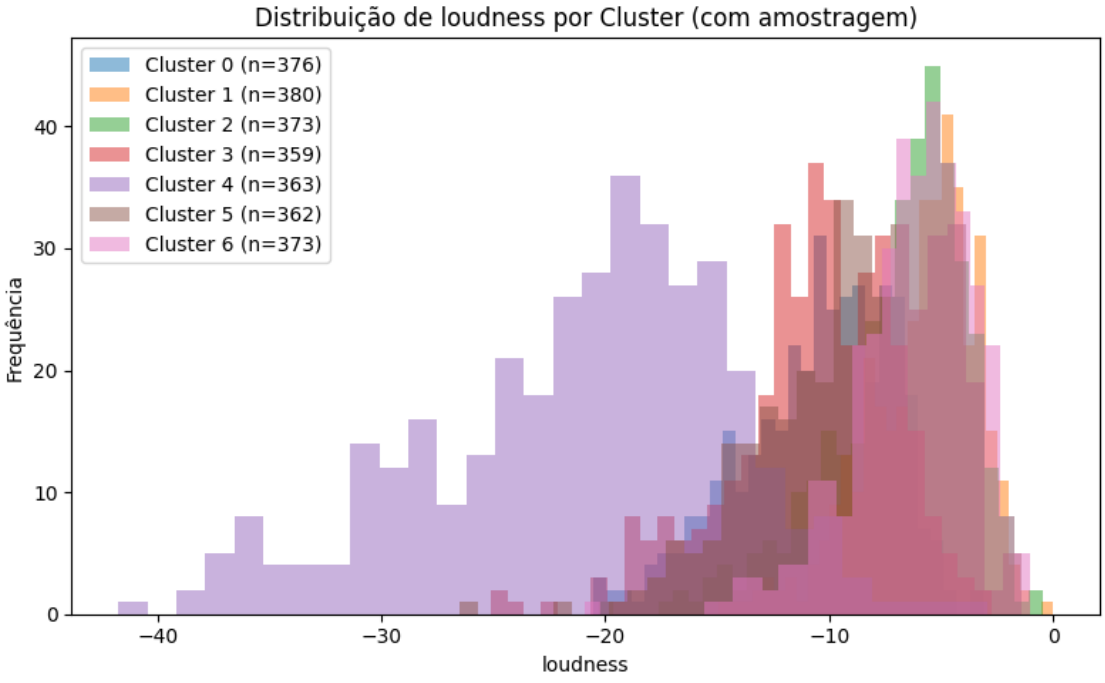
Distribuição de loudness por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
loudness

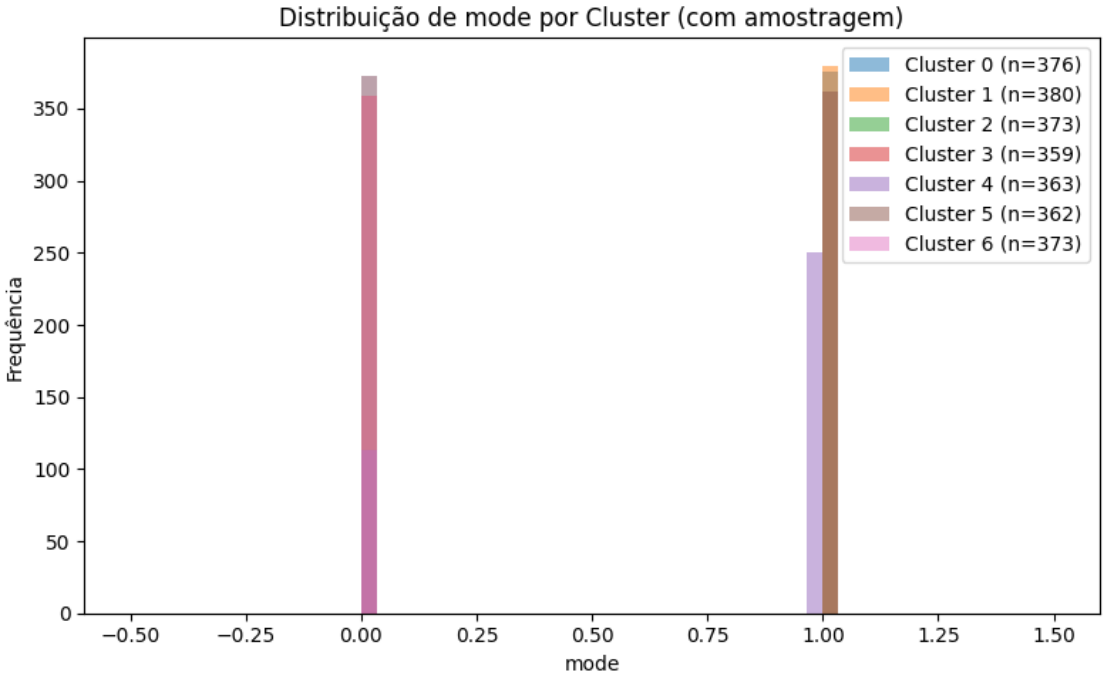
Distribuição de mode por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
mode

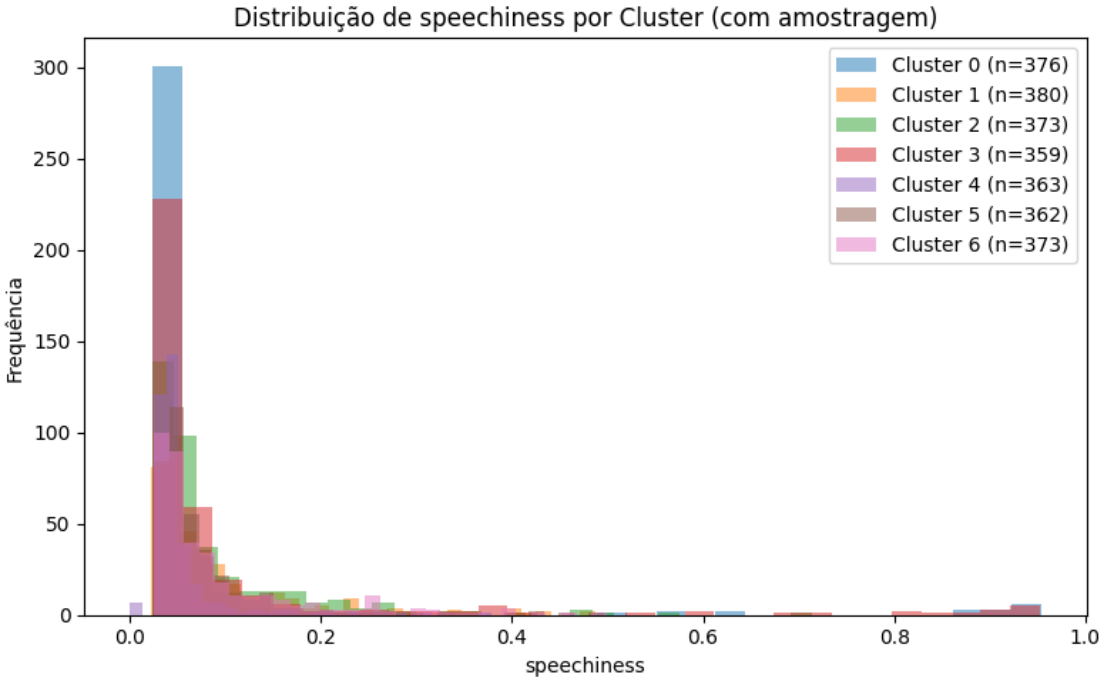
Distribuição de speechiness por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
speechiness

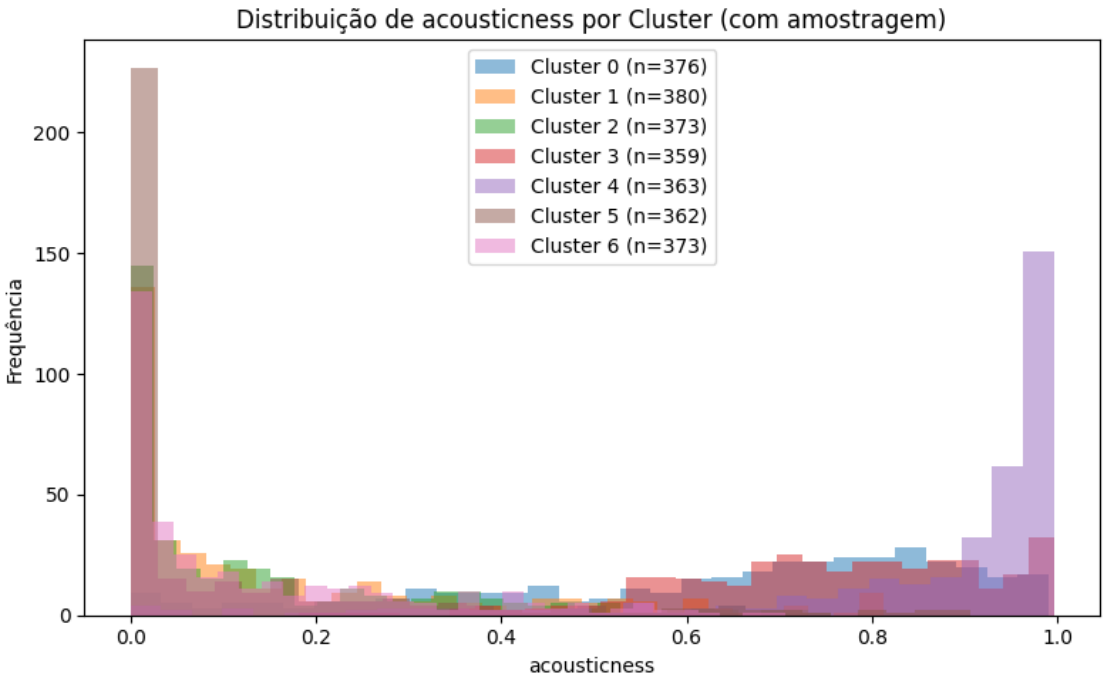
Distribuição de acousticness por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
acousticness
0
50
100
150
200
0.0
0.2
0.4
0.6
0.8
1.0

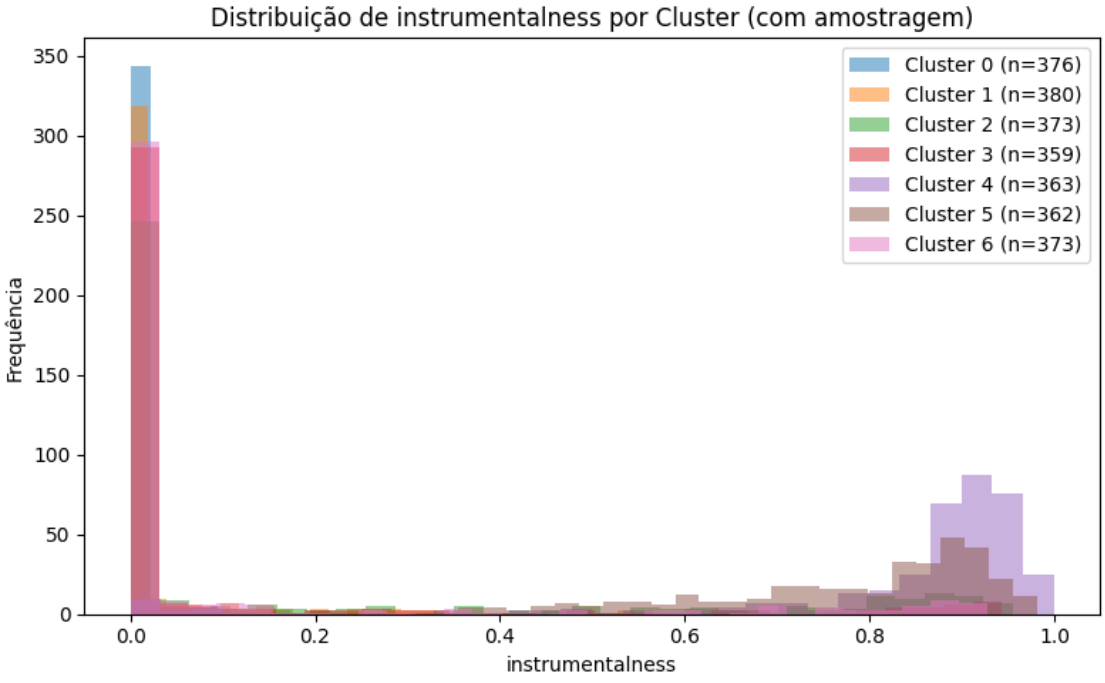
Distribuição de instrumentalness por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
instrumentalness
0
50
100
150
200
250
300
350
0.0
0.2
0.4
0.6
0.8
1.0

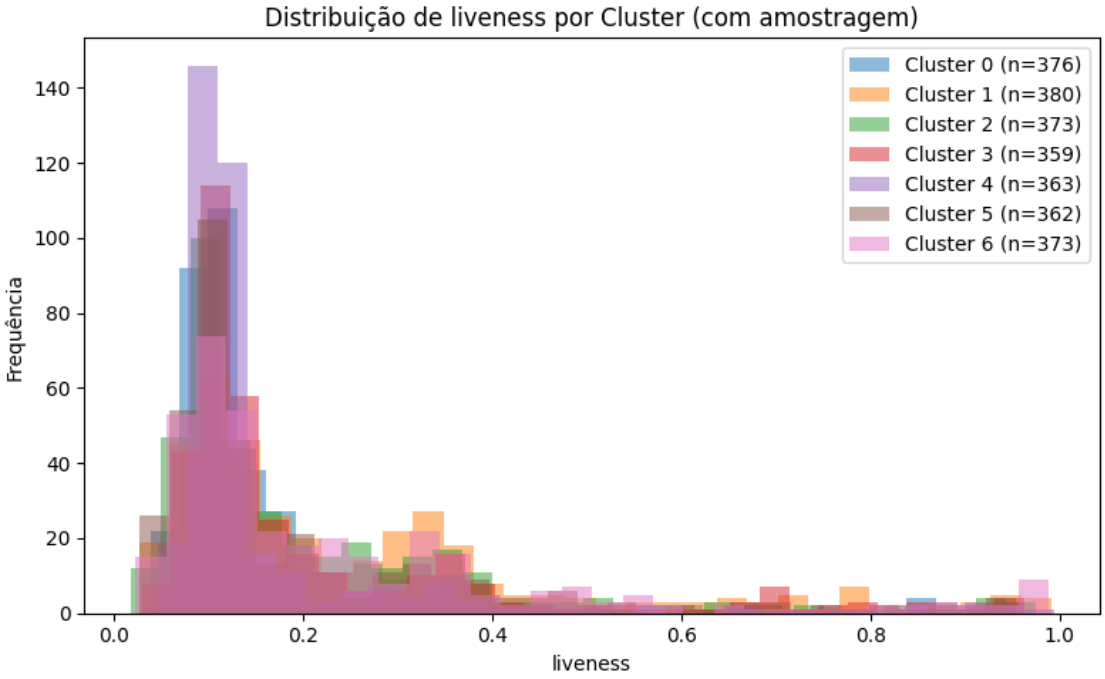
Distribuição de liveness por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
liveness
0
20
40
60
80
100
120
140
0.0
0.2
0.4
0.6
0.8
1.0

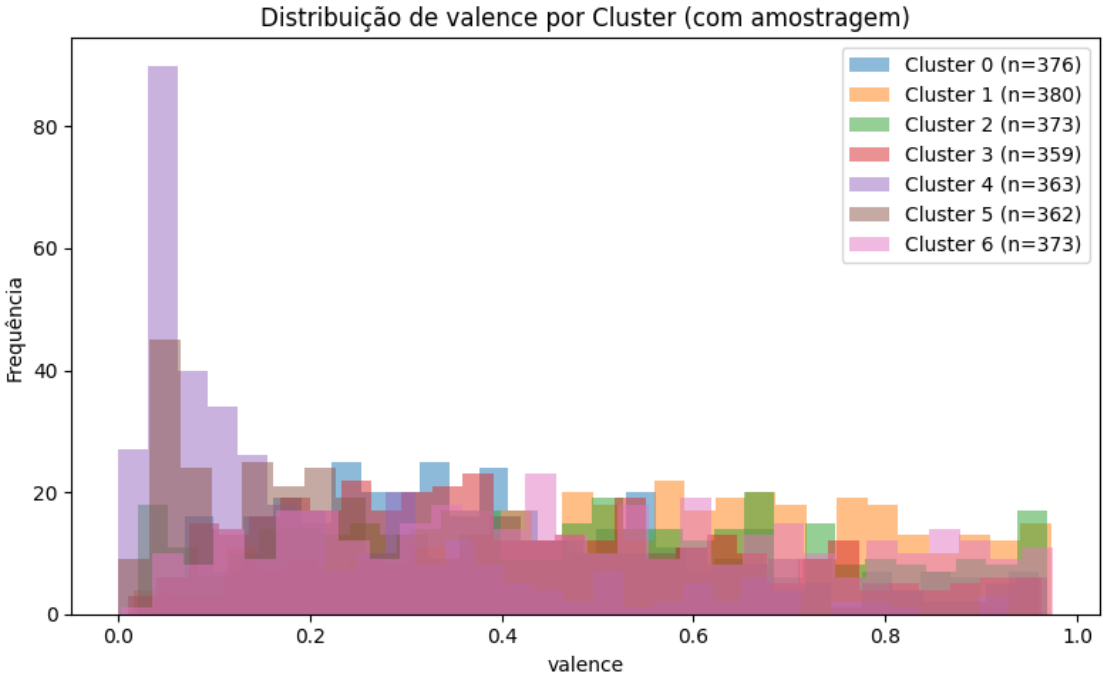
Distribuição de valence por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
valence
0
20
40
60
80
0.0
0.2
0.4
0.6
0.8
1.0

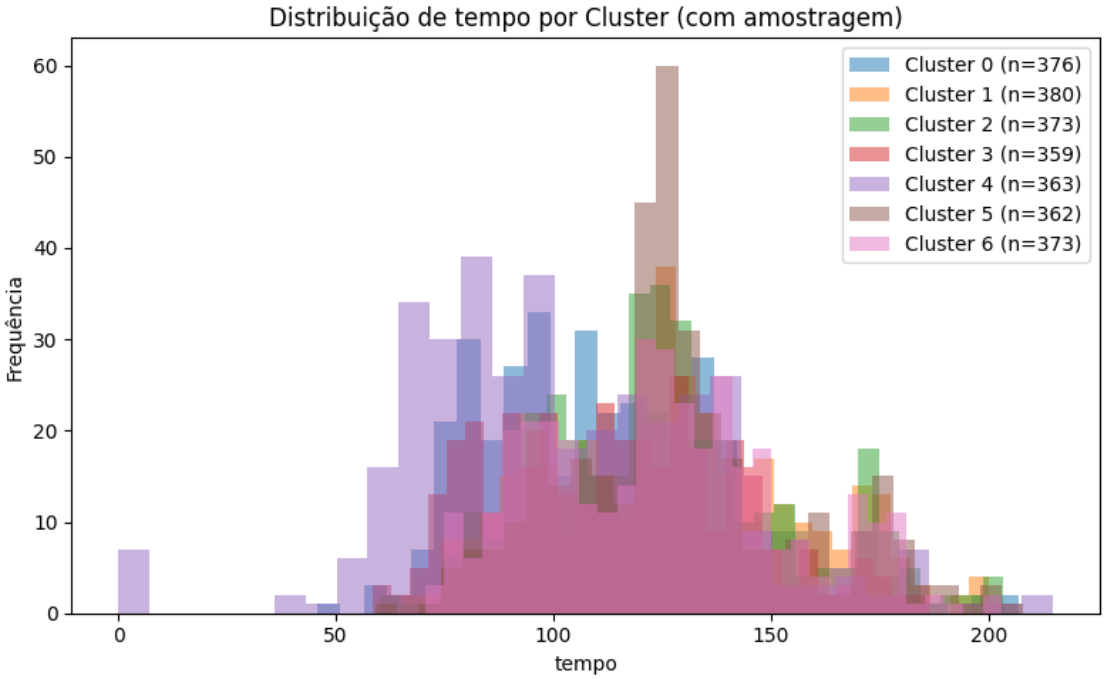
Distribuição de tempo por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
tempo
0
10
20
30
40
50
60
0
50
100
150
200

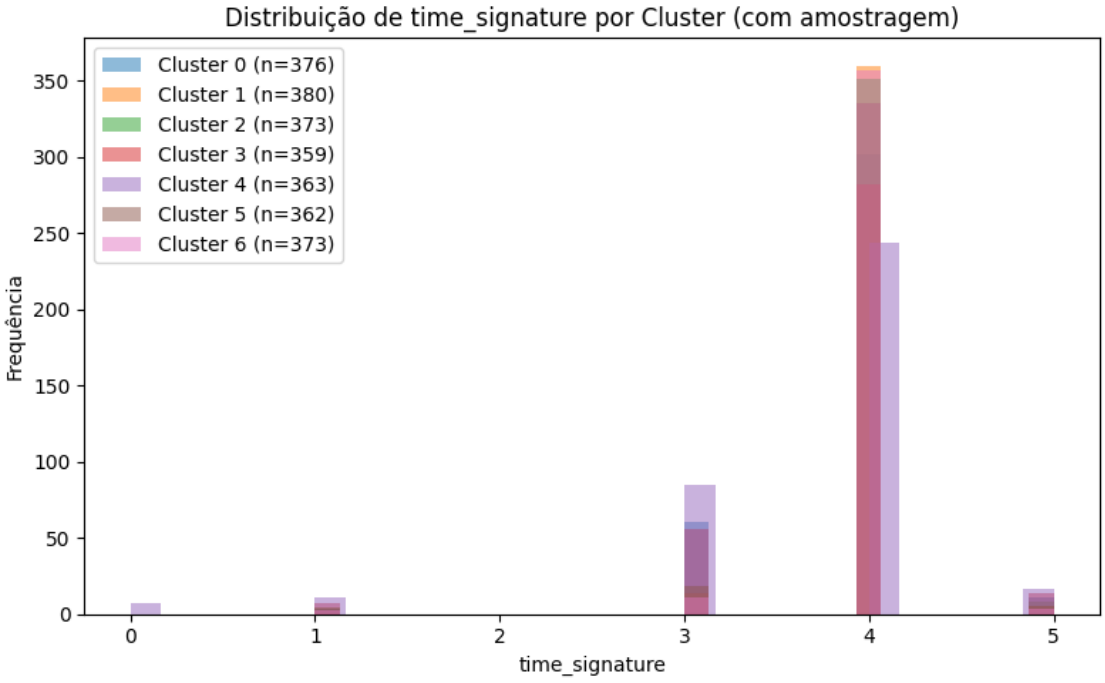
Distribuição de time_signature por Cluster (com amostragem)
Cluster 0 (n=376)
Cluster 1 (n=380)
Cluster 2 (n=373)
Cluster 3 (n=359)
Cluster 4 (n=363)
Cluster 5 (n=362)
Cluster 6 (n=373)
Frequência
time_signature
0
50
100
150
200
250
300
350
0
1
2
3
4
5

5.4 Musica

[146]:
```
recomendar_musicas(track_id='2aibwv5hGXSgw7Yru8IYTO',df_dados_normalizados=df_dados_normalizad
```

```
Cluster: 1
```

[146]:

	track_name	artists	track_genre
2110	Monster	Skillet	alt-rock
44195	Fake It	Seether	grunge
56827	I'm Born To Run	American Authors	indie-pop
82063	Buddy Holly	Weezer	power-pop
2357	HandClap	Fitz and The Tantrums	alt-rock
65364	Love Maze	BTS	k-pop
65464	Alcohol-Free	TWICE	k-pop
30764	What Would You Do?	Joel Corry;David Guetta;Bryson Tiller	edm
38090	Teddy Picker	Arctic Monkeys	garage
65823	DOMINO	Stray Kids	k-pop

6 Sem normalizar os dados

[147]:
```
df_dados = df_musicas.select_dtypes(include='number')
soma_erros = calcular_soma_erros(df_dados)
```

[148]:
```
plt.plot(range(1, 20), soma_erros, marker='o')
plt.xlabel('Número de Clusters (k)')
plt.ylabel('Soma dos Erros Quadrados (SEQ)')
plt.title('Método do Cotovelo')
plt.show()
```

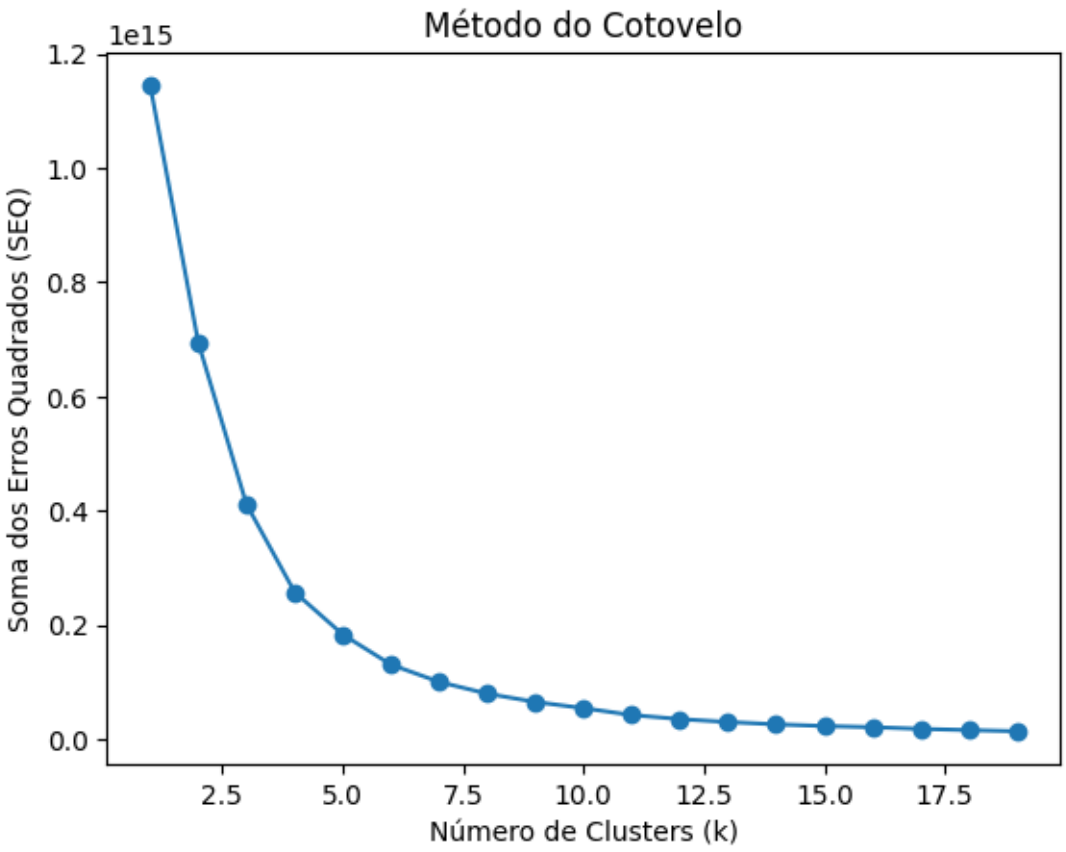

[149]:
```
numero_clusters = optimal_number_of_clusters(soma_erros)
numero_clusters
```

[149]: 6

[150]:
```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=numero_clusters, random_state=14)
clusters = kmeans.fit_predict(df_dados)

df_musicas_= df_musicas.copy()
df_musicas_['cluster'] = clusters
df_dados['cluster'] = clusters
```

6.1 Plotagem 2D e 3D

[151]:
```
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt

pca = PCA(n_components=2)
X_pca = pca.fit_transform(df_dados)
```

```
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=df_dados['cluster'], cmap='viridis')
plt.xlabel('PCA 1')
plt.ylabel('PCA 2')
plt.title('Clusters de músicas')
plt.show()
```

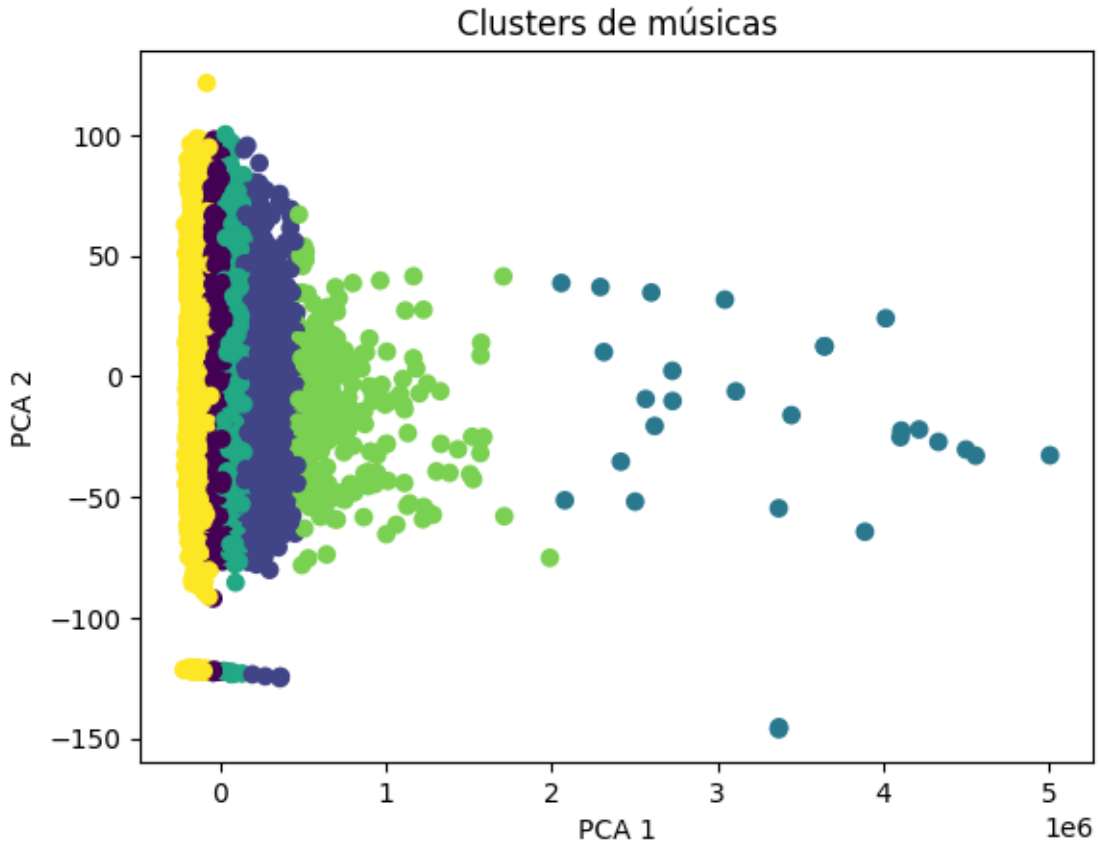

[152]:
```
from mpl_toolkits.mplot3d import Axes3D

pca = PCA(n_components=3)
X_pca_3d = pca.fit_transform(df_dados)

fig = plt.figure(figsize=(10,8))
ax = fig.add_subplot(111, projection='3d')
scatter = ax.scatter(X_pca_3d[:, 0], X_pca_3d[:, 1], X_pca_3d[:, 2],
                     c=df_dados['cluster'], cmap='viridis')
ax.set_xlabel('PCA 1')
ax.set_ylabel('PCA 2')
ax.set_zlabel('PCA 3')
```

```
plt.title('Clusters em 3D com PCA')
fig.colorbar(scatter, ax=ax, label='Cluster')
plt.show()
```

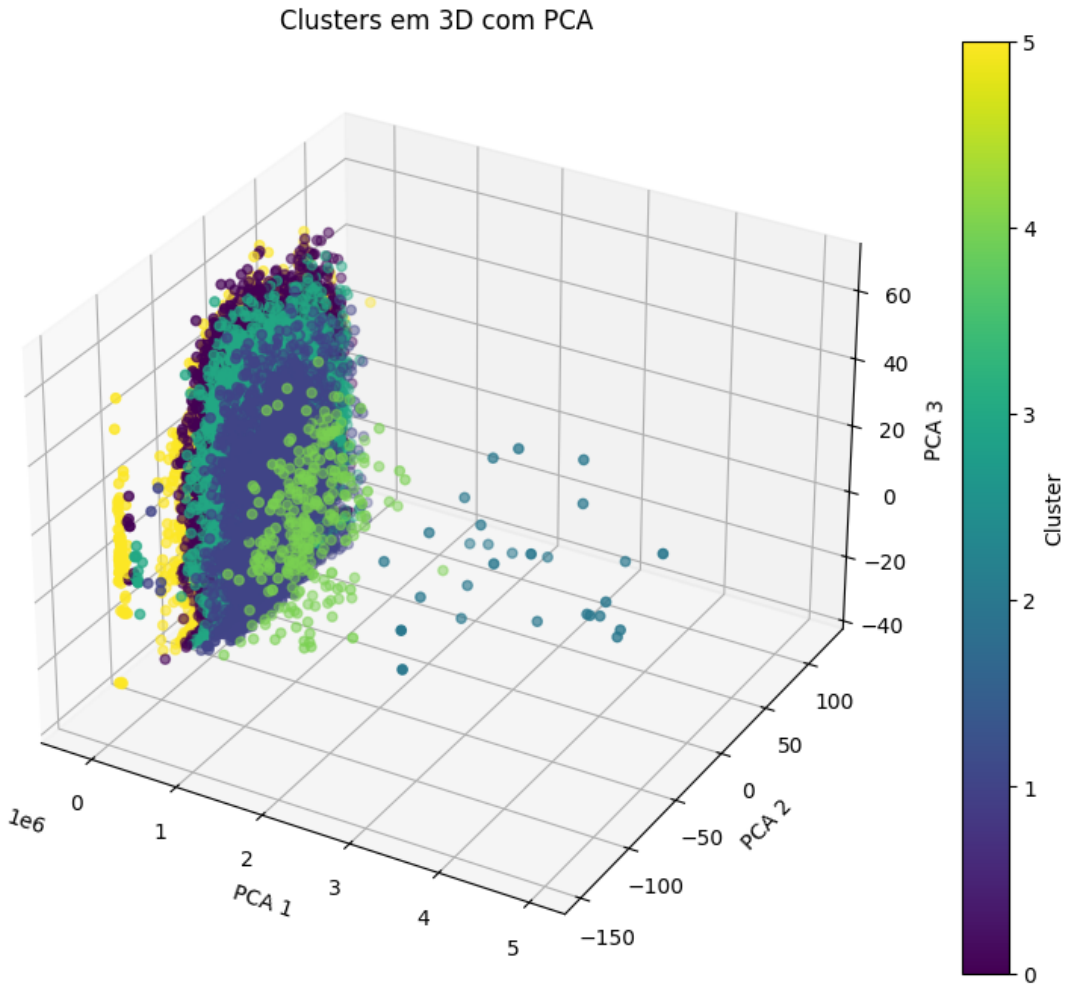

6.2 Analisando os Dados

[153]:
```
df_dados['cluster'].value_counts()
```

[153]:
```
cluster
0    40722
5    22719
3    20455
1     5527
4      289
2       28
Name: count, dtype: int64
```

6.2.1 Média por colunas em cada cluster

[154]:
```
df_dados_media = df_dados.groupby('cluster').mean(numeric_only=True) #Para␣
↪histogramas
df_dados_media
```

[154]:

cluster	popularity	duration_ms	danceability	energy	key	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	34.816856	2.111165e+05	0.572026	0.661627	5.293674	-7.619783	0.633441	0.083476	0.299293	0.105262	0.215343	0.488386	122.882838	3.920583
1	27.684096	4.471515e+05	0.542549	0.637954	5.438755	-10.198387	0.583318	0.081148	0.243171	0.452481	0.223716	0.335568	122.529896	3.894156
2	22.642857	3.539151e+06	0.535950	0.669855	4.821429	-9.679250	0.642857	0.054343	0.304207	0.357049	0.166929	0.396290	123.613500	3.607143
3	33.698802	2.946916e+05	0.538147	0.660156	5.307993	-8.196155	0.620093	0.075459	0.288332	0.187837	0.216945	0.422715	123.558110	3.908726
4	24.716263	9.428537e+05	0.417203	0.511397	4.989619	-12.935190	0.626298	0.115398	0.453128	0.409456	0.290933	0.295293	115.700588	3.820069
5	31.310929	1.362483e+05	0.572769	0.563295	5.209868	-9.876261	0.671684	0.106557	0.435370	0.211471	0.217392	0.512559	119.193605	3.847881

6.3 Gêneros de músicas por cluster

[155]:
```
genero_por_cluster = df_musicas_.groupby('cluster').apply(
    lambda x: x['track_genre'].value_counts().head(7),
    include_groups=False
)
genero_por_cluster
```

[155]:

cluster	track_genre	
0	country	647
	dancehall	635
	dance	622
	alt-rock	599
	spanish	595

```
          party             594
          disco             586
1         minimal-techno    439
          detroit-techno    416
          chicago-house     405
          iranian           256
          trance            216
          black-metal       210
          new-age           181
2         breakbeat           7
          chicago-house       3
          sleep               3
          classical           2
          detroit-techno      2
          guitar              2
          k-pop               2
3         salsa             611
          j-idol            520
          drum-and-bass     517
          pop-film          489
          breakbeat         440
          mandopop          423
          malay             416
4         iranian            27
          new-age            27
          folk               24
          detroit-techno     22
          black-metal        21
          classical          20
          comedy             12
5         study             856
          children          710
          grindcore         707
          honky-tonk        689
          disney            620
          kids              600
          sleep             568
Name: count, dtype: int64
```

6.4 Gráficos

6.4.1 Características x Cluster

[156]:
```
df_dados_media.plot(kind='bar')
plt.title('Caracteristicas por cluster')
plt.legend(bbox_to_anchor=(1.0, 1.0))
plt.show()
```

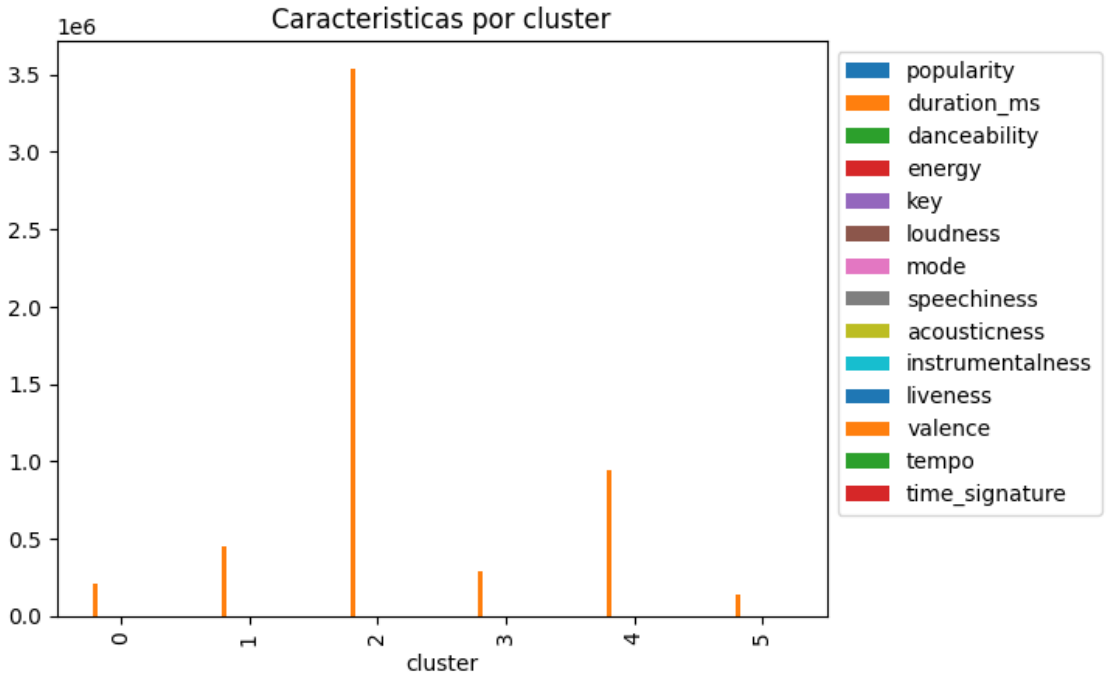

6.4.2 Cluster x Características

[157]:
```
df_dados_media.T.plot(kind='bar')
plt.title('Clusters por característica')
plt.legend(title='Cluster', bbox_to_anchor=(1.0, 1.0))
plt.tight_layout()
plt.show()
```

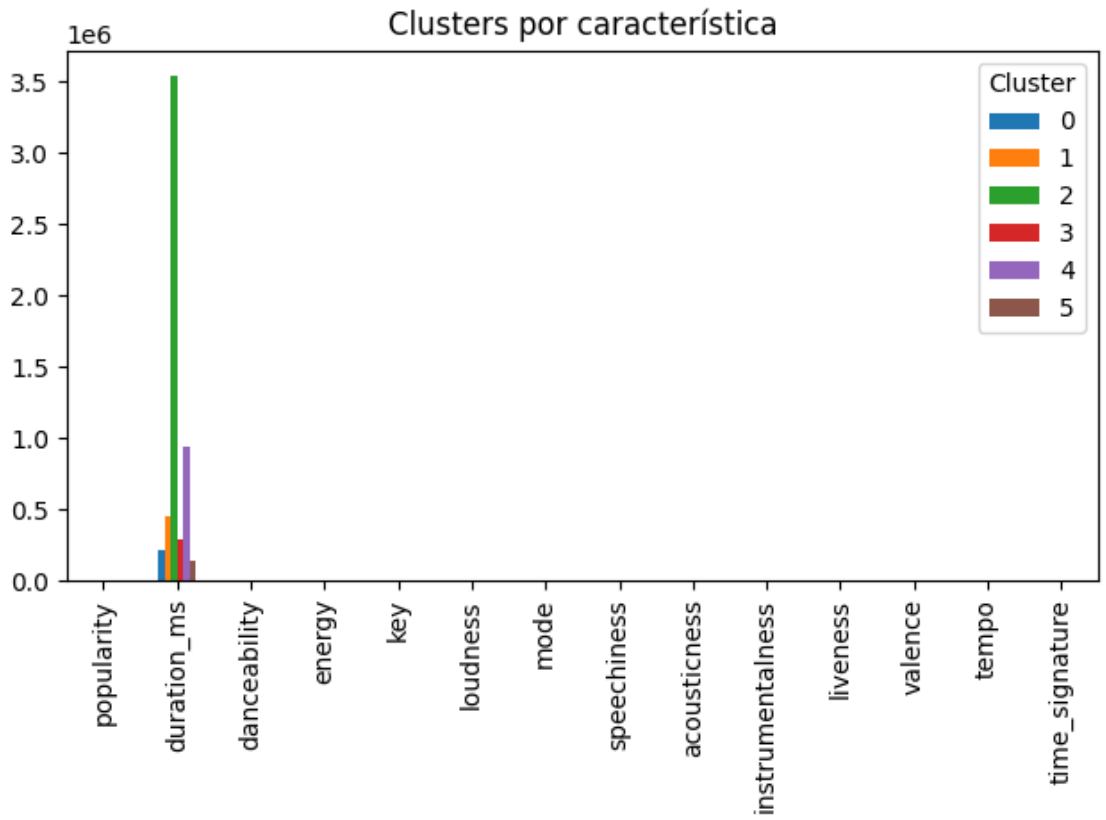

6.4.3 Histogramas

[158]:
```
import matplotlib.pyplot as plt

for feature in df_dados.columns.drop('cluster'):
    plt.figure(figsize=(8, 5))

    for cluster_id in sorted(df_dados['cluster'].unique()):
        subset = df_dados[df_dados['cluster'] == cluster_id]
        tamanho = tamanho_amostra(len(subset))
        amostra = subset.sample(n=min(tamanho, len(subset)), random_state=42)
 ↪# Garante que não passa o tamanho real
        plt.hist(amostra[feature], bins=30, alpha=0.5, label=f'Cluster
 ↪{cluster_id} (n={len(amostra)})')

    plt.title(f'Distribuição de {feature} por Cluster (com amostragem)')
    plt.xlabel(feature)
    plt.ylabel('Frequência')
    plt.legend()
    plt.tight_layout()
```

```
    plt.show()
```

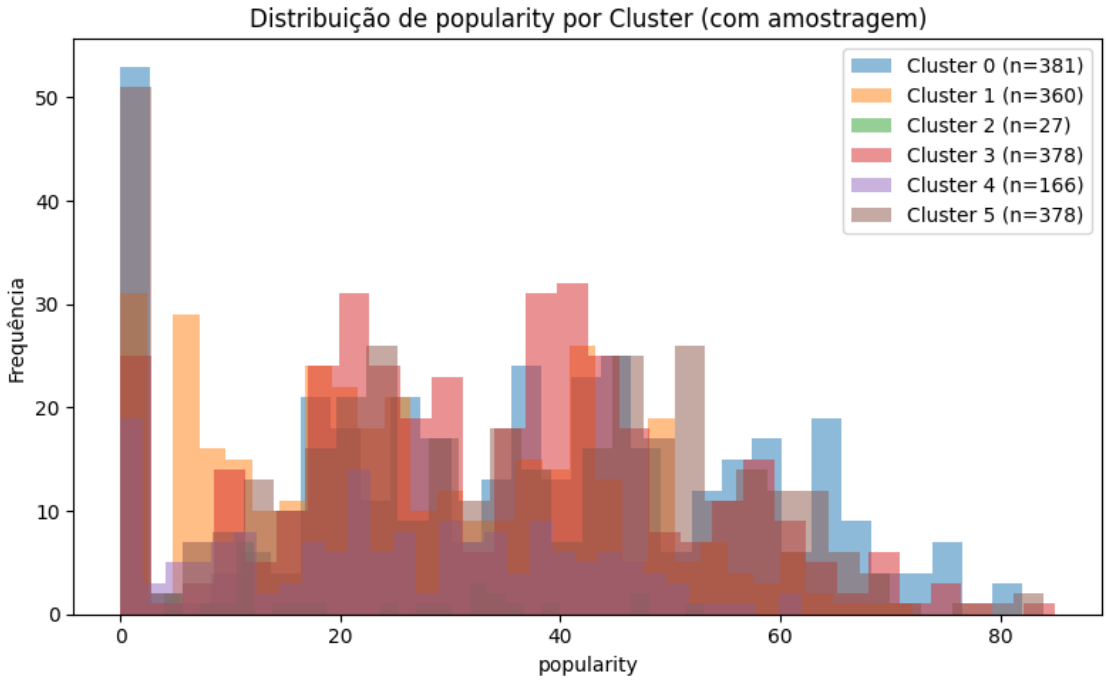
Distribuição de popularity por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
popularity
0
10
20
30
40
50
0
20
40
60
80

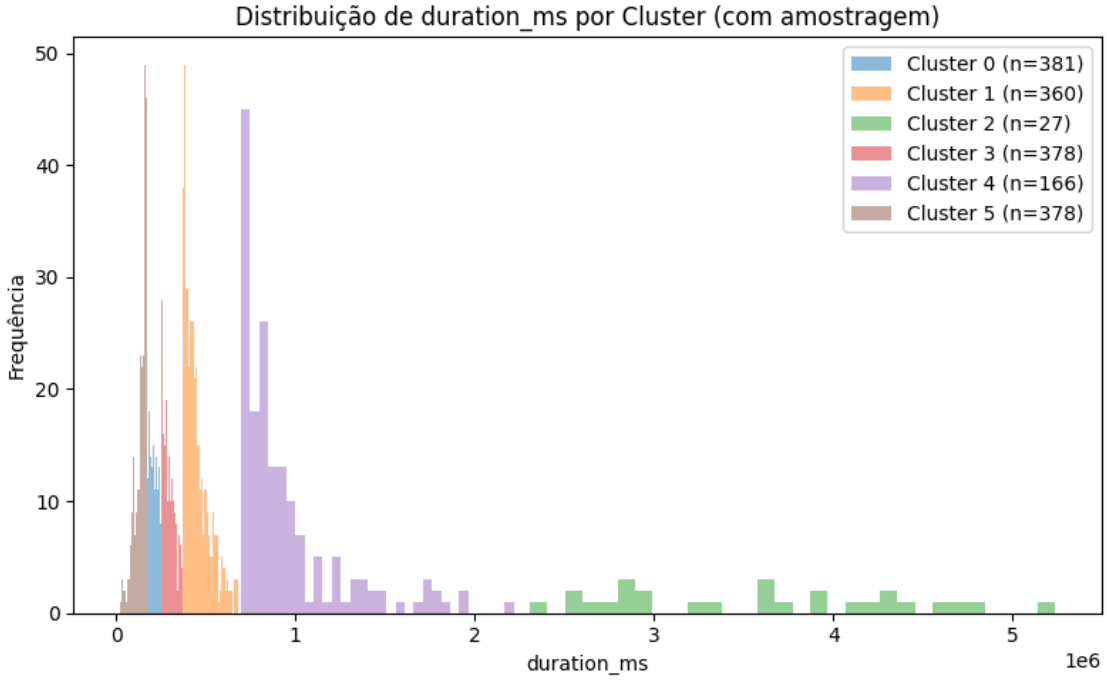
Distribuição de duration_ms por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
duration_ms
1e6
0
10
20
30
40
50
0
1
2
3
4
5

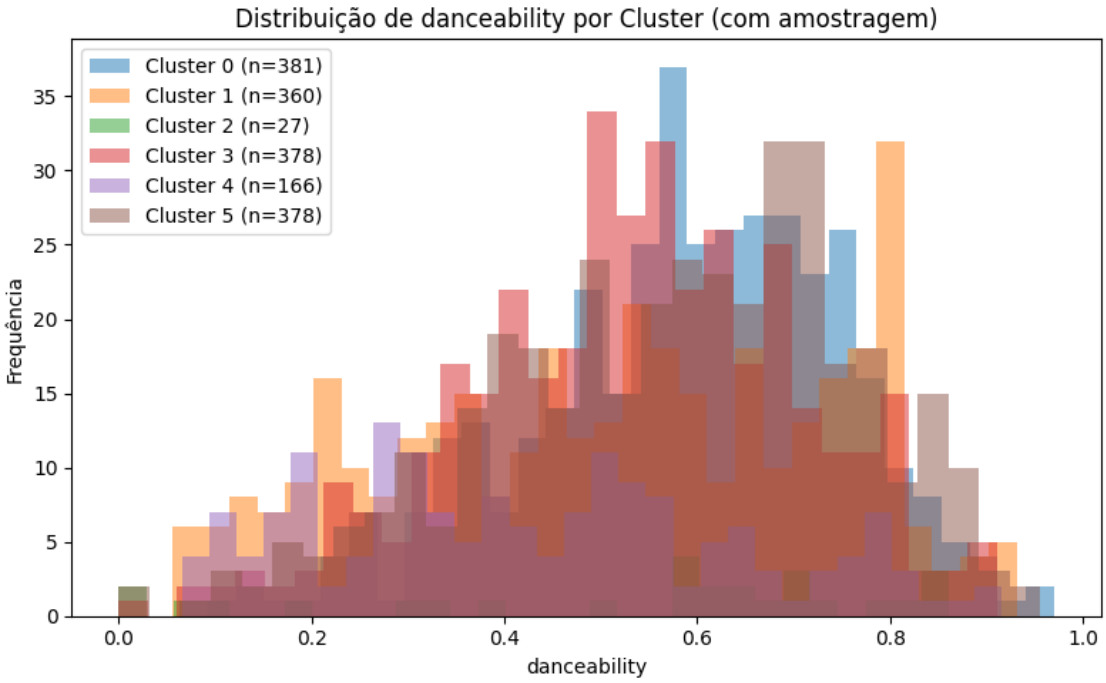
Distribuição de danceability por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
danceability
0
5
10
15
20
25
30
35
0.0
0.2
0.4
0.6
0.8
1.0

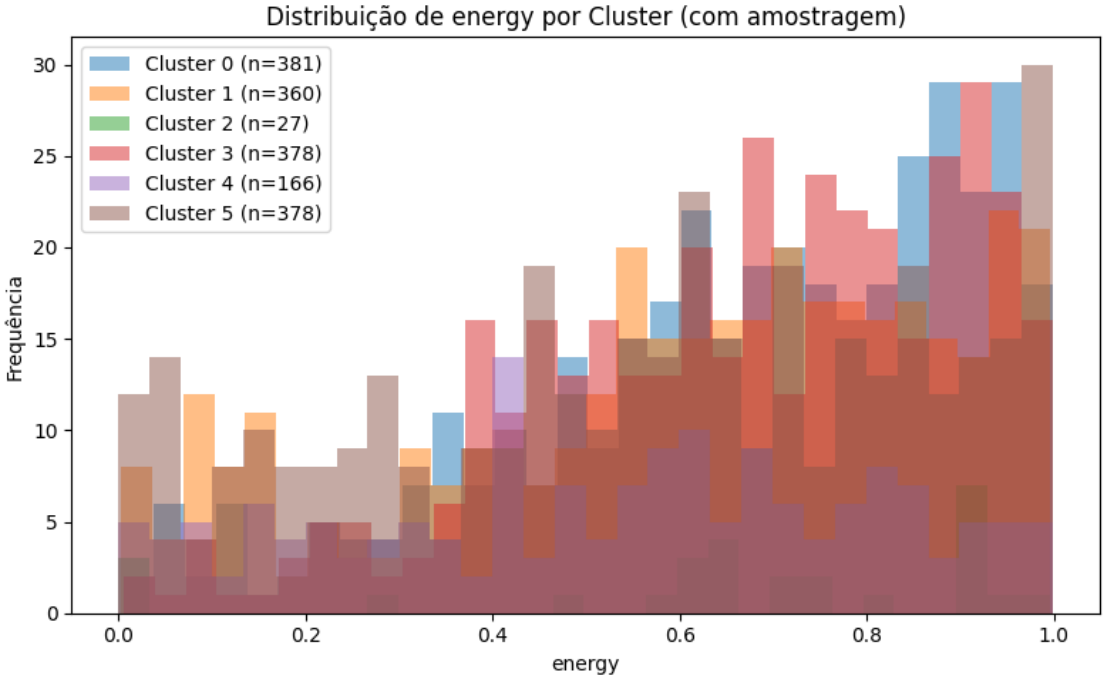
Distribuição de energy por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
energy
0
5
10
15
20
25
30
0.0
0.2
0.4
0.6
0.8
1.0

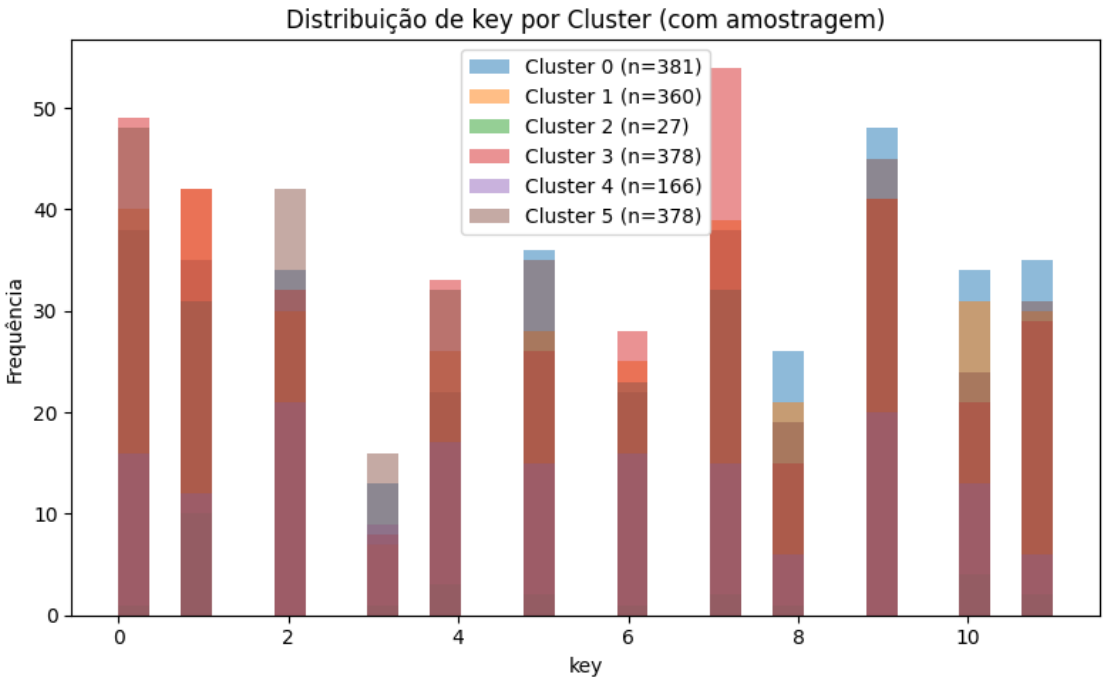
Distribuição de key por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
key
0
2
4
6
8
10
0
10
20
30
40
50

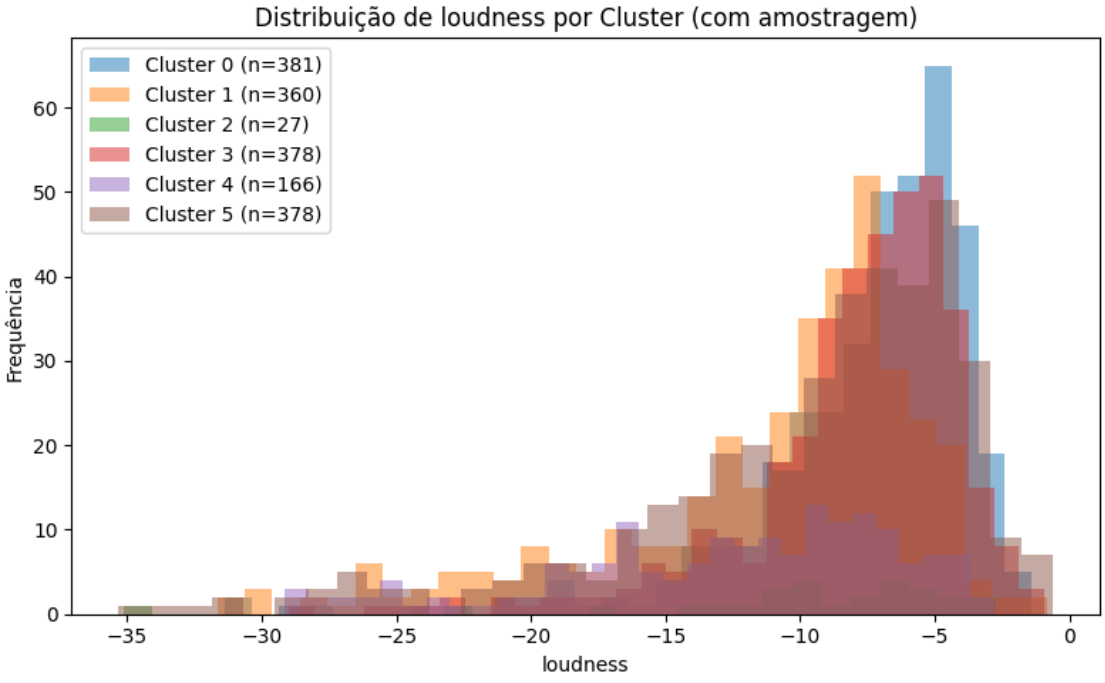
Distribuição de loudness por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
loudness
−35
−30
−25
−20
−15
−10
−5
0
0
10
20
30
40
50
60

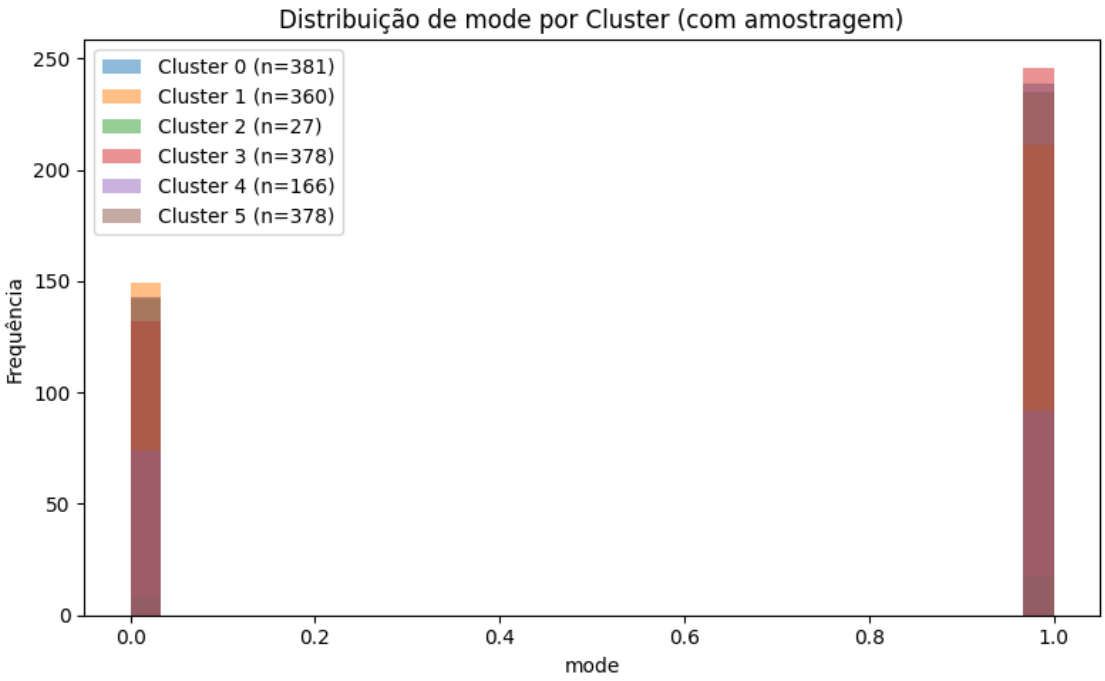
Distribuição de mode por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
mode
0
50
100
150
200
250
0.0
0.2
0.4
0.6
0.8
1.0

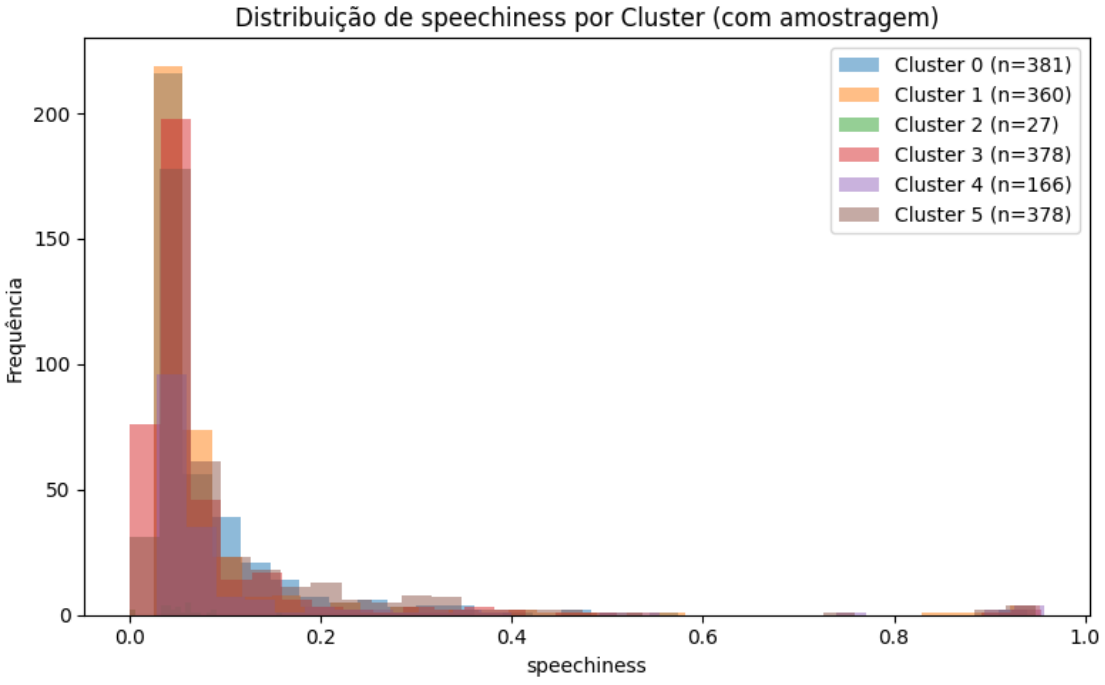
Distribuição de speechiness por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
speechiness
0
50
100
150
200
0.0
0.2
0.4
0.6
0.8
1.0

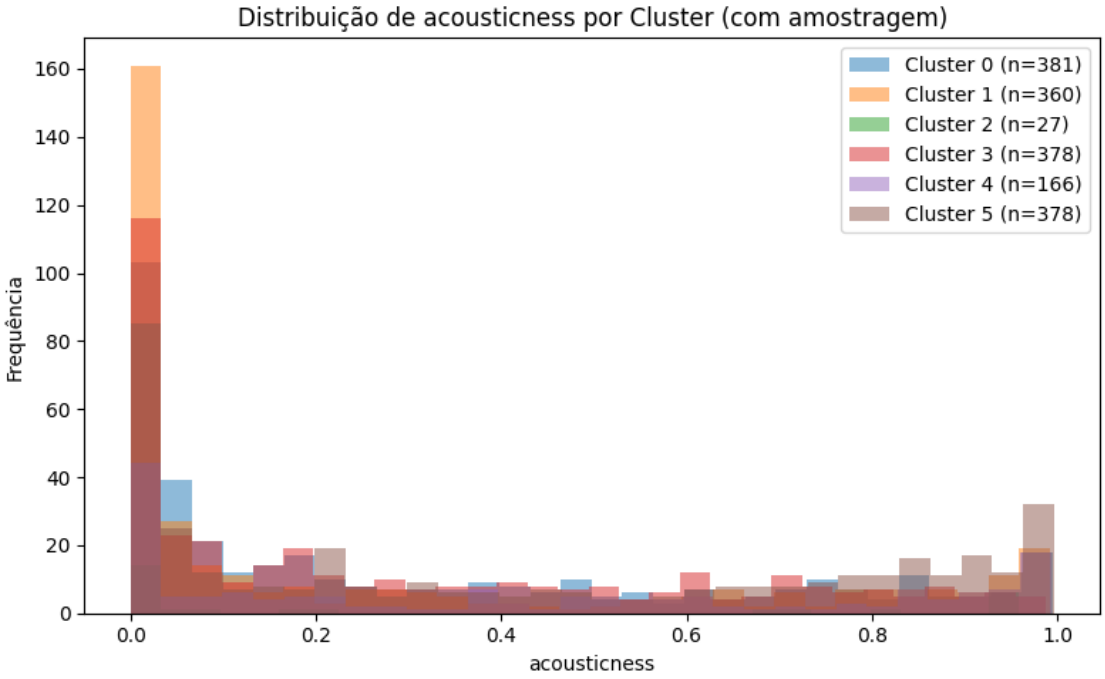
Distribuição de acousticness por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
acousticness
0
20
40
60
80
100
120
140
160
0.0
0.2
0.4
0.6
0.8
1.0

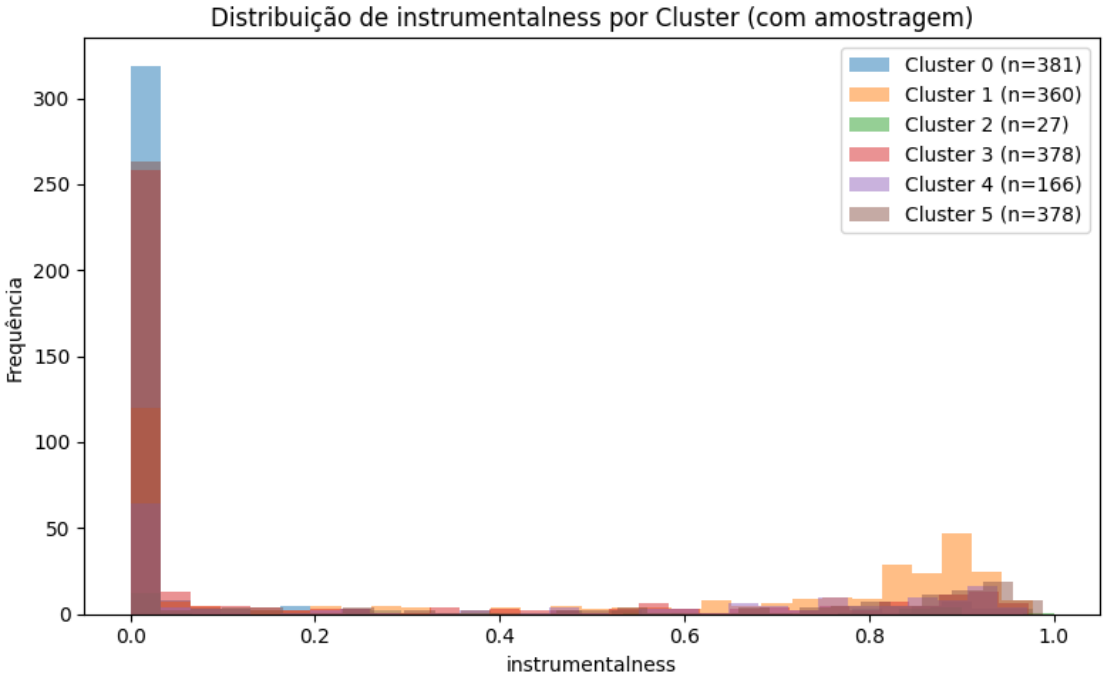
Distribuição de instrumentalness por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
instrumentalness
0
50
100
150
200
250
300
0.0
0.2
0.4
0.6
0.8
1.0

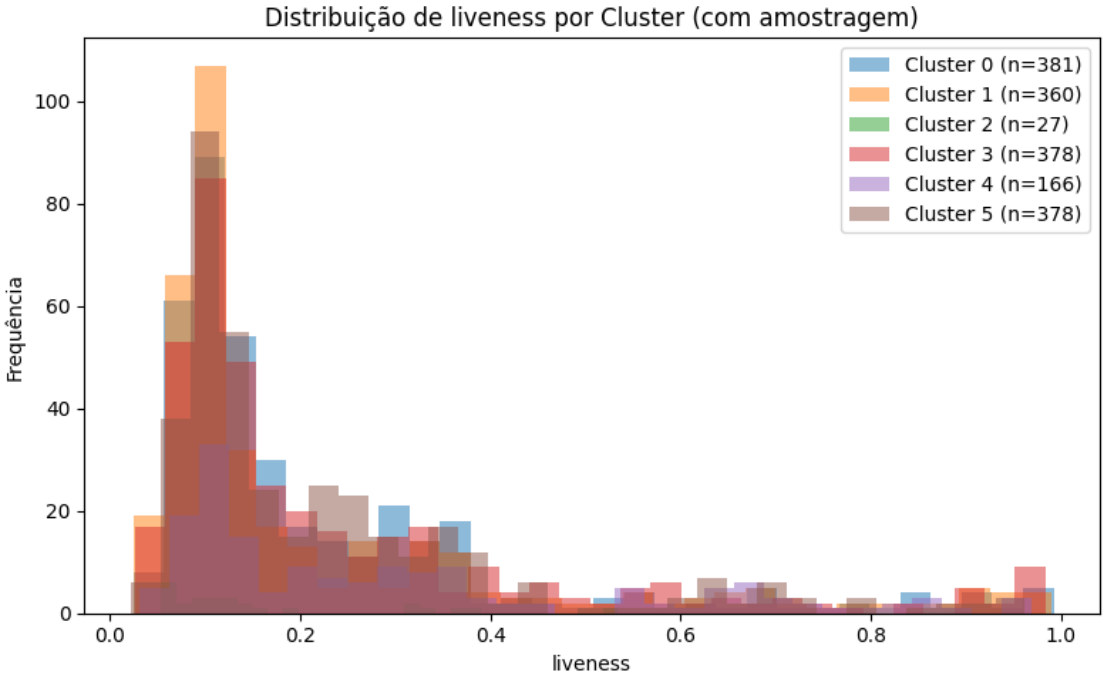
Distribuição de liveness por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
liveness
0
20
40
60
80
100
0.0
0.2
0.4
0.6
0.8
1.0

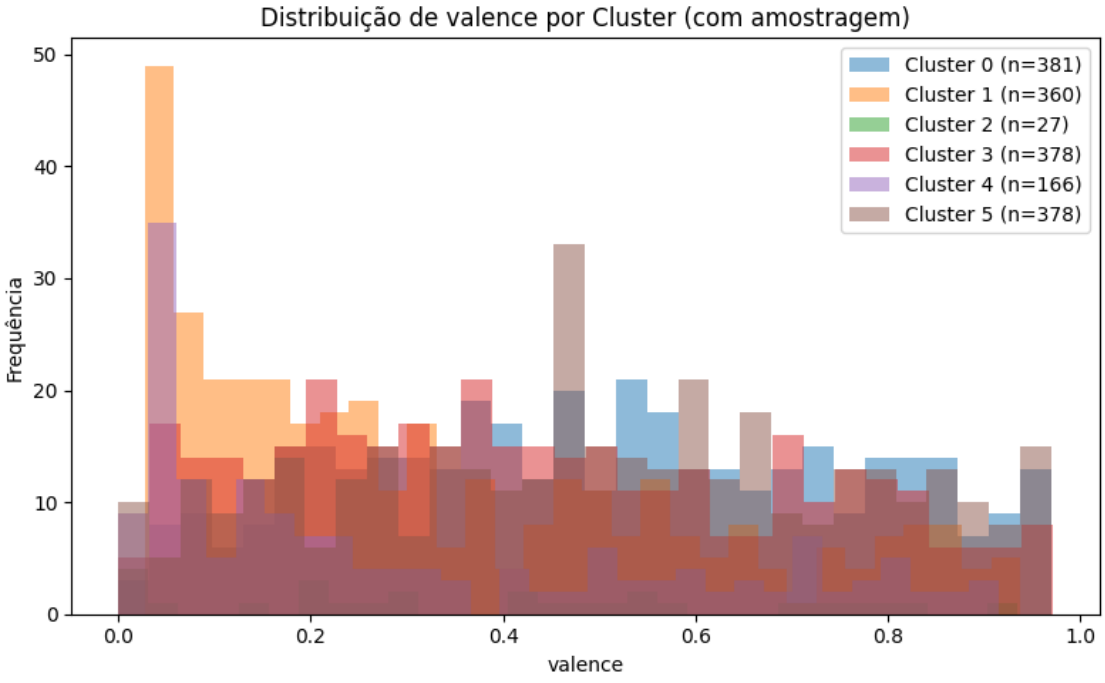
Distribuição de valence por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
valence
0
10
20
30
40
50
0.0
0.2
0.4
0.6
0.8
1.0

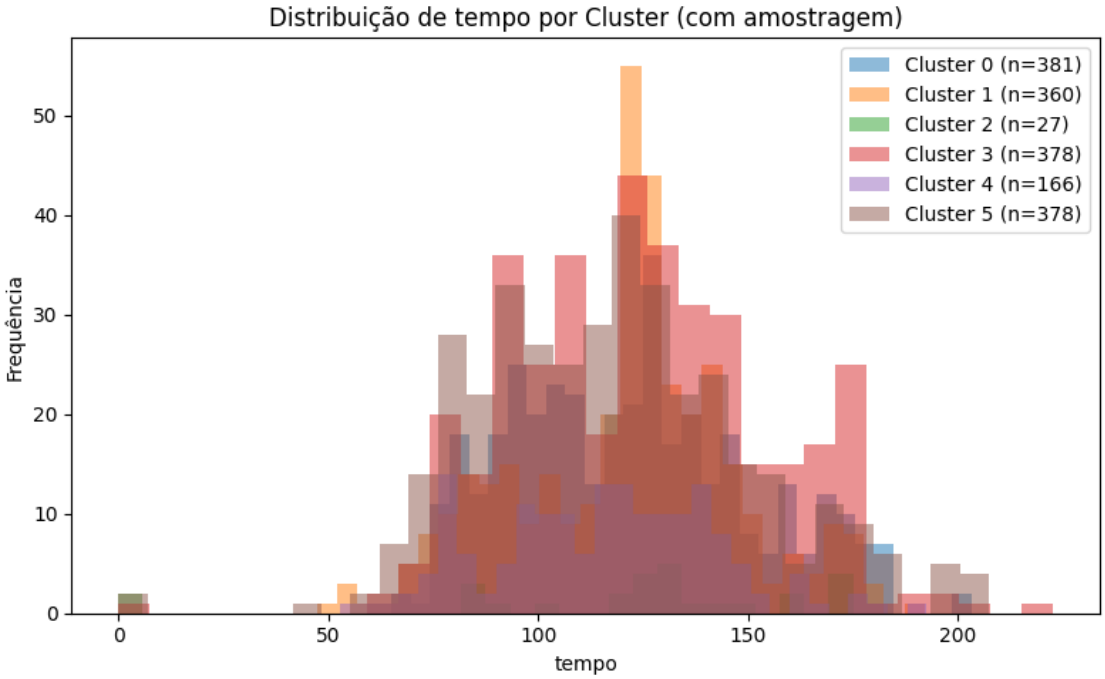
Distribuição de tempo por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
tempo
0
10
20
30
40
50
0
50
100
150
200

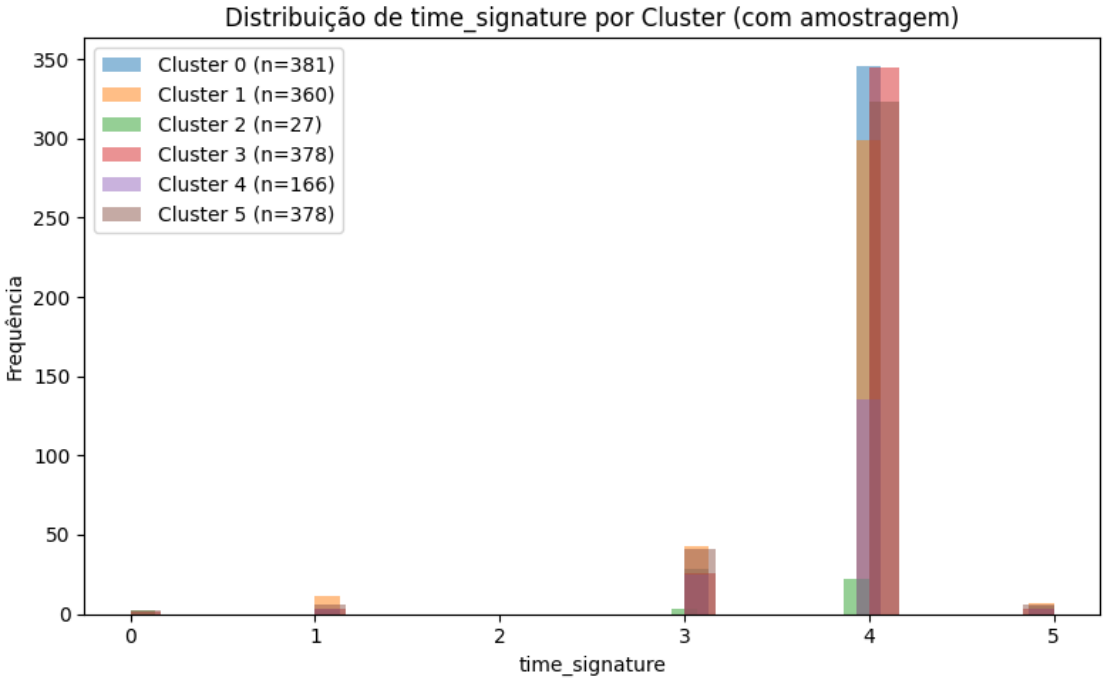
Distribuição de time_signature por Cluster (com amostragem)
Cluster 0 (n=381)
Cluster 1 (n=360)
Cluster 2 (n=27)
Cluster 3 (n=378)
Cluster 4 (n=166)
Cluster 5 (n=378)
Frequência
time_signature
0
50
100
150
200
250
300
350
0
1
2
3
4
5

6.5 Música

[159]:
```
from scipy.spatial.distance import euclidean, cosine

def recomendar_musicas(track_id, df_dados_normalizados, df_musicas):
    idx = df_musicas.index[df_musicas['track_id'] == track_id][0]
    cluster_id = df_musicas.loc[idx, 'cluster']
    print(f"Cluster: {cluster_id}")
    musica_base = df_dados_normalizados.drop(columns='cluster').iloc[idx].values

    subset = df_dados_normalizados[df_dados_normalizados['cluster'] ==␣
 ↪cluster_id].copy()
    subset['distancia'] = subset.drop(columns='cluster').apply(lambda row:␣
 ↪cosine(row.values, musica_base), axis=1)

    resultado_idx = subset.sort_values('distancia').index
    recomendacoes = df_musicas.loc[resultado_idx][['track_name',␣
 ↪'artists','track_genre']]
    recomendacoes = recomendacoes[recomendacoes.index != idx]

    return recomendacoes.head(10)
```

[160]:
```
recomendar_musicas(track_id='2aibwv5hGXSgw7Yru8IYTO',df_dados_normalizados=df_dados,df_musicas
```

```
Cluster: 3
```

[160]:

	track_name	artists	track_genre
47014	Back In Black	AC/DC	hard-rock
68663	La Llevo Al Cielo (Ft. Ñengo Flow)	Chris Jedi;Anuel AA;Chencho Corleone;Ñengo Flow	latino
91018	Bad Liar	Imagine Dragons	rock
51032	Chidiya	Vilen	hip-hop
37950	I Got 5 On It	Luniz;Michael Marshall	funk
60	Pano	Zack Tabudlo	acoustic
91914	Wonderwall - Remastered	Oasis	rock
2259	Heart-Shaped Box	Nirvana	alt-rock
48125	Party Up	DMX	hardcore
68906	AM Remix		

```
68906                    Nio Garcia;J Balvin;Bad Bunny      latino
```

7 Recomendação de Músicas

[161]:
```
def recomendar_musicas_por_genero(track_id, df_dados_normalizados, df_musicas):
    # Alinhar índices
    df_dados_normalizados = df_dados_normalizados.reset_index(drop=True)
    df_musicas = df_musicas.reset_index(drop=True)

    idx = df_musicas.index[df_musicas['track_id'] == track_id][0]
    cluster_id = df_musicas.loc[idx, 'cluster']
    genero_base = df_musicas.loc[idx, 'track_genre']
    print(f"Cluster: {cluster_id} | Gênero: {genero_base}")

    musica_base = df_dados_normalizados.drop(columns='cluster').iloc[idx].values

    # Filtra por cluster
    subset = df_dados_normalizados[df_dados_normalizados['cluster'] ==␣
 ↪cluster_id].copy()

    # Filtra por gênero
    subset = subset[df_musicas.loc[subset.index, 'track_genre'] == genero_base]

    # Calcula a distância
    subset['distancia'] = subset.drop(columns='cluster').apply(
        lambda row: cosine(row.values, musica_base), axis=1
    )

    resultado_idx = subset.sort_values('distancia').index
    recomendacoes = df_musicas.iloc[resultado_idx][['track_name', 'artists',␣
 ↪'track_genre']]
    recomendacoes = recomendacoes[recomendacoes.index != idx]

    return recomendacoes.head(10)
```

Busca de músicas por artistas

[162]:
```
nome_artista= r"Deftones"
df_musicas[df_musicas['artists'] == nome_artista][['track_id','artists',␣
 ↪'track_name', 'album_name']]
```

[162]:

	track_id	artists	track_name	\
2032	4nzIpIeHWiuFQnOV5ZELnj	Deftones	Ohms	
2033	0FrFqoPT7JB0ezIU9g2OLC	Deftones	Ohms	
2851	51c94ac31swyDQj9B3Lzs3	Deftones	Change (In the House of Flies)	
71451	1EryAkZ0VHstC6haIxVBiE	Deftones	Sextape	
71478	1158ckiB5S4cpsdYHDB9IF	Deftones	My Own Summer (Shove It)	

```
71519  4Uiw0Sl9yskBaC6P4DcdVD  Deftones   Be Quiet and Drive (Far Away)
71551  70L6nHORQsblY813yNqUR3  Deftones                     Cherry Waves
71801  4FEr6dIdH6EqLKR0jB560J  Deftones                         Rosemary

                album_name
2032          Metal Lives!
2033                 Metal
2851           White Pony
71451         Diamond Eyes
71478       Around the Fur
71519       Around the Fur
71551  Saturday Night Wrist
71801         Koi No Yokan
```

7.1 Robusts Scale

[168]:
```
recomendar_musicas_por_genero('4FEr6dIdH6EqLKR0jB560J',df_dados_normalizados1,df_musicas_rs)
```

```
Cluster: 3 | Gênero: metal
```

[168]:

	track_name	artists	track_genre
59944	Always	Bon Jovi	metal
59917	Always	Bon Jovi	metal
60014	Sober	TOOL	metal
60028	Adderall	Slipknot	metal
60115	I Won't See You Tonight Part 1	Avenged Sevenfold	metal
59916	Bed Of Roses	Bon Jovi	metal
60008	Abrazar la Niebla	Viernes Verde	metal
59948	Shepherd of Fire	Avenged Sevenfold	metal
59965	Cherry Waves	Deftones	metal
59939	Wanted Dead Or Alive	Bon Jovi	metal

7.2 Min Max Scale

[169]:
```
recomendar_musicas_por_genero('4FEr6dIdH6EqLKR0jB560J',df_dados_normalizados2,df_musicas_minma
```

```
Cluster: 4 | Gênero: metal
```

[169]:

	track_name	artists	track_genre
60059	Spiders	System Of A Down	metal
59966	Hypnotize	System Of A Down	metal
59916	Bed Of Roses	Bon Jovi	metal
59939	Wanted Dead Or Alive	Bon Jovi	metal
60000	Shadow Moses	Bring Me The Horizon	metal
60008	Abrazar la Niebla	Viernes Verde	metal
60010	Not Strong Enough	Apocalyptica;Brent Smith	metal
60078	Happy Song	Bring Me The Horizon	metal
60076	True Friends	Bring Me The Horizon	metal

```
59975              Stricken                 Disturbed       metal
```

7.3 Standart Scale

[170]:
```
recomendar_musicas_por_genero('4FEr6dIdH6EqLKR0jB560J',df_dados_normalizados3,df_musicas_stand
```

```
Cluster: 5 | Gênero: metal
```

[170]:

	track_name	artists	track_genre
59939	Wanted Dead Or Alive	Bon Jovi	metal
60008	Abrazar la Niebla	Viernes Verde	metal
59916	Bed Of Roses	Bon Jovi	metal
60059	Spiders	System Of A Down	metal
59966	Hypnotize	System Of A Down	metal
60122	Critical Acclaim	Avenged Sevenfold	metal
59978	Nero Forte	Slipknot	metal
59982	Hive Mind	Slipknot	metal
60010	Not Strong Enough	Apocalyptica;Brent Smith	metal
60003	Danger Line	Avenged Sevenfold	metal

7.4 Max Abs Scale

[171]:
```
recomendar_musicas_por_genero('4FEr6dIdH6EqLKR0jB560J',df_dados_normalizados4,df_musicas_maxab
```

```
Cluster: 1 | Gênero: metal
```

[171]:

	track_name	artists	track_genre
60059	Spiders	System Of A Down	metal
59966	Hypnotize	System Of A Down	metal
59916	Bed Of Roses	Bon Jovi	metal
59944	Always	Bon Jovi	metal
60112	Falling Away from Me	Korn	metal
60014	Sober	TOOL	metal
59939	Wanted Dead Or Alive	Bon Jovi	metal
60000	Shadow Moses	Bring Me The Horizon	metal
60008	Abrazar la Niebla	Viernes Verde	metal
60010	Not Strong Enough	Apocalyptica;Brent Smith	metal

7.5 Sem normalizar os dados

[172]:
```
recomendar_musicas_por_genero(track_id='4FEr6dIdH6EqLKR0jB560J',df_dados_normalizados=df_dados
```

```
Cluster: 1 | Gênero: metal
```

[172]:

	track_name	artists	track_genre
59932	Buried Alive	Avenged Sevenfold	metal
60102	Vicarious	TOOL	metal
60035	Lateralus	TOOL	metal
60008	Abrazar la Niebla	Viernes Verde	metal

59995	Drive Home	Steven Wilson	metal
60031	Soothsayer (Dedicated to Aunt Suzie)	Buckethead	metal
60115	I Won't See You Tonight Part 1	Avenged Sevenfold	metal
60098	Right In Two	TOOL	metal
59916	Bed Of Roses	Bon Jovi	metal

8 Conclusão

Dependendo o método que utilizarmos para normalizar os dados, ele irá sim, tanto no agrupamento quanto na recomendação das músicas. Como podemos ver anteriormente na recomendação das músicas, a pesar de algumas músicas aparecerem em todas as listagens, elas aparecem em posições diferentes, com exceção de Min Max Scale e Max Abs Scale onde o top 5 é idêntico em ambas. Também temos que levar em consideção que algumas músicas pertencem a mais de um gênero, e isso acaba impactando diretamente na forma com que as músicas são recomendadas. Portanto, uma possível solução é tentar dividir as músicas em grupos maiores como por exemplo, Heavy Metal e Power Metal, ambos serem do gênero 'Metal'.

9 Referências e Links

https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset/data
https://medium.com/pizzadedados/kmeans-e-metodo-do-cotovelo-94ded9fdf3a9 https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.RobustScaler.html https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.maxabs_scale.html https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.minmax_scale.html https://scikit-learn.org/stable/index.html