

Modelagem Matemática e Computacional

Modelos compartimentais – IV

Modelagem estocástica

Prof. Daniel G. Alfaro Vigo
dgalfaro@ic.ufrj.br

- 1 Introdução
- 2 Conceitos Básicos de Probabilidade
- 3 Variáveis Aleatórias e Processos Estocásticos
- 4 Cadeias de Markov
- 5 Modelos Compartimentais
- 6 Modelos Compartimentais Estocásticos
- 7 Conclusão

Modelos compartimentais podem ser utilizados para estudar diferentes fenômenos, como por exemplo:

- Crescimento de uma população.
- A **propagação** de doenças contagiosas em uma população.
- A disseminação de um rumor ou notícia (informações) em uma população/comunidade.

Objetivo: Apresentar a modelagem estocástica de epidemias, com ênfase em modelos compartimentais, seus fundamentos matemáticos e sua conexão com os sistemas determinísticos.

Por que estocástico?

A aleatoriedade é intrínseca ao fenômeno, especialmente em populações pequenas.

Modelo determinístico

Dado o estado inicial, o futuro é *único* e previsível.


⇒ Equação diferencial ordinária

Modelo estocástico

Dado o estado inicial, o futuro é uma *distribuição de possibilidades*.

⇒ Processo estocástico

A curva determinística é a **média** das realizações estocásticas — mas cada epidemia real segue *uma* trajetória aleatória.



Espaço Amostral (Ω)

Conjunto de todos os resultados possíveis de um experimento aleatório.

Ex.: $\Omega = \{0, 1, 2, \dots, N\}$ (número de infectados possíveis)

Evento

Um subconjunto do espaço amostral ao qual se atribui uma probabilidade.

Ex.: $A \subset \Omega$.

Ex.: $A = \{I(t) > 50\}$ (mais de 50 infectados no tempo t)

Variável Aleatória

Uma função $X : \Omega \rightarrow \mathbb{R}$ que associa um número real a cada resultado.

- **Discreta:** número finito ou contável de valores. (ex:
 $I(t) \in \{0, 1, \dots, N\}$)
- **Contínua:** valores em um intervalo contínuo.

Dado um espaço amostral Ω e um evento E , a função de probabilidade $\mathbb{P}(E)$ deve satisfazer:

- 1 $0 \leq \mathbb{P}(E) \leq 1$
- 2 $\mathbb{P}(\Omega) = 1$
- 3 Para eventos mutuamente exclusivos $E_1, E_2, \dots$, (tais que $E_i \cap E_j = \emptyset$ quando $i \neq j$)

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(E_i)$$

Motivação

Muitas vezes, ao realizar um experimento, temos **informação parcial** sobre o resultado. Como essa informação atualiza a probabilidade de um evento de interesse?

Definição Formal

Sejam A e B dois eventos, com $\mathbb{P}(B) > 0$. A **probabilidade condicional** de A dado que B ocorreu é definida por:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$


Interpretação

A ocorrência de B redefine o espaço amostral. A probabilidade de A passa a ser a probabilidade relativa da parte de A que está contida em B .

Theorem (Lei da Probabilidade Total)

Se os eventos $B_1, B_2, \dots, B_n$ são mutuamente exclusivos e sua união é o espaço amostral Ω , então para qualquer evento A :

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i)$$



O que são Variáveis Aleatórias?

Motivação

Quando um experimento é realizado, às vezes nos preocupamos principalmente com o valor de alguma **quantidade numérica** determinada pelo resultado.

Definição

Uma **variável aleatória** é definida por uma função:

$$X : \Omega \rightarrow S, \quad S \subset \mathbb{R}.$$

Exemplo

No lançamento de três moedas, podemos definir a variável aleatória X como o **número de caras obtidas**. Os possíveis valores são 0, 1, 2, 3.

Definição

A função de distribuição acumulativa, ou função de distribuição, F da variável aleatória X é definida para qualquer número real x como:

$$F(x) = \mathbb{P}(\{X \leq x\})$$

Propriedades

- F é não decrescente
- $\lim_{x \rightarrow -\infty} F(x) = 0$
- $\lim_{x \rightarrow +\infty} F(x) = 1$
- F é contínua à direita

Definição

Uma variável aleatória que pode assumir um número **finito** ou **no máximo contável** de valores possíveis é considerada **discreta**, ou seja

$$S = \{x_1, x_2, \dots\}.$$

Função de Probabilidade (ou massa)

$$p(x) = \mathbb{P}\{X = x\} = \begin{cases} 0, & \text{se } x \notin S \\ p_i > 0, & \text{se } x = x_i \in S \end{cases}$$

Propriedade Fundamental

Como X deve assumir um dos valores possíveis $x_1, x_2, \dots$:

$$\sum_{x_i \in S} p(x_i) = 1$$

Exemplo: Variável Aleatória Discreta

Exemplo

Experimento: lançar uma moeda **justa** três vezes.

Espaço amostral:

$$\Omega = \{CaCaCa, CaCaCo, CaCoCa, CaCoCo, CoCaCa, CoCaCo, CoCoCa\}$$

Cada elemento tem probabilidade $1/8 = 0.125$.

Seja X = número de caras obtidas. Possíveis valores: 0, 1, 2, 3.

Valor de X	Eventos	Probabilidade
0	$\{CoCoCo\}$	$1/8 = 0.125$
1	$\{CaCoCo, CoCaCo, CoCoCa\}$	$3/8 = 0.375$
2	$\{CaCaCo, CaCoCa, CoCaCa\}$	$3/8 = 0.375$
3	$\{CaCaCa\}$	$1/8 = 0.125$

Definição

Uma variável aleatória X é dita **contínua** quando seus valores possíveis formam um **intervalo** (ou união de intervalos) na reta real.

Função Densidade de Probabilidade $f(x)$

- É uma função **não negativa** definida para todo número real x
- A probabilidade de X pertencer a um conjunto C é dada pela integral:

$$\mathbb{P}(X \in C) = \int_C f(x) dx$$

Relação com a Distribuição Acumulativa

$$F(a) = \mathbb{P}(X \leq a) = \int_{-\infty}^a f(x) dx$$

Exemplos

- Tempo entre duas chegadas sucessivas a um sistema de filas
- Temperatura em um reator nuclear

Característica	Variável Discreta	Variável Contínua
Valores possíveis	Conjunto finito ou enumerável	Intervalo (infinito não enumerável)
Probabilidade pontual	$p(x) = \mathbb{P}(X = x) > 0$	$\mathbb{P}(X = a) = 0$
Representação	Função de massa (soma)	Função densidade (integral)

Esperança (Média) — $\mathbb{E}[X]$

- Caso Discreto: $\mathbb{E}[X] = \sum_{x_i \in S} x_i \cdot \mathbb{P}(X = x_i)$
- Caso Contínuo: $\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot f(x) dx$

$\mathbb{E}[I(t)]$ = número *médio esperado* de infectados no tempo t — é isso que o modelo determinístico captura.

Variância — $\text{Var}(X)$

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Mede a dispersão em torno da média; fundamental para quantificar a aleatoriedade do modelo.

Covariância — $\text{Cov}(X, Y)$

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Bernoulli(p) — o experimento mais simples

$$X \in \{0, 1\}; \quad \mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

$$\mathbb{E}[X] = p; \quad \text{Var}(X) = p(1 - p).$$

Ex.: um contato entre suscetível e infectado resulta, ou não, em transmissão.

Binomial(n, p) — n tentativas independentes

X = número de sucessos em n tentativas Bernoulli(p).

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n$$

$$\mathbb{E}[X] = np; \quad \text{Var}(X) = np(1 - p).$$

Ex.: número de novos infectados entre n contatos de um único infeccioso.


Distribuição de Poisson

Limite da Binomial quando $n \rightarrow \infty$,
 $p \rightarrow 0$, $np \rightarrow \lambda$ fixo.

Poisson(λ)

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

$$\mathbb{E}[X] = \lambda; \quad \text{Var}(X) = \lambda.$$



Aplicações típicas


- Número de chamadas telefônicas por hora
- Número de acidentes em um cruzamento por mês
- Número de partículas radioativas emitidas por segundo

Uniforme(a, b)

V.a. **contínua** $a \leq X \leq b$:

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$

$$\mathbb{E}[X] = \frac{a+b}{2}; \quad \text{Var}(X) = \frac{(b-a)^2}{12}.$$



Exponencial(λ)

V.a. **contínua** $X \geq 0$:


$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$$\mathbb{E}[X] = \frac{1}{\lambda}; \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$

Propriedade sem memória

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$$

O tempo *restante* é independente do tempo já esperado — fundamental para processos de Markov.




Distribuição Normal (Gaussiana)

Normal(μ, σ)

V.a. **contínua** $-\infty < X < +\infty$:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R}$$

$$\mathbb{E}[X] = \mu; \quad \text{Var}(X) = \sigma^2.$$



Função de Distribuição Conjunta

Para especificar a relação entre duas variáveis aleatórias X e Y :

$$F(x, y) = \mathbb{P}\{X \leq x, Y \leq y\}$$

Caso Discreto: Função de massa conjunta

$$p(x, y) = \mathbb{P}\{X = x, Y = y\}$$

Caso Contínuo: Função de densidade conjunta

$$\mathbb{P}\{X \in C, Y \in D\} = \iint_{x \in C, y \in D} f(x, y) dx dy$$

Definition

As variáveis aleatórias X e Y são consideradas **independentes** se, para quaisquer conjuntos C e D :

$$\mathbb{P}\{X \in C, Y \in D\} = \mathbb{P}\{X \in C\} \cdot \mathbb{P}\{Y \in D\}$$

Interpretação

X e Y são independentes se o **conhecimento do valor de um deles não afeta a distribuição de probabilidade do outro**.

*Variáveis aleatórias que não são independentes são consideradas **dependentes**.*

Caso Discreto

X e Y são independentes **se e somente se**, para todos x, y :

$$\mathbb{P}\{X = x, Y = y\} = \mathbb{P}\{X = x\} \cdot \mathbb{P}\{Y = y\}$$

ou equivalentemente:

$$p(x, y) = p_X(x) \cdot p_Y(y)$$

Caso Contínuo

X e Y são independentes **se e somente se**, para todos x, y :

$$f(x, y) = f_X(x) \cdot f_Y(y)$$

onde $f_X(x)$ e $f_Y(y)$ são as funções densidade de X e Y , respectivamente.

Teorema Central do Limite (TCL)

Theorem (Teorema Central do Limite)

Seja $X_1, X_2, \dots$ uma sequência de variáveis aleatórias **independentes e identicamente distribuídas** (i.i.d.) tendo média finita μ e variância finita σ^2 . Então:

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ \frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}} \leq x \right\} = \Phi(x)$$

onde $\Phi(x)$ é a função de distribuição acumulativa da v.a. normal padrão $\text{Normal}(0, 1)$.

Importância

Para n suficientemente grande, a distribuição da soma padronizada se aproxima de uma **distribuição normal padrão**, independentemente da distribuição original de X_i .

O que é um Processo Estocástico?

Definição

Um Processo Estocástico é definido por uma família de variáveis aleatórias $\{X_t : t \in T\}$ num mesmo espaço de probabilidade $(\Omega, \mathbb{P})$, indexada pelo **tempo** t . Dessa forma, temos uma função

$$X : T \times \Omega \rightarrow S.$$

Para cada $\omega \in \Omega$ fixado, $t \mapsto X(t, \omega)$ é uma **trajetória** (realização) do processo.

Classificação pelo tempo T :

- **Discreto:** $T = \{0, 1, 2, \dots\}$
- **Contínuo:** $T = [0, \infty)$

Classificação pelo espaço de estados S :

- **Discreto:** $S = \{x_1, x_2, \dots\}$ ex: $\{0, \dots, N\}$
- **Contínuo:** $S = \mathbb{R}$

Vamos focar no caso em que o espaço de estados é **discreto** (finito ou enumerável). Note que quando o tempo é contínuo o estado do processo muda por *saltos* em instantes aleatórios.

Um passeio aleatório (simples) é um processo estocástico $\{X_n\}$ a tempo discreto cujas trajetórias são dadas pelas sequências $X_0, X_1, X_2, \dots$ em que X_n representa a **posição** de uma partícula nos inteiros $\mathbb{Z}$. A partícula inicia seu movimento na origem ($X_0 = 0$) e a cada passo de tempo se desloca aleatoriamente para uma posição vizinha de acordo com as seguintes probabilidades

$$\mathbb{P}(X_{n+1} = i_n + \delta \mid X_0 = i_0, \dots, X_n = i_n) = \begin{cases} p, & \text{se } \delta = 1 \\ q = 1 - p, & \text{se } \delta = -1 \end{cases}$$

Propriedade de Markov


O passeio aleatório possui a seguinte propriedade importante

$$\mathbb{P}(X_{n+1} = j \mid X_0 = i_0, \dots, X_n = i_n) = \mathbb{P}(X_{n+1} = j \mid X_n = i_n).$$

O futuro depende apenas do presente, não do passado.

Como consequência os incrementos $D_k = X_{k+1} - X_k$, $k = 0, 1, \dots$, formam uma sequência de variáveis aleatórias independentes e identicamente distribuídas. Além disso, temos que $D_k = 2B_k - 1$ onde as variáveis aleatórias B_k possuem a distribuição Bernoulli(p).

Diagrama de Transição



Caminho amostral

Considere $X_0 = 0$ e uma sequência de passos (incrementos):

$$+1, +1, -1, +1, -1, -1, +1, \dots$$

As posições sucessivas são:

$$0 \xrightarrow{+1} 1 \xrightarrow{+1} 2 \xrightarrow{-1} 1 \xrightarrow{+1} 2 \xrightarrow{-1} 1 \xrightarrow{-1} 0 \xrightarrow{+1} 1 \dots$$

Exemplo: Passeio Aleatório

Objetivo: Gerar os passos de uma trajetória de um passeio aleatório.

Algoritmo: Simulação da trajetória de um passeio aleatório

Entrada: p (probabilidade de um passo para frente), n (quantidade total de passos)

Saída : $X[0 : n]$ (sequência das posições)

$X[0] \leftarrow 0, i \leftarrow 1;$

while $i \leq n$ **do**

 Gere $B \sim \text{Bernoulli}(p);$

$D \leftarrow 2B - 1;$

$X[i] \leftarrow X[i - 1] + D;$

$i \leftarrow i + 1;$

end

return $X[0 : n];$

Exemplo: Passeio Aleatório




Figura: Gráfico de 4 realizações (trajetórias) de um passeio aleatório.

Exemplo: Processo de Poisson

Um processo de Poisson é um processo estocástico a tempo contínuo $\{N(t), t \geq 0\}$ que modela a quantidade de eventos aleatórios que ocorrem ao longo do tempo. Temos que $N(0) = 0$ e os eventos acontecem aleatoriamente de acordo com as seguintes probabilidades, para $s \geq 0$, $h > 0$

$$\mathbb{P}(N(s+h) = N(s) + k \mid N(t), t \in [0, s]) = e^{-\lambda h} \frac{(\lambda h)^k}{k!}, \quad k = 0, 1, \dots$$

onde $\lambda > 0$ é a taxa (média) de eventos por unidade de tempo.

Exemplos clássicos

- Chamadas chegando a uma central telefônica.
- Clientes entrando em uma loja.
- Número de acidentes em uma rodovia.

Propriedades importantes

- **Propriedade de Markov:** Para quaisquer $t > s \geq 0$,

$$\mathbb{P}(N(t) = j \mid N(\tau), \tau \in [0, s]) = \mathbb{P}(N(t) = j \mid N(s)).$$

O futuro depende apenas do presente, não do passado.


- **Incrementos Independentes:** Para quaisquer $t_n > \dots > t_1 > t_0 \geq 0$ as diferenças $N(t_n) - N(t_{n-1}), \dots, N(t_1) - N(t_0)$ são variáveis aleatórias independentes entre si.

O que ocorre num intervalo não influencia outro intervalo disjunto.

- **Tempos de espera:** Considerando os tempos $\tau_1, \tau_2, \dots$ em que acontecem os eventos que podem ser definidos como $\tau_k = \min\{t \geq 0 \mid N(t) \geq k\}$, temos que os **tempos de espera entre eventos** $E_k = \tau_k - \tau_{k-1}$ ($k = 1, 2, \dots$), são uma sequência de variáveis aleatórias independentes com a distribuição exponencial com taxa λ .

Exemplo: Processo de Poisson

$N(t)$ permanece **constante por intervalos** e muda abruptamente nos instantes de transição, com o tempo de espera entre saltos tem distribuição **Exponencial**.



Definição alternativa

Seja $N(t)$ o número de eventos em $[0, t]$. O processo $\{N(t), t \geq 0\}$ é um **Processo de Poisson** com taxa $\lambda > 0$ se (Ross, 2013, p. 28–29):

- 1 $N(0) = 0$.
- 2 **Incrementos Independentes e Estacionários:** o número de eventos em intervalos disjuntos é independente e depende apenas do comprimento do intervalo.
- 3 Probabilidades de transição: para quaisquer $j \geq i$, $i, j \in \mathbb{N}$

$$\mathbb{P}(N(s+h) = j \mid N(s) = i) = \begin{cases} 1 - \lambda h + o(h), & \text{se } j = i \\ \lambda h + o(h), & \text{se } j = i + 1 \\ o(h), & \text{se } j - i \geq 2. \end{cases}$$

Exemplo: Processo de Poisson

Objetivo: Gerar tempos de ocorrências e número de eventos.

Algoritmo: Simulando um Processo de Poisson

Entrada: λ (taxa de ocorrências), T (tempo final)

Saída : M (número total de eventos), $t[0 : M]$ e $N[0 : M]$ (tempos das ocorrências e quantidade correspondente de eventos)

$M \leftarrow 0, t[0] \leftarrow 0, N[0] \leftarrow 0;$

Gere $E \sim \text{Exponencial}(\lambda);$

$t_c \leftarrow E;$

while $t_c < T$ **do**

$M \leftarrow M + 1;$

$t[M] \leftarrow t_c, N[M] \leftarrow M;$

 Gere $E \sim \text{Exponencial}(\lambda)$

$t_c \leftarrow t_c + E;$

end

return $M, t[0 : M], N[0 : M];$

Exemplo: Processo de Poisson




Figura: Gráfico de 4 realizações (trajetórias) de um processo de Poisson.

Cadeias de Markov: Intuição

Descrevem sistemas que evoluem no tempo onde o **futuro depende apenas do estado presente** — não do passado.

Exemplo: Previsão do tempo

- Se hoje choveu
 $\Rightarrow \mathbb{P}(\text{chuva amanhã}) = 0.7$
- Se hoje fez sol
 $\Rightarrow \mathbb{P}(\text{chuva amanhã}) = 0.4$




Diagrama de estados: setas mostram transições com suas probabilidades.

Propriedade-chave

Para prever amanhã, só importa *hoje* — o que aconteceu na semana passada é irrelevante.

Propriedade de Markov

Um processo estocástico $\{X_n \mid n \in \mathbb{N}\}$ (a tempo discreto) é uma **Cadeia de Markov** se:

$$\begin{aligned} & \mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) \\ &= \mathbb{P}(X_{n+1} = j \mid X_n = i) \end{aligned}$$

- As probabilidades $P_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i)$ são as **probabilidades de transição**.
- $\sum_j P_{ij} = 1$ (de cada estado, o processo vai a algum lugar).

Cadeias de Markov: Tempo Contínuo — Definição

Um processo estocástico $\{X(t) \mid t \geq 0\}$ (a tempo contínuo) é um processo de Markov, se possui a **Propriedade de Markov**: Para quaisquer $t > s \geq 0$,

$$\mathbb{P}(X(t) = j \mid X(\tau), \tau \in [0, s]) = \mathbb{P}(X(t) = j \mid X(s)).$$

- As trajetórias são contínuas por parte, com limite à esquerda.
- No estado i , o tempo de espera até a próxima transição é uma v.a. independente com distribuição Exponencial(λ_i).
- Ao ocorrer uma transição, o processo passa do estado i para o j com probabilidade P_{ij} (observe que $P_{ii} = 0$, $\sum_{j \neq i} P_{ij} = 1$).

Taxa de Transição

A probabilidade com que o processo evolui no intervalo $(t, t + \Delta t]$ satisfaz:

$$\mathbb{P}(X(t + \Delta t) = j \mid X(t) = i) = \begin{cases} 1 - \lambda_i \Delta t + o(\Delta t), & \text{se } i = j \\ \lambda_i P_{ij} \Delta t + o(\Delta t), & \text{se } i \neq j \end{cases}$$

- Os estados $i \in S$ tais que $\lambda_i = 0$ são chamados de **estados absorventes**. Uma vez que o sistema entra nesse estado, a probabilidade de sair dele é zero, e o processo permanece lá indefinidamente.
- Nas simulações consideramos que a cadeia (processo) de Markov tem a seguinte propriedade: o conjunto $S_i \subset S$ dos estados que podem ser atingidos diretamente partindo do estado i , é finito, ou seja que $P_{ij} = 0, \forall j \in S \setminus S_i$.

Algoritmo

Entrada: λ_i (taxas), P_{ij} (probabilidades de salto), i_0 (estado inicial), T (tempo final)

Saída : M (número de saltos), $t[0 : M]$ (tempos), $s[0 : M]$ (estados)

$i \leftarrow i_0$, $M \leftarrow 0$, $t[0] \leftarrow 0$, $s[0] \leftarrow i_0$;

Gere $E \sim \text{Exponencial}(\lambda_i)$;

$t_c \leftarrow E$;

while $t_c < T$ **do**

$M \leftarrow M + 1$;

$k \leftarrow \text{Gerar_salto}(i, P_{ij})$;

$t[M] \leftarrow t_c$, $s[M] \leftarrow k$, $i \leftarrow k$;

 Gere $E \sim \text{Exponencial}(\lambda_i)$

$t_c \leftarrow t_c + E$;

end

return $M, t[0 : M], s[0 : M]$;

Algoritmo: $k \leftarrow \text{Gerar_salto}(i, P_{ij})$

Entrada: i (estado atual), P_{ij} (probabilidades de salto)

Saída : k (próximo estado)

Gere $U \sim \text{Uniforme}(0, 1)$;

$p \leftarrow 0$;

for $k \in S_i$ **do**

$p \leftarrow p + P_{ik}$;

if $p > U$ **then**


return k ;

end


end

return k ;

- **Compartimentos (caixas):** representam os possíveis estados dos indivíduos.
- O vetor $(X_1(t), \dots, X_k(t))$ descreve o número de indivíduos em cada compartimento.
- O modelo determinístico consiste em um sistema de EDOs que é obtido identificando as taxas de transferência dos indivíduos entre os compartimentos.
- O modelo estocástico considera um processo (vetorial) de Markov definido a partir das taxas de transição entre os diferentes estados do sistema.




Modelo com 3 compartimentos




Transições na cadeia de Markov

Exemplo: Crescimento espontâneo de uma população

Esse exemplo corresponde a uma população que evolui seguindo uma taxa de crescimento per capita constante. O tamanho da população é representado por N .



Modelo com um único compartimento



Transições da cadeia de Markov

Exemplo: Crescimento espontâneo de uma população

Esse processo é definido pelas trajetórias $\{N(t) \mid t \geq 0, t \in \mathbb{R}\}$ constantes por partes, contínuas à direita com valores em $\mathbb{N}$ tais que:

- $N(0) = N_0 > 0$;
- Para $t, \Delta t \geq 0$ e $i, j \in \mathbb{N}$:

$$\mathbb{P}(N(t+\Delta t) = j \mid N(t) = i) = \begin{cases} 0, & \text{se } j < i \\ 1 - \lambda N(t)\Delta t + o(\Delta t), & \text{se } j = i \\ \lambda N(t)\Delta t + o(\Delta t), & \text{se } j = i + 1 \\ o(\Delta t), & \text{se } j \geq i + 2 \end{cases}$$

em que o parâmetro $\lambda > 0$ é a taxa de crescimento per capita.

Exemplo: Crescimento espontâneo de uma população






Figura: Gráfico de 4 realizações (trajetórias) de um processo de crescimento populacional.

Exemplo: Crescimento de uma população com nascimentos e mortes

Esse exemplo corresponde a uma população que evolui segundo uma taxa de nascimentos per capita e um tempo médio de vida constantes. O tamanho da população é representado por N .



Modelo com um único compartimento



Transições na cadeia de Markov

Exemplo: Crescimento de uma população com nascimentos e mortes

Esse processo é definido pelas trajetórias $\{N(t) \mid t \geq 0, t \in \mathbb{R}\}$ constantes por partes, contínuas à direita com valores em $\mathbb{N}$ tais que:

- $N(0) = N_0 > 0$;
- Para $t, \Delta t \geq 0$ e $i, j \in \mathbb{N}$:

$$\mathbb{P}(N(t + \Delta t) = j \mid N(t) = i) = \begin{cases} 1 - (\nu + \mu)N(t)\Delta t + o(\Delta t), & \text{se } j = i \\ \nu N(t)\Delta t + o(\Delta t), & \text{se } j = i + 1 \\ \mu N(t)\Delta t + o(\Delta t), & \text{se } j = i - 1 \\ o(\Delta t), & \text{se } |j - i| \geq 2 \end{cases}$$

em que o parâmetro $\nu > 0$ é a taxa de nascimentos per capita e $1/\mu$ o tempo médio de vida dos indivíduos.

Exemplo: Crescimento espontâneo de uma população






Figura: Gráfico de 4 realizações (trajetórias) de um processo de crescimento populacional com nascimentos e mortes.

Exemplo: O Modelo SI estocástico

- O modelo corresponde a propagação de uma doença infecciosa numa população em que os indivíduos ficam infectados para sempre.
- Há dois possíveis estados para os indivíduos: suscetível (S) e infectado (I).
- O tamanho da população $N = S + I$ permanece constante.
- **Transferência:** $S \rightarrow I$ (infecção).
- **Taxa de transferência:** $\beta \frac{SI}{N}$.



Modelo com dois compartimentos



Transições na cadeia de Markov

Exemplo: O Modelo SI estocástico

As trajetórias $\{(I(t), S(t)) \mid t \geq 0, t \in \mathbb{R}\}$ do processo são constantes por partes, contínuas à direita com valores em $\mathbb{N}^2$:

- $(I(0), S(0)) = (I_0, S_0), \quad I(t) + S(t) = N = \text{const} > 0;$
- Para $t, \Delta t \geq 0$ e $k \geq 0$:

$$\mathbb{P}((I(t + \Delta t), S(t + \Delta t)) = (I_t + k, S_t - k) \mid (I(t), S(t)) = (I_t, S_t)) = \begin{cases} 1 - \beta \frac{I_t S_t}{N} \Delta t + o(\Delta t), & \text{se } k = 0 \\ \beta \frac{I_t S_t}{N} \Delta t + o(\Delta t), & \text{se } k = 1 \\ o(\Delta t), & \text{se } 2 \leq k \leq S_t \\ 0, & \text{se } k > S_t \end{cases}$$

em que o parâmetro $\beta > 0$ é a taxa de infecção.

Exemplo: O Modelo SI estocástico




Figura: Gráfico de 4 realizações (trajetórias) de um processo de propagação de uma doença.

- O **Processo de Poisson** é a base para a modelagem de eventos discretos em tempo contínuo.
- As **Cadeias de Markov** fornecem o formalismo matemático para a modelagem de sistemas que evoluem sem memória do passado.
- Os **Modelos compartimentais estocásticos** capturam a dinâmica aleatória das mudanças do estado dos indivíduos da população.
- Os modelos compartimentais estocásticos possuem uma relação direta com modelos compartimentais determinísticos baseados em EDOs que descrevem o comportamento “médio” de grandes populações.
- Apresentamos modelos baseados nas cadeias de Markov homogêneas (no tempo), ou seja quando a taxa de transição depende apenas dos estados e do tamanho do intervalo mas independe do tempo. Em algumas situações mais complexas pode ser necessário desenvolver modelos baseados nas cadeias de Markov heterogêneas.

- Ross, S. M. *Simulation*. 5. ed. Academic Press, 2013.
- Stewart, W. J. *Probability, Markov chains, queues, and simulation*. Princeton University Press, 2009.
- Greenwood, P. E.; Gordillo, L. F. *Stochastic Epidemic Modeling*. In: Mathematical and Statistical Estimation Approaches in Epidemiology. Springer, 2009.