Comparação de Algoritmos Genéticos na Função de Rosenbrock: Implementação Manual e Framework *pymoo*

Davi dos Santos Mattos[119133049]

Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil
secgrad@ic.ufrj.br

Resumo Este trabalho apresenta um estudo comparativo entre três versões de algoritmo genético aplicadas à minimização da função de Rosenbrock: (i) implementação manual, (ii) implementação padrão do framework *pymoo* e (iii) implementação no *pymoo* com operadores configurados para aproximar a estratégia manual. O estudo utiliza seleção por torneio, recombinação BLX-α e mutação *creep* na versão manual, com critério de parada por número máximo de avaliações da função objetivo. São analisadas a dinâmica populacional, as curvas médias de convergência em 30 execuções e a escalabilidade para diferentes dimensionalidades. Os resultados mostram superioridade consistente das abordagens baseadas em *pymoo*, com destaque para a versão configurada em cenários de maior dimensionalidade.

Keywords: Algoritmo Genético · Rosenbrock · Metaheurísticas · pymoo · Otimização.

1 Introdução

A função de Rosenbrock é um problema clássico para validação de métodos de otimização por apresentar um vale estreito e curvatura acentuada, o que dificulta o processo de busca do mínimo global. Nesse contexto, algoritmos genéticos (AGs) constituem uma alternativa robusta por não dependerem de informação de gradiente e por explorarem o espaço de busca de forma populacional.

Este relatório compara três configurações de AG com foco em desempenho de convergência e robustez: uma implementação manual e duas variantes no *pymoo*. O objetivo é verificar o impacto dos operadores genéticos e da infraestrutura de execução sobre a qualidade das soluções finais.

2 Metodologia

* Todo o código utilizado e implementado está disponível através do Google Colab.

2.1 Problema de otimização

A função objetivo utilizada foi a função de Rosenbrock em dimensão d:

$$f(\mathbf{x}) = \sum_{i=1}^{d-1} \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2\right]. \tag{1}$$

O mínimo global ocorre em $\mathbf{x}^* = (1, \ldots, 1)$, com $f(\mathbf{x}^*) = 0$.

2.2 Algoritmo genético manual

A implementação manual foi construída com indivíduos reais no intervalo $[-5, 10]$ e os seguintes componentes:

- Seleção por torneio;
- Cruzamento BLX-α (com $\alpha = 0{,}3$);
- Mutação *creep* gaussiana (taxa de mutação de 0,05 e $\sigma = 0{,}1$);
- Critério de parada por número máximo de avaliações da função (até 100.000).

2.3 Configurações no *pymoo*

Foram avaliadas duas variantes:

- **GA padrão**: configuração nativa do *pymoo*, alterando apenas o tamanho da população e o limite de avaliações;
- **GA configurado**: versão com seleção por torneio , cruzamento BLX-α e mutação *creep*, mantendo a eliminação de duplicatas (versão criada com auxílio de LLM).

2.4 Protocolo experimental

Os experimentos seguiram os mesmos limites de busca e tamanho populacional ($N = 100$), com análise em duas etapas:

- Análise da dinâmica populacional em 2D para 1, 2.500, 5.000 e 100.000 avaliações;
- Comparação estatística por curva média em 30 execuções para 2, 5, 10 e 30 dimensões.

As curvas são apresentadas em escala logarítmica no eixo de *fitness*.

3 Resultados

3.1 Evolução da população (2D)

As Figuras 1–4 ilustram a distribuição da população sobre as curvas de nível da função de Rosenbrock. Observa-se que a população inicia dispersa e, ao longo das avaliações, concentra-se progressivamente na região do mínimo global.

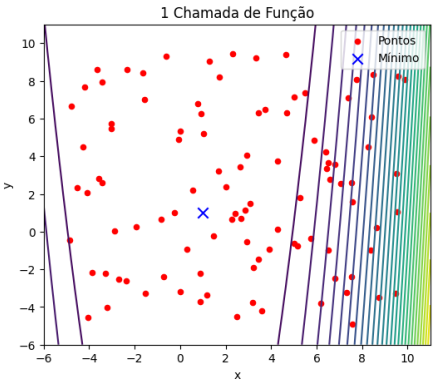

Figura 1. População com 1 avaliação.

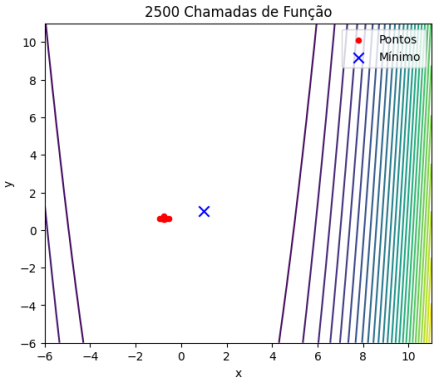

Figura 2. População com 2.500 avaliações.

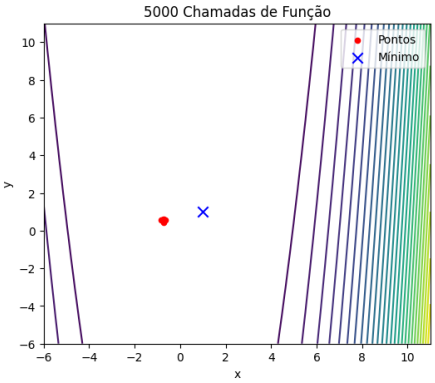

Figura 3. População com 5.000 avaliações.

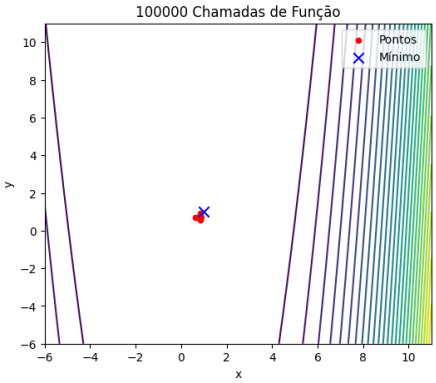

Figura 4. População com 100.000 avaliações.

3.2 Comparação em 2D

A Figura 5 compara o AG manual e o GA padrão do *pymoo* em 30 execuções. Nota-se uma convergência significativamente mais rápida do *pymoo*, atingindo valores de *fitness* menores em um menor número de avaliações.

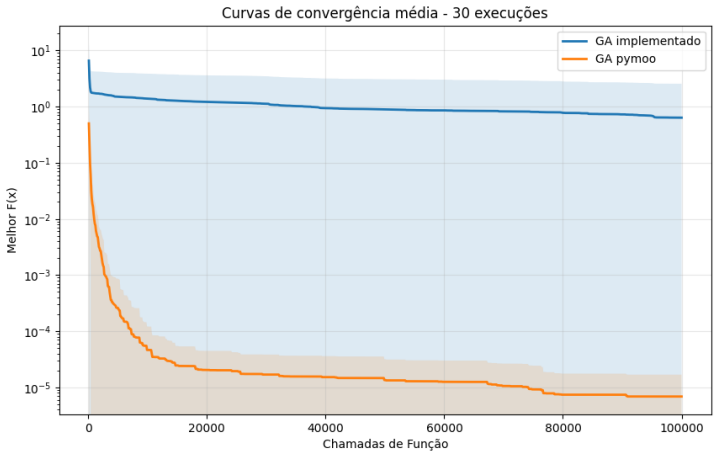

Figura 5. Curvas médias de convergencia (30 execuções) para AG manual e GA padrão do *pymoo* em 2D.

A Figura 6 inclui também a versão configurada do *pymoo*. Em 2D, o GA padrão e o GA configurado apresentam desempenho competitivo entre si, ambos superiores ao AG manual.

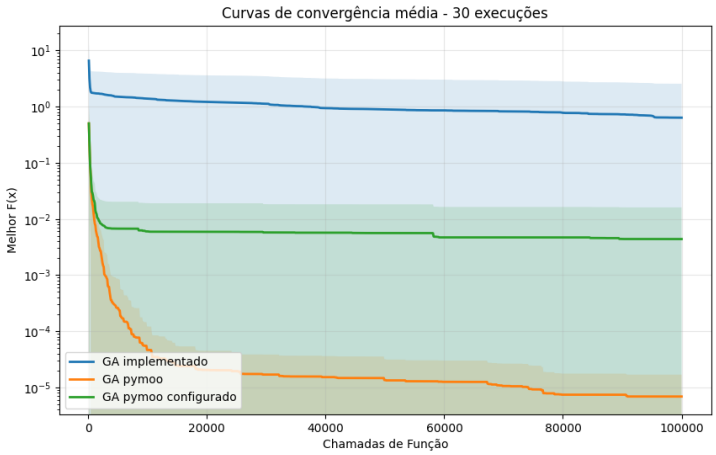

Figura 6. Curvas médias de convergência (30 execuções) para as três abordagens em 2D.

3.3 Tabela final de comparação (item 6)

Para atender ao item 6 do enunciado, a Tabela 1 apresenta a comparação entre as três versões avaliadas em 2D, com 30 execuções. O *fitness* final considerado é o valor do melhor indivíduo (*best*) na última geração de cada execução.

Tabela 1. Resumo estatístico final em 2D (30 execuções): AG implementado, GA *pymoo* e GA *pymoo* configurado.

Versão	Média final	Desvio padrão final	Mediana final	Execução mediana	*Fitness* da execução mediana
GA implementado	13,6985	25,5053	5,23377	16	5,24958
GA *pymoo*	5,57747	1,92067	6,05638	30	6,05737
GA *pymoo* configurado	7,19376	0,281863	7,28029	21	7,27686

Pelos resultados da Tabela 1, a versão que se sobressai em 2D é o **GA *pymoo*** em média final, enquanto o **AG implementado** apresenta a menor mediana final. O **GA *pymoo* configurado** aparece como alternativa intermediária, com baixa variabilidade entre execuções.

4 Comparação por Dimensionalidade (item 7)

Neste item, cada dimensionalidade é apresentada como subitem com: (i) curva de convergência média de 30 execuções, (ii) interpretação sobre qual versão se sobressai e (iii) tabela com média, desvio padrão, mediana, execução mediana e *fitness* da execução mediana.

Os gráficos de convergência média mostram, para cada número de avaliações da função objetivo, o comportamento médio do melhor *fitness* obtido ao longo das 30 execuções. A linha principal resume a tendência central de cada algoritmo, enquanto a faixa sombreada indica a dispersão dos resultados entre as execuções, permitindo avaliar simultaneamente velocidade de convergência e estabilidade.

4.1 Dimensão 5D

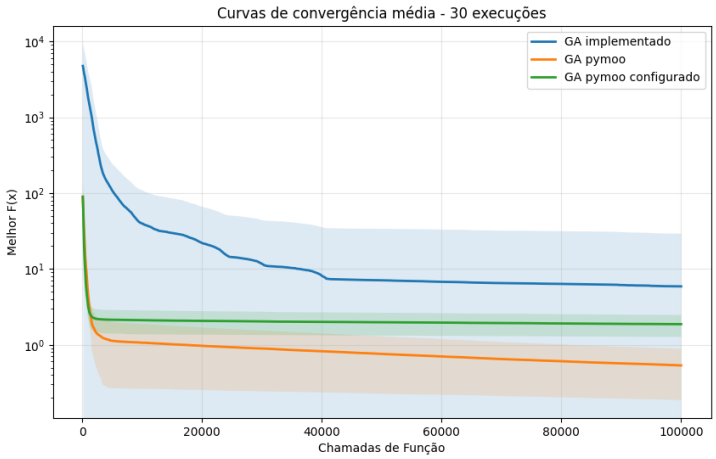

Figura 7. Curvas médias de convergência (30 execuções) em 5D.

Em 5D, a versão que mais se sobressai é o **GA *pymoo***, pois apresenta o menor *fitness* médio final e também a menor mediana final entre as três abordagens.

Tabela 2. Resumo estatístico final em 5D (30 execuções).

Versão	Média final	Desvio padrão final	Mediana final	Execução mediana	*Fitness* da execução mediana
GA implementado	5,88677	23,3532	0,712228	7	0,685854
GA *pymoo*	0,533806	0,346973	0,657363	9	0,620673
GA *pymoo* configurado	1,86835	0,597288	1,98421	8	1,9609

4.2 Dimensão 10D

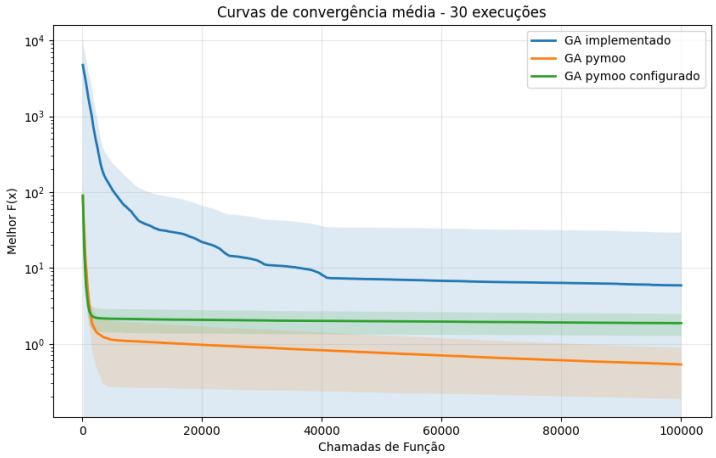

Figura 8. Curvas médias de convergência (30 execuções) em 10D.

Em 10D, novamente o **GA *pymoo*** se sobressai em média final, enquanto o AG implementado apresenta a menor mediana final. A versão configurada permanece competitiva, mas não supera o GA *pymoo* padrão neste conjunto de execuções.

Tabela 3. Resumo estatístico final em 10D (30 execuções).

Versão	Média final	Desvio padrão final	Mediana final	Execução mediana	*Fitness* da execução mediana
GA implementado	13,6985	25,5053	5,23377	16	5,24958
GA *pymoo*	5,57747	1,92067	6,05638	30	6,05737
GA *pymoo* configurado	7,19376	0,281863	7,28029	21	7,27686

4.3 Dimensão 30D

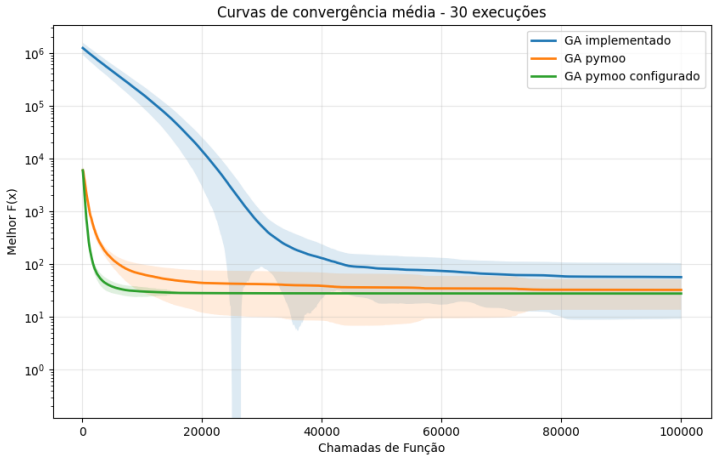

Figura 9. Curvas médias de convergência (30 execuções) em 30D.

Em 30D, o **GA *pymoo* configurado** continua sendo a melhor alternativa. A diferença para as outras versões é ainda mais acentuada, com ganhos de várias ordens de grandeza no *fitness* final.

Tabela 4. Resumo estatístico final em 30D (30 execuções).

Versão	Média final	Desvio padrão final	Mediana final	Execução mediana	*Fitness* da execução mediana
GA implementado	56,3063	47,1505	26,7902	21	26,8206
GA *pymoo*	32,2322	18,6446	26,7791	23	26,7267
GA *pymoo* configurado	27,5255	0,567078	27,6556	5	27,663

4.4 Síntese

Considerando 5D, 10D e 30D, a versão que se sobressai de forma consistente é o **GA *pymoo*** em 5D e 10D, enquanto o **GA *pymoo* configurado** apresenta a menor média final em 30D. Em termos de mediana, o GA *pymoo* permanece competitivo, mas o desempenho relativo varia com a dimensionalidade.

5 Conclusão

Este trabalho comparou três variantes de algoritmo genético para a minimização da função de Rosenbrock. A análise experimental mostrou que:

1. O AG manual apresenta a pior taxa de convergência média;

2. O GA padrão do *pymoo* melhora substancialmente os resultados em 2D, 5D e 10D;
3. O GA configurado no *pymoo* apresenta o melhor desempenho em 30D.

Como extensão futura, recomenda-se avaliar a sensibilidade de hiperparâmetros (pressão de torneio, taxa de mutação e α do BLX), além de incluir testes estatísticos formais (por exemplo, Wilcoxon ou Friedman) para consolidar a comparação entre os métodos.

Referências

1. Takahashi, R.H.C.: Notas de Aula: Otimização Escalar e Vetorial – Volume 2: Otimização Escalar. Departamento de Engenharia Elétrica, Universidade Federal de Minas Gerais, Belo Horizonte (2023).
2. Mattos, D.S.: Código do trabalho no Google Colab. `https://colab.research.google.com/drive/1QzpCkviWcmNqncEVkiM7mFcWjVB7TdL_?usp=sharing`
3. VLSE: Virtual Library of Simulation Experiments. `https://www.sfu.ca/~ssurjano/optimization.html`, último acesso em 06/04/2026.
4. Marcelino, C.G.: Slides de aula da disciplina de Otimização com Metaheurísticas. Universidade Federald do Rio de Janeiro, 2026/1.
5. Blank, J., Deb, K.: *pymoo: Multi-Objective Optimization in Python*. IEEE Access 8, 89497–89509 (2020). `https://pymoo.org/`
6. Rosenbrock, H.H.: *An Automatic Method for Finding the Greatest or Least Value of a Function*. The Computer Journal 3(3), 175–184 (1960).