Comparação de Algoritmos Genéticos na Função de Rosenbrock: Implementação Manual e Framework *pymoo*

Davi dos Santos Mattos[119133049]

Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil
secgrad@ic.ufrj.br

Resumo Este trabalho apresenta um estudo comparativo entre três versões de algoritmo genético aplicadas à minimização da função de Rosenbrock: (i) implementação manual, (ii) implementação padrão do framework *pymoo* e (iii) implementação no *pymoo* com operadores configurados para aproximar a estratégia manual. O estudo utiliza seleção por torneio, recombinação BLX-α e mutação *creep* na versão manual, com critério de parada por número máximo de avaliações da função objetivo. São analisadas a dinâmica populacional, as curvas médias de convergência em 30 execuções e a escalabilidade para diferentes dimensionalidades. Os resultados mostram superioridade consistente das abordagens baseadas em *pymoo*, com destaque para a versão configurada em cenários de maior dimensionalidade.

Keywords: Algoritmo Genético · Rosenbrock · Metaheurísticas · pymoo · Otimização.

1 Introdução

A função de Rosenbrock é um problema clássico para validação de métodos de otimização por apresentar um vale estreito e curvatura acentuada, o que dificulta o processo de busca do mínimo global. Nesse contexto, algoritmos genéticos (GAs) constituem uma alternativa robusta por não dependerem de informação de gradiente e por explorarem o espaço de busca de forma populacional.

Este relatório compara três configurações de GA com foco em desempenho de convergência e robustez: uma implementação manual e duas variantes no *pymoo*. O objetivo é verificar o impacto dos operadores genéticos e da infraestrutura de execução sobre a qualidade das soluções finais.

2 Metodologia

* Todo o código utilizado e implementado está disponível através do Google Colab.

2.1 Problema de otimização

A função objetivo utilizada foi a função de Rosenbrock em dimensão d:

$$f(\mathbf{x}) = \sum_{i=1}^{d-1} \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2\right]. \tag{1}$$

O mínimo global ocorre em $\mathbf{x}^* = (1, \ldots, 1)$, com $f(\mathbf{x}^*) = 0$.

2.2 Algoritmo genético manual

A implementação manual foi construída com indivíduos reais no intervalo $[-5, 10]$ e os seguintes componentes:

- Seleção por torneio;
- Cruzamento BLX-α (com $\alpha = 0{,}3$);
- Mutação *creep* gaussiana (taxa de mutação de 0,05 e $\sigma = 0{,}1$);
- Critério de parada por número máximo de avaliações da função (até 100.000).

2.3 Configurações no *pymoo*

Foram avaliadas duas variantes:

- **GA padrão**: configuração nativa do *pymoo*, alterando apenas o tamanho da população e o limite de avaliações;
- **GA configurado**: versão com seleção por torneio , cruzamento BLX-α e mutação *creep*, mantendo a eliminação de duplicatas (versão criada com auxílio de LLM).

2.4 Protocolo experimental

Os experimentos seguiram os mesmos limites de busca e tamanho populacional ($N = 100$), com análise em duas etapas:

- Análise da dinâmica populacional em 2D para 1, 2.500, 5.000 e 100.000 avaliações;
- Comparação estatística por curva média em 30 execuções para 2, 5, 10 e 30 dimensões.

As curvas são apresentadas em escala logarítmica no eixo de *fitness*.

3 Resultados

3.1 Evolução da população (2D)

As Figuras 1–4 ilustram a distribuição da população sobre as curvas de nível da função de Rosenbrock. Observa-se que a população inicia dispersa e, ao longo das avaliações, concentra-se progressivamente na região do mínimo global.

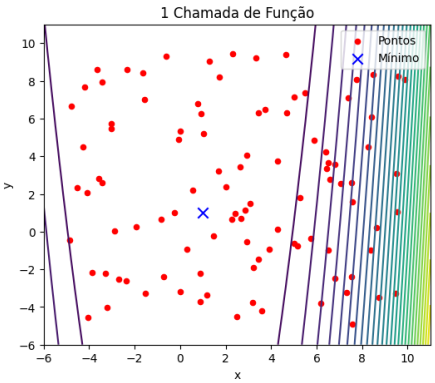

Figura 1. População com 1 avaliação.

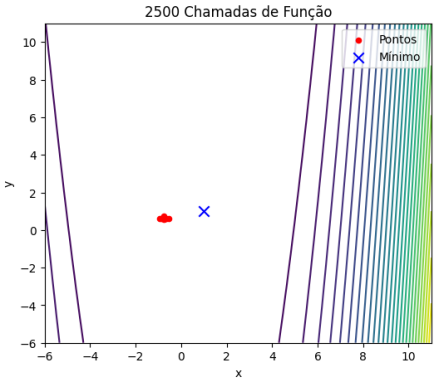

Figura 2. População com 2.500 avaliações.

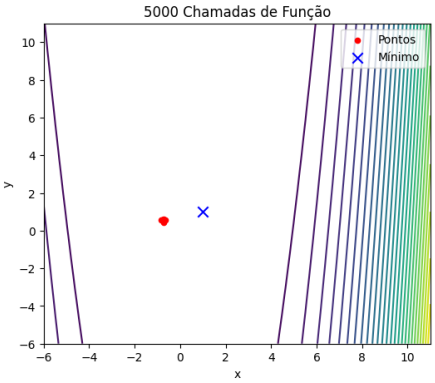

Figura 3. População com 5.000 avaliações.

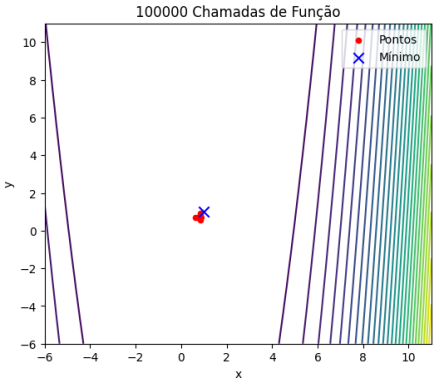

Figura 4. População com 100.000 avaliações.

3.2 Comparação em 2D

A Figura 5 compara o GA manual e o GA padrão do *pymoo* em 30 execuções. Nota-se uma convergência significativamente mais rápida do *pymoo*, atingindo valores de *fitness* menores em um menor número de avaliações.

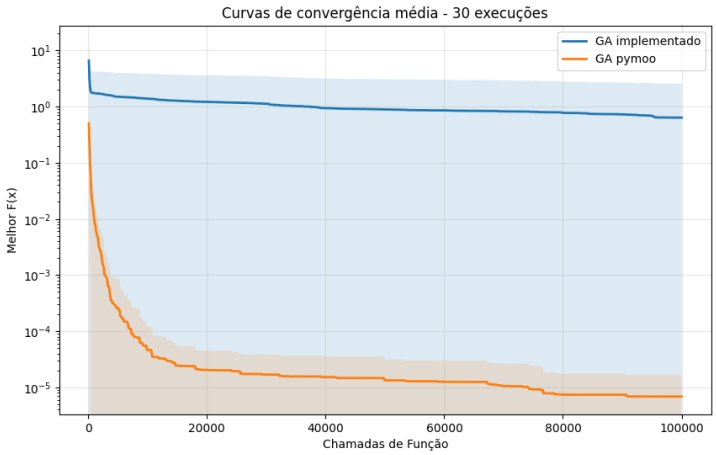

Figura 5. Curvas médias de convergencia (30 execuções) para GA manual e GA padrão do *pymoo* em 2D.

A Figura 6 inclui também a versão configurada do *pymoo*. Em 2D, o GA padrão e o GA configurado apresentam desempenho competitivo entre si, ambos superiores ao GA manual.

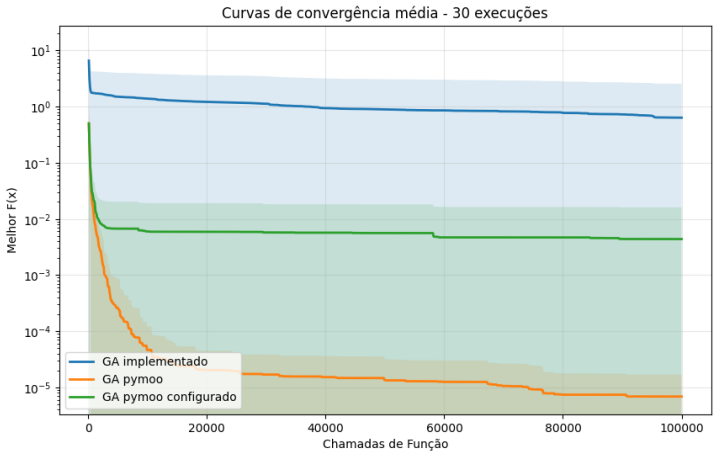

Figura 6. Curvas médias de convergência (30 execuções) para as três abordagens em 2D.

3.3 Tabela final de comparação

A Tabela 1 apresenta a comparação entre as três versões avaliadas em 2D, com 30 execuções. O *fitness* final considerado é o valor do melhor indivíduo (*best*) na última geração de cada execução.

Tabela 1. Resumo estatístico final em 2D (30 execuções): GA implementado, GA *pymoo* e GA *pymoo* configurado.

Versão	Média final	Desvio padrão final	Mediana final	Execução mediana	Indivíduo mediano	*Fitness* da execução mediana
GA implementado	0,635246	1,91969	0,0377446	4	[0,805007, 0,64809]	0,0380226
GA *pymoo*	6,87271e-06	9,95935e-06	2,71525e-06	7	[1,001728, 1,003463]	2,98872e-06
GA *pymoo* configurado	0,00437722	0,0116346	2,70014e-05	25	[1,005664, 1,011365]	3,20797e-05

Pelos resultados da Tabela 1, a versão que se sobressai em 2D é o **GA *pymoo*** em média final, enquanto o **GA implementado** apresenta a menor mediana final. O **GA *pymoo* configurado** aparece como alternativa intermediária, com baixa variabilidade entre execuções.

4 Comparação por Dimensionalidade

Neste item, cada dimensionalidade é apresentada como subitem com: (i) curva de convergência média de 30 execuções, (ii) interpretação sobre qual versão se sobressai e (iii) tabela com média, desvio padrão, mediana, execução mediana, indivíduo mediano e *fitness* da execução mediana.

Os gráficos de convergência média mostram, para cada número de avaliações da função objetivo, o comportamento médio do melhor *fitness* obtido ao longo

das 30 execuções. A linha principal resume a tendência central de cada algoritmo, enquanto a faixa sombreada indica a dispersão dos resultados entre as execuções, permitindo avaliar simultaneamente velocidade de convergência e estabilidade.

4.1 Dimensão 5D

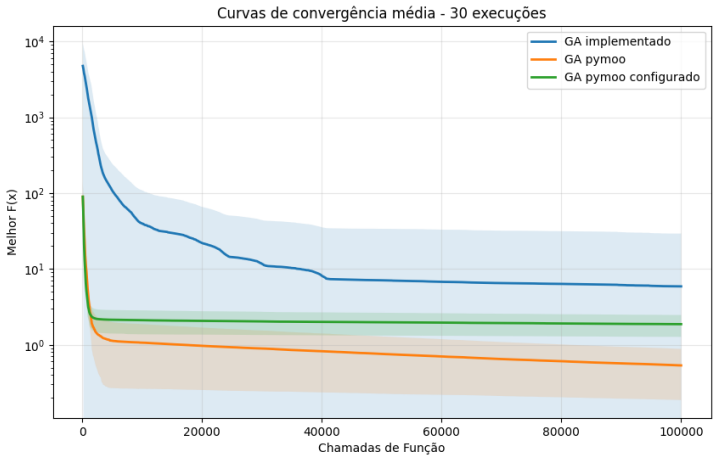

Figura 7. Curvas médias de convergência (30 execuções) em 5D.

Em 5D, a versão que mais se sobressai é o **GA *pymoo***, pois apresenta o menor *fitness* médio final e também a menor mediana final entre as três abordagens.

Tabela 2. Resumo estatístico final em 5D (30 execuções).

Versão	Média final	Desvio padrão final	Mediana final	Execução mediana	Indivíduo mediano	*Fitness* da execução mediana
GA implementado	5,88677	23,3532	0,712228	7	[0,871666, 0,763261, 0,581052, 0,342265, 0,113116]	0,685854
GA *pymoo*	0,533806	0,346973	0,657363	9	[0,880485, 0,776246, 0,608622, 0,372583, 0,131571]	0,620673
GA *pymoo* configurado	1,86835	0,597288	1,98421	8	[0,669392, 0,445484, 0,208888, 0,049786, 0,002367]	1,9609

4.2 Dimensão 10D

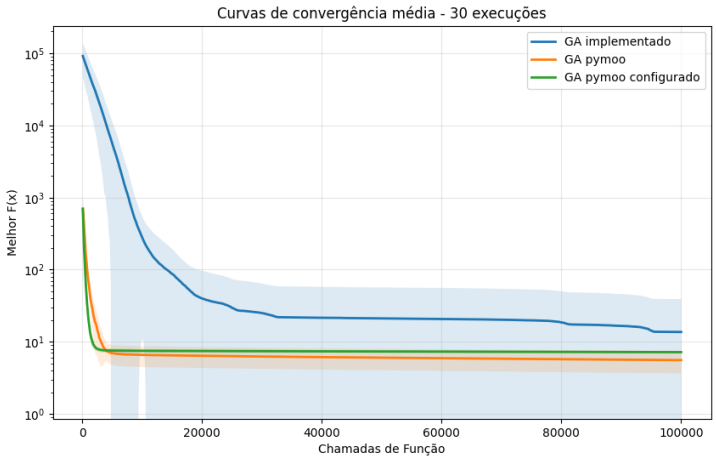

Figura 8. Curvas médias de convergência (30 execuções) em 10D.

Em 10D, novamente o **GA *pymoo*** se sobressai em média final, enquanto o GA implementado apresenta a menor mediana final. A versão configurada permanece competitiva, mas não supera o GA *pymoo* padrão neste conjunto de execuções.

Tabela 3. Resumo estatístico final em 10D (30 execuções).

Versão	Média final	Desvio padrão final	Mediana final	Exec. mediana	Indivíduo mediano	*Fitness* execução mediana
GA implementado	13,6985	25,5053	5,23377	16	[8.78e-01, 7.75e-01, ..., 1.01e-02, 6.75e-04]	5,24958
GA *pymoo*	5,57747	1,92067	6,05638	30	[0,803, 0,647, ..., 0,011, 0,00124]	6,05737
GA *pymoo* configurado	7,19376	0,281863	7,28029	21	[5.84e-01, 3.47e-01, ..., 1.02e-02, -2.43e-04]	7,27686

4.3 Dimensão 30D

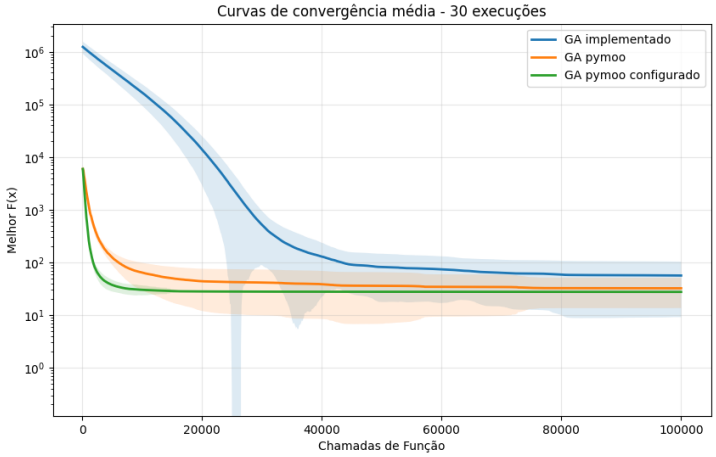

Figura 9. Curvas médias de convergência (30 execuções) em 30D.

Em 30D, o **GA *pymoo* configurado** se torna a melhor alternativa, com menos variabilidade. Porém o **GA *pymoo*** continua sendo competitivo com uma melhor Mediana e Fitness da exeução mediana.

Tabela 4. Resumo estatístico final em 30D (30 execuções).

Versão	Média final	Desvio padrão final	Mediana final	Exec. mediana	Indivíduo mediano	*Fitness* execução mediana
GA implementado	56,3063	47,1505	26,7902	21	[0,645, 0,420, ..., 0,0101, 0,00111]	26,8206
GA *pymoo*	32,2322	18,6446	26,7791	23	[0,675, 0,445, ..., 0,00993, 5,06e-04]	26,7267
GA *pymoo* configurado	27,5255	0,567078	27,6556	5	[0,434, 0,182, ..., 0,0156, 2,23e-04]	27,663

4.4 Dimensão 30D (Implementado + pymoo padrão)

Em 30D, a comparação entre o GA implementado e o GA *pymoo* padrão confirma a vantagem do *pymoo* em média final e em mediana final.

Tabela 5. Resumo estatístico final em 30D (30 execuções): GA implementado e GA *pymoo*.

Versão	Média final	Desvio padrão final	Mediana final	Exec. mediana	Indivíduo mediano	*Fitness* execução mediana
GA implementado	56,3063	47,1505	26,7902	21	[0,645, 0,420, ..., 0,0101, 0,00111]	26,8206
GA *pymoo*	32,2322	18,6446	26,7791	23	[0,675, 0,445, ..., 0,00993, 5,06e-04]	26,7267

4.5 Síntese

Considerando 5D, 10D e 30D, a versão que se sobressai de forma consistente é o **GA *pymoo*** em 5D e 10D, enquanto o **GA *pymoo* configurado** apresenta a menor média final em 30D. Em termos de mediana, o GA *pymoo* permanece competitivo, mas o desempenho relativo varia com a dimensionalidade.

5 Conclusão

Este trabalho comparou três variantes de algoritmo genético para a minimização da função de Rosenbrock. A análise experimental mostrou que:

1. O GA manual apresenta a pior taxa de convergência média;
2. O GA padrão do *pymoo* melhora substancialmente os resultados em 2D, 5D e 10D;
3. O GA configurado no *pymoo* apresenta o melhor desempenho em 30D.

Como extensão futura, recomenda-se avaliar a sensibilidade de hiperparâmetros (pressão de torneio, taxa de mutação e α do BLX), além de incluir testes estatísticos formais (por exemplo, Wilcoxon ou Friedman) para consolidar a comparação entre os métodos.

Referências

1. Takahashi, R.H.C.: Notas de Aula: Otimização Escalar e Vetorial – Volume 2: Otimização Escalar. Departamento de Engenharia Elétrica, Universidade Federal de Minas Gerais, Belo Horizonte (2023).
2. Mattos, D.S.: Código do trabalho no Google Colab. `https://colab.research.google.com/drive/1QzpCkviWcmNqncEVkiM7mFcWjVB7TdL_?usp=sharing`
3. VLSE: Virtual Library of Simulation Experiments. `https://www.sfu.ca/~ssurjano/optimization.html`, último acesso em 06/04/2026.
4. Marcelino, C.G.: Slides de aula da disciplina de Otimização com Metaheurísticas. Universidade Federald do Rio de Janeiro, 2026/1.
5. Blank, J., Deb, K.: *pymoo: Multi-Objective Optimization in Python*. IEEE Access 8, 89497–89509 (2020). `https://pymoo.org/`
6. Rosenbrock, H.H.: *An Automatic Method for Finding the Greatest or Least Value of a Function*. The Computer Journal 3(3), 175–184 (1960).