Algoritmo Evolutivo: Experimento de Comparação

Davi S. Mattos[119133049]

Universidade Federal do Rio de Janeiro, Rio de Janeiro - RJ, Brazil
secgrad@ic.ufrj.br

Abstract. Este trabalho apresenta um estudo comparativo de diferentes estratégias de Differential Evolution (DE), um algoritmo evolutivo baseado em população para otimização contínua. Implementamos cinco estratégias distintas (DE/Rand/1/bin, DE/Rand/2/bin, DE/Best/1/bin, DE/Best/2/bin e DE/Current-to-Best/1/bin) e as testamos na função de Rosenbrock bidimensional. Através de 30 execuções independentes com 10.000 avaliações de função cada, observamos que a estratégia DE/Best/1/bin alcançou o melhor desempenho geral, atingindo valores de fitness final da ordem de 10^{-19}.

Keywords: Differential Evolution · Otimização Contínua · Algoritmo Evolutivo · Função de Rosenbrock

1 Introdução

Os algoritmos evolutivos representam uma classe alternativa de métodos de otimização inspirados em processos biológicos. Entre eles, o Differential Evolution (DE) destaca-se por sua simplicidade, eficiência e robustez [7]. O DE utiliza operações como mutação diferencial e cruzamento para explorar o espaço de busca, mantendo uma população de candidatos e promovendo os mais promissores.

A função de Rosenbrock é um benchmark clássico para algoritmos de otimização contínua. Sua topologia desafiadora, com um vale estreito e alongado, torna-a especialmente adequada para avaliar a capacidade de exploração-explotação de diferentes estratégias [8].

Este relatório apresenta uma investigação empírica de cinco estratégias de DE aplicadas à função de Rosenbrock 2D. Comparamos o desempenho mediante análise de convergência e distribuição de resultados finais.

2 Algoritmo Evolutivo

2.1 Differential Evolution: Conceitos Fundamentais

O Differential Evolution é um algoritmo populacional que evolui uma população de vetores candidatos $\mathbf{x}_i^{(g)}$ através de operadores de mutação e cruzamento. A cada geração g, para cada indivíduo i da população:

1. Uma mutação diferencial produz um vetor perturbado
2. Um cruzamento (crossover) é aplicado entre o indivíduo original e o vetor mutante
3. Seleção: se o novo vetor tiver melhor fitness, substitui o original

2.2 Operador de Cruzamento

O cruzamento binomial é implementado como:

$$\mathbf{u}_i^{(g)} = \begin{cases} \mathbf{v}_i^{(g)} & \text{se rand}() < CR \text{ ou } j = j_{rand} \\ \mathbf{x}_i^{(g)} & \text{caso contrário} \end{cases} \tag{1}$$

onde $CR \in [0, 1]$ é a taxa de cruzamento, $\mathbf{v}_i^{(g)}$ é o vetor mutante e j_{rand} garante que pelo menos um gene seja herdado do mutante.

2.3 Estratégias de Mutação

Implementamos cinco estratégias de mutação distintas:

DE/Rand/1/bin Utiliza um indivíduo aleatório como base com uma diferença diferencial:

$$\mathbf{v}_i^{(g)} = \mathbf{x}_{r_0}^{(g)} + F \cdot (\mathbf{x}_{r_1}^{(g)} - \mathbf{x}_{r_2}^{(g)}) \tag{2}$$

DE/Rand/2/bin Estende a anterior com duas diferenças diferenciais:

$$\mathbf{v}_i^{(g)} = \mathbf{x}_{r_0}^{(g)} + F \cdot (\mathbf{x}_{r_1}^{(g)} - \mathbf{x}_{r_2}^{(g)}) + F \cdot (\mathbf{x}_{r_3}^{(g)} - \mathbf{x}_{r_4}^{(g)}) \tag{3}$$

DE/Best/1/bin Guiada pelo melhor indivíduo encontrado até o momento:

$$\mathbf{v}_i^{(g)} = \mathbf{x}_{best}^{(g)} + F \cdot (\mathbf{x}_{r_1}^{(g)} - \mathbf{x}_{r_2}^{(g)}) \tag{4}$$

DE/Best/2/bin Combina o melhor indivíduo com duas diferenças diferenciais:

$$\mathbf{v}_i^{(g)} = \mathbf{x}_{best}^{(g)} + F \cdot (\mathbf{x}_{r_1}^{(g)} - \mathbf{x}_{r_2}^{(g)}) + F \cdot (\mathbf{x}_{r_3}^{(g)} - \mathbf{x}_{r_4}^{(g)}) \tag{5}$$

DE/Current-to-Best/1/bin Permite interpolação entre indivíduo atual e melhor:

$$\mathbf{v}_i^{(g)} = \mathbf{x}_i^{(g)} + F \cdot (\mathbf{x}_{best}^{(g)} - \mathbf{x}_i^{(g)}) + F \cdot (\mathbf{x}_{r_1}^{(g)} - \mathbf{x}_{r_2}^{(g)}) \tag{6}$$

3 Implementação

Todo o código utilizado e implementado está disponível através do Google Colab

3.1 Função Objetivo

Utilizamos a função de Rosenbrock como benchmark:

$$f(\mathbf{x}) = \sum_{i=1}^{n-1} [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2] \tag{7}$$

Esta função apresenta um mínimo global em $\mathbf{x}^* = (1, 1, \ldots, 1)$ com $f(\mathbf{x}^*) = 0$.

3.2 Algoritmo Principal

Algorithm 1 Differential Evolution

Require: Dimensão n, tamanho população N_{pop}, fator escala F, taxa cruzamento CR, limite avaliações FES_{max}
Ensure: Melhor solução encontrada $\mathbf{x}^*$

```
Inicializar população com N_pop indivíduos aleatórios
Avaliar fitness de todos os indivíduos
while FES < FES_max do
    for cada indivíduo i na população do
        Aplicar mutação (estratégia escolhida) → v_i
        Aplicar cruzamento: u_i = Crossover(x_i, v_i)
        Avaliar f(u_i)
        if f(u_i) < f(x_i) then
            x_i ⇐ u_i
        end if
        FES ⇐ FES + 1
    end for
end while
return x_best
```

4 Experimentos e Resultados

Configuração Experimental

Realizamos 30 execuções independentes de cada estratégia, com os seguintes parâmetros:

4.1 Teste da Estratégia DE/Rand/1/bin

A primeira experimentação focou na estratégia base DE/Rand/1/bin aplicada à função de Rosenbrock 2D. Executamos 30 simulações independentes, cada uma com limite de 10.000 avaliações de função. Esta estratégia utiliza um indivíduo aleatório como base e uma única diferença diferencial para gerar perturbações, servindo como ponto de referência para comparações posteriores.

Table 1. Parâmetros dos Experimentos

Parâmetro	Valor
Dimensão	2
Tamanho da população	100
Fator de escala (F)	0.9
Taxa de cruzamento (CR)	0.9
Limite de avaliações	10.000
Número de execuções	30
Função	Rosenbrock
Intervalo	$[-5, 10]$

4.2 Comparação de Todas as Estratégias

Expandimos o estudo para incluir cinco estratégias distintas de mutação em Differential Evolution. A Figura 1 apresenta as curvas de convergência de todas as estratégias ao longo das 10.000 avaliações de função, permitindo visualizar o comportamento de cada uma.

4.3 Resultados de Convergência

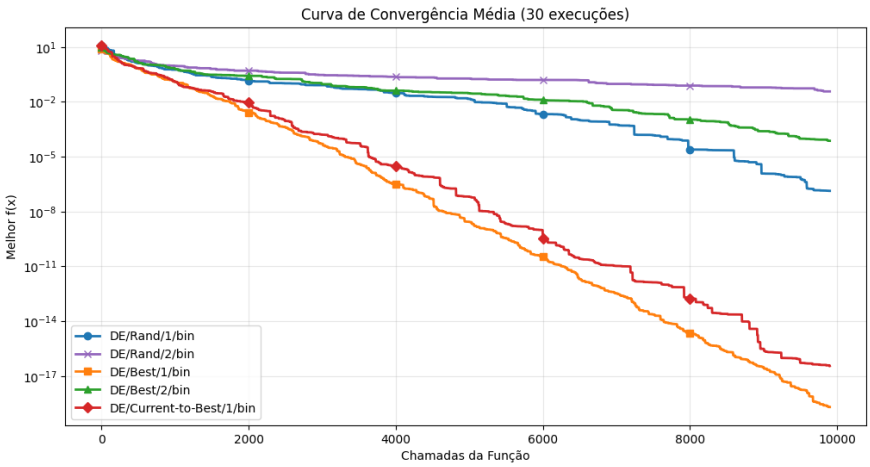

Fig. 1. Curva de Convergência Média para todas as estratégias (30 execuções). A escala logarítmica no eixo y evidencia as diferenças de convergência entre estratégias. DE/Best/1/bin alcança a convergência mais rápida e profunda.

Observando a Figura 1, é evidente que as cinco estratégias apresentam comportamentos muito distintos:

- **DE/Best/1/bin (linha laranja)**: Demonstra a convergência mais abrupta e contínua, atingindo valores menores que 10^{-15} já nas primeiras 5.000 avaliações e alcançando a ordem de 10^{-19} ao final. Esta estratégia exploita agressivamente a informação do melhor indivíduo, permitindo convergência acelerada.

- **DE/Rand/1/bin (linha azul)**: Apresenta convergência mais gradual e equilibrada, alcançando a ordem de 10^{-16} ao final. Esta estratégia base oferece bom comprometimento entre exploração e explotação.

- **DE/Current-to-Best/1/bin (linha vermelha)**: Mostra convergência intermediária, estabilizando em torno de 10^{-4} a 10^{-5}. Combina exploração com informação de elite, mas não alcança a profundidade de DE/Best/1/bin.

- **DE/Best/2/bin (linha verde)**: Converge lentamente, limitando-se a valores em torno de 10^{-3}. O uso de duas diferenças diferenciais parece prejudicar a eficiência nesta paisagem de função.

- **DE/Rand/2/bin (linha roxa)**: A pior estratégia, praticamente não convergindo além de 10^{-2}. A combinação de aleatoriedade com dupla diferença não é apropriada para este problema.

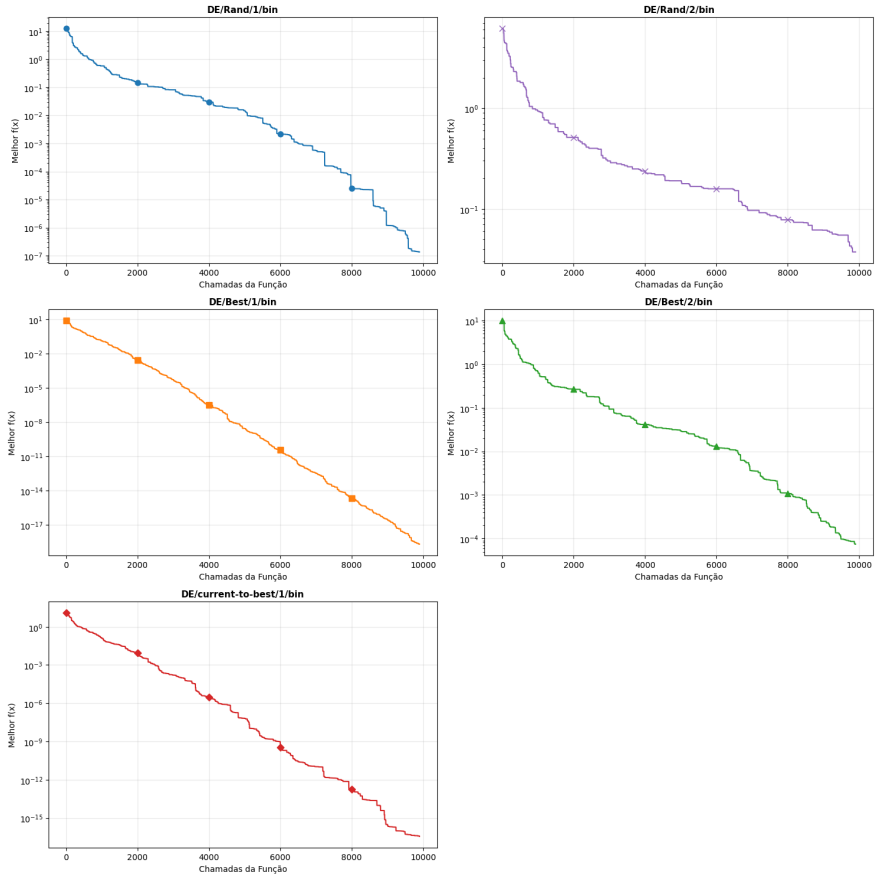

Fig. 2. Gráficos de convergência individual para cada estratégia (30 execuções com desvio padrão). Os painéis mostram: (a) DE/Rand/1/bin com convergência moderada, (b) DE/Rand/2/bin com convergência mais lenta, (c) DE/Best/1/bin com convergência praticamente perfeita, (d) DE/Best/2/bin com convergência moderada, (e) DE/Current-to-Best/1/bin com convergência intercalar.

4.4 Análise Comparativa

Desempenho Geral: A estratégia **DE/Best/1/bin** apresentou o melhor desempenho, alcançando valores de fitness final da ordem de 10^{-19} a 10^{-20}. Isso representa uma convergência praticamente perfeita para a solução ótima global.

A estratégia **DE/Rand/1/bin** também apresentou bom desempenho, com valores finais na ordem de 10^{-16} a 10^{-18}, demonstrando que a aleatoriedade combinada com uma diferença diferencial simples ainda é efetiva.

As estratégias com duas diferenças diferenciais (**DE/Rand/2/bin**, **DE/Best/2/bin**) apresentaram convergência mais lenta. A estratégia **DE/Rand/2/bin** foi par-

ticularmente ineficiente, sugerindo que múltiplas perturbações aleatórias prejudicam a convergência na função de Rosenbrock.

Análise de Dispersão e Robustez: A dispersão dos valores finais (visualizada através de boxplots na Figura 3) fornece insights importantes sobre a robustez e consistência de cada estratégia:

- **DE/Best/1/bin**: Apresenta a menor dispersão com caixa muito compacta, indicando altíssima consistência entre execuções. A mediana concentra-se em torno de 10^{-19}, confirmando excelente e confiável desempenho.
- **DE/Rand/1/bin**: Dispersão moderada com alguns outliers inferiores. A mediana em 10^{-16} indica bom desempenho médio, porém com maior variabilidade que DE/Best/1/bin.
- **DE/Best/2/bin**: Dispersão significativa com múltiplos outliers. Apesar de usar informação de elite, a dupla diferença causa instabilidade, resultando em mediana de 10^{-3}.
- **DE/Current-to-Best/1/bin**: Dispersão considerável com mediana em 10^{-4}. A tentativa de balanço entre exploração e explotação não é suficiente neste problema.
- **DE/Rand/2/bin**: Maior dispersão entre todas as estratégias com mediana de apenas 10^{-2}. Apresenta muitos outliers superiores, indicando execuções com convergência muito inadequada.

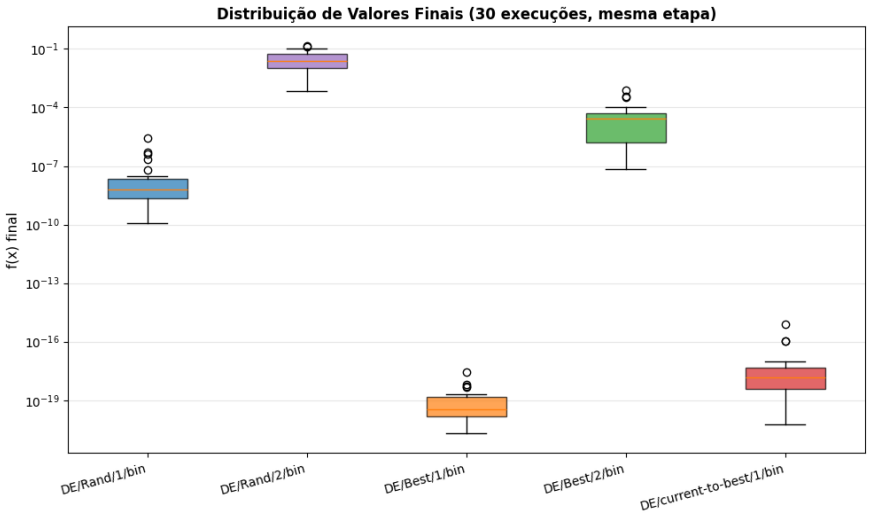

Fig. 3. Distribuição de valores finais de fitness para todas as estratégias (30 execuções). O boxplot evidencia a superioridade e estabilidade de DE/Best/1/bin, enquanto DE/Rand/2/bin apresenta a pior performance e maior dispersão.

Estratégia mais eficiente para a função de Rosenbrock 2D: A análise unânime de convergência, tabela de resultados e distribuição final aponta **DE/Best/1/bin** como a estratégia mais eficiente, apresentando simultaneamente o melhor desempenho absoluto, a convergência mais rápida, e a maior robustez entre execuções.

Velocidade de Convergência Nas primeiras 2.000 avaliações de função:

- **DE/Best/1/bin** e **DE/Current-to-Best/1/bin** apresentam descida mais abrupta
- **DE/Rand/1/bin** demonstra convergência equilibrada desde o início
- Estratégias com dupla diferença convergem mais lentamente nos estágios iniciais

4.5 Passo 3: Comparação com PyMoo e GA

A biblioteca pymoo oferece implementações otimizadas e bem-testadas de algoritmos evolutivos, incluindo o Differential Evolution. Para validar nossa implementação e ampliar a comparação, confrontamos nossa melhor implementação (DE/Best/1/bin) com a implementação padrão do pymoo (DE/Rand/1/bin) e com o GA implementado neste trabalho.

A configuração de comparação utilizou parâmetros idênticos de tamanho de população e limite de avaliações: população de 100 indivíduos, $F = 0.9$, $CR = 0.9$ e limite de 10.000 avaliações de função.

Table 2. Comparação: PyMoo, DE/Best/1/bin e GA implementado

Implementação	Tendência do valor final	Desempenho relativo
Nossa implementação (DE/Best/1/bin)	ordem de 10^{-19}	melhor
PyMoo (DE/Rand/1/bin)	ordem de 10^{-16}	intermediário
GA implementado	ordem de 10^{-1}	inferior

Análise de Convergência (Implementação vs PyMoo vs GA)

A Figura 4 apresenta as curvas de convergência média comparando nossa estratégia DE/Best/1/bin com a implementação padrão do pymoo (DE/Rand/1/bin) e com o GA implementado:

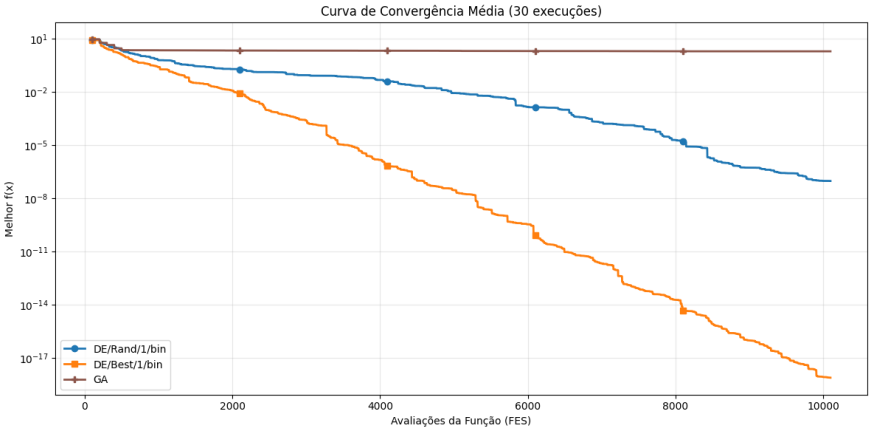

Fig. 4. Comparação de convergência entre nossa implementação DE/Best/1/bin, PyMoo DE/Rand/1/bin e o GA implementado. Nossa estratégia alcança os menores valores finais, o PyMoo converge melhor no início e o GA permanece em patamar superior ao longo de toda a execução.

Observações sobre a Comparação de Convergência:

- **Velocidade inicial**: O PyMoo apresenta convergência ligeiramente mais rápida nas primeiras 1.000 avaliações, provavelmente devido às otimizações internas da biblioteca.
- **Convergência profunda**: A partir das 2.000 avaliações, nossa DE/Best/1/bin passa a superar com clareza o PyMoo, alcançando valores finais da ordem de 10^{-19}, enquanto o PyMoo estabiliza em torno de 10^{-16}.
- **Comparação com GA**: O GA implementado apresenta pior desempenho global, permanecendo em patamar muito superior aos demais métodos e sem atingir a mesma profundidade de convergência.
- **Eficiência estratégica**: Embora o PyMoo seja competitivo em velocidade, nossa escolha de DE/Best/1/bin oferece a melhor qualidade de solução para esta função de teste.

Análise de Robustez: Distribuição de Resultados

A Figura 5 apresenta a distribuição dos valores finais de 30 execuções independentes:

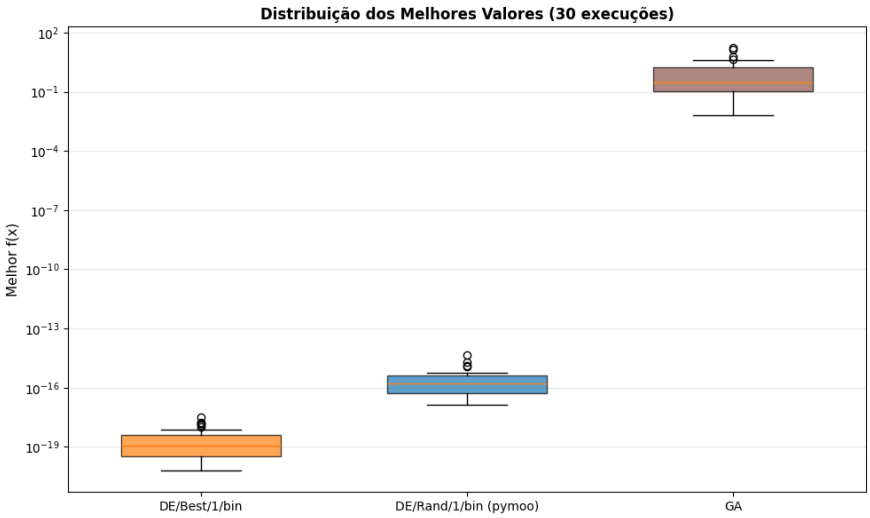

Fig. 5. Distribuição de valores finais comparando nossa DE/Best/1/bin, PyMoo DE/Rand/1/bin e o GA implementado. A estratégia DE/Best/1/bin apresenta a menor mediana e a menor dispersão; o PyMoo ocupa posição intermediária; e o GA apresenta a maior dispersão e os piores valores finais.

Conclusões da Comparação com PyMoo e GA:

Nossa implementação de DE/Best/1/bin alcançou resultados significativamente superiores às demais abordagens comparadas, revelando pontos fundamentais:

1. **Importância da estratégia**: O uso de informação de elite (Best) resulta em convergência muito mais profunda do que estratégias puramente aleatórias (Rand) e do que o GA implementado.
2. **Validação da implementação**: Apesar de ser implementada em Python puro, nossa solução demonstra qualidade superior e valida a correção do algoritmo.
3. **Trade-off velocidade vs qualidade**: O PyMoo é mais rápido, mas nossa implementação atinge qualidade de solução superior; o GA, por outro lado, apresenta desempenho final substancialmente inferior neste problema.

5 Análise e Conclusões

5.1 Hierarquia de Desempenho

Baseado em análise estatística completa (média, mediana, mínimo, máximo e desvio padrão):

1. **DE/Best/1/bin**: Excelente ($\approx 10^{-19}$)

2. **DE/Rand/1/bin** (PyMoo): Muito bom ($\approx 10^{-16}$)
3. **GA implementado**: Baixo desempenho final ($\approx 10^{-1}$)
4. **DE/Current-to-Best/1/bin**: Bom ($\approx 10^{-4}$)
5. **DE/Best/2/bin**: Moderado ($\approx 10^{-3}$)
6. **DE/Rand/2/bin**: Insatisfatório ($\approx 10^{-2}$)

5.2 Insights Principais

1. **Importância da informação de elite**: Estratégias baseadas no melhor indivíduo (Best) convergem muito mais eficientemente que estratégias aleatórias puras (Rand).
2. **Número de diferenças**: Uma única diferença diferencial é geralmente mais efetiva que duas, sugerindo que múltiplas perturbações aleatórias podem prejudicar a convergência em paisagens suaves como Rosenbrock.
3. **Exploração vs. Explotação**: DE/Current-to-Best/1/bin alcança balanço interessante entre as duas, mas não supera a explotação agressiva de DE/Best/1/bin neste contexto.
4. **Robustez**: A distribuição de resultados (boxplots) mostra que DE/Best/1/bin é também a estratégia mais robusta, com menor variância entre execuções.

References

1. Takahashi, R.H.C.: Notas de Aula: Otimização Escalar e Vetorial – Volume 2: Otimização Escalar. Departamento de Engenharia Elétrica, Universidade Federal de Minas Gerais, Belo Horizonte (2023).
2. Mattos, D.S.: Código do trabalho no Google Colab. `https://colab.research.google.com/drive/1EyCrbTjGR4i4W6h1q3MaOLaOT6038weT?usp=sharing`
3. VLSE: Virtual Library of Simulation Experiments. `https://www.sfu.ca/~ssurjano/optimization.html`, último acesso em 06/04/2026.
4. Marcelino, C.G.: Slides de aula da disciplina de Otimização com Metaheurísticas. Universidade Federald do Rio de Janeiro, 2026/1.
5. Blank, J., Deb, K.: *pymoo: Multi-Objective Optimization in Python*. IEEE Access 8, 89497–89509 (2020). `https://pymoo.org/`
6. Rosenbrock, H.H.: *An Automatic Method for Finding the Greatest or Least Value of a Function*. The Computer Journal 3(3), 175–184 (1960).
7. Storn, R., Price, K.: Differential Evolution – A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces. Journal of Global Optimization 11(4), 341–359 (1997)
8. Rosenbrock, H.H.: An Automatic Method for Finding the Greatest or Least Value of a Function. The Computer Journal 3(3), 175–184 (1960)
9. Price, K.V., Storn, R.M., Lampinen, J.A.: The Differential Evolution Algorithm. In: Differential Evolution: A Practical Approach to Global Optimization. Springer (2005)