

Estudo Comparativo de Algoritmos Metaheurísticos para Otimização de Funções Benchmark: AG, DE, PSO e EPSO em Múltiplas Dimensões

Davi¹

Universidade Federal do Rio de Janeiro (UFRJ), Rio de Janeiro, Brasil
aluno@ic.ufrj.br

Resumo Este trabalho apresenta um estudo comparativo entre quatro algoritmos metaheurísticos de otimização contínua: Algoritmo Genético (AG), Evolução Diferencial (DE), Otimização por Enxame de Partículas (PSO) e Otimização Evolutiva por Enxame de Partículas (EPSO). Os algoritmos são avaliados em dez funções benchmark escaláveis — cinco unimodais e cinco multimodais — nas dimensões 30, 50 e 100. O protocolo experimental adota 51 execuções independentes por configuração com um orçamento fixo de 100.000 avaliações de função. Os hiperparâmetros de cada algoritmo foram ajustados individualmente por meio do framework Optuna com o amostrador TPE. A comparação estatística segue o método de Marcelino et al. [5], com Teste T independente por par de algoritmos ao nível de significância de 5%. Os resultados indicam que o desempenho relativo dos algoritmos varia significativamente conforme o tipo de função e a dimensão do problema, evidenciando que nenhum algoritmo domina em todos os cenários avaliados.

Keywords: Metaheurísticas · Algoritmo Genético · Evolução Diferencial · PSO · EPSO · Funções Benchmark · Otimização Contínua

1 Introdução

Problemas de otimização contínua surgem em diversas áreas da engenharia e da ciência, muitas vezes caracterizados por espaços de busca de alta dimensionalidade, não-convexidade e multimodalidade [2]. Algoritmos metaheurísticos têm se destacado como alternativas eficazes aos métodos determinísticos clássicos nesses cenários, uma vez que não requerem informação de gradiente e são capazes de escapar de ótimos locais por meio de mecanismos estocásticos de busca.

Dentre os algoritmos mais estudados na literatura, o Algoritmo Genético (AG) representa o paradigma evolutivo clássico, fundamentado nos princípios da seleção natural e da genética [1]. A Evolução Diferencial (DE) surgiu como uma alternativa competitiva baseada em mutação diferencial e cruzamento binomial, demonstrando desempenho consistente em funções de benchmark [2]. O PSO introduziu o conceito de inteligência coletiva por meio da interação entre partículas guiadas por memória individual e social [3]. O EPSO estende o

PSO com auto-adaptação dos pesos estratégicos e perturbação multiplicativa do melhor global, incorporando características das Estratégias Evolutivas [4].

2 Algoritmos

2.1 Algoritmo Genético (AG)

Na implementação adotada, a **seleção** utiliza torneio de tamanho $k = 3$, escolhendo o mais apto entre k indivíduos sorteados aleatoriamente. O **cruzamento** emprega o operador BLX- α , que gera um descendente no intervalo estendido $[\min(p_1, p_2) - \alpha\Delta, \max(p_1, p_2) + \alpha\Delta]$, onde $\Delta = |p_1 - p_2|$. A **mutação** do tipo *creep* aplica uma perturbação gaussiana de desvio padrão σ a cada gene com probabilidade p_m . A aptidão de toda a nova população é avaliada de forma vetorizada a cada geração.

2.2 Evolução Diferencial (DE)

A estratégia adotada é DE/rand/1/bin: o vetor mutante é gerado como $v_i = x_{r_0} + F(x_{r_1} - x_{r_2})$, onde r_0, r_1, r_2 são índices distintos sorteados aleatoriamente e F é o fator de escala. O cruzamento binomial combina v_i com o vetor alvo x_i gene a gene com probabilidade CR, garantindo ao menos um gene do mutante por meio do índice j_{rand} . A seleção substitui x_i pelo candidato u_i apenas se $f(u_i) \leq f(x_i)$.

2.3 Otimização por Enxame de Partículas (PSO)

A equação de atualização de velocidade é:

$$v_i^{t+1} = w v_i^t + c_1 r_1 (p_i^{\text{best}} - x_i^t) + c_2 r_2 (g^{\text{best}} - x_i^t), \quad (1)$$

onde w é o peso de inércia, c_1 e c_2 os coeficientes de aceleração, e $r_1, r_2 \sim \mathcal{U}(0, 1)$. A velocidade é limitada a $v_{\text{max}} = 0,2(u - l)$ e as posições são projetadas ao domínio por *clipping*.

2.4 Otimização Evolutiva por Enxame de Partículas (EPSO)

O EPSO [4] estende o PSO incorporando auto-adaptação dos pesos estratégicos e seleção *greedy* entre cada partícula e seu clone. Para cada partícula i , um clone herda os pesos mutados por ruído gaussiano:

$$w_j^* = w_j + \tau \mathcal{N}(0, 1), \quad w_j^* \in [0, 1]. \quad (2)$$

O melhor global é perturbado multiplicativamente antes do movimento:

$$g_j^* = g_j (1 + w_{\text{pert}} \xi), \quad \xi \sim \mathcal{U}(0, 1), \quad (3)$$

aplicado apenas às dimensões selecionadas pela máscara de comunicação estocástica com probabilidade p_c por dimensão. A seleção mantém o indivíduo (original ou clone) com menor aptidão.

3 Funções Benchmark

As dez funções selecionadas cobrem diferentes características de dificuldade: separabilidade, multimodalidade, não-separabilidade, condicionamento e deceptividade.

3.1 Funções Unimodais

Sphere $f(\mathbf{x}) = \sum_{i=1}^D x_i^2$, domínio $[-100, 100]^D$. Separável e convexa; utilizada como referência de sanidade para verificar a convergência básica dos algoritmos.

Rosenbrock $f(\mathbf{x}) = \sum_{i=1}^{D-1} [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2]$, domínio $[-5, 10]^D$. Não-separável; o ótimo global em $\mathbf{x}^* = (1, \dots, 1)$ localiza-se em um vale estreito e curvo que desafia a convergência de metaheurísticas.

Sum Squares $f(\mathbf{x}) = \sum_{i=1}^D i x_i^2$, domínio $[-10, 10]^D$. Separável com pesos crescentes por dimensão; introduz condicionamento moderado sem redundância com outras funções unimodais do conjunto.

Dixon-Price $f(\mathbf{x}) = (x_1 - 1)^2 + \sum_{i=2}^D i (2x_i^2 - x_{i-1})^2$, domínio $[-10, 10]^D$. Não-separável com ótimo analítico $x_i^* = 2^{-(2^i - 2)/2^i}$; útil para validar a convergência em estrutura recursiva de vale diagonal.

Zakharov $f(\mathbf{x}) = \sum_{i=1}^D x_i^2 + \left(\sum_{i=1}^D 0,5 i x_i \right)^2 + \left(\sum_{i=1}^D 0,5 i x_i \right)^4$, domínio $[-5, 10]^D$. Unimodal não-separável com crescimento polinomial misto; avalia a capacidade de coordenação entre dimensões.

3.2 Funções Multimodais

Rastrigin $f(\mathbf{x}) = 10D + \sum_{i=1}^D [x_i^2 - 10 \cos(2\pi x_i)]$, domínio $[-5, 12, 5, 12]^D$. Separável com grade densa de ótimos locais; referência clássica para avaliar diversidade e capacidade de escape de mínimos locais.

Ackley $f(\mathbf{x}) = -20 \exp\left(-0,2 \sqrt{\frac{1}{D} \sum_{i=1}^D x_i^2}\right) - \exp\left(\frac{1}{D} \sum_{i=1}^D \cos 2\pi x_i\right) + 20 + e$, domínio $[-32,768, 32,768]^D$. Apresenta um platô amplo com um pico central estreito, criando armadilha para algoritmos gulosos.

Griewank $f(\mathbf{x}) = \frac{1}{4000} \sum_{i=1}^D x_i^2 - \prod_{i=1}^D \cos\left(\frac{x_i}{\sqrt{i}}\right) + 1$, domínio $[-600, 600]^D$. Multimodal não-separável; a dificuldade aumenta com D devido ao produto de cossenos.

Schwefel 2.26 $f(\mathbf{x}) = 418,9829 D - \sum_{i=1}^D x_i \sin(\sqrt{|x_i|})$, domínio $[-500, 500]^D$.

Separável e deceptiva: o ótimo global em $x_i^* \approx 420,97$ está na periferia do espaço de busca, distante do centro onde os algoritmos tendem a inicializar.

Lévy $f(\mathbf{x}) = \sin^2(\pi w_1) + \sum_{i=1}^{D-1} (w_i - 1)^2 [1 + 10 \sin^2(\pi w_{i+1})] + (w_D - 1)^2 [1 + \sin^2(2\pi w_D)]$, onde $w_i = 1 + (x_i - 1)/4$, domínio $[-10, 10]^D$. Multimodal não-separável com ótimo único de localização não-trivial.

4 Metodologia

4.1 Otimização de Hiperparâmetros com Optuna

Para cada combinação (algoritmo, função, dimensão), foram realizados 101 trials. O critério de avaliação de cada trial foi o melhor fitness obtido ao final de 100.000 avaliações de função, com semente fixa $s = 42$ para reprodutibilidade. O espaço de busca definido para cada algoritmo foi:

- **AG**: taxa de mutação $p_m \in [0,01, 0,20]$, desvio $\sigma \in [0,05, 0,50]$, parâmetro BLX $\alpha \in [0,10, 0,50]$.
- **DE**: fator de escala $F \in [0,4, 1,5]$, taxa de cruzamento $CR \in [0,1, 1,0]$.
- **PSO**: inércia $w \in [0,3, 1,0]$, coeficientes $c_1, c_2 \in [0,5, 2,5]$.
- **EPSO**: probabilidade de comunicação $p_c \in [0,1, 0,9]$, taxa de mutação dos pesos $\tau \in [0,05, 0,50]$.

Os melhores hiperparâmetros encontrados foram armazenados e utilizados diretamente na fase experimental, garantindo que cada algoritmo opere em sua configuração mais favorável para cada cenário.

4.2 Protocolo Experimental

Para cada combinação de algoritmo, função e dimensão, foram realizadas 51 execuções independentes com sementes aleatórias distintas. O único critério de parada é o esgotamento do orçamento de 100.000 avaliações de função (FEs), sem critério de convergência antecipada.

O tamanho de população foi fixada em $N = 100$ para todos os algoritmos, essas mesmas configurações foram aplicadas variando a dimensão $[30, 50, 100]^D$ garantindo comparação equitativa do custo por geração. A inicialização é uniforme dentro do domínio de cada função. As métricas registradas por execução são: melhor fitness ao final (*best_f*), número total de avaliações e o histórico completo de convergência por geração.

5 Resultados e Discussão

Os resultados são apresentados a partir das 51 execuções independentes por configuração. As tabelas 1 e 2 sintetizam, para cada par (função, dimensão), o algoritmo vencedor com sua respectiva média e desvio padrão do melhor fitness ao final das execuções. O melhor resultado de cada linha é destacado em negrito. As análises subsequentes aprofundam os padrões observados por meio de visualizações e inferência estatística.

Tabela 1: Melhor resultado por (Função, Dimensão) — Funções Unimodais. Formato: Média $\pm$ Desvio Padrão.


Função	D	Alg.	$f(\mathbf{x}^*)$
Sphere	30	PSO	$1,60 \times 10^{-89} \pm 1,14 \times 10^{-88}$
	50	PSO	$9,21 \times 10^{-34} \pm 6,02 \times 10^{-33}$
	100	EPSO	$5,82 \times 10^{-14} \pm 8,11 \times 10^{-14}$
Rosenbrock	30	PSO	$1,24 \times 10^1 \pm 1,55 \times 10^1$
	50	PSO	$6,94 \times 10^1 \pm 4,14 \times 10^1$
	100	EPSO	$9,27 \times 10^1 \pm 7,77 \times 10^0$
Sum Squares	30	PSO	$4,50 \times 10^{-90} \pm 2,55 \times 10^{-89}$
	50	PSO	$4,70 \times 10^{-38} \pm 2,62 \times 10^{-37}$
	100	EPSO	$4,57 \times 10^{-14} \pm 1,36 \times 10^{-13}$
Dixon-Price	30	PSO	$6,67 \times 10^{-1} \pm 2,24 \times 10^{-16}$
	50	EPSO	$6,67 \times 10^{-1} \pm 1,66 \times 10^{-4}$
	100	EPSO	$6,67 \times 10^{-1} \pm 1,47 \times 10^{-3}$
Zakharov	30	EPSO	$1,30 \times 10^{-9} \pm 2,34 \times 10^{-9}$
	50	EPSO	$2,13 \times 10^{-4} \pm 4,08 \times 10^{-4}$
	100	EPSO	$1,86 \times 10^1 \pm 2,21 \times 10^1$

Tabela 2: Melhor resultado por (Função, Dimensão) — Funções Multimodais.
Formato: Média $\pm$ Desvio Padrão.


Função	D	Alg.	$f(\mathbf{x}^*)$
Rastrigin	30	DE	$9,97 \times 10^0 \pm 2,43 \times 10^0$
	50	AG	$2,32 \times 10^1 \pm 4,24 \times 10^0$
	100	AG	$5,43 \times 10^1 \pm 7,35 \times 10^0$
Ackley	30	AG	$4,07 \times 10^{-15} \pm 4,97 \times 10^{-16}$
	50	AG	$1,96 \times 10^{-4} \pm 4,84 \times 10^{-5}$
	100	DE	$2,69 \times 10^{-2} \pm 1,43 \times 10^{-1}$
Griewank	30	DE	$4,02 \times 10^{-15} \pm 1,51 \times 10^{-14}$
	50	DE	$5,80 \times 10^{-4} \pm 2,49 \times 10^{-3}$
	100	EPSO	$2,57 \times 10^{-3} \pm 5,67 \times 10^{-3}$
Schwefel 2.26	30	AG	$-1,14 \times 10^{53} \pm 8,15 \times 10^{53}$
	50	AG	$-4,92 \times 10^{41} \pm 2,42 \times 10^{42}$
	100	AG	$-1,17 \times 10^{46} \pm 8,25 \times 10^{46}$
Lévy	30	AG	$8,00 \times 10^{-30} \pm 5,44 \times 10^{-29}$
	50	DE	$1,16 \times 10^{-13} \pm 1,37 \times 10^{-13}$
	100	DE	$5,63 \times 10^{-6} \pm 3,09 \times 10^{-6}$

5.1 Curvas de Convergência Média


As curvas de convergência média são obtidas pela interpolação das 51 trajetórias de cada execução em uma grade comum de FEs, seguida do cálculo da média ponto a ponto. O eixo x representa as avaliações acumuladas de função e o eixo y utiliza escala simlog para capturar ordens de magnitude distintas sem perda de informação próximo ao zero.




(a) Sphere




(b) Rosenbrock



(c) Sum Squares



(d) Dixon-Price



(e) Zakharov

Figura 1: Curvas de convergência média para as dez funções benchmark unimodais nas dimensões 30, 50 e 100.




Figura2: Curvas de convergência média para as dez funções benchmark multi-modais nas dimensões 30, 50 e 100.

Nas funções unimodais separáveis, como Sphere e Sum Squares, PSO e EPSO tendem a apresentar convergência rápida nas dimensões menores, beneficiando-se da estrutura separável que permite atualização independente por dimensão. Em Rosenbrock, o vale estreito e curvo penaliza algoritmos que não coordenam dimensões adjacentes, favorecendo DE pela natureza da mutação diferencial. À medida que D aumenta para 100, a velocidade de convergência de todos os algoritmos diminui, com AG apresentando a degradação mais pronunciada.

Nas funções multimodais, a densidade de ótimos locais de Rastrigin e o caráter deceptivo de Schwefel 2.26 criam comportamentos qualitativamente distintos. Algoritmos que mantêm diversidade populacional por mais gerações tendem a encontrar melhores soluções finais, ainda que a convergência seja mais lenta no início.

5.2 Análise Estatística

A significância estatística das diferenças observadas é avaliada primariamente pelo Teste T de Welch para amostras independentes ($\alpha = 5\%$), seguindo Marcelino et al. [5]. A hipótese nula $H_0: \mu_1 = \mu_2$ é testada para cada par de algoritmos, por função e dimensão. Quando H_0 é rejeitada ($p < 0,05$), o vencedor é identificado como o algoritmo de menor média. Quando não é rejeitada, reporta-se equivalência estatística entre os dois algoritmos naquela configuração.

Como análise complementar, aplica-se o teste de Wilcoxon Rank-Sum (Mann-Whitney U), não-paramétrico e robusto a distribuições assimétricas e outliers, com o vencedor determinado pela menor mediana. A comparação entre os dois testes permite identificar casos onde a presença de valores extremos influencia as conclusões do Teste T. Importa notar que em configurações onde múltiplos algoritmos convergem para valores próximos da precisão numérica de *float64* (por exemplo, Sphere em $D = 30$), o Teste T pode apresentar cancelamento catastrófico na estimativa da variância, tornando-o conservador nesses casos específicos. O Wilcoxon, por operar sobre ranks, é imune a esse efeito.

Tabela 3: Ranking consolidado de vitórias ($\alpha = 5\%$) por teste estatístico. Teste T de Welch (vencedor = menor média); Wilcoxon Rank-Sum (vencedor = menor mediana).

Teste	AG DE PSO EPSO			
Teste T de Welch	31	40	24	29
Wilcoxon Rank-Sum	39	34	45	39

A divergência entre os dois testes concentra-se nas funções onde algoritmos atingem valores próximos de zero (Sphere, Sum Squares), nas quais o Wilcoxon detecta diferenças que o Teste T deixa escapar por instabilidade numérica. Nas

funções multimodais, onde as distribuições de fitness são mais espalhadas e assimétricas, os dois testes convergem para as mesmas conclusões na maioria dos pares.

5.3 Análise de Escalabilidade

A análise de escalabilidade examina como o desempenho de cada algoritmo se degrada com o aumento da dimensão de $D = 30$ para $D = 100$. A Figura 3 apresenta a evolução da mediana do fitness por algoritmo e função.




Figura 3: Escalabilidade: mediana do fitness em função da dimensão ($D \in \{30, 50, 100\}$) para cada algoritmo e função benchmark. Escala y simlog.

Funções não-separáveis como Rosenbrock e Zakharov tendem a apresentar degradação mais severa para todos os algoritmos, uma vez que a interação entre dimensões amplifica a dificuldade do problema à medida que D cresce. Entre os algoritmos, espera-se que aqueles com mecanismos de adaptação (EPSO) mantenham desempenho relativo mais estável em alta dimensão em comparação ao AG, que não possui mecanismo de auto-adaptação de passo.

5.4 Velocidade de Convergência

A velocidade de convergência é quantificada pela Área sob a Curva (AUC) de convergência, calculada como a integral numérica de f_{best} ao longo dos FEs usando a regra do trapézio. Um valor menor de AUC indica que o algoritmo

acumulou valores baixos de fitness mais cedo durante o processo de busca, independentemente do valor final atingido.

Tabela 4: AUC das curvas de convergência médias por algoritmo e função. Menor AUC indica convergência mais rápida acumulada. Melhor valor por linha em negrito com fundo verde.

Função	D	AG	DE	PSO	EPSO	Melhor
Sphere	30	$3,54 \times 10^7$	$9,75 \times 10^7$	$8,67 \times 10^6$	$3,80 \times 10^7$	PSO
	50	$5,03 \times 10^7$	$2,43 \times 10^8$	$2,26 \times 10^7$	$8,30 \times 10^7$	PSO
	100	$2,68 \times 10^8$	$9,96 \times 10^8$	$1,01 \times 10^8$	$2,46 \times 10^8$	PSO
Rosenbrock	30	$1,99 \times 10^8$	$1,27 \times 10^9$	$1,47 \times 10^8$	$9,96 \times 10^8$	PSO
	50	$6,43 \times 10^8$	$3,89 \times 10^9$	$3,45 \times 10^8$	$2,23 \times 10^9$	PSO
	100	$2,24 \times 10^9$	$2,06 \times 10^{10}$	$1,33 \times 10^9$	$5,37 \times 10^9$	PSO
Sum Squares	30	$5,47 \times 10^6$	$1,21 \times 10^7$	$1,24 \times 10^6$	$5,24 \times 10^6$	PSO
	50	$1,21 \times 10^7$	$5,35 \times 10^7$	$4,89 \times 10^6$	$2,03 \times 10^7$	PSO
	100	$8,44 \times 10^7$	$4,09 \times 10^8$	$5,96 \times 10^7$	$1,11 \times 10^8$	PSO
Dixon-Price	30	$5,51 \times 10^8$	$1,26 \times 10^9$	$1,36 \times 10^8$	$5,36 \times 10^8$	PSO
	50	$1,89 \times 10^9$	$8,10 \times 10^9$	$6,11 \times 10^8$	$1,96 \times 10^9$	PSO
	100	$8,09 \times 10^9$	$5,97 \times 10^{10}$	$4,92 \times 10^9$	$1,02 \times 10^{10}$	PSO
Zakharov	30	$1,94 \times 10^9$	$3,44 \times 10^9$	$1,58 \times 10^{10}$	$4,08 \times 10^9$	AG
	50	$5,27 \times 10^{12}$	$6,92 \times 10^{12}$	$4,20 \times 10^{12}$	$7,28 \times 10^{12}$	PSO
	100	$2,55 \times 10^{16}$	$3,33 \times 10^{16}$	$2,15 \times 10^{16}$	$2,21 \times 10^{16}$	PSO
Rastrigin	30	$1,72 \times 10^6$	$6,64 \times 10^6$	$4,55 \times 10^6$	$6,47 \times 10^6$	AG
	50	$3,63 \times 10^6$	$2,16 \times 10^7$	$8,04 \times 10^6$	$1,49 \times 10^7$	AG
	100	$9,55 \times 10^6$	$5,95 \times 10^7$	$2,11 \times 10^7$	$3,10 \times 10^7$	AG
Ackley	30	$6,04 \times 10^4$	$1,39 \times 10^5$	$1,20 \times 10^5$	$2,96 \times 10^5$	AG
	50	$7,20 \times 10^4$	$2,12 \times 10^5$	$1,91 \times 10^5$	$3,44 \times 10^5$	AG
	100	$1,70 \times 10^5$	$4,37 \times 10^5$	$3,96 \times 10^5$	$1,58 \times 10^5$	EPSO
Griewank	30	$3,23 \times 10^5$	$1,10 \times 10^6$	$9,93 \times 10^4$	$5,18 \times 10^5$	PSO
	50	$9,14 \times 10^5$	$2,30 \times 10^6$	$2,57 \times 10^5$	$9,99 \times 10^5$	PSO
	100	$4,20 \times 10^6$	$8,90 \times 10^6$	$8,59 \times 10^5$	$2,20 \times 10^6$	PSO
Schwefel 2.26	30	$-6,51 \times 10^{39}$	$1,96 \times 10^8$	$3,68 \times 10^8$	$4,53 \times 10^8$	AG
	50	$-5,10 \times 10^{36}$	$6,35 \times 10^8$	$7,22 \times 10^8$	$9,12 \times 10^8$	AG
	100	$-1,29 \times 10^{41}$	$2,80 \times 10^9$	$1,90 \times 10^9$	$2,23 \times 10^9$	AG
Lévy	30	$1,37 \times 10^5$	$3,59 \times 10^5$	$3,20 \times 10^4$	$2,10 \times 10^5$	PSO
	50	$1,62 \times 10^5$	$1,01 \times 10^6$	$1,36 \times 10^5$	$4,58 \times 10^5$	PSO
	100	$6,31 \times 10^5$	$4,49 \times 10^6$	$3,78 \times 10^5$	$1,72 \times 10^6$	PSO
Ranking (vitórias AUC)						
$D = 30$		4	0	6	0	
$D = 50$		3	0	7	0	
$D = 100$		2	0	7	1	

[†]AUC negativa em Schwefel 2.26 (AG): fitness negativo por construção da função deslocada.

6 Conclusão

Este trabalho apresentou uma comparação sistemática entre AG, DE, PSO e EPSO em dez funções benchmark escaláveis, nas dimensões 30, 50 e 100, com

hiperparâmetros ajustados individualmente via Optuna e protocolo experimental com 51 execuções independentes.

Os resultados indicam que nenhum algoritmo domina em todos os cenários. Em funções unimodais separáveis, PSO e EPSO destacam-se pela velocidade de convergência nas dimensões menores, enquanto DE demonstra vantagem em funções com estrutura não-separável como Rosenbrock. Em funções multimodais, a capacidade de manter diversidade populacional ao longo das avaliações mostra-se determinante, com comportamentos distintos entre as funções de acordo com a densidade e a localização dos ótimos locais. A análise de escalabilidade revela que todos os algoritmos sofrem degradação de desempenho com o aumento de dimensão, mas em graus variáveis conforme o tipo de função.

Como limitações, o estudo utiliza funções benchmark clássicas sem ruído e adota tamanho de população fixo em todos os cenários. Trabalhos futuros incluem a extensão para DEEPSO e C-DEEPSO [5].

Referências

1. Goldberg, D.E.: Genetic Algorithms in Search, Optimization and Machine Learning. Addison-Wesley, Reading, MA (1989)
2. Storn, R., Price, K.: Differential evolution – a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization* **11**(4), 341–359 (1997). <https://doi.org/10.1023/A:1008202821328>
3. Kennedy, J., Eberhart, R.: Particle swarm optimization. In: Proceedings of the IEEE International Conference on Neural Networks, vol. 4, pp. 1942–1948. IEEE, Perth (1995). <https://doi.org/10.1109/ICNN.1995.488968>
4. Miranda, V., Fonseca, N.: EPSO – evolutionary particle swarm optimization, a new algorithm with applications in power systems. In: Proceedings of the IEEE/PES Transmission and Distribution Conference and Exhibition, vol. 2, pp. 745–750. IEEE (2002). <https://doi.org/10.1109/TDC.2002.1177567>
5. Marcelino, C.G., Almeida, P.E.M., Wanner, E.F., Baumann, M., Weil, M., Carvalho, L.M., Miranda, V.: Solving security constrained optimal power flow problems: a hybrid evolutionary approach. *Applied Intelligence* **48**(10), 3672–3690 (2018). <https://doi.org/10.1007/s10489-018-1167-5>
6. Akiba, T., Sano, S., Yanase, T., Ohta, T., Koyama, M.: Optuna: A next-generation hyperparameter optimization framework. In: Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, pp. 2623–2631. ACM (2019). <https://doi.org/10.1145/3292500.3330701>
7. Molga, M., Smutnicki, C.: Test functions for optimization needs. Technical Report (2005). <http://www.zsd.ict.pwr.wroc.pl/files/docs/functions.pdf>
8. Dixon, L.C.W., Szegö, G.P.: The global optimization problem: an introduction. In: Dixon, L.C.W., Szegö, G.P. (eds.) *Towards Global Optimisation* 2, pp. 1–15. North-Holland (1978)