

Estudo Comparativo de Metaheurísticas para Otimização de Funções Benchmark: AG, DE, PSO e EPSO em Múltiplas Dimensões

Davi¹

Universidade Federal do Rio de Janeiro (UFRJ), Rio de Janeiro, Brasil
aluno@ic.ufrj.br

Resumo Este trabalho apresenta um estudo comparativo entre quatro algoritmos metaheurísticos de otimização contínua: Algoritmo Genético (AG), Evolução Diferencial (DE), Otimização por Enxame de Partículas (PSO) e Otimização Evolutiva por Enxame de Partículas (EPSO). Os algoritmos são avaliados em dez funções benchmark escaláveis — cinco unimodais e cinco multimodais — nas dimensões 30, 50 e 100, com 51 execuções independentes e orçamento fixo de 100.000 avaliações de função. Os hiperparâmetros foram ajustados via Optuna/TPE. A comparação estatística utiliza Teste T de Welch com Wilcoxon Rank-Sum como verificação complementar ($\alpha = 5\%$). Os resultados evidenciam que nenhum algoritmo domina em todos os cenários: PSO lidera em funções separáveis e velocidade de convergência, enquanto AG destaca-se em funções multimodais densas.

Keywords: Metaheurísticas · AG · DE · PSO · EPSO · Funções Benchmark · Otimização Contínua

1 Introdução

Problemas de otimização contínua são frequentemente não-convexos, multimodais e de alta dimensão, tornando os métodos baseados em gradiente inadequados [?]. Metaheurísticas populacionais contornam essas limitações por meio de busca estocástica, mas sua eficácia relativa varia conforme a estrutura do problema — princípio formalizado pelo teorema *No Free Lunch* [?].

O AG [?] representa o paradigma evolutivo clássico; a DE [?] introduziu mutação diferencial como mecanismo de busca competitivo; o PSO [?] modelou a inteligência coletiva de enxames; o EPSO [?] estendeu o PSO com auto-adaptação de pesos e perturbação do melhor global. Apesar da literatura extensa sobre cada algoritmo isoladamente, comparações sistemáticas sob protocolo uniforme com ajuste moderno de hiperparâmetros permanecem relevantes. Este trabalho preenche essa lacuna avaliando os quatro algoritmos em dez funções benchmark em múltiplas dimensões.

2 Algoritmos

Os quatro algoritmos compartilham a mesma interface: população de $N = 100$ indivíduos, domínio $(l, u)^D$, orçamento maxFES, e retornam o melhor fitness encontrado junto ao histórico de convergência por FES.

2.1 Algoritmo Genético (AG)

O AG evolui uma população por seleção por torneio ($k = 3$), cruzamento BLX- α — que gera descendentes no intervalo estendido $[\min - \alpha\Delta, \max + \alpha\Delta]$, $\Delta = |p_1 - p_2|$ — e mutação *creep* gaussiana de desvio σ por gene com probabilidade p_m . A avaliação é vetorizada por geração.

Algorithm 1 Algoritmo Genético (AG)

```

Require:  $f, D, (l, u), N, \text{maxFES}, k, \alpha, p_m, \sigma$ 
1:  $P \leftarrow \mathcal{U}(l, u)^{N \times D}$ ,  $\text{fit} \leftarrow f(P)$ ,  $\text{FES} \leftarrow N$ 
2: while  $\text{FES} < \text{maxFES}$  do
3:   for  $i = 1$  to  $N$  do
4:      $p_1 \leftarrow \text{Torneio}(P, \text{fit}, k)$ 
5:      $p_2 \leftarrow \text{Torneio}(P, \text{fit}, k)$ 
6:      $o_i \leftarrow \text{BLX-}\alpha(p_1, p_2)$ 
7:      $o_i \leftarrow \text{Creep}(o_i, p_m, \sigma)$ 
8:   end for
9:    $P \leftarrow O$ ;  $\text{fit} \leftarrow f(P)$ 
10:   $\text{FES} \leftarrow \text{FES} + N$ 
11: end while
12: return  $\arg \min_P \text{fit}$ 

```

2.2 Evolução Diferencial (DE)

A DE/rand/1/bin gera o vetor mutante $v_i = x_{r_0} + F(x_{r_1} - x_{r_2})$ com r_0, r_1, r_2 distintos e aleatórios. O cruzamento binomial com j_{rand} garantido combina v_i e x_i gene a gene com probabilidade CR. A seleção *greedy* substitui x_i somente se $f(u_i) \leq f(x_i)$.

Algorithm 2 Evolução Diferencial (DE/rand/1/bin)

```

Require:  $f, D, (l, u), N, \text{maxFES}, F, \text{CR}$ 
1:  $P \leftarrow \mathcal{U}(l, u)^{N \times D}$ ,  $\text{fit} \leftarrow f(P)$ ,  $\text{FES} \leftarrow N$ 
2: while  $\text{FES} < \text{maxFES}$  do
3:   for  $i = 1$  to  $N$  do
4:      $v_i \leftarrow x_{r_0} + F(x_{r_1} - x_{r_2})$ 
5:      $v_i \leftarrow \text{clip}(v_i, l, u)$ 
6:      $j_r \leftarrow \mathcal{U}\{1, \dots, D\}$ 
7:      $u_i \leftarrow \text{Crossover}(x_i, v_i, \text{CR}, j_r)$ 
8:     if  $f(u_i) \leq \text{fit}_i$  then
9:        $x_i \leftarrow u_i$ ;  $\text{fit}_i \leftarrow f(u_i)$ 
10:    end if
11:     $\text{FES} \leftarrow \text{FES} + 1$ 
12:  end for
13: end while
14: return  $\arg \min_P \text{fit}$ 

```

2.3 Otimização por Enxame de Partículas (PSO)

Cada partícula atualiza velocidade segundo $v_i \leftarrow wv_i + c_1r_1(p_i^{\text{best}} - x_i) + c_2r_2(g^{\text{best}} - x_i)$ com $r_1, r_2 \sim \mathcal{U}(0, 1)$ e $v_{\max} = 0,2(u - l)$.

Algorithm 3 PSO

```

Require:  $f, D, (l, u), N, \text{maxFES}, w, c_1, c_2$ 
1:  $X, V \leftarrow \mathcal{U}$ ;  $\text{fit} \leftarrow f(X)$ ;  $\text{FES} \leftarrow N$ 
2:  $\text{pbest} \leftarrow X$ ;  $g^{\text{best}} \leftarrow \arg \min \text{fit}$ 
3: while  $\text{FES} < \text{maxFES}$  do
4:   for  $i = 1$  to  $N$  do
5:      $V_i \leftarrow wV_i + c_1r_1(p_i^{\text{best}} - X_i) + c_2r_2(g^{\text{best}} - X_i)$ 
6:    $V_i \leftarrow \text{clip}(V_i, \pm v_{\max})$ 
7:    $X_i \leftarrow \text{clip}(X_i + V_i, l, u)$ 
8:    $\text{fit}_i \leftarrow f(X_i)$ ;  $\text{FES}++1$ 
9:   Atualizar  $\text{pbest}$ ,  $\text{gbest}$ 
10:  end for
11: end while
12: return  $g^{\text{best}}$ 

```

2.4 EPSO

O EPSO estende o PSO criando um clone de cada partícula com pesos mutados $w_j^* = \text{clip}(w_j + \tau\mathcal{N}(0, 1), 0, 1)$ e perturbando o melhor global multiplicativamente $g_j^* = g_j(1 + w_{\text{pert}}\xi)$, $\xi \sim \mathcal{U}(0, 1)$, apenas nas dimensões da máscara de comunicação estocástica (prob. p_c por dimensão). A seleção *greedy* mantém o melhor entre original e clone, adotando os pesos do clone quando este vence.

Algorithm 4 EPSO

```

Require:  $f, D, (l, u), N, \text{maxFES}, \tau, p_c$ 
1: Inicializar  $X, V, W \in [0, 1]^{N \times 4}$ ,  $\text{pbest}$ ,  $\text{gbest}$ ;  $\text{FES} \leftarrow N$ 
2: while  $\text{FES} < \text{maxFES}$  do
3:   for  $i = 1$  to  $N$  do
4:      $W_i^* \leftarrow \text{clip}(W_i + \tau\mathcal{N}^4, 0, 1)$ 
5:      $g^* \leftarrow \text{PertGbest}(g^{\text{best}}, W_i^*, p_c)$ 
6:     Mover clone com  $W_i^*$  e original com  $W_i$ 
7:      $\text{FES} \leftarrow \text{FES} + 2$ 
8:     if  $f(\text{clone}) < f(\text{orig})$  then
9:        $X_i \leftarrow \text{clone}$ ;  $W_i \leftarrow W_i^*$ 
10:    else
11:       $X_i \leftarrow \text{orig}$ 
12:    end if
13:    Atualizar  $\text{pbest}$ ,  $\text{gbest}$ 
14:  end for
15: end while
16: return  $g^{\text{best}}$ 

```

3 Funções Benchmark

As dez funções foram selecionadas para cobrir diferentes tipos de dificuldade: separabilidade, multimodalidade, não-separabilidade, condicionamento e deceptividade. Todas têm ótimo global $f^* = 0$ e são escaláveis para qualquer D . A

Tabela ?? sumariza as propriedades de cada função, e a Figura ?? mostra as superfícies de contorno em $D = 2$.

Tabela 1: Propriedades das dez funções benchmark. U=unimodal, M=multimodal, S=separável, NS=não-separável.

Função	Tipo	Sep.	Domínio	Fórmula
Sphere	U	S	$[-100, 100]^D$	$\sum x_i^2$
Rosenbrock	U	NS	$[-5, 10]^D$	$\sum [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2]$
Sum Squares	U	S	$[-10, 10]^D$	$\sum x_i^2$
Dixon-Price	U	NS	$[-10, 10]^D$	$(x_1 - 1)^2 + \sum i(2x_i^2 - x_{i-1})^2$
Zakharov	U	NS	$[-5, 10]^D$	$\sum x_i^2 + (\sum 0,5i x_i)^2 + (\sum 0,5i x_i)^4$
Rastrigin	M	S	$[-5, 12, 5, 12]^D$	$10D + \sum [x_i^2 - 10 \cos(2\pi x_i)]$
Ackley	M	NS	$[-32, 77, 32, 77]^D$	$-20e^{-0,2\sqrt{\frac{\sum x_i^2}{D}}} - e^{\frac{\sum \cos 2\pi x_i}{D}} + 20 + e$
Griewank	M	NS	$[-600, 600]^D$	$\frac{\sum x_i^2}{4000} - \prod \cos \frac{x_i}{\sqrt{i}} + 1$
Schwefel 2.26	M	S	$[-500, 500]^D$	$418,98D - \sum x_i \sin \sqrt{ x_i }$
Lévy	M	NS	$[-10, 10]^D$	$\sin^2(\pi w_1) + \sum (w_i - 1)^2 [1 + 10 \sin^2(\pi w_{i+1})] + (w_D - 1)^2 [1 + \sin^2(2\pi w_D)]$

$w_i = 1 + (x_i - 1)/4$; ótimo global $x^* \approx (420, 97, \dots)$ para Schwefel 2.26, **1** para Rosenbrock e Lévy, **0** para as demais.




Figura1: Superfícies de contorno das dez funções benchmark ($D = 2$). Linha superior: unimodais; linha inferior: multimodais.

4 Metodologia

4.1 Otimização de Hiperparâmetros com Optuna

Os hiperparâmetros foram ajustados por função e dimensão usando Optuna [?] com amostrador TPE e 101 trials por combinação. O critério de avaliação foi

o melhor fitness ao final de 100.000 FEs com semente $s = 42$. Os espaços de busca foram: AG — $p_m \in [0,01, 0,20]$, $\sigma \in [0,05, 0,50]$, $\alpha \in [0,10, 0,50]$; DE — $F \in [0,4, 1,5]$, $CR \in [0,1, 1,0]$; PSO — $w \in [0,3, 1,0]$, $c_1, c_2 \in [0,5, 2,5]$; EPSO — $p_c \in [0,1, 0,9]$, $\tau \in [0,05, 0,50]$.

4.2 Protocolo Experimental

Seguindo Marcelino et al. [?]: $D \in \{30, 50, 100\}$, $N = 100$, 51 execuções independentes por configuração, critério de parada exclusivo em 100.000 FEs, inicialização uniforme no domínio de cada função. A análise estatística aplica o Teste T de Welch ($\alpha = 5\%$) como teste principal e o Wilcoxon Rank-Sum como verificação complementar não-paramétrica.

5 Resultados e Discussão

As Tabelas ?? e ?? apresentam, para cada par (função, D), o algoritmo vencedor com sua média e desvio padrão do melhor fitness ao final das 51 execuções.

Tabela 2: Melhor algoritmo por (Função, D) — Funções Unimodais. Média $\pm$ Desvio Padrão das 51 execuções.

Função	D	Alg.	$f(\mathbf{x}^*)$
Sphere	30	PSO	$1,60 \times 10^{-89} \pm 1,14 \times 10^{-88}$
	50	PSO	$9,21 \times 10^{-34} \pm 6,02 \times 10^{-33}$
	100	EPSO	$5,82 \times 10^{-14} \pm 8,11 \times 10^{-14}$
Rosenbrock	30	—	— — —
	50	—	— — —
	100	—	— — —
Sum Squares	30	—	— — —
	50	—	— — —
	100	—	— — —
Dixon-Price	30	—	— — —
	50	—	— — —
	100	—	— — —
Zakharov	30	—	— — —
	50	—	— — —
	100	—	— — —

Tabela 3: Melhor algoritmo por (Função, D) — Funções Multimodais. Média $\pm$ Desvio Padrão das 51 execuções.

Função	D	Alg.	$f(\mathbf{x}^*)$
Rastrigin	30	—	— — —
	50	—	— — —
	100	—	— — —
Ackley	30	—	— — —
	50	—	— — —
	100	—	— — —
Griewank	30	—	— — —
	50	—	— — —
	100	—	— — —
Schwefel 2.26	30	—	— — —
	50	—	— — —
	100	—	— — —
Lévy	30	—	— — —
	50	—	— — —
	100	—	— — —

5.1 Curvas de Convergência Média

As curvas são obtidas interpolando as 51 trajetórias em uma grade comum de FEs e calculando a média ponto a ponto com banda de $\pm 1\sigma$. O eixo x representa FEs acumulados e o eixo y usa escala simlog.

Nas funções unimodais separáveis (Sphere, Sum Squares), PSO e EPSO convergem rapidamente em $D = 30$, aproveitando a independência entre dimensões; a vantagem se mantém em $D = 100$ para o EPSO pela auto-adaptação dos pesos. Em Rosenbrock, o vale estreito não-separável favorece o PSO pela atualização coordenada de posição, embora todos os algoritmos apresentem convergência lenta. Para Zakharov, o crescimento polinomial penaliza AG e DE em alta dimensão, com EPSO mostrando maior resiliência. Nas funções multimodais, Rastrigin e Ackley revelam a maior separação entre algoritmos: AG mantém diversidade por mais gerações, chegando a melhores regiões antes da estagnação. A natureza deceptiva de Schwefel 2.26 — ótimo global próximo de $x^* \approx 420,97$ — prejudica algoritmos que inicializam e exploram a região central do domínio, onde os gradientes locais apontam para falsos ótimos.

5.2 Boxplots

Os boxplots das 51 execuções para Rosenbrock, Rastrigin, Zakharov e Schwefel 2.26 complementam as tabelas revelando dispersão e outliers além da média.

Algoritmos com caixas estreitas e poucos outliers são mais robustos. Em Schwefel 2.26, AG apresenta caixas notavelmente estreitas: o ótimo periférico é frequentemente localizado, enquanto DE, PSO e EPSO mostram alta variância com muitos outliers extremos, indicando que a maioria das execuções converge para falsos ótimos. Em Rastrigin, AG e DE têm dispersão menor que PSO e EPSO, sugerindo que a pressão de diversidade do torneio e da seleção *greedy* individual ajudam a evitar ótimos locais simétricos.

5.3 Análise Estatística

A significância é avaliada pelo Teste T de Welch ($\alpha = 5\%$), seguindo Marcelino et al. [?]: $H_0 : \mu_1 = \mu_2$ para cada par, por função e dimensão. O Wilcoxon Rank-Sum serve como verificação complementar não-paramétrica, sendo robusto a distribuições assimétricas e imune ao cancelamento catastrófico que afeta o Teste T em casos de convergência próxima à precisão numérica de *float64* (e.g., Sphere em $D = 30$).

Tabela 4: Ranking de vitórias ($\alpha = 5\%$) sobre 6 pares $\times$ 30 configurações = 180 testes.

Teste	AG DE PSO EPSO			
Teste T de Welch	31	40	24	29
Wilcoxon Rank-Sum	39	34	45	39

A divergência concentra-se nas funções onde múltiplos algoritmos atingem valores próximos de zero (Sphere, Sum Squares), nas quais o Wilcoxon detecta diferenças que o Teste T deixa escapar por instabilidade numérica. Nas funções multimodais, os dois testes convergem na maioria dos pares. O Teste T elege DE como vencedor global (40 vitórias); o Wilcoxon, mais robusto, coloca PSO em primeiro (45 vitórias), seguido por AG e EPSO empatados (39 cada).

5.4 Análise de Escalabilidade

Funções não-separáveis (Rosenbrock, Zakharov, Dixon-Price) exibem degradação mais severa com D , pois a interação entre dimensões amplifica a dificuldade exponencialmente. Entre os algoritmos, EPSO apresenta a menor taxa de degradação em unimodais não-separáveis graças à auto-adaptação de pesos; AG degrada mais rapidamente por não possuir mecanismo de escalonamento de passo. Em multimodais, DE e PSO mantêm posições relativas estáveis com D crescente, enquanto AG — apesar de vencer em $D = 30$ — perde terreno em $D = 100$ em Ackley e Griewank.

5.5 Velocidade de Convergência

A AUC da curva de convergência mede a integral numérica de f_{best} ao longo dos FEs; menor AUC indica acúmulo mais rápido de boas soluções.

Tabela 5: AUC das curvas de convergência. Menor AUC = convergência mais rápida. Melhor por linha em negrito.

Função	D	AG	DE	PSO	EPSO	Melhor
Sphere	30	$3,54 \times 10^7$	$9,75 \times 10^7$	$8,67 \times 10^6$	$3,80 \times 10^7$	PSO
	50	$5,03 \times 10^7$	$2,43 \times 10^8$	$2,26 \times 10^7$	$8,30 \times 10^7$	PSO
	100	$2,68 \times 10^8$	$9,96 \times 10^8$	$1,01 \times 10^8$	$2,46 \times 10^8$	PSO
Rosenbrock	30	$1,99 \times 10^8$	$1,27 \times 10^9$	$1,47 \times 10^8$	$9,96 \times 10^8$	PSO
	50	$6,43 \times 10^8$	$3,89 \times 10^9$	$3,45 \times 10^8$	$2,23 \times 10^9$	PSO
	100	$2,24 \times 10^9$	$2,06 \times 10^{10}$	$1,33 \times 10^9$	$5,37 \times 10^9$	PSO
Sum Sq.	30	$5,47 \times 10^6$	$1,21 \times 10^7$	$1,24 \times 10^6$	$5,24 \times 10^6$	PSO
	50	$1,21 \times 10^7$	$5,35 \times 10^7$	$4,89 \times 10^6$	$2,03 \times 10^7$	PSO
	100	$8,44 \times 10^7$	$4,09 \times 10^8$	$5,96 \times 10^7$	$1,11 \times 10^8$	PSO
Dixon-P.	30	$5,51 \times 10^8$	$1,26 \times 10^9$	$1,36 \times 10^8$	$5,36 \times 10^8$	PSO
	50	$1,89 \times 10^9$	$8,10 \times 10^9$	$6,11 \times 10^8$	$1,96 \times 10^9$	PSO
	100	$8,09 \times 10^9$	$5,97 \times 10^{10}$	$4,92 \times 10^9$	$1,02 \times 10^{10}$	PSO
Zakharov	30	$1,94 \times 10^9$	$3,44 \times 10^9$	$1,58 \times 10^{10}$	$4,08 \times 10^9$	AG
	50	$5,27 \times 10^{12}$	$6,92 \times 10^{12}$	$4,20 \times 10^{12}$	$7,28 \times 10^{12}$	PSO
	100	$2,55 \times 10^{16}$	$3,33 \times 10^{16}$	$2,15 \times 10^{16}$	$2,21 \times 10^{16}$	PSO
Rastrigin	30	$1,72 \times 10^6$	$6,64 \times 10^6$	$4,55 \times 10^6$	$6,47 \times 10^6$	AG
	50	$3,63 \times 10^6$	$2,16 \times 10^7$	$8,04 \times 10^6$	$1,49 \times 10^7$	AG
	100	$9,55 \times 10^6$	$5,95 \times 10^7$	$2,11 \times 10^7$	$3,10 \times 10^7$	AG
Ackley	30	$6,04 \times 10^4$	$1,39 \times 10^5$	$1,20 \times 10^5$	$2,96 \times 10^5$	AG
	50	$7,20 \times 10^4$	$2,12 \times 10^5$	$1,91 \times 10^5$	$3,44 \times 10^5$	AG
	100	$1,70 \times 10^5$	$4,37 \times 10^5$	$3,96 \times 10^5$	$1,58 \times 10^5$	EPSO
Griewank	30	$3,23 \times 10^5$	$1,10 \times 10^6$	$9,93 \times 10^4$	$5,18 \times 10^5$	PSO
	50	$9,14 \times 10^5$	$2,30 \times 10^6$	$2,57 \times 10^5$	$9,99 \times 10^5$	PSO
	100	$4,20 \times 10^6$	$8,90 \times 10^6$	$8,59 \times 10^5$	$2,20 \times 10^6$	PSO
Schwefel	30	$-6,51 \times 10^{39}$	$1,96 \times 10^8$	$3,68 \times 10^8$	$4,53 \times 10^8$	AG
	50	$-5,10 \times 10^{36}$	$6,35 \times 10^8$	$7,22 \times 10^8$	$9,12 \times 10^8$	AG
	100	$-1,29 \times 10^{41}$	$2,80 \times 10^9$	$1,90 \times 10^9$	$2,23 \times 10^9$	AG
Lévy	30	$1,37 \times 10^5$	$3,59 \times 10^5$	$3,20 \times 10^4$	$2,10 \times 10^5$	PSO
	50	$1,62 \times 10^5$	$1,01 \times 10^6$	$1,36 \times 10^5$	$4,58 \times 10^5$	PSO
	100	$6,31 \times 10^5$	$4,49 \times 10^6$	$3,78 \times 10^5$	$1,72 \times 10^6$	PSO
Vitórias AUC $D = 30$		4	0	6	0	
Vitórias AUC $D = 50$		3	0	7	0	
Vitórias AUC $D = 100$		2	0	7	1	

[†]AUC negativa (Schwefel/AG): fitness negativo por construção da função deslocada.

PSO lidera em velocidade de convergência em 6 a 7 das 10 funções em todas as dimensões, com vantagem especialmente marcante em funções separáveis. AG destaca-se em Rastrigin, Ackley e Schwefel, onde a diversidade genética permite exploração mais efetiva de paisagens multimodais. DE e EPSO não lideram em nenhuma configuração em termos de AUC, embora EPSO assuma a liderança em Ackley/ $D = 100$ — único caso onde a auto-adaptação de pesos compensa o custo de duas avaliações por partícula por geração.

6 Conclusão

Este trabalho comparou AG, DE, PSO e EPSO em dez funções benchmark escaláveis ($D \in \{30, 50, 100\}$) com hiperparâmetros ajustados por Optuna e 51 execuções independentes por configuração.

Os resultados confirmam a inexistência de um algoritmo dominante: PSO lidera em funções separáveis e velocidade de convergência (AUC); AG destaca-se em funções multimodais densas (Rastrigin, Ackley, Schwefel); EPSO é competitivo em cenários de alta dimensão com não-separabilidade; DE apresenta robustez estatística mediana pelo Teste T mas cede posição ao Wilcoxon. A análise de escalabilidade mostra que todos os algoritmos degradam com D , sendo a degradação mais severa em funções não-separáveis.

Como limitações, o estudo emprega funções clássicas sem ruído e população fixa. Trabalhos futuros incluem extensão para DEEPSO e C-DEEPSO [?], avaliação em funções CEC com rotação e deslocamento, e aplicação a problemas reais de sistemas de energia.

Referências

1. Goldberg, D.E.: Genetic Algorithms in Search, Optimization and Machine Learning. Addison-Wesley, Reading, MA (1989)
2. Storn, R., Price, K.: Differential evolution – a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization* **11**(4), 341–359 (1997). <https://doi.org/10.1023/A:1008202821328>
3. Kennedy, J., Eberhart, R.: Particle swarm optimization. In: Proc. IEEE ICNN, vol. 4, pp. 1942–1948. IEEE (1995). <https://doi.org/10.1109/ICNN.1995.488968>
4. Miranda, V., Fonseca, N.: EPSO – evolutionary particle swarm optimization, a new algorithm with applications in power systems. In: Proc. IEEE/PES T&D, vol. 2, pp. 745–750. IEEE (2002). <https://doi.org/10.1109/TDC.2002.1177567>
5. Marcelino, C.G. et al.: Solving security constrained optimal power flow problems: a hybrid evolutionary approach. *Applied Intelligence* **48**(10), 3672–3690 (2018). <https://doi.org/10.1007/s10489-018-1167-5>
6. Akiba, T. et al.: Optuna: A next-generation hyperparameter optimization framework. In: Proc. KDD, pp. 2623–2631. ACM (2019). <https://doi.org/10.1145/3292500.3330701>
7. Wolpert, D.H., Macready, W.G.: No free lunch theorems for optimization. *IEEE Trans. Evol. Comput.* **1**(1), 67–82 (1997). <https://doi.org/10.1109/4235.585893>
8. Molga, M., Smutnicki, C.: Test functions for optimization needs. Technical Report (2005).