

# Introdução à Estatística

## 1. Probabilidade

---

**Espaço Amostral ( $\Omega$ )**: Enumeração (finita ou infinita) de todos os resultados possíveis.

$$\Omega = A1, A2, A3, \dots$$

**Evento (A)**: Resultados ou conjunto de resultados possíveis. Chamamos 'evento' qualquer subconjunto do espaço amostral.

**Evento Impossível ( $\emptyset$ )**: Conjunto Vazio, pois ele nunca acontecerá.

**Probabilidade ( $P(A)$ )**: Probabilidade de um evento **A** ocorrer.

$$P(A) = \frac{A}{\Omega}$$

### União - ( $A \cup B$ )

Pelo menos um ocorre

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A \cup B) = P(A) + P(B), \text{ Para eventos mutuamente exclusivos.}$$

### Interseção - ( $A \cap B$ )


A e B ocorrem

$$P(A \cap B) = P(A) \cdot P(B) - \text{Eventos Independentes}$$

$$P(A \cap B) = P(A) \cdot P(B|A) - \text{Eventos Dependentes}$$

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

### Evento Complementar ( $A^c$ )



$$P(A^c) = 1 - P(A)$$

$$(A \cap B)^c = A^c \cup B^c$$

$$(A \cup B)^c = A^c \cap B^c$$

## Probabilidade Condicional (B|A)

B dado que A ocorre


$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(A|B) = 1 - P(A^c|B)$$

$$P(A_1 \cup A_2|B) = P(A_1|B) + P(A_2|B) - P(A_1 \cap A_2|B)$$

## Eventos Independentes

A não interfere em B



$$P(A|B) = P(A)$$

$$P(A \cap B) = P(A) + P(B)$$

### Lei de Morgan

$$A^c \cap B^c = (A \cup B)^c = 1 - P(A \cup B)$$

$$A^c \cup B^c = (A \cap B)^c = 1 - P(A \cap B)$$

### Teorema de Bayes

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}$$

$$P(A \cap B) = P(A) \cdot P(B|A)$$

## 2. Variáveis Aleatórias

Uma variável aleatória (v.a.) pode ser entendida como uma variável quantitativa, cujo o resultado (valor) depende de fatores aleatórios

$$X : w \in \Omega \rightarrow X(w) \in \mathbb{R}$$

$$\text{Ex: } X = \begin{cases} 0, & \text{se ocorrer } \{(C, C)\} \\ 1, & \text{se ocorrer } \{(C, K), (K, C)\} \\ 2, & \text{se ocorrer } \{(K, K)\} \end{cases}$$

Campo de Definição ( $R_x$ ) = Conjunto de valores possíveis da variável aleatória  $X$ ,  $R_x = (0, 1, 2)$

## Variáveis Aleatórias Discretas

Uma v.a. é discreta se os possíveis resultados estão contidos em um conjunto finito ou enumerável

**Função de Probabilidade:** associa a cada valor possível da variável aleatória discreta sua respectiva probabilidade

$$p(x) = P(X = x)$$

Tal que,

$$p(x) = \begin{cases} P(X = x), & x \in R_x \\ 0, & \text{caso contrário} \end{cases}$$

Satisfazendo,  $p(x) \geq 0$  e  $\sum_{x \in R_x} p(x) = 1$

**Função de Distribuição Acumulada (FDA)**

$$F(x) = P(X \leq x)$$

Onde  $F(x)$  é a probabilidade da v.a.  $X$  assumir um valor menor ou igual ( $\leq$ ) a  $x$

Satisfazendo,  $F(x)$  não é decrescente,  $\lim_{x \rightarrow -\infty} F(x) = 0$ ,  $\lim_{x \rightarrow +\infty} F(x) = 1$

- Valor Esperado (Esperança)**

$$[E] = \sum_{x \in R_x} x \cdot p(x)$$

Onde,  $x$  é o valor de  $X$ , e  $p(x)$  é a probabilidade de  $X$ .

O valor esperado é uma **constante**

- Variância**

$$\text{Var}(X) = \sum_{x \in R_x} (x - E[X])^2 \cdot p(x) = \sum_{x \in R_x} x^2 \cdot p(x) - (E[X])^2$$

Ou seja,

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

- Desvio Padrão**

$$DP(X) = \sqrt{\text{Var}(X)}$$

# Modelo Probabilísticos

## Modelo Uniforme Discreto

$$X \sim Uniforme\{X_1, X_2, X_3, \dots, X_n\}$$

$$p(x) = \begin{cases} \frac{1}{x}, & x \in Rx \\ 0, & \text{Caso contrário} \end{cases}$$

- Valor Esperado

$$E[X] = \frac{1}{x} \cdot \sum_{i=1}^n X_i$$

- Variância

$$Var(X) = \frac{1}{x} \left( \sum x^2 - \frac{(\sum x)^2}{k} \right)$$

## Modelo Bernoulli

Sucesso ou Fracasso

$$X \sim Bernoulli(p), \quad p(0 < p < 1)$$

$$P(0) = P(X = 0) = 1 - P$$

$$P(1) = P(X = 1) = P$$

$$E[X] = P \quad Var(X) = P(1 - P)$$

## Modelo Binomial

$$X \sim Binomial(n, p)$$

Chama-se de experimento binomial ao experimento que

- consiste em n ensaios de Bernoulli
- cujo ensaios são independentes, e
- para qual a probabilidade de sucessos em casa ensaio é sempre igual a p ( $0 < p < 1$ )

$$P(X = x) = \binom{n}{k} \cdot p^x \cdot (1 - p)^{n-x}, \quad k \in \{0, 1, 2, \dots, n\}$$
$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

$$E[X] = n \cdot p$$

$$Var(X) = n \cdot p \cdot (1 - p)$$

## Modelo Geométrico

$$X \sim Geo(p)$$

Número de repetições de um ensaio de Bernoulli com probabilidade de sucesso  $p$  ( $0 < p < 1$ ) até ocorrer o primeiro sucesso

$$p(x) = \begin{cases} p \cdot (1-p)^{x-1}, & x \in \mathbb{N} \\ 0, & \text{caso contrário} \end{cases}$$

$$E[X] = \frac{1}{p}$$

$$Var(X) = \frac{1-p}{p^2}$$

## Modelo Hipergeométrico

$$X \sim Hipergeométrico(N, r, n)$$

$N \rightarrow$  Tamanho total

$r \rightarrow$  Número de Casos com atributos de interesse

$n \rightarrow$  Tamanho da amostra

$$p(X) = \begin{cases} \frac{\binom{r}{x} \cdot \binom{N-r}{n-x}}{\binom{N}{n}}, & x \in R_x \\ 0, & \text{Caso contrário} \end{cases}$$

$$E[X] = n \cdot \frac{r}{N}$$

$$Var(X) = n \cdot \frac{n}{N} \cdot \frac{N-r}{N} \cdot \frac{N-n}{N-1}$$

## Modelo Poisson

$$X \sim Poiss(\lambda)$$

Eventos Raros

$$p(x) = e^{-\lambda} \cdot \frac{\lambda^x}{x!}, \quad x = \{0, 1, 2, \dots\}$$

$$E[X] = Var(x) = \lambda$$

## Variáveis Aleatórias Contínuas

Uma  $f(x)$  definida sobre o espaço amostral ( $\Omega$ ) e assumindo valores num intervalo de número reais, é dita uma variável aleatória contínua. Uma v.a. é contínua se existir

$f_x : \mathbb{R} \rightarrow \mathbb{R}$ , denominada **função de densidade de probabilidade (f.d.p.)**, satisfazendo:

$$f(x) \geq 0, \forall x \in \mathbb{R}$$

$$P(a \leq x \leq b) = \int_a^b f(x)dx = P(A) \int_{-\infty}^{+\infty} f(x)dx = 1$$

Variável Aleatória Discreta → **Contagem**

Variável Aleatória Contínua → Medição

- Função de Distribuição Acumulada (f.d.a.)

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt, \quad x \in \mathbb{R} \quad \forall f(x) = F'(x)$$

$$E[X] = \int_{-\infty}^{+\infty} x \cdot f(x)dx$$

$$Var(X) = \int_{\mathbb{R}} (x - E[X])^2 \cdot f(x)dx = E[X^2] \cdot E[X]^2$$

## Modelos Probabilísticos

### Modelo Uniforme Contínuo

$$X \sim Uniforme(a, b)$$

Dizemos que X é uma variável uniforme no intervalo  $[a, b]$ ,  $(a, b) \in \mathbb{R}$ ,  $a < b$ , se a função de densidade de probabilidade da variável x é constante nesse intervalo e nula fora dele

- Função de densidade de probabilidade

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{caso contrário} \end{cases}$$

- Função de distribuição

$$F(x) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x \geq b \end{cases}$$

- Esperança

$$E[X] = \frac{a+b}{2}$$

- Variância

$$Var(x) = \frac{(a+b)^2}{12}$$

### Modelo Exponencial

$$X \sim Exp(\lambda)$$

Dizemos que  $X$  é uma variável exponencial com parâmetro  $\lambda$ ,  $\lambda > 0$ , se a função de densidade de  $X$  é dada por:

$$f(x) = \begin{cases} \lambda \cdot e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

- Função de distribuição

$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

- Esperança

$$E[X] = \frac{1}{\lambda}$$

- Variância

$$Var(X) = \frac{1}{\lambda^2}$$

## Modelo Normal

$$X \sim N(\mu, \sigma^2)$$

$$f(x) = \frac{1}{\sigma \cdot \sqrt{2\pi}} \cdot e^{-\frac{1}{2} \left( \frac{x-\mu}{\sigma} \right)^2}, \quad \forall x \in \mathbb{R}$$

- Esperança

$$E[X] = \mu$$

- Variância

$$Var(x) = \sigma^2$$

## 3. Variáveis aleatórias bivariadas e n-variadas. Covariância e correlação

**Exemplo 1:** Considere um teste do tipo certo ou errado com apenas três questões. Suponha que as respostas às questões desse teste serão escolhidas ao acaso. Defina as variáveis

$X_1$  : número de acertos nas duas primeiras questões, e

$X_2$  : número de acertos nas duas últimas.

Observe que  $X_1$  e  $X_2$  têm o mesmo campo de definição, a saber,  $\{0, 1, 2\}$ .

Nesse caso, podemos construir uma tabela de dupla entrada....



$X_1 \downarrow X_2 \rightarrow$	0	1	2
0	1/8	1/8	0
1	1/8	1/4	1/8
2	0	1/8	1/8

## Probabilidade Marginal

Dada a função de probabilidade conjunta das variáveis  $X_1$  e  $X_2$ , como determinar as probabilidades marginais (individuais) das duas variáveis separadamente, isto é, como determinar, por exemplo,  $P(X_1 = 2)$  ?

Nesse caso, tem-se:

$$(X_1 = 2) = (X_1 = 2; X_2 = 0) \cup (X_1 = 2; X_2 = 1) \cup (X_1 = 2; X_2 = 2)$$

ou seja,

$$P(X_1 = 2) = \sum_{x_2 \in R_2} P(X_1 = 2; X_2 = x_2) = \frac{2}{8} = \frac{1}{4}$$

Portanto as funções de probabilidade marginais de  $X_1$  e de  $X_2$  são dadas, respectivamente, por

$$\begin{aligned} pX_1(x_1) &= \sum_{x_2 \in R_2} p(x_1, x_2), \quad x_1 \in \mathbb{R} \\ pX_2(x_2) &= \sum_{x_1 \in R_2} p(x_1, x_2), \quad x_2 \in \mathbb{R} \end{aligned}$$

No exemplo 1, as funções de probabilidade marginais são dadas por:

$X_1 \downarrow X_2 \rightarrow$	0	1	2	$px_1$
0	1/8	1/8	0	1/4
1	1/8	1/4	1/8	1/2
2	0	1/8	1/8	1/4
$px_2$	1/4	1/2	1/4	1

$pX_1(x) = pX_2(x)$ , qualquer que seja  $x \in R$ .

## Função de probabilidade condicional

Se a função de probabilidade conjunta de  $X_1$  e  $X_2$  é dada por  $p(x_1, x_2)$  e os respectivos campos de definição são  $R_1$  e  $R_2$ , então a função de probabilidade condicional de  $X_2$  dado que  $X_1 = x_1$ ,  $x_1 \in R_1$  é dada por

$$p_{X_2|X_1=x_1}(x_2|x_1) = \frac{P(X_1 = x_1; X_2 = x_2)}{P(X_1 = x_1)}$$

da mesma forma, tem-se

$$p_{X_1|X_2=x_2}(x_1|x_2) = \frac{P(X_1 = x_1; X_2 = x_2)}{P(X_2 = x_2)}$$

**Exemplo 2:** Determine a probabilidade condicional de  $X_2$  dado que  $X_1 = 0$

$X_1 \downarrow X_2 \rightarrow$	0	1	2	$px_1$
0	1/8	1/8	0	1/4
1	1/8	1/4	1/8	1/2
2	0	1/8	1/8	1/4
$px_2$	1/4	1/2	1/4	1

$$P(X_2 = 0; X_1 = 0) = \frac{1/8}{1/4} = \frac{1}{2}$$

$$P(X_2 = 1; X_1 = 0) = \frac{1/8}{1/4} = \frac{1}{2}$$

$$P(X_2 = 2; X_1 = 0) = \frac{0}{1/4} = 0$$

Assim, a função de probabilidade condicional de  $X_2$  dado  $X_1 = 0$  é dada por

$x_2$	$p_{X_2 X_1=0}$
0	1/2
1	1/2

## Independência

Dizemos que  $X_1$  e  $X_2$  são variáveis aleatórias independentes se, e somente se, sua função de probabilidade conjunta fatora no produto de suas funções de probabilidade marginais, isto é.

$$p(x_1, x_2) = p_{X_1}(x_1) \cdot p_{X_2}(x_2), \quad \forall (x_1, x_2) \in \mathbb{R}^2$$

## Funções de Variáveis Aleatórias

Se  $X_1$  e  $X_2$  são variáveis aleatórias com função de probabilidade conjunta dada por  $p(x_1, x_2)$ , podemos definir novas variáveis aleatórias tais como  $Z = X_1 + X_2$ ,  $W = X_1 \cdot X_2$  etc.

**Exemplo:** Defina a variável  $W = X_1 \cdot X_2$ . Determine o valor esperado de  $W$ .

$X_1 \downarrow X_2 \rightarrow$	0	1	2	$px_1$
0	1/8	1/8	0	1/4

$X_1 \downarrow X_2 \rightarrow$	0	1	2	$px_1$
1	1/8	1/4	1/8	1/2
2	0	1/8	1/8	1/4
$px_2$	1/4	1/2	1/4	1

O campo de definição de  $W$  é  $\{0, 1, 2, 4\}$  e, as respectivas probabilidades são

$(X_1, X_2)$	$p(X_1; X_2)$	$W = X_1 \cdot X_2$
(0,0)	1/8	0
(0,1)	1/8	0
(0,2) = (2,0)	0	0
(1,0)	1/8	1
(1,1)	1/4	1
(1,2)	1/8	2
(2,1)	1/8	2
(2,2)	1/8	4

$W = X_1 \cdot X_2$	0	1	2	4
$p(W = X_1 \cdot X_2)$	3/8	2/8	2/8	1/8

$$E[W] = \frac{5}{4} \neq E[X_1 \cdot X_2] = E[X_1] \cdot E[X_2]$$

Se definirmos  $Z = X_1 + X_2$ , o campo de definição de  $Z$  é  $0, 1, 2, 3, 4$

Assim, diferentemente de  $E[W]$ :

$$E[Z] = 2 = E[X_1 + X_2] = E[X_1] + E[X_2]$$

## Covariância e Correlação

Sejam  $X_1$  e  $X_2$  variáveis aleatórias com função de probabilidade conjunta dada por  $p(x_1, x_2)$ .

A **covariância** entre  $X_1$  e  $X_2$  é definida por

$$Cov(X_1, X_2) = E[(X_1 - E[X_1]) \cdot (X_2 - E[X_2])]$$

$$Cov(X_1, X_2) = E[X_1 X_2] - E[X_1] E[X_2]$$

$$E[X_1 X_2] = \sum_{x_1} \cdot \sum_{x_2} \cdot p(X_1; X_2)$$


Se as variáveis são independentes, então  $Cov(X_1, X_2) = 0$   $\neq$  Se a  $Cov(X_1, X_2) = 0$ , as variáveis são independentes.

Sejam  $X_1$  e  $X_2$  variáveis aleatórias com função de probabilidade conjunta dada por  $p(x_1, x_2)$ . A **correlação** entre  $X_1$  e  $X_2$  é definida por

$$\rho = \rho_{12} = \frac{Cov(X_1; X_2)}{\sqrt{Var(X_1) \cdot Var(X_2)}}$$

## 4. Inferência Estatística

- **População** é o conjunto de todos os elementos sob investigação com pelo menos uma característica em comum.
- **Amostra** é qualquer subconjunto não-vazio da população.



- **Parâmetro** Característica numérica da população
- **Estatística** Característica numérica da população

---

**Atenção:** Na estatística inferencial, a palavra estatística tem outro significado. Um estimador de um parâmetro é uma estatística.

---

Notação usual para parâmetros e estatísticas

Parâmetro	Estatística
tamanho da população $N$	tamanho da amostra $n$
média populacional $E[X] = \mu$	média amostral $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
variância populacional $\text{Var}(X) = \sigma^2$	variância amostral $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
proporção populacional $\pi$ ou $p$	proporção amostral $\hat{\pi}$ ou $\hat{p}$

## Problemas de Inferência

- Verificação de um tempo médio de vida de uma lâmpada fluorescente especificado pelo fabricante
- Avaliação de um novo produto, Antes do lançamento o produto será distribuído a um grupo de consumidores potenciais que responderão um questionário.
- Previsão do tempo médio de espera dos clientes no caixa do banco.
- Há razões para supor que o tempo de reação  $Y$  a certo estímulo visual depende da idade do indivíduo.

## Como selecionar uma amostra?

As observações contidas numa amostra são tanto mais informativas sobre a população, quanto mais conhecimento tivermos dessa mesma população.

Por exemplo a análise quantitativa de glóbulos brancos obtida de algumas gotas de sangue da ponta do dedo de um paciente dá a ideia geral da quantidade de glóbulos brancos no corpo todo, pois sabe-se que a distribuição dos glóbulos brancos é homogênea, e de qualquer lugar que se tivesse retirado a amostra ela seria “representativa”.

Nem sempre a escolha de uma amostra adequada é imediata.

## Procedimentos de levantamento de dados

- Levantamentos Amostrais

A amostra é obtida de uma população bem definida, por meio de processos bem protocolados e controlados pelo pesquisador.

Tais levantamentos costumam ser subdivididos em dois subgrupos: **probabilísticos e não-probabilísticos**.

O primeiro reúne todas as técnicas que usam mecanismos aleatórios de seleção dos elementos de uma amostra, atribuindo a cada um deles, uma probabilidade, conhecida a priori, de pertencer à mostra.

No segundo grupo estão os demais procedimentos, tais como amostras intencionais, nas quais os elementos são selecionados com o auxílio de especialistas, e amostras de voluntários, como corre em alguns testes sobre novos medicamentos e vacinas.

- Planejamento de Experimentos

Têm como principal objetivo analisar o efeito de uma variável sobre outra(s). Requer interferências do pesquisador sobre o ambiente em estudo (população), bem como o controle de fatores externos, com o intuito de medir o efeito desejado.

- Levantamentos Observacionais

Os dados são coletados sem que o pesquisador tenha controle sobre as informações obtidas, exceto eventualmente sobre possíveis erros grosseiros. As séries de dados temporais são exemplos típicos desses levantamentos.

## Amostragem Aleatória Simples (AAS)

Uma amostra aleatória simples ocorre quando atribuímos probabilidades de seleção na amostra iguais para todos os elementos da população. Com relação a precisão neste tipo de amostragem existe diferença se a seleção é feita com reposição ou sem reposição.

## Amostragem Simétrica

Supõe-se dispor de uma listagem de todos os elementos da população em alguma ordem que não esteja relacionada à variável de interesse. Por exemplo, ordem alfabética, ordem de número de matrícula etc.

Suponha que a população tenha  $N$  elementos e que iremos sortear uma amostra sistemática de tamanho  $n$ , usando essa listagem em que todos os elementos da população estão ordenados de 1 até  $N$ .

A ideia é primeiro dividir a listagem em  $n$  blocos de tamanhos  $k = \lceil N/n \rceil$  em que  $\lceil N/n \rceil$  é o menor inteiro que é maior ou igual a  $N/n$ .

## Amostragem aleatória estratificada

A população é dividida em estratos (subpopulações), geralmente de acordo com os valores (ou categorias) de uma variável, e depois AAS é utilizada na seleção de uma amostra de cada estrato. O

procedimento mais comum envolve, depois de fixado o tamanho da amostra, especificar os tamanhos amostrais em cada estrato de forma proporcional ao tamanho de cada estrato.

## Amostragem por conglomerados

A população é dividida em grupos (subpopulações) distintos, chamados conglomerados. Por exemplo, podemos dividir uma cidade em bairros ou quadras ou ruas. Usamos AAS para selecionar uma amostra desses conglomerados e depois todos os indivíduos dos conglomerados selecionados são investigados.

## Distribuição Amostral


Suponha o problema de estimar um parâmetro  $\theta$  de certa população e que para isso dispomos de uma amostra de tamanho  $n$  dessa população:  $x_1, x_2, \dots, x_n$ . Suponha também que usaremos uma estatística  $T$  função da amostra para estimar  $\theta$ .

$$T = t(x_1, x_2, \dots, x_n)$$

$T$  pode ser a soma ( $\sum_{i=1}^n x_i$ ), a média ( $\bar{x}$ ), a mediana, a amplitude, o desvio padrão amostral, e sua escolha dependerá do parâmetro que queremos estimar.

Essa distribuição é chamada **distribuição amostral da estatística  $T$**  e desempenha papel fundamental na teoria da inferência estatística. Esquemáticamente, teríamos o procedimento representado abaixo, em que temos:

1. uma população  $X$ , com determinado parâmetro de interesse  $\theta$ ;
2. todas as amostras retiradas da população, de acordo com certo procedimento;
3. para cada amostra, calculamos o valor  $t$  da estatística  $T$ ; e
4. os valores  $t$  formam uma nova população, cuja distribuição recebe o nome de distribuição amostral de  $T$ .



Mas como poderemos pelo menos fazer um histograma de valores da estatística se só dispomos de uma amostra?

Vamos simplificar o problema de estimação de um parâmetro genérico  $\theta$  para um problema específico de estimação da média populacional,  $\mu$ .

Para isso dispomos de uma amostra aleatória de tamanho  $n$  da população cujos valores observados são  $x_1, x_2, \dots, x_n$ .

No que segue usaremos:

$\mu$  para a média da população e

- $\mu$  para média da população
- $\sigma^2$  para variância da população ( $\sigma$  - desvio padrão da população)
- Um estimador natural de  $\mu$  a ser usado é a média amostral  $\bar{X}$ .

## Teorema Central do Limite (TCL)

Se  $X_1, X_2, \dots, X_n$  é uma amostra aleatória simples de uma população qualquer cuja a média é  $\mu$  e a variância é  $\sigma^2$ , a distribuição amostral de  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ , a média amostral, se aproxima de uma distribuição normal com média  $\mu$  e a variância  $\frac{\sigma^2}{n}$  quando  $n$  cresce.

Ou seja, para  $n$  suficientemente grande,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

ou equivalentemente,



$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

## 5. Estimação

A Inferência Estatística tem por objetivo fazer generalizações sobre uma população, com base nos dados de uma amostra. Existem dois problemas básicos nesse processo:

- (a) estimação de parâmetros e
- (b) teste de hipóteses sobre parâmetros.

Lembrem-se que parâmetros são funções de valores populacionais, enquanto estatísticas são funções de valores amostrais.

Um estimador  $T$  do parâmetro  $\theta$  é qualquer função das observações na amostra, ou seja,

$$T = g(X_1, X_2, \dots, X_n)$$

O problema de estimação pode ser descrito como o problema de determinar uma função  $T = g(X_1, X_2, \dots, X_n)$  que seja “próxima” de  $\theta$ , segundo algum critério.

O estimador  $T$  do parâmetro  $\theta$  é não viesado se

$$E[T] = \theta, \quad \forall \theta$$

**Observação:** Estimativa é o valor assumido pelo estimador em uma particular amostra.

Uma sequência  $\{T_n\}$  de estimadores de um parâmetro  $\theta$  é consistente se para todo  $\epsilon > 0$ ,

$$P(|T_n - \theta| \geq \epsilon) \rightarrow 0$$

quando  $n \rightarrow \infty$ .

**Proposição:** Uma sequência  $\{T_n\}$  de estimadores de  $\theta$  é consistente se

- (1)  $\lim_{n \rightarrow \infty} E[T_n] = \theta$
- (2)  $\lim_{n \rightarrow \infty} Var[T_n] = 0$

Se  $T$  e  $T'$  são dois estimadores não viesados de  $\theta$  e  $Var(T) < Var(T')$ , então  $T$  é um estimador mais eficiente do que  $T'$

Chama-se erro quadrático médio (EQM) do estimador  $T$  do parâmetro  $\theta$  ao valor

$$EQM(T; \theta) = E[(T - \theta)^2]$$

$$EQM(T; \theta) = Var(T) + (E[T] - \theta)^2$$

## Desigualdade de Tchebyshev

Para provar a consistência de um estimador usa-se a desigualdade de Tchebyshev

Seja  $X$  uma variável aleatória com valor esperado  $E[X] = \mu$  e variância  $Var(X) = \sigma^2$ .

Então, para todo  $t > 0$ ,

$$P(|X - \mu| \geq t) \leq \frac{\sigma^2}{t^2}$$

Se  $X_1, X_2, \dots, X_n$  é uma amostra aleatória de uma população cuja média (valor esperado) é  $\mu$  e cuja variância é  $\sigma^2$ , vimos que  $\bar{X}$  é uma variável aleatória com média  $\mu$  e variância  $\frac{\sigma^2}{n}$ .

Usando a desigualdade de Tchebyshev, tem-se, para todo  $t > 0$ ,

$$P(|\bar{X} - \mu| \geq t) \leq \frac{\sigma^2}{n \cdot t^2}$$

## Lei dos Grandes Números

Considere a repetição independente de  $n$  ensaios de Bernoulli cuja probabilidade de sucesso é  $p$ ,  $0 < p < 1$ , e seja  $k$  o número de sucessos nos  $n$  ensaios. A Lei dos Grandes Números (LGN) afirma que, para  $n$  grande, a proporção observada de sucessos  $k/n$  estará próxima de  $p$ .

Formalmente, para todo  $\epsilon > 0$ .

$$P\left(\left|\frac{k}{n} - p\right| \geq \epsilon\right) \leq \frac{p(1-p)}{n\epsilon^2}$$

A demonstração da LGN segue da desigualdade de Tchebyshev.

## Métodos de Estimação

### 1. Métodos dos Momentos

Nesse método as propostas de estimadores são feitas igualando-se os momentos populacionais aos momentos amostrais correspondentes. O momento populacional de ordem  $k$ ,  $k \in \mathbb{N}$  e definido por  $M_k = E[X_k]$ .

O momento amostral de ordem  $k$ , dada uma amostra aleatória  $X_1, X_2, \dots, X_n$  da população é definido por  $m_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ .

Nesse método, para encontrar estimadores de parâmetros, resolvemos equações do tipo

$$m_k = M_k$$

ou seja, usamos os momentos amostrais como estimadores dos momentos populacionais.

### 2. Método da máxima verossimilhança

O princípio da verossimilhança afirma que devemos escolher aquele valor do parâmetro desconhecido que maximiza a probabilidade de obter a amostra particular observada, ou seja, o valor que torna aquela amostra a “mais provável”.

- Função de verossimilhança

Dada uma amostra aleatória simples de tamanho  $n : X_1, X_2, \dots, X_n$  tem-se  $n$  variáveis aleatórias independentes e identicamente distribuídas.

Portanto, a função de densidade de probabilidade (função de probabilidade) conjunta  $f_n(p_n)$  fatora nas funções de densidade de probabilidade (funções de probabilidade) marginais.

$$f_n(x_1, x_2, \dots, x_n; \theta) = f(x_1; \theta) f(x_2; \theta) \dots f(x_n; \theta)$$

ou

$$p_n(x_1, x_2, \dots, x_n; \theta) = p(x_1; \theta) p(x_2; \theta) \dots p(x_n; \theta)$$

em que  $\theta$  é um parâmetro de caracteriza a distribuição da população. De fato,  $\theta$  pode representar mais de um parâmetro quando for o caso.

Em geral,  $\theta$  é desconhecido e, depois de observar a amostra temos os valores  $x_1, x_2, \dots, x_n$ .

Podemos então, olhar a densidade (probabilidade) conjunta como uma função de  $\theta$ .

$$L(\theta; x_1, \dots, x_n) = p_n(x_1, \dots, x_n; \theta)$$

tem-se assim a função de verossimilhança.

O estimador de  $\theta$  é então obtido, maximizando-se a função de verossimilhança.

**Observação:** Como a função de verossimilhança é não negativa e a função log. natural é estritamente crescente, o máximo da função de verossimilhança ser à equivalente ao máximo a função log. natural da função de verossimilhança.

$$l(\theta; x_1, \dots, x_n) = \ln\{L(\theta; x_1, x_2, \dots, x_n)\}$$

Propriedades dos estimadores de máxima verossimilhança:

1. Os Estimadores da máxima verossimilhança são constantes
2. Os Estimadores de máxima verossimilhança são invariantes sob transformações: se  $\hat{\theta}$  é estimador de máxima verossimilhança de  $\theta$ , segue que  $g(\hat{\theta})$  é o estimador de máxima verossimilhança de  $g(\theta)$

## 6. Intervalos de Confiança

Intervalos de Confiança com nível de confiança  $\gamma$  para a média populacional Amostras da distribuição normal ou amostras suficientemente grandes  $n \geq 30$

$$IC(\mu, \gamma) : \bar{X} \pm z_{(\frac{1+\gamma}{2})} \cdot \frac{\sigma}{\sqrt{n}}$$

**Observação:** se o valor de  $\sigma$  não for conhecido substitua-o na expressão acima por uma estimativa.

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

## Inferência na Normal

1.  $\bar{X} \sim N(\mu; \frac{\sigma^2}{n})$
2.  $S^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$
3.  $(\frac{n-1}{\sigma^2}) S^2$
4.  $T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$

Intervalo de Confiança (IC)	Z
80	1,28
85	1,44
90	1,64
95	1,96
99	2,57
99,5	2,80
99,9	3,29

## Intervalo de confiança para a proporção amostral

Nesse caso, a população ( $X$ ) é considerada uma Bernoulli ( $p$ ) em que  $p$  é a proporção populacional que desejamos estimar.

$$IC(p, \gamma) : \hat{p} \pm z_{(\frac{1+\gamma}{2})} \cdot \left( \sqrt{\frac{1}{4n}} \text{ ou } \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \right)$$

## Quando a Variância é desconhecida

$$IC(\mu, \gamma) : \bar{X} \pm t_{(\frac{1-\gamma}{2}, n-1)} \cdot \frac{s}{\sqrt{n}}$$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

No R:

```

x <- c(82, 102, 91, 90, 87, 107, 83, 78, 88, 101, 99, 76, 67,
87, 99, 88) #Conjunto de Amostra
desvioAmostrai <- function(x,n){
  desvio <- 0
  for (i in x){
    if (mean(x)>=i){
      desvio <- desvio + ((mean(x)-i)^2)
    }
    if(mean(x)<=i){
      desvio <- desvio + ((i-mean(x))^2)
    }
  }
  desvio <- desvio / (n-1)
  return(sqrt(desvio))
}
desvioAmostrai(x,length(x))

```

## 7. Testes de Hipóteses

Uma **hipótese** é uma afirmativa sobre um parâmetro , ou seja, sobre uma característica da população.

Um **teste de hipótese** é um procedimento para testar uma hipótese baseado numa amostra da população

**Regra do evento raro:** Se, sob uma suposição, a probabilidade de um evento particular observado é excepcionalmente pequena, concluímos que a suposição provavelmente não está correta.

Exemplo: Se um produto que permite escolher o sexo de uma criança for testado por 100 casais. Podemos obter 2 resultados. (a) 52 meninas e (b) 97 meninas. Embora ambos estejam “acima da média” (50), o resultado 52 não é significativo enquanto que o 97 é um resultado significativo.

### Fundamentos do Teste de Hipótese

#### 1. Hipótese Nula ( $H_0$ ) e Alternativa ( $H_1$ )

A hipótese nula, denotada por  $H_0$ , é uma afirmativa sobre um parâmetro. Por exemplo:  $\mu = 90$ ,  $p=0,10$ ,  $\sigma \geq 2$  etc. A hipótese alternativa, denotada por  $H_1$ , é uma afirmativa complementar à hipótese nula tal que não exista interseção entre as duas hipóteses. Por exemplo:  $\mu > 90$ ,  $p \neq 0,10$ ,  $\sigma < 2$  etc.

Temos que decidir por uma das duas hipóteses baseando-nos numa amostra da população. Logo, estamos sujeitos a dois erros diferentes.

Decisão	$H_0$ é Verdadeira	$H_0$ é Falsa
Assumir $H_0$ como Falsa	Erro Tipo I	sem erro
Assumir $H_0$ como Verdadeira	sem erro	Erro Tipo II

1. **Estatística de Teste:** é uma função que produz um valor real com base nos dados amostrais.
2. **Região Crítica:** Uma regra de decisão ou procedimento de teste consiste em especificar um conjunto de valores da estatística de teste para os quais rejeitaremos a hipótese nula ( $H_0$ ). Chamamos esse conjunto de valores, para os quais rejeitaremos  $H_0$ , de Região Crítica do teste.
3. **Nível de Significância ( $\alpha$ ) do teste:** é a probabilidade de ser cometer o erro do tipo I, ou seja, é a probabilidade de rejeitar uma hipótese nula verdadeira.

Quando não é mencionado adota-se  $\alpha = 5\%$ . Os valores comuns para  $\alpha$  são 10% 5% e 1%


$\alpha$	$Z_c$
5%	1,645
10%	1,28
1%	2,32

4. **Erro do Tipo II:** usamos a letra grega  $\beta$  para representar a probabilidade de cometer o erro tipo II: “não rejeitar uma hipótese nula falsa”.
5. **Testes Bilaterais e Unilaterais:**

Unilateral à esquerda:

$$H_0: \mu = 50$$


$$H_1: \mu > 50$$



Unilateral à direita:

$$H_0: \mu = 50$$


$$H_1: \mu < 50$$



Bilateral:

$$H_0: \mu = 50$$

$$H_1: \mu \neq 50$$



#### 1. Procedimento clássico de testes de hipóteses

- Passo 1: Fixe a hipótese nula a ser testada e qual é a forma da hipótese alternativa.
- Passo 2: Use a teoria estatística e as informações disponíveis para decidir qual estatística será usada no teste. Obtenha a distribuição amostral da estatística de teste.
- Passo 3: Fixe o nível de significância  $\alpha$  do teste, isto é, a probabilidade de rejeitar uma hipótese nula verdadeira e determine a região crítica do teste.
- Passo 4: Use a amostra para calcular o valor amostral da estatística de teste.
- Passo 5: Se o valor amostral cair na região crítica, rejeite  $H_0$ , caso contrário, não rejeite  $H_0$ .

## Teste Z para uma amostra



Usada quando temos amostras grandes ( $n \geq 30$ ) e desvio-padrão populacional,  $\sigma$ , conhecido.



$$z = \frac{\bar{x} - \mu_0}{\left(\frac{\sigma}{\sqrt{n}}\right)}$$

## Teste t para uma amostra: Distribuição de t de Student



Usada quando temos amostras pequenas ( $n < 30$ ) e desvio-padrão populacional,  $\sigma$ , desconhecido.



$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

Para  $n$  grande:

$$\frac{\hat{p} - p}{\sqrt{p(1-p)/n}}$$

### 1. p-Valor ou Nível Descritivo ou Probabilidade de significância

Outra maneira de proceder consiste em apresentar o p-valor do teste. De maneira informal, o p-valor caracteriza o grau de adesão dos dados amostrais à hipótese nula. É calculado usando-se uma probabilidade condicional, supondo que  $H_0$  é verdadeira. Portanto, o p-valor está entre 0 e 1. Na prática, rejeitaremos  $H_0$  para p-valores muito pequenos.

p-valor	Natureza da evidência contra $H_0$
0,10	Marginal
0,05	Moderada
0,025	Substancial
0,01	Forte
0,005	Muito Forte
0,001	Fortíssima